

Çekişmeli Eğitilmiş ResNet-18 ve ViT-Tiny’nin CIFAR-10 Üzerinde Davranışsal Karşılaştırması: Transfer Metrikleri, Gradyan Yapısı ve Katman Bazlı Öznitelik Kayması

A Behavioral Comparison of Adversarially Trained ResNet-18 and ViT-Tiny on CIFAR-10: Transfer Metrics, Gradient

Structure, and Layer-wise Feature Drift

Çağrı Şahin
Yazılım Mühendisliği Bölümü
Fırat Üniversitesi
Elazığ, Türkiye
csahin@firat.edu.tr

Özal Yıldırım
Yazılım Mühendisliği Bölümü
Fırat Üniversitesi
Elazığ, Türkiye

Özet—Evrışimli sinir ağları (CNN) ile Görü Dönüştürücülerinin (Vision Transformer, ViT) çekişmeli saldırılar altındaki farkları genellikle tek bir gürbüz doğruluk sayısı ile özetlenir. Bu bildiri, CIFAR-10 üzerinde çekişmeli eğitilmiş (adversarial training, AT) ResNet-18 ile ViT-Tiny’nin tam test kümesinde AutoAttack ile ($\epsilon = 8/255$) değerlendirildiği, devam etmekte olan bir davranışsal karşılaştırmanın ön sonuçlarını sunar ve tek sayının hikâyesinin çoğunu gizlediğini savunur. İlk olarak, CNN mutlak gürbüz doğrulukta önde olsa da (%35,74’e karşı %32,94; McNemar $p < 10^{-11}$), koşullu ayrıştırma tablonun görünümüne bağlı olduğunu gösterir: PGD-10 farkının tamamı temiz doğruluk farkından gelir, AutoAttack altında model bazlı koşullu sıralama hafifçe ViT lehine döner, ancak iki modelin de temizde doğru sınıfladığı ortak altkümede CNN’in üstünlüğü anlamlı biçimde sürer. İkinci olarak, mimariler arası transfer asimetrisi ölçümde kullanılan koşullama protokolüne güçlü biçimde bağlıdır: ham metrik 8,3 puanlık yapay bir asimetri üretir, hedef-doğru koşullu oranlar istatistiksel olarak eşdeğerdir, her-ikisi-doğru ve başarılı-kaynak protokolleri ise 5,3 puanlık anlamlı bir CNN→ViT üstünlüğü ortaya çıkarır — protokol seçimi yönlü sonuçları yaratabilir, silebilir veya tersine çevirebilir. Üçüncü olarak, ölçek-değişmez ölçüler CNN girdi gradyanlarının bir miktar daha seyrek olduğunu, ViT’in örnekler arası gradyan hizalanmasının ise mutlak — fakat işaretli olmayan — kosinüste daha yüksek olduğunu gösterir. Dördüncü olarak, saldırı altında ViT öznitelikleri erken-düşüş + orta-ağ-platosu profiliyle kayarken CNN’in profili derinlikle monoton bozulur. Sonuçlar mimari başına tek bir eğitim koşumundan gelmektedir ve ön sonuç olarak okunmalıdır; genişletilmiş bir analiz hazırlanmaktadır.

Anahtar Kelimeler—çekişmeli örnekler, çekişmeli eğitim, CIFAR-10, evrışimli sinir ağları, gürbüzlük, transfer saldırıları, Görü Dönüştürücü

çekişmeli örnekler (adversarial examples) — karşı savunmasızdır [1], [2]. Görü Dönüştürücülerini (ViT) [3] evrışimli sinir ağlarının (CNN) [4] yanında baskın bir mimari ailesi hâline gelirken, iki ailenin saldırı altında nasıl farklılaştığı doğal bir sorudur. Literatürün önemli bölümü bu soruyu bir yarışma olarak ele alır ve hangi mimarinin daha yüksek gürbüz doğruluk elde ettiğini raporlar [5]–[7]. Bu bildiri farklı, davranışsal bir bakış benimser: çekişmeli eğitilmiş sabit bir model çifti için mimariler *nasıl* farklılaşır — manşet gürbüzlük sayısının bileşiminde, çekişmeli örneklerin aralarındaki transferinde, girdi gradyanlarının yapısında ve pertürbasyonların katmanlar boyunca yayılımında?

Bu soruya ilişkin devam eden bir çalışmanın ön sonuçlarını CIFAR-10 [8] üzerinde raporluyoruz: aynı çekişmeli amaç fonksiyonu ve tehdit modeliyle eğitilmiş bir ResNet-18 ile bir ViT-Tiny, tam test kümesinde AutoAttack [9] ile değerlendirilmiştir. Katkılarımız: (i) “CNN daha gürbüz” manşetinin bileşime bağlı olduğunu gösteren koşullu gürbüzlük ayrıştırması; (ii) mimariler arası transfer asimetrisinin ölçülen yönünün ve büyüklüğünün koşullama protokolüne bağlı olduğunu gösteren çok protokollü transfer analizi — transfer çalışmaları için metodolojik bir uyarı; (iii) işaretli/mutlak hizalanma ayrımını içeren, eşleştirilmiş ve ölçek-değişmez gradyan yapısı karşılaştırmaları; (iv) nitel olarak farklı derinlik profillerini ortaya koyan katman bazlı öznitelik kayması karşılaştırması. Tüm sonuçlar örnek bazında kayıtlı değerlendirmelerden türetilmiştir; sonuçlar mimari başına tek bir eğitim koşumundan gelmektedir ve ön sonuç olarak okunmalıdır.

I. GİRİŞ

Derin görüntü sınıflandırıcıları, tahminleri yüksek güvenle değiştirebilen küçük ve özenle üretilmiş pertürbasyonlara —

II. İLGİLİ ÇALIŞMALAR

Çekişmeli örnekler ve gradyan tabanlı saldırılar Szegedy vd. [1] ile Goodfellow vd. [2] tarafından ortaya konmuştur; iz-

düşümlü gradyan inişi (PGD) ile çekişmeli eğitim [10] standart savunma olmayı sürdürmekte, gürbüz aşırı öğrenme ve erken durdurma Rice vd. [11] tarafından karakterize edilmektedir. AutoAttack [9] ve RobustBench [12] gürbüzlük değerlendirmesini standartlaştırmıştır.

Doğrudan CNN-ViT gürbüzlük karşılaştırmaları arasında, adil eğitim tarifleri altında dönüştürücülerin CNN'lerden daha çekişmeli-gürbüz olmadığını bulan Bai vd. [5] ile Benz vd. [6] sayılabilir. Bizim kurulumumuza en yakın çalışma olan Ali vd. [7], standart eğitilmiş ViT ve CNN'lerin gürbüzlüğüne FGSM, PGD ve DeepFool skor karşılaştırmalarıyla incelemiştir. Çalışmamız üç yönden ayrışır: her iki model de eşleşmiş bir amaç fonksiyonuyla *çekişmeli eğitilmiştir*; değerlendirme, örnek bazında eşleştirilmiş istatistiklerle tam-test AutoAttack kullanır; karşılaştırma skorların ötesine geçerek koşullu ayrıştırmaları, protokolü açık transferi, gradyan yapısını ve katman bazlı kaymayı kapsar. ViT çekişmeli eğitiminin küçük veri kümelerinde tarife duyarlı olduğu bilinmektedir [13], [14]; özelleşmiş veri artırmayla ViT'ler CIFAR-10'da WideResNet'leri geçebilmektedir [15]. Dolayısıyla vardığımız sonuçlar, incelediğimiz temel tarif altında geçerlidir; en iyi şekilde eğitilmiş ViT'ler için değil.

Transfer değerlendirmesinde, doğru sınıflanan örneklerle koşullama yerleşik pratiktir [16]–[19]; her-ikisi-doğru varyantları Mahmood vd. [18] ve TREND [19] tarafından kullanılmıştır. Bizim katkımız, bu protokoller arasındaki *seçimin* asimetri sonucunu nitel olarak değiştirdiğini tek bir veri kümesi üzerinde göstermektedir.


III. YÖNTEM

A. Veri Kümesi, Modeller ve Eğitim

Deneyler CIFAR-10 [8] üzerinde yürütülmüştür: on dengeli sınıfta 60.000 adet 32×32 renkli görüntü (50.000 eğitim / 10.000 test); Şekil 1 (üst) her sınıftan bir örnek göstermektedir. ResNet-18 (11,2M parametre; CIFAR tipi gövde) ile ViT-Tiny (5,7M parametre; `timm` [20] mimarisi, 224×224 'e çift doğrusal yukarı örneklenen girdiler üzerinde 16×16 yamalar) karşılaştırılmıştır; iki model de CIFAR-10 üzerinde sıfırdan, temel veri artırmayla eğitilmiş ve ardından çekişmeli ince ayara tabi tutulmuştur. Çekişmeli eğitim, $(1 - \lambda)\mathcal{L}_{CE}(f(x), y) + \lambda\mathcal{L}_{CE}(f(x_{adv}), y)$ karma amacını $\lambda = 0,5$ ile enküçültür; x_{adv} , standart pratiğe uygun olarak [10], [11] eğitim kipinde PGD-10 ($\epsilon = 8/255$, $\alpha = 2/255$) ile üretilir. İnce ayar düşük öğrenme oranları (10^{-3} ; CNN için SGD, ViT için AdamW [21]) ve eğitim kümesinden ayrılan 2.000 örneklik doğrulama bölümü üzerinde erken durdurma kullanır; test kümesine yalnızca nihai değerlendirmelerde dokunulur. Üst referans olarak Goyal vd.'nin [22] RobustBench [12] üzerinden dağıtılan WideResNet-28-10 kontrol noktası dahil edilmiştir; bu model ek veri ve daha güçlü bir tarifile eğitildiğinden eşleşmiş çiftten görsel ve analitik olarak ayrı tutulur.

B. Değerlendirme ve Metrikler

Tüm değerlendirmeler, örnek bazında sonuç kaydıyla 10.000 örneklik tam test kümesinde yapılır. Gürbüzlük FGSM, PGD-10 ve standart AutoAttack topluluğuyla $\epsilon = 8/255$ 'te



Şekil 1. Üstte: her CIFAR-10 sınıfından bir örnek. Altta: aynı test görüntüsüne her modelin kendi beyaz-kutu saldırısı (PGD-10, $\epsilon=8/255$) — temiz tahmin, pertürbasyon ($10\times$ büyütülmüş) ve çekişmeli tahmin. Pertürbasyonlar sınırlıdır ve özgün ölçekte görsel olarak zor fark edilir; yine de tahminleri yüksek güvenle değiştirir. İki mimarinin ürettiği pertürbasyon yapısının nitel farkına dikkat ediniz (CNN'de dağınık, ViT'te yama hizalı). Görüntüler 32×32 piksel çözünürlüktedir ve piksel-sadık (en-yakın komşu) büyütmeyle gösterilmiştir.

ölçülür. Mutlak gürbüz doğruluğun yanında *koşullu yanılma oranı* (saldırının, temizde doğru sınıflanan örneklerin ne kadarını devirdiği) raporlanır; temizde yanlış sınıflanan örnekler gürbüz-değil sayıldığından, mutlak gürbüzlük tam olarak gürbüz = temiz $\times (1 - \text{koşullu yanılma})$ biçiminde çarpanlarına ayrılır ve temiz-doğruluk bileşeni ile koşullu-duyarlılık bileşeni ayrışır. Ayrıca *her-ikisi-doğru* altkümesi (iki modelin de temizde doğru sınıfladığı örnekler) değerlendirilir; bu, birebir eşleştirilmiş karşılaştırmalar sağlar.


Transfer için, kaynak modelde üretilen çekişmeli örnekler diğer (hedef) modelde üç koşullama protokolüyle değerlendirilir: *hedef-doğru* (hedef, temiz örneği doğru sınıflar), *her-ikisi-doğru* [18], [19] ve *başarılı-kaynak* (hedef-doğru ve saldırı kaynağında beyaz-kutu anlamda başarılı). Güven aralıkları yüzdelik bootstrap ile (10.000 yeniden örnekleme); eşleştirilmiş protokol karşılaştırmaları işaret-çevirme permütasyon testleri ve iki tek-yönlü eşdeğerlik testleri (TOST) ile verilir.

Gradyan yapısı, 500 sabit test örneğinde örnek başına kayıp gradyanlarıyla incelenir: ölçek-değişmez seyreklik (Hoyer, Gini [23] ve örnek maksimumunun %1'inin altındaki bileşen oranı) örnek bazında eşleştirilmiş Wilcoxon testleriyle (Holm düzeltmeli); örnekler arası gradyan hizalanması, tüm örnek çiftleri üzerinden ortalama mutlak kosinüs olarak, işaretli ortalamayla birlikte raporlanır. Katman bazlı öznelilik kayması, temiz ve çekişmeli temsilleri blok başına karşılaştırır (kosinüs benzerliği, norm değişimi): ViT'in 12 dönüştürücü bloğu ile CNN'in 8 artık bloğu ($n=100$).

Tablo I
CIFAR-10 TAM TEST KÜMESİNDE GÜRBÜZLÜK ($\epsilon = 8/255$).

Model	AT	Temiz	FGSM	PGD-10	AA
ResNet-18	—	94,37	30,93	0,01	—
ViT-Tiny	—	77,50	3,34	0,03	—
ResNet-18	✓	85,42	49,90	40,97	35,74
ViT-Tiny	✓	75,65	40,07	36,09	32,94
WRN-28-10 [†]	✓	89,48	70,91	66,92	62,76

[†]Harici referans kontrol noktası [22]: daha güçlü tarif ve ek veri; AA değeri RobustBench raporudur.




Şekil 2. Temiz, PGD-10 ve AutoAttack doğrulukları. Eşleşmiş çekişmeli eğitilmiş çift (solda) çalışmanın konusudur; WRN-28-10 (sağda, taramalı) daha güçlü tarif ve ek veriyle eğitilmiş harici bir referanstır.

IV. SONUÇLAR

A. Gürbüzlük: Tek Manşet, Üç Okuma

Tablo I ve Şekil 2 mutlak sonuçları verir: çekişmeli eğitilmiş CNN her saldırıda ViT'in önündedir (AutoAttack %35,74'e karşı %32,94; ortak örneklerde McNemar $\chi^2 = 48,65$, $p < 10^{-11}$) ve ikisi de, üstünlüğü kapasite, ek veri ve daha güçlü tarifin ortak ürünü olan referans WideResNet'in gerisindedir [22]. Şekil 3 farkın pertürbasyon bütçeleri boyunca kararlı olduğunu gösterir.

Koşullu ayırıştırma (Tablo II) okumayı değiştirir. PGD-10 altında iki modelin koşullu yanıtma oranları istatistiksel olarak ayırt edilemez (%52,15'e karşı %52,33); dolayısıyla mutlak PGD farkının tamamı temiz doğrulukla açıklanır ($85,42 \times 0,478$ 'e karşı $75,65 \times 0,477$). AutoAttack altında model bazlı koşullu sıralama hafifçe ViT lehine bile döner (yanıtma %58,16'ya karşı %56,46). Ancak 7.260 ortak çözölen örnekte — birebir eşleştirilmiş karşılaştırma — CNN iki saldırıda da anlamlı biçimde öndedir (PGD %54,92'ye karşı %49,61, McNemar $p < 10^{-20}$; AA %48,15'e karşı %45,33, $p < 10^{-6}$). Bu görünümeler bileşimsel olarak uzlaşır: yalnızca CNN'in temizde çözödüğü ~ 1.300 örnek neredeyse hiç gürbüz değildir (PGD sağkalımı %8'in altında) ve CNN'in model bazlı koşullu oranını aşağı çeker. Tek bir gürbüz doğruluk sayısı tüm bu yapıyı gizlerdi.



Şekil 3. Pertürbasyon bütçesine göre PGD-10 doğruluğu (tam test kümesi). Referans model, eşleşmiş çiftten görsel olarak ayrı kalması için gri ve kesikli çizilmiştir.

Tablo II
KOŞULLU AYIRIŞTIRMA (TAM TEST; %95 BOOTSTRAP GA'LARI).
HER-İKİSİ-DOĞRU: İKİ MODELİN DE TEMİZDE DOĞRU SINIFLADIĞI
 $n=7.260$ ÖRNEK.

Model	Koşullu yanıtma (%) PGD-10	AA	Her-ikisi-doğru gürbüz (%) PGD-10	AA
ResNet-18 AT	52,15 [51,1; 53,2]	58,16 [57,1; 59,2]	54,92	48,15
ViT-Tiny AT	52,33 [51,2; 53,5]	56,46 [55,4; 57,6]	49,61	45,33

B. Transfer: Protokol, Sonucun Parçasıdır

Tablo III mimariler arası transferi üç yerleşik koşullama protokolüyle raporlar. Ham (koşulsuz) oranlar CNN kaynakları lehine 8,3 puanlık bir asimetri önerir (%40,2'ye karşı %31,9) — hedeflerin on puanlık temiz doğruluk farkının bir yapaylığı. Hedef-doğru protokolü bu karıştırıcıyı giderir ve neredeyse parite gösterir (fark 0,63 puan; ± 2 puan marjında TOST eşdeğerliği, $p = 0,016$); bu parite momentum tabanlı MIFGSM [17] altında da kararlıdır (%19,85'e karşı %20,11). Ancak her-ikisi-doğru ve başarılı-kaynak protokolleri *sonucu yeniden tersine çevirir*: ortak çözölen örneklerde yönler belirgin biçimde ayrışır ($\sim 5,3$ puanlık CNN $\rightarrow$ ViT üstünlüğü; eşleştirilmiş bootstrap GA [4,39; 6,25]; işaret-çevirme permütasyonu $p < 5 \times 10^{-5}$; TOST eşdeğerliği ± 3 puanda bile reddedilir). Mekanizma bileşimseldir: hedefin temizde çözödüğü ama kaynağın çözemediği örnekler iki yönde de aşırı kırılıgandır (%56,9 ve %63,0 yanıtma) ve bu marjinal altkümelere asimetrik boyutları (1.282'ye karşı 305) hedef-doğru oranlarını pariteye çeker. Mimariler arası transfer çalışmaları için pratik ders: koşullama protokolü aynı veri üzerinde yönlü bir farkı yaratabilir, silebilir veya ortaya çıkarabilir; bu nedenle açıkça beyan edilmeli ve mümkünse çeşitlendirilmelidir.

C. Gradyan Yapısı

Her iki modelde de ölçülen 500 sabit test örneğinde, CNN girdi gradyanları üç ölçek-değişmez ölçünün üçünde de ViT'inkilerden tutarlı fakat ölçülü biçimde daha seyrek-tir (Hoyer $0,474 \pm 0,009$ 'a karşı $0,449 \pm 0,011$; Gini $0,634$ 'e

Tablo III

ÜÇ KOŞULLAMA PROTOKOLÜ ALTINDA TRANSFER ASİMETRİSİ (PGD-10, $\epsilon=8/255$, TAM TEST; %95 BOOTSTRAP GA'LARI).

Protokol	CNN→ViT	ViT→CNN	Fark
Hedef-doğru	20,95 [20,03; 21,88]	20,32 [19,47; 21,19]	+0,63
Her-ikisi-doğru	19,19 [18,26; 20,10]	13,86 [13,07; 14,66]	+5,33
Başarılı-kaynak	39,07 [37,47; 40,66]	33,79 [32,48; 35,13]	+5,28

karşı 0,606; örnek maksimumunun %1'i altındaki bileşenler %31,5'e karşı %25,8) ve eşleştirilmiş Wilcoxon testleri son derece anlamlıdır (Holm düzeltmeli $p < 10^{-15}$; eşleştirilmiş Cohen d 'si 0,34–0,65). İlginç biçimde bu sıralamayı çekişmeli eğitim yaratır: temiz eğitilmiş çiftte seyrek olan model ViT'tir (Hoyer 0,406'ya karşı 0,354) ve bu, çekişmeli eğitimin CNN gradyanları üzerindeki güçlü seyrekleştirici etkisiyle uyumludur [24]. Örnekler arası gradyan hizalanması, tüm çiftler üzerinden ortalama mutlak kosinüste ViT'te daha yüksektir (0,052'ye karşı 0,038; temiz eğitilmiş çiftte neredeyse aynı düzeyler, farkın eğitim değil mimari kaynaklı olduğunu gösterir); ancak *işareti* ortalama kosinüs iki modelde de sıfıra yakındır ($\leq 0,002$): örneklerin paylaştığı şey tutarlı yönler değil, duyarlılık eksenleridir.


D. Katman Bazlı Öznitelik Kayması

Şekil 4, saldırıya uğramış bir girdinin her bloktaki temsiline temiz karşılığından ne kadar uzaklaştığını karşılaştırır. ViT erken-düşüş + orta-ağ-platosu profili gösterir: kosinüs benzerliği hızla düşerek 8. blokta 0,955 minimumuna iner, ardından hafifçe toparlanır (10–11. bloklarda 0,965); öznitelik normları baştan sona %1,5'ten az değişir — pertürbasyon temsiline büyüklüğünü değil *yönünü* bozar. CNN nitel olarak farklı davranır: kosinüs benzerliği derinlikle monoton ve ivmelenerek düşer (0,995'ten son artık blokta 0,913'e) ve son iki blokta büyük norm bozulmaları görülür ($- \%6,4$ ve $+ \%7,2$). Plato-ve-toparlanma biçimi bu nedenle derin ağların genel bir özelliği değil, incelenen ViT'e özgüdür; temiz eğitilmiş ViT'lerin katman bazlı temsil analizlerini [25] çekişmeli eğitilmiş ortama taşır.

V. TARTIŞMA VE SINIRLILIKLAR

Üç ana çıkarım öne çıkmaktadır. Birincisi, tek sayılık gürbüzlük karşılaştırmaları kayıplıdır: koşullu ayrıştırma "CNN daha gürbüzdür" (mutlak ve her-ikisi-doğru görünümüleri), "koşullu duyarlılık eşleştirmesi" (model bazlı PGD) ve "ViT kendi çözdüğü örneklerde daha az kaybeder" (model bazlı AutoAttack) okumalarının üçünü de aynı anda destekler. İkincisi, transfer asimetrisi iddiaları protokole görelidir; mimariler arası çalışmalar koşullama protokolünü sonucun bir parçası olarak raporlamalıdır. Üçüncüsü, mimariler gradyan yoğunlaşmasında ve çekişmeli hasarın derinlik boyunca nerede biriktiğinde davranışsal olarak ayrışır; bu, iki mimari için farklı yerlere konumlanmış kararlılaştırma (stabilizasyon) önerir.

Bu sonuçları birkaç sınırlılık çerçeveler. Sonuçlar, tek bir temel tarif altında, mimari başına tek eğitim koşumundan gelmektedir ve ön sonuç olarak okunmalıdır; ViT gürbüzlüğü'nün tarife duyarlı olduğu bilinmektedir [13]–[15]. Çalışma



Şekil 4. Beyaz-kutu PGD-10 altında görel derinliğe göre temiz-çekişmeli kosinüs benzerliği ($n=100$). ViT: erken düşüş, orta-ağ minimumu, hafif toparlanma. CNN: monoton, ivmelenen düşüş ve büyük son-blok norm bozulması.

tek veri kümesini, tek model çiftini ve koşullu analizler için tek bütçeli L_∞ tehdit modelini kapsar. Gradyan ve kayma ölçümleri davranışsal korelasyonlardır; yerleşik nedensel açıklamalar değildir. Eğitim tohumu varyansını, ek transfer saldırılarını ve uzamsal gradyan istatistiklerini ele alan genişletilmiş bir analiz hazırlanmaktadır.

VI. SONUÇ

CIFAR-10 üzerinde eşleşmiş çekişmeli eğitilmiş bir ResNet-18/ViT-Tiny çifti için gürbüzlük manşetinin bileşime bağlı olduğunu, ölçülen transfer asimetrisinin büyük ölçüde koşullama protokolünün bir özelliği olduğunu, gradyan yapısı farklarının tutarlı fakat ölçülü olduğunu (hizalanma farkının doğası gereği işaretsiz kaldığını) ve çekişmeli hasarın iki mimaride nitel olarak farklı derinliklerde biriktiğini gösterdik. Bu ön sonuçları, mimari aileleri arasında protokolü açık, çok görünümlü gürbüzlük karşılaştırmaları için bir şablon olarak sunuyoruz.

KAYNAKLAR

- [1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, "Intriguing properties of neural networks," in *International Conference on Learning Representations*, 2014.
- [2] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and harnessing adversarial examples," in *International Conference on Learning Representations*, 2015.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations*, 2021.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [5] Y. Bai, J. Mei, A. L. Yuille, and C. Xie, "Are transformers more robust than cnns?" in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 26 831–26 843.
- [6] P. Benz, S. Ham, C. Zhang, A. Karjauv, and I. S. Kweon, "Adversarial robustness comparison of vision transformer and MLP-Mixer to CNNs," in *Proceedings of the 32nd British Machine Vision Conference (BMVC)*, 2021.
- [7] K. Ali, M. S. Bhatti, A. Saeed, A. Athar, M. A. Al Ghamdi, S. H. Almotiri, and S. Akram, "Adversarial robustness of vision transformers versus convolutional neural networks," *IEEE Access*, vol. 12, pp. 105 281–105 293, 2024.

- [8] A. Krizhevsky, G. Hinton *et al.*, “Learning multiple layers of features from tiny images,” University of Toronto, Tech. Rep., 2009.
- [9] F. Croce and M. Hein, “Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks,” in *International Conference on Machine Learning*, 2020, pp. 2206–2216.
- [10] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, “Towards deep learning models resistant to adversarial attacks,” in *International Conference on Learning Representations*, 2018.
- [11] L. Rice, E. Wong, and J. Z. Kolter, “Overfitting in adversarially robust deep learning,” in *International Conference on Machine Learning*, 2020, pp. 8093–8104.
- [12] F. Croce, M. Andriushchenko, V. Schwag, E. Debenedetti, N. Flammarion, M. Chiang, P. Mittal, and M. Hein, “RobustBench: a standardized adversarial robustness benchmark,” in *NeurIPS Datasets and Benchmarks Track*, 2021.
- [13] Y. Mo, D. Wu, Y. Wang, Y. Guo, and Y. Wang, “When adversarial training meets vision transformers: Recipes from training to architecture,” in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 18 599–18 611.
- [14] E. Debenedetti, V. Schwag, and P. Mittal, “A light recipe to train robust vision transformers,” in *IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2023, pp. 225–253.
- [15] J. Wu, Z. Song, X. Zhang, S. Xie, L. Lin, and K. Wang, “Vision transformers beat WideResNets on small scale datasets adversarial robustness,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 1, 2025, pp. 886–894.
- [16] Y. Liu, X. Chen, C. Liu, and D. Song, “Delving into transferable adversarial examples and black-box attacks,” in *Proceedings of the 5th International Conference on Learning Representations (ICLR)*, 2017.
- [17] Y. Dong, F. Liao, T. Pang, H. Su, J. Zhu, X. Hu, and J. Li, “Boosting adversarial attacks with momentum,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 9185–9193.
- [18] K. Mahmood, R. Mahmood, and M. Van Dijk, “On the robustness of vision transformers to adversarial examples,” in *IEEE/CVF International Conference on Computer Vision*, 2021, pp. 7838–7847.
- [19] D. Ravikumar, S. Kodge, I. Garg, and K. Roy, “TREND: Transferability-based robust ENsemble design,” *IEEE Transactions on Artificial Intelligence*, vol. 4, no. 3, pp. 534–548, 2023.
- [20] R. Wightman, “Pytorch image models,” <https://github.com/rwightman/pytorch-image-models>, 2019.
- [21] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [22] S. Gowal, C. Qin, J. Uesato, T. Mann, and P. Kohli, “Uncovering the limits of adversarial training against norm-bounded adversarial examples,” *arXiv preprint arXiv:2010.03593*, 2020.
- [23] N. Hurley and S. Rickard, “Comparing measures of sparsity,” *IEEE Transactions on Information Theory*, vol. 55, no. 10, pp. 4723–4741, Oct. 2009.
- [24] P. Chalasani, J. Chen, A. R. Chowdhury, X. Wu, and S. Jha, “Concise explanations of neural networks using adversarial training,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 1383–1391.
- [25] M. Raghu, T. Unterthiner, S. Kornblith, C. Zhang, and A. Dosovitskiy, “Do vision transformers see like convolutional neural networks?” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 12 116–12 128.