

Çekişmeli Eğitilmiş ResNet-18 ve ViT-Tiny'nin CIFAR-10 Üzerinde Davranışsal Karşılaştırması: Transfer Metrikleri, Gradyan Yapısı ve Blok Bazlı Öznitelik Kayması

A Behavioral Comparison of Adversarially Trained ResNet-18 and ViT-Tiny on CIFAR-10: Transfer Metrics, Gradient

Structure, and Block-wise Feature Drift

Çağrı Şahin
Yazılım Mühendisliği Bölümü
Fırat Üniversitesi
Elazığ, Türkiye
csahin@firat.edu.tr

Özal Yıldırım
Yazılım Mühendisliği Bölümü
Fırat Üniversitesi
Elazığ, Türkiye

Özet—Evrişimli sinir ağları (CNN) ile Görü Dönüştürücülerinin (Vision Transformer, ViT) çekişmeli saldırılar altındaki farkları genellikle tek bir gürbüz doğruluk sayısı ile özetlenir. Bu bildiri, CIFAR-10 üzerinde çekişmeli eğitilmiş (adversarial training, AT) ResNet-18 ile ViT-Tiny'nin tam test kümesinde AutoAttack ile ($\epsilon = 8/255$) değerlendirildiği, devam etmekte olan bir davranışsal karşılaştırmanın ön sonuçlarını sunar ve tek sayının hikâyesinin çoğunu gizlediğini savunur. İlk bulguya göre CNN mutlak gürbüz doğrulukta önde olsa da (%35,74'e karşı %32,94; McNemar $p < 10^{-11}$), koşullu ayırıştırma, genel görünümün hangi açıdan bakıldığına bağlı olduğunu gösterir: PGD-10 farkının tamamı temiz doğruluk farkından gelir, AutoAttack altında model bazlı koşullu sıralama hafifçe ViT lehine döner, ancak iki modelin de temizde doğru sınıfladığı ortak altkümede CNN'in üstünlüğü anlamlı biçimde sürer. İkinci bulgu, mimariler arası transfer asimetrisinin ölçümde kullanılan koşullama protokolüne güçlü biçimde bağlı olduğudur: koşulsuz (ham) oran 8,3 puanlık yapay bir asimetri üretir, hedef doğru koşullu oranlar istatistiksel olarak eşdeğerdir, her ikisi doğru ve başarılı kaynak protokolleri ise 5,3 puanlık anlamlı bir CNN→ViT üstünlüğü ortaya çıkarır. Kısacası protokol seçimi yönlü sonuçlar yaratabilir, silebilir veya tersine çevirebilir. Üçüncü bulgu gradyan yapısına ilişkindir: ölçekten bağımsız ölçüler CNN girdi gradyanlarının bir miktar daha seyrek olduğunu, ViT'in örnekler arası gradyan hizalanmasının ise mutlak kosinüste daha yüksek kaldığını gösterir (işaretli kosinüs her iki modelde sıfıra yakındır). Son olarak, saldırı altında ViT öznitelikleri erken düşüş ve orta ağ platosu profiliyle kayarken CNN'in profili derinlikle monoton bozulur. Sonuçlar mimari başına tek bir eğitim koşusundan gelmektedir ve ön sonuç olarak okunmalıdır; genişletilmiş bir analiz hazırlanmaktadır.

Anahtar Kelimeler—çekişmeli örnekler, çekişmeli eğitim, CIFAR-10, evrişimli sinir ağları, gürbüzlük, transfer saldırıları, Görü Dönüştürücü

çekişmeli örneklere (adversarial examples) karşı savunmasızdır [1], [2]. Görü Dönüştürücülerini (Vision Transformer, ViT) [3] evrişimli sinir ağlarının (CNN) [4] yanında baskın bir mimari ailesi hâline gelirken, iki ailenin saldırı altında nasıl farklılaştığı doğal bir sorudur. Literatürün önemli bölümü bu soruyu bir yarışma olarak ele alır ve hangi mimarinin daha yüksek gürbüz doğruluk elde ettiğini raporlar [5]–[7]. Bu bildiri farklı, davranışsal bir bakış benimser: çekişmeli eğitilmiş sabit bir model çifti için mimariler manşet gürbüzlük sayısının bileşiminde, çekişmeli örneklerin aralarındaki transferinde, girdi gradyanlarının yapısında ve pertürbasyonların katmanlar boyunca yayılımında *nasıl* farklılaşır?

Bu soruya ilişkin devam eden bir çalışmanın ön sonuçlarını CIFAR-10 [8] üzerinde raporluyoruz: aynı çekişmeli amaç fonksiyonu ve tehdit modeliyle eğitilmiş bir ResNet-18 ile bir ViT-Tiny, tam test kümesinde AutoAttack [9] ile değerlendirilmiştir. Katkılarımız: (i) “CNN daha gürbüz” manşetinin bileşime bağlı olduğunu gösteren koşullu gürbüzlük ayırıştırması; (ii) mimariler arası transfer asimetrisinin ölçülen yönünün ve büyüklüğünün koşullama protokolüne bağlı olduğunu gösteren, transfer çalışmaları için metodolojik bir uyarı niteliğindeki çok protokollü analiz; (iii) işaretli/mutlak hizalanma ayrımını içeren, eşleştirilmiş ve ölçekten bağımsız gradyan yapısı karşılaştırmaları; (iv) nitel olarak farklı derinlik profillerini ortaya koyan blok bazlı öznitelik kayması karşılaştırması. Tüm sonuçlar örnek bazında kayıtlı değerlendirmelerden türetilmiştir; sonuçlar mimari başına tek bir eğitim koşusundan gelmektedir ve ön sonuç olarak okunmalıdır.

I. GİRİŞ

Derin görüntü sınıflandırıcıları, tahminleri yüksek güvenle değiştirebilen küçük ve özenle üretilmiş pertürbasyonlara, yani

II. İLGİLİ ÇALIŞMALAR

Çekişmeli örnekler ve gradyan tabanlı saldırılar Szegedy vd. [1] ile Goodfellow vd. [2] tarafından ortaya konmuştur; iz-

düşümlü gradyan inişi (PGD) ile çekişmeli eğitim (adversarial training, AT) [10] standart savunma olmayı sürdürmekte, gürbüz aşırı öğrenme ve erken durdurma Rice vd. [11] tarafından karakterize edilmektedir. AutoAttack [9] ve RobustBench [12] gürbüzlük değerlendirmesini standartlaştırmıştır.


Doğrudan CNN-ViT gürbüzlük karşılaştırmalarında bulgular kurulumla göre değişmektedir: Bai vd. [5] adil eğitim tarifleri altında dönüştürücülerin çekişmeli gürbüzlükte CNN'lerden üstün olmadığını bulurken, Benz vd. [6] standart eğitilmiş modellerde ViT'leri CNN'lerden daha gürbüz raporlamıştır; bu karşıtlık, karşılaştırma sonuçlarının kurulum ve protokole duyarlılığına dair tezimizle uyumludur. Bizim kurulumumuza en yakın çalışma olan Ali vd. [7], standart eğitilmiş ViT ve CNN'lerin gürbüzlüğünü FGSM (Fast Gradient Sign Method), PGD ve DeepFool skor karşılaştırmalarıyla incelemiştir. Çalışmamız üç yönden ayrışır: her iki model de eşleşmiş bir amaç fonksiyonuyla *çekişmeli eğitilmiştir*; değerlendirme, tam test kümesinde örnek bazında eşleştirilmiş istatistiklerle AutoAttack kullanır; karşılaştırma skorların ötesine geçerek koşullu ayrıştırılmaları, protokolü açık transferi, gradyan yapısını ve blok bazlı kaymayı kapsar. ViT çekişmeli eğitiminin küçük veri kümelerinde tarife duyarlı olduğu bilinmektedir [13], [14]; difüzyon modeliyle üretilmiş sentetik ek veriyle ViT'ler CIFAR-10'da WideResNet'leri geçebilmektedir [15]. Dolayısıyla vardığımız sonuçlar, incelediğimiz temel tarif altında geçerlidir; en iyi şekilde eğitilmiş ViT'ler için değil.

Transfer değerlendirmesinde, doğru sınıflanan örneklerle koşullama yerleşik pratiktir [16]–[19]; her ikisi doğru varyantları Mahmood vd. [18] ve TREND [19] tarafından kullanılmıştır. Bizim katkımız, bu protokoller arasındaki *seçimin* asimetri sonucunu nitel olarak değiştirdiğini tek bir veri kümesi üzerinde göstermektedir.

III. YÖNTEM

A. Veri Kümesi, Modeller ve Eğitim

Deneyler CIFAR-10 [8] üzerinde yürütülmüştür: on dengeli sınıfta 60.000 adet 32×32 renkli görüntü (50.000 eğitim / 10.000 test). Şekil 1, veri kümesini ve saldırının etkisini örneklendirir: gösterilen örnek, test sırasına göre temizde doğru sınıflanan ve saldırının sınıf değiştirdiği ilk örnektir (deterministik seçim); pertürbasyonlar özgün ölçekte zor fark edilir ancak tahminleri yüksek güvenle değiştirir ve iki mimaride nitel olarak farklı yapıdadır (CNN'de dağınık, ViT'te yama hizalı). Görüntüler 32×32 çözünürlüktedir ve pikselleri birebir koruyan (en yakın komşu) büyütmeyle gösterilmiştir. ResNet-18 (11,2M parametre; CIFAR tipi gövde) ile ViT-Tiny (5,7M parametre; timm [20] mimarisi, 224×224 'e çift doğrusal yukarı örneklenen girdiler üzerinde 16×16 yamalar) karşılaştırılmıştır; iki model de CIFAR-10 üzerinde sıfırdan, temel veri artırmayla eğitilmiş ve ardından çekişmeli ince ayara tabi tutulmuştur. Saldırıları dahil tüm işlemler özgün 32×32 CIFAR-10 piksel uzayında tanımlıdır: $32 \rightarrow 224$ çift doğrusal büyütme, ViT sarmalayıcısının *içinde* türevlenebilir bir katmandır (nn.Upsample). Dolayısıyla iki model aynı L_∞ tehdit modelini ($\epsilon = 8/255$, $[0, 1]$ ham piksel uzayında)



Şekil 1. Üstte her CIFAR-10 sınıfından bir örnek; altta aynı test görüntüsüne her modelin kendi beyaz kutu PGD-10 saldırısı ($\epsilon = 8/255$): temiz tahmin, pertürbasyon ($10\times$) ve çekişmeli tahmin.

paylaşır ve transfer edilen çekişmeli örnekler her iki modele aynı 32×32 girdiler olarak verilir.

Çekişmeli eğitim, $(1-\lambda)\mathcal{L}_{CE}(f(x), y) + \lambda\mathcal{L}_{CE}(f(x_{adv}), y)$ karma amacını $\lambda = 0,5$ ile enküçültür; x_{adv} , standart pratiğe uygun olarak [10], [11] eğitim kipinde PGD-10 ($\epsilon = 8/255$, $\alpha = 2/255$, $\mathcal{U}(-\epsilon, \epsilon)$ rastgele başlangıç, tek yeniden başlatma) ile üretilir. Temiz ön eğitim 200 dönemdir (CNN: SGD, öğrenme oranı 0,1, ağırlık sönümü 5×10^{-4} ; ViT: AdamW [21], 10^{-3} , sönüm 0,05; kosinüs tavlama); çekişmeli ince ayar en fazla 100 dönem, 10^{-3} öğrenme oranı ve 128 (CNN) / 64 (ViT) parti boyutuyla yapılır. Veri artırma 4 piksel dolgu rastgele kırpma ve yatay çevirmedir. Erken durdurma ve model seçimi, eğitim kümesinden ayrılan 2.000 örneklik doğrulama bölmesinin PGD-10 doğruluğu üzerinden yürütülür (sabır 20, 0,1 puan eşiği); test kümesine yalnızca nihai değerlendirmelerde dokunulur. Üst referans olarak Gowal vd.'nin [22] RobustBench [12] üzerinden dağıtılan WideResNet-28-10 kontrol noktası dahil edilmiştir; bu model ek veri ve daha güçlü bir tarifle eğitildiğinden eşleşmiş çiftten görsel ve analitik olarak ayrı tutulur.

B. Değerlendirme ve Metrikler

Tüm değerlendirmeler, örnek bazında sonuç kaydıyla 10.000 örneklik tam test kümesinde yapılır. Gürbüzlük FGSM, PGD-10 ve standart AutoAttack (AA) topluluğuyla (resmi uygulama, sürüm 0.1: APGD-CE, APGD-T, FAB-T, Square) $\epsilon = 8/255$ 'te ölçülür. Mutlak gürbüz doğruluğun yanında *koşullu yanılma oranı* (saldırının, temizde doğru sınıflanan örneklerin ne kadarını devirdiği) raporlanır; temizde yanlış sınıflanan örnekler gürbüz olmayan örnek sayıldığından, mutlak gürbüzlük tam olarak gürbüz = temiz $\times (1 - \text{koşullu yanılma})$ biçiminde çarpanlarına ayrılır ve temiz doğruluk bileşeni ile

Tablo I
CIFAR-10 TAM TEST KÜMESİNDE GÜRBÜZLÜK ($\epsilon = 8/255$).

Model	AT	Temiz	FGSM	PGD-10	AA
ResNet-18	–	94,37	30,93	0,01	–
ViT-Tiny	–	77,50	3,34	0,03	–
ResNet-18	✓	85,42	49,90	40,97	35,74
ViT-Tiny	✓	75,65	40,07	36,09	32,94
WRN-28-10 [†]	✓	89,48	70,91	66,92	62,76

[†] Harici referans kontrol noktası [22]: daha güçlü tarif ve ek veri; AA değeri RobustBench raporudur.

koşullu duyarlılık bileşeni ayrıştır. Ayrıca *her ikisi doğru* altkümesi (iki modelin de temizde doğru sınıfladığı örnekler) değerlendirilir; bu, birebir eşleştirilmiş karşılaştırmalar sağlar.

Transfer için, kaynak modelde üretilen çekişmeli örnekler diğer (hedef) modelde üç koşullama protokolüyle değerlendirilir: *hedef doğru* (hedef, temiz örneği doğru sınıflar), *her ikisi doğru* [18], [19] ve *başarılı kaynak* (hedef doğru ve saldırı kaynakta beyaz kutu anlamında başarılı). Güven aralıkları (GA) yüzdelik bootstrap ile (10.000 yeniden örnekleme) verilir. Her ikisi doğru protokolünde iki yönün yanıltma göstergeleri *aynı* örnekler üzerinde tanımlıdır: eşleştirilmiş bootstrap ortak kümenin örneklerini yeniden örnekler, işaret çevirme permütasyon testi örnek başına yön farkları üzerinde kurulur. İki tek yönlü eşdeğerlik testinin (TOST) ± 2 puanlık ana marjı, eğitim koşusu düzeyinde gözlenen varyasyonun (birkaç puan) altında kalan farkları pratikte eşdeğer sayma ilkesiyle seçilmiştir; ± 1 ve ± 3 duyarlılıkları da metinde raporlanır.


Gradyan yapısı, 500 sabit test örneğinde örnek başına kayıp gradyanlarıyla incelenir: ölçekten bağımsız seyreklik (Hoyer, Gini [23] ve örnek maksimumunun %1'inin altındaki bileşen oranı) örnek bazında eşleştirilmiş Wilcoxon testleriyle (Holm düzeltmeli); örnekler arası gradyan hizalanması, tüm örnek çiftleri üzerinden ortalama mutlak kosinüs olarak, işaretli ortalamayla birlikte raporlanır. Blok bazlı öznetelik kayması, test kümesinin (seçimsiz, doğruluğa bakılmaksızın) ilk 100 örneği üzerinde, her modelin *kendi* beyaz kutu PGD-10 örnekleriyle ölçülür: ViT'te her dönüştürücü bloğunun MLP alt-blok çıktısı tüm belirteçler (CLS + 196 yama) üzerinden, CNN'de her artık blok çıktısı uzamsal boyutlar üzerinden örnek başına düzeltilir; temiz ile çekişmeli temsiller arasındaki kosinüs benzerliği ve norm değişimi hesaplanır (ViT 12 blok, CNN 8 artık blok).

IV. SONUÇLAR


A. Gürbüzlük: Tek Manşet, Üç Okuma

Tablo I ve Şekil 2 mutlak sonuçları verir: çekişmeli eğitilmiş CNN her saldırıda ViT'in önündedir (AutoAttack %35,74'e karşı %32,94; ortak örneklerde McNemar $\chi^2 = 48,65$, $p < 10^{-11}$) ve ikisi de referans WideResNet'in gerisindedir; bu modelin üstünlüğü kapasite, ek veri ve daha güçlü tarifi ortak ürünüdür [22]. Şekil 3 farkın pertürbasyon bütçeleri boyunca kararlı olduğunu gösterir.

Koşullu ayrıştırma (Tablo II) okumayı değiştirir. PGD-10 altında iki modelin koşullu yanıltma oranları istatistik-



Şekil 2. Temiz, PGD-10 ve AutoAttack doğrulukları. WRN-28-10 (taramalı) daha güçlü tarif ve ek veriyle eğitilmiş harici referanstır.



Şekil 3. Pertürbasyon bütçesine göre PGD-10 doğruluğu (tam test kümesi).

sel olarak ayırt edilemez (%52,15'e karşı %52,33); dolayısıyla mutlak PGD farkının tamamı temiz doğrulukla açıklanır ($85,42 \times 0,478$ 'e karşı $75,65 \times 0,477$). AutoAttack altında model bazlı koşullu sıralama hafifçe ViT lehine bile döner (yanıltma %58,16'ya karşı %56,46). Ancak birebir eşleştirilmiş bir karşılaştırma sunan 7.260 ortak çözölen örnekte CNN iki saldırıda da anlamlı biçimde öndedir (PGD %54,92'ye karşı %49,61, McNemar $p < 10^{-20}$; AA %48,15'e karşı %45,33, $p < 10^{-6}$). Bu görünümeler bileşimsel olarak uzlaşır: yalnızca CNN'in temizde çözdüğü ~ 1.300 örnek neredeyse hiç gürbüz değildir (PGD sağkalımı %8'in altında) ve CNN'in model bazlı koşullu oranını aşağı çeker. Tek bir gürbüz doğruluk sayısı tüm bu yapıyı gizlerdi.

B. Transfer: Protokol, Sonucun Parçasıdır

Tablo III mimariler arası transferi, koşulsuz (ham) oranlar birlikte üç yerleşik koşullama protokolüyle raporlar (her protokolün paydaları tablo dipnotundadır). Koşulsuz (ham) oranlar CNN kaynakları lehine 8,3 puanlık bir asimetri önerir (%40,2'ye karşı %31,9); bu fark, hedefler arasındaki on puanlık temiz doğruluk farkının ürettiği yapay bir sonuçtur. Hedef

Tablo II
KOŞULLU AYRIŞTIRMA (TAM TEST; %95 BOOTSTRAP GA'LARI). HER
İKİSİ DOĞRU: İKİ MODELİN DE TEMİZDE DOĞRU SINIFLADIĞI $n = 7.260$
ÖRNEK.

Model	Koşullu yanılma (%)		Her ikisi doğru gürbüz (%)	
	PGD-10	AA	PGD-10	AA
ResNet-18 AT	52,15 [51,1; 53,2]	58,16 [57,1; 59,2]	54,92	48,15
ViT-Tiny AT	52,33 [51,2; 53,5]	56,46 [55,4; 57,6]	49,61	45,33

Tablo III
KOŞULSUZ ORAN VE ÜÇ KOŞULLAMA PROTOKOLÜ ALTINDA TRANSFER
ASİMETRİSİ (PGD-10, $\epsilon = 8/255$, TAM TEST; %95 BOOTSTRAP
GA'LARI).


Protokol	CNN→ViT	ViT→CNN	Fark
Koşulsuz (ham)	40,17	31,90	+8,27
Hedef doğru	20,95 [20,03; 21,88]	20,32 [19,47; 21,19]	+0,63
Her ikisi doğru	19,19 [18,26; 20,10]	13,86 [13,07; 14,66]	+5,33
Başarılı kaynak	39,07 [37,47; 40,66]	33,79 [32,48; 35,13]	+5,28

Paydalar (CNN→ViT / ViT→CNN): koşulsuz $N = 10.000/10.000$;
hedef doğru $N = 7.565/8.542$; her ikisi doğru $N = 7.260$ (ortak küme);
başarılı kaynak $N = 3.576/4.936$.

doğru protokolü bu karıştırıcı etkeni (confounder) giderir ve neredeyse parite gösterir (fark 0,63 puan; ± 2 puan marjında TOST eşdeğerliği, $p = 0,016$); bu parite momentum tabanlı MI-FGSM [17] altında da kararlıdır (%19,85'e karşı %20,11). Ancak her ikisi doğru ve başarılı kaynak protokolleri *farklı ortak kümede yeniden CNN lehine döndürür*: ortak çözölen örneklerde yönler belirgin biçimde ayrışır ($\sim 5,3$ puanlık CNN→ViT üstünlüğü; eşleştirilmiş bootstrap GA [4,39; 6,25]; işaret çevirme permütasyonu $p < 5 \times 10^{-5}$; TOST eşdeğerliği ± 3 puanda bile reddedilir). Mekanizma bileşimseldir: hedefin temizde çözödüğü ama kaynağın çözemediği örnekler iki yönde de aşırı kırılmalıdır (%56,9 ve %63,0 yanılma) ve bu marjinal altkümelerin asimetrik boyutları (1.282'ye karşı 305) hedef doğru oranlarını pariteye çeker. Mimariler arası transfer çalışmaları için pratik ders: koşullama protokolü aynı veri üzerinde yönlü bir farkı yaratabilir, silebilir veya ortaya çıkarabilir; bu nedenle açıkça beyan edilmeli ve mümkünse çeşitlendirilmelidir.

C. Gradyan Yapısı

Her iki modelde de ölçölen 500 sabit test örneğinde, CNN girdi gradyanları, ölçekten bağımsız her üç ölçöde de ViT'inkilerden tutarlı fakat ölçölü biçimde daha seyrek-tir (Hoyer $0,474 \pm 0,009$ 'a karşı $0,449 \pm 0,011$; Gini $0,634$ 'e karşı $0,606$; örnek maksimumunun %1'i altındaki bileşenler %31,5'e karşı %25,8) ve fark eşleştirilmiş Wilcoxon testle-rinde anlamlıdır (Holm düzeltmeli $p < 10^{-15}$; eşleştirilmiş Cohen d 'si $0,34-0,65$). Bu sıralamayı çekişmeli eğitim ya-ratır: temiz eğitilmiş çiftte seyrek olan model ViT'tir (Ho-yer $0,406$ 'ya karşı $0,354$) ve bu, çekişmeli eğitimin CNN gradyanları üzerindeki güçlü seyrekleştirici etkisiyle uyum-ludur [24]. Örnekler arası gradyan hizalanması, tüm çiftler üzerinden ortalama mutlak kosinüste ViT'te daha yüksektir ($0,052$ 'ye karşı $0,038$; temiz eğitilmiş çiftte neredeyse aynı düzeylerin gözlenmesi, incelenen kontrol noktalarında bu far-



Şekil 4. Göreli derinliğe göre temiz ve çekişmeli temsiller arasındaki blok bazlı kosinüs benzerliği ($n = 100$; bantlar ± 1 standart sapma).

kın yalnızca çekişmeli eğitimden kaynaklanmadığına işaret eder); ancak *işaretili* ortalama kosinüs iki modelde de sıfıra yakındır ($\leq 0,002$): örneklerin paylaştığı şey tutarlı yönler değil, duyarlılık eksenleridir.

D. Blok Bazlı Öznitelik Kayması

Şekil 4, saldırıya uğramış bir girdinin her bloktaki temsiline temiz karşılığından ne kadar uzaklaştığını karşılaştırır. ViT erken düşüş ve orta ağ platosu profili gösterir: kosinüs benzerliği hızla düşerek 8. blokta 0,955 minimumuna iner, ardından hafifçe toparlanır (10–11. bloklarda 0,965); öznitelik normları baştan sona %1,5'ten az değişir; pertürbasyon temsilin büyüklüğünü değil yönünü bozar. CNN nitel olarak farklı davranır: kosinüs benzerliği derinlikle monoton ve ivmelenerek düşer (0,995'ten son artık blokta 0,913'e) ve son iki blokta büyük norm bozulmaları görülür ($-\%6,4$ ve $+\%7,2$). Bu plato ve toparlanma biçimi derin ağların genel bir özelliği değildir; incelenen model çiftinde ViT'e özgüdür. Analiz, temiz eğitilmiş ViT'lerin katman bazlı temsil incelemelerini [25] çekişmeli eğitilmiş ortama taşımaktadır. Şekil 4'teki gölgeli bantlar, 5 parti ortalaması üzerinden ± 1 standart sapmayı gösterir.

V. TARTIŞMA VE SINIRLILIKLAR

Üç ana çıkarım öne çıkmaktadır. Birincisi, tek sayılık gürbüzlük karşılaştırmaları kayıplıdır: koşullu ayırıştırma-mamız “CNN daha gürbüzdür” (mutlak ve her ikisi doğru görünümleri), “koşullu duyarlılık eşleşiktir” (model bazlı PGD) ve “ViT kendi çözödüğü örneklerde daha az kaybeder” (model bazlı AutoAttack) okumalarının üçünü de aynı anda destekler. Buna ek olarak, transfer asimetrisi iddiaları protokole görelidir; mimariler arası çalışmalar koşullama protokolünü sonucun bir parçası olarak raporlamalıdır. Son çıkarım davranışsal ayrışmadır: mimariler gradyan yoğunlaşmasında ve çekişmeli hasarın derinlik boyunca nerede biriktiğinde ayrışır; bu, iki mimari için farklı yerlere konumlanmış kararlılaştırma (stabilizasyon) önerir.

Bu sonuçları birkaç sınırlılık çerçeveler. Bulgular tek bir temel tarif altında, mimari başına tek eğitim koşusuna dayanır;

bu nedenle kesinleşmiş değil, yönlendirici niteliktedir. Ayrıca kullanılan tüm istatistiksel testler (McNemar, Wilcoxon, bootstrap, permütasyon) örneklem düzeyinde çıkarım yapar ve *eğitilmiş sabit kontrol noktalarına koşulludur*; eğitim tohumu belirsizliğini nicelemezler. ViT gürbüzlüğünün tarife duyarlı olduğu da bilinmektedir [13]–[15]. Çalışma tek veri kümesini, tek model çiftini ve koşullu analizler için tek bütçeli L_∞ tehdit modelini kapsar. Gradyan ve kayma ölçümleri davranışsal korelasyonlardır; yerleşik nedensel açıklamalar değildir. Eğitim tohumu belirsizliğini nicelemek üzere mimari başına üç bağımsız eğitim koşusu içeren tekrarlar hâlen yürütülmektedir; ek transfer saldırılarını ve uzamsal gradyan istatistiklerini de ele alan genişletilmiş analiz hazırlanmaktadır.

VI. SONUÇ

CIFAR-10 üzerinde eşleşmiş çekişmeli eğitilmiş bir ResNet-18/ViT-Tiny çifti için gürbüzlük manşetinin bileşime bağlı olduğunu, ölçülen transfer asimetrisinin büyük ölçüde koşullama protokolünün bir özelliği olduğunu, gradyan yapısı farklarının tutarlı fakat ölçülü olduğunu (hizalanma farkının doğası gereği işaretli kaldığını) ve çekişmeli hasarın iki mimaride nitel olarak farklı derinliklerde biriktiğini gösterdik. Bu ön sonuçları, mimari aileleri arasında protokolü açık, çok görünümlü gürbüzlük karşılaştırmaları için bir şablon olarak sunuyoruz.

KAYNAKLAR

- [1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, “Intriguing properties of neural networks,” in *International Conference on Learning Representations*, 2014.
- [2] I. J. Goodfellow, J. Shlens, and C. Szegedy, “Explaining and harnessing adversarial examples,” in *International Conference on Learning Representations*, 2015.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [5] Y. Bai, J. Mei, A. L. Yuille, and C. Xie, “Are transformers more robust than cnns?” in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 26 831–26 843.
- [6] P. Benz, S. Ham, C. Zhang, A. Karjauv, and I. S. Kweon, “Adversarial robustness comparison of vision transformer and MLP-Mixer to CNNs,” in *Proceedings of the 32nd British Machine Vision Conference (BMVC)*, 2021.
- [7] K. Ali, M. S. Bhatti, A. Saeed, A. Athar, M. A. Al Ghamdi, S. H. Almotiri, and S. Akram, “Adversarial robustness of vision transformers versus convolutional neural networks,” *IEEE Access*, vol. 12, pp. 105 281–105 293, 2024.
- [8] A. Krizhevsky, G. Hinton *et al.*, “Learning multiple layers of features from tiny images,” University of Toronto, Tech. Rep., 2009.
- [9] F. Croce and M. Hein, “Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks,” in *International Conference on Machine Learning*, 2020, pp. 2206–2216.
- [10] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, “Towards deep learning models resistant to adversarial attacks,” in *International Conference on Learning Representations*, 2018.
- [11] L. Rice, E. Wong, and J. Z. Kolter, “Overfitting in adversarially robust deep learning,” in *International Conference on Machine Learning*, 2020, pp. 8093–8104.
- [12] F. Croce, M. Andriushchenko, V. Schwag, E. Debenedetti, N. Flammarion, M. Chiang, P. Mittal, and M. Hein, “RobustBench: a standardized adversarial robustness benchmark,” in *NeurIPS Datasets and Benchmarks Track*, 2021.
- [13] Y. Mo, D. Wu, Y. Wang, Y. Guo, and Y. Wang, “When adversarial training meets vision transformers: Recipes from training to architecture,” in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 18 599–18 611.
- [14] E. Debenedetti, V. Schwag, and P. Mittal, “A light recipe to train robust vision transformers,” in *IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2023, pp. 225–253.
- [15] J. Wu, Z. Song, X. Zhang, S. Xie, L. Lin, and K. Wang, “Vision transformers beat WideResNets on small scale datasets adversarial robustness,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 1, 2025, pp. 886–894.
- [16] Y. Liu, X. Chen, C. Liu, and D. Song, “Delving into transferable adversarial examples and black-box attacks,” in *Proceedings of the 5th International Conference on Learning Representations (ICLR)*, 2017.
- [17] Y. Dong, F. Liao, T. Pang, H. Su, J. Zhu, X. Hu, and J. Li, “Boosting adversarial attacks with momentum,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 9185–9193.
- [18] K. Mahmood, R. Mahmood, and M. Van Dijk, “On the robustness of vision transformers to adversarial examples,” in *IEEE/CVF International Conference on Computer Vision*, 2021, pp. 7838–7847.
- [19] D. Ravikumar, S. Kodge, I. Garg, and K. Roy, “TREND: Transferability-based robust ENsemble design,” *IEEE Transactions on Artificial Intelligence*, vol. 4, no. 3, pp. 534–548, 2023.
- [20] R. Wightman, “Pytorch image models,” <https://github.com/rwightman/pytorch-image-models>, 2019.
- [21] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [22] S. Gowal, C. Qin, J. Uesato, T. Mann, and P. Kohli, “Uncovering the limits of adversarial training against norm-bounded adversarial examples,” *arXiv preprint arXiv:2010.03593*, 2020.
- [23] N. Hurley and S. Rickard, “Comparing measures of sparsity,” *IEEE Transactions on Information Theory*, vol. 55, no. 10, pp. 4723–4741, Oct. 2009.
- [24] P. Chalasani, J. Chen, A. R. Chowdhury, X. Wu, and S. Jha, “Concise explanations of neural networks using adversarial training,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 1383–1391.
- [25] M. Raghu, T. Unterthiner, S. Kornblith, C. Zhang, and A. Dosovitskiy, “Do vision transformers see like convolutional neural networks?” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 12 116–12 128.