Ölçüm Protokolü Sonucu Belirler: CNN ile Görü Dönüştürücüsü Çekişmeli Gürbüzlük Karşılaştırmalarının Yöntembilimsel Bir İncelemesi

The Measurement Protocol Decides the Conclusion: A Methodological Study of CNN and Vision Transformer Adversarial Robustness Comparisons

Çağrı Şahin ve Özal Yıldırım

***Özet*—Mimari aileleri arasındaki çekişmeli gürbüzlük karşılaştırmaları birbiriyle çelişen sonuçlar bildirmekte ve bu anlaşmazlık genellikle modellere, eğitim tariflerine ya da veri kümelerine bağlanmaktadır. Bu çalışmada anlaşmazlığın büyük kısmının ölçüm protokolünden geldiğini gösteriyoruz. Mimari başına üç eğitim koşumu, örnek bazında kayıtla tam test kümesi değerlendirmesi ve her eğitimden önce ayrılmış bir doğrulama bölmesi kullanan çekişmeli eğitilmiş ResNet-18 ve ViT-Tiny çiftlerinde modelleri, veriyi, tehdit modelini ve saldırı bütçesini sabit tutup yalnızca transferin nasıl puanlandığını değiştiriyoruz. Dört koşullama protokolü altında ölçülen CNN'den ViT'e transfer asimetrisi CIFAR-10'da $4{,}4$ ile $19{,}4$ puan arasında değişmekte, oysa iki mimariyi yeniden eğitmek aynı büyüklüğü $1{,}5$ puandan az oynatmaktadır. $15{,}01$ puanlık yayılım iki parçadan oluşur: türettiğimiz bir özdeşlik $9{,}21$ puanını kapalı formda kaldırır, $5{,}79$ puanı ise farklı bir niceliği kestiren bir protokolden gelir. Düzeltmeden sonra ayakta kalan, onayladığımız iki protokol arasındaki $3{,}91$ puanlık takdirdir. Özdeşlik, koşulsuz oranın koşullu orandan sapmasının hedefin temiz hatasının bir eksi koşullu oranla ölçeklenmiş haline eşit olduğunu söyler ve onun öncülünü varsaymak yerine ölçüyoruz. Tasarımın CIFAR-100'de yinelenmesi on iki ölçümün tamamında işareti korumaktadır. Aynı tarifin iki mimariyi temiz doğrulukta $1{,}85$ puan ayırdığı SVHN'de ise protokol büyüklük kadar işarete de karar vermektedir: iki protokol CNN, ikisi ViT üstünlüğü bildirmekte, onayladığımız iki protokol ise birbiriyle uyuşmaktadır. Yalnızca kontrol noktası seçim kuralını değiştirmek, neredeyse hiç raporlanmayan dördüncü bir varyans kaynağı eklemektedir. Üç okuma daha doğrudan ölçüldüğünde doğrulanmamakta; çalışmayı mimariler arası gürbüzlük çalışmaları için raporlama gereklilikleriyle kapatıyoruz.**

***Anahtar Kelimeler*—Çekişmeli gürbüzlük, değerlendirme yöntembilimi, derin öğrenme güvenliği, evrişimli sinir ağları, görü dönüştürücüsü, tekrarlanabilirlik, transfer saldırıları**

I. Giriş

Derin sinir ağları, küçük bir norm bütçesiyle sınırlı kalırken yüksek güvenle yanlış sınıflandırmaya yol açan, özenle üretilmiş pertürbasyonlar olan çekişmeli örneklere (adversarial examples) karşı savunmasızdır [1], [2]. Görü Dönüştürücüleri (Vision Transformer, ViT) [3], [4] evrişimli sinir ağlarının (CNN) [5] yanında baskın bir mimari aile haline gelince doğal bir soru ortaya çıkmıştır: hangi aile daha gürbüzdür ve neden?

Literatür bu soruya tutarsız yanıtlar verir: Bai vd. [6] eşleşmiş eğitim tarifleri altında dönüştürücülerin CNN'leri geçmediğini, Benz vd. [7] ise standart eğitilmiş modellerde ViT'lerin daha gürbüz olduğunu bildirir. Transfer çalışmaları buna kendi uyuşmazlıklarını ekler: birçoğu saldırıların ViT'den CNN'e, tersine göre daha kolay taşındığını bildirir [7]–[9], Naseer vd. [10] ise ViT üzerinde üretilen pertürbasyonların geleneksel saldırılar altında zayıf transfer ettiğini bulur; bu makalede ölçülen yön ilk grubunkinin tersidir ve Bölüm V bu noktaya geri döner. Bu uyuşmazlıklar genellikle model, eğitim tarifi veya veri kümesi farklarına atfedilir ve standart tepki, eşleşmiş bir tarif altında karşılaştırma yapmaktır.

Modeller, veri, tehdit modeli ve saldırı bütçesinin tamamı sabit tutulduğunda bile sonuç, nadiren raporlanan bir seçime bağlı kalmaya devam eder: *ölçüm protokolü*. Transfer çalışmaları paydaya hangi örneklerin gireceğine karar vermek zorundadır (tüm test örnekleri mi, hedefin doğru sınıflandırdıkları mı, her iki modelin de doğru sınıflandırdıkları mı, yoksa kaynak saldırının başarılı olduğu örnekler mi); gürbüzlük karşılaştırmaları da mutlak bir skor mu raporlayacaklarına yoksa onu temiz doğruluk ve koşullu duyarlılık bileşenlerine mi ayıracaklarına karar vermek zorundadır. Makaleler bu seçimleri genellikle raporlama ayrıntısı sayar, oysa bunlar sonucun parçasıdır.

Ölçüm sorusunu yalıtabilmek için kurulum küçük tutulmuştur. CIFAR-10 [11] üzerinde ResNet-18 ile ViT-Tiny'yi eşleşmiş bir amaç fonksiyonu ve tehdit modeliyle çekişmeli eğitiyoruz; mimari başına üç bağımsız eğitim koşusu yapıyoruz; *her* eğitim aşamasından önce ayrılan sabit bir doğrulama bölmesi kullandığımız için hiçbir model gördüğü veriyle seçilmiyor. Tüm değerlendirmeler tam test kümesinde, örnek bazında sonuç kaydıyla koşar; bu kayıt eşleştirilmiş istatistikleri mümkün kılar: aynı örnekler, saldırıyı yeniden koşmadan farklı protokoller altında yeniden ağırlıklandırılabilir. Modeller sabitken yalnızca protokolü değiştiriyor ve sonucun ne kadar kaydığını ölçüyoruz.

Mimari karşılaştırmaları üç okumayı da davet eder; biz bunları ölçülebilir hipotez olarak ele alıyoruz: CNN girdi

Çağrı Şahin, Muş Alparslan Üniversitesi Yazılım Mühendisliği Bölümü'ndedir (49250 Muş, Türkiye) ve ayrıca Fırat Üniversitesi Yazılım Mühendisliği Bölümü'nde doktora öğrencisidir (23119 Elazığ, Türkiye).

Özal Yıldırım, Fırat Üniversitesi Yazılım Mühendisliği Bölümü'ndedir, 23119 Elazığ, Türkiye.

Sorumlu yazar: Çağrı Şahin (e-posta: c.sahin@alparslan.edu.tr).

gradyanlarının mekansal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini (attention) bozduğu ve ViT'e özgü transfer saldırılarının mimariler arası transferi iyileştirdiği. Yalnız sonuncusu yayımlanmış bir iddiadır; ilk ikisi, bir seyreklik sonucunun ya da bir avuç dikkat şeklinin kolayca akla getirdiği yorumlardır ve kendi önceki şekillerimiz de aynı yorumu düşündürüyordu. Her birini amaca özel bir ölçümle doğrudan sınıyoruz.

İlk katkımız protokol duyarlılığını nicelemektir. Aynı modeller ve aynı veri üzerinde, ölçülen mimariler arası transfer asimetrisi dört koşullama protokolü boyunca $+4{,}4$ ile $+19{,}4$ puan arasında değişirken her iki mimariyi sıfırdan yeniden eğitmek aynı niceliği $1{,}5$ puandan az oynatır. Yayılım şöyle ayrışır. Koşulsuz kestirimi hedef doğru kestirimden ayıran $9{,}21$ puanı türettiğimiz bir özdeşlik kapalı formda kaldırır, $5{,}79$ puan ise farklı bir niceliği kestiren bir protokolden gelir. Düzeltmeden sonra ikisi de savunulabilir iki protokol arasında $3{,}91$ puanlık bir takdir payı kalır ve bu pay hala yeniden eğitme etkisinin iki katından büyüktür. Bir eşdeğerlik testinin kabul mü ret mi edileceğine de protokol karar verir. Asimetrinin yönü ise büyüklüğünün aksine *iki model temiz doğrulukta ayrıştığı sürece* kararlıdır; eşitlendiklerinde dört protokolün ikisi yönü tersine çevirir. Tasarımın CIFAR-100 üzerinde bütünüyle yinelenmesi yayılımı CIFAR-10'daki büyüklüğüne yakın tutar ve işaretini korur; sabit bir eğitim yörüngesi üzerinde değiştirilen çevrimdışı kontrol noktası seçim kuralı da makalelerin nadiren raporladığı bir varyans kaynağı olarak ortaya çıkar.

İkinci katkı, hedefin temiz hatasıyla karışmış olan koşulsuz transfer oranlarına ilişkindir. WideResNet-28-10 referansının eklendiği 3×3 transfer matrisinde ham oranların koşullu oranlardan sapması bir özdeşliğe uyar. Hedefin zaten yanlış sınıflandırdığı örnekler pertürbasyonla neredeyse hiç kurtulmadığı için (36 yönde $0{,}989$ ile $1{,}000$ arasında), ham oran, temiz hata artı bir eksi o hatayla ölçeklenmiş koşullu orana $0{,}41$ puandan küçük bir farkla eşittir. Gelen transfer de hedefin kendi kırılganlığını izler (üç hedef üzerinde $r = 0{,}986$) ve asimetriyi daha zayıf hedefin bir özelliği olarak yeniden çerçeveler. Mutlak gürbüzlük ise temiz doğruluk ile koşullu duyarlılığın çarpımına birebir ayrışır. İki çarpanın da raporlanması gerekir, çünkü mutlak sıralama değişmediği halde aralarındaki pay önceki tek koşuluk kontrol noktalarımız ile üç yeni koşu arasında değişmiştir.

Raporladığımız sonuçların üçü negatiftir: ölçekten bağımsız seyreklik farkları mekansal lokalite farkına karşılık gelmez; dört mekansal ölçütün dördü de sıfır sonuç vermiştir. CLS dikkat entropisi $n = 1000$'de saldırı altında ölçülebilir biçimde değişmez. ViT'e özgü bir transfer saldırısı olan Jeton Gradyanı Düzenlileştirme (TGR) [12] bu rejimde transfer kazancı sağlamaz, eşleşmiş bütçede düz MI-FGSM'ye yenilir. İki davranışsal fark ise ayakta kalır. Gradyan seyrekliği farkları bağımsız kontrol noktası kümelerinde tekrarlanır, çekişmeli eğitimle ortaya çıkar ve yalnızca mutlak kosinüste var olan bir hizalanma farkıyla birlikte gelir. Çekişmeli hasar iki mimaride nitel olarak farklı derinliklerde birikir ve ölçülen kayma profili, hesaplamada kullanılan jeton (token) agregasyonuna bağlıdır.

Ölçümler, mimariler arası gürbüzlük çalışmaları için somut raporlama gerekliliklerine dönüşür; bu gereklilikler tartışmanın sonunda bir arada verilmiştir.

Bu çalışmanın ön sürümü ATEEC 2026'ya gönderilmiştir [13]. O sürüm koşullu ayrıştırmayı, dört protokollü transfer karşılaştırmasını, gradyan yapısı ölçümlerini ve blok bazlı kayma profillerini yalnızca CIFAR-10 üzerinde raporlar ve bunları ön sonuç olarak niteler. Bu makale iki veri kümesi daha, ikinci bir tehdit modeli, Bölüm IV'teki cebirsel özdeşlik, kontrol noktası seçimi ablasyonu, dönüştürücüye özgü transfer saldırısı ve ön kayıtlı analiz protokolünü ekler; ayrıca önceki sürümün bir iddiasını düzeltir: mimariler temiz doğrulukta eşitlendiğinde asimetrinin yönü kararlı değildir.

Bölüm II çekişmeli değerlendirme pratiğini ve mimari karşılaştırma çalışmalarını gözden geçirir; Bölüm III eğitim protokolünü, koşullama protokollerini ve ölçümleri tanımlar; Bölüm IV sonuçları verir. Çıkarımlar ve sınırlılıklar Bölüm V'te, sonuç Bölüm VI'da yer alır.

II. İLGILI ÇALIŞMALAR

A. Çekişmeli Saldırılar

Çekişmeli saldırılar, yanlış sınıflandırmaya yol açan en küçük pertürbasyonları bulmayı amaçlar. Hızlı Gradyan İşaret Yöntemi (FGSM) [2], kayıp gradyanının işaretini izleyerek pertürbasyonu tek adımda üretir; pertürbasyon büyüklüğü L_∞ normu altında sınırlıdır. İzdüşümlü Gradyan İnişi (PGD) [14] FGSM'yi yinelemeli eniyilemeyle genişletir: birden çok gradyan-işaret adımı atar ve her adımdan sonra ϵ-topuna geri izdüşüm yapar (biçimsel tanımlar Bölüm III-C).

Carlini-Wagner (C&W) saldırısı [15] çekişmeli örnek üretimini bir eniyileme problemi olarak kurar; genellikle daha yüksek başarı oranlarına ulaşır ancak hesaplama maliyeti artar. Daha yakın tarihli AutoAttack [16], güvenilir bir gürbüzlük değerlendirmesi sağlamak için birden çok saldırı stratejisini (APGD-CE, APGD-T, FAB-T, Square) birleştirir ve kıyaslamada fiili standart haline gelmiştir.

B. Savunma Mekanizmaları

Çekişmeli eğitim (adversarial training, AT) [14] en etkili savunma olmayı sürdürmektedir; modeli her partide üretilen çekişmeli örneklerle eğitir:

$$\min_{\theta} \mathbb{E}_{(x,y)\sim\mathcal{D}} \left[\max_{\|\delta\|_\infty \le \epsilon} \mathcal{L}(f_\theta(x+\delta), y) \right] \tag{1}$$

TRADES [17], doğal doğruluk ile gürbüzlük arasında kuramsal temelli bir ödünleşim sunar:

$$\mathcal{L}_{\text{TRADES}} = \mathcal{L}_{CE}(f(x), y) + \beta \cdot \text{KL}(f(x) \| f(x_{adv})) \tag{2}$$

burada β ödünleşim parametresidir.

MART [18], yanlış sınıflandırılan örnekleri eğitim sırasında vurgulayarak ele alır. Diğer yaklaşımlar arasında girdi dönüşümü [19], rastgeleleştirilmiş yumuşatma yoluyla sertifikalı savunmalar [20] ve topluluk yöntemleri [21] bulunur. Sertifikalı gürbüzlükteki güncel gelişmeler arasında, rastgeleleştirilmiş yumuşatmayı test zamanında uyarlanan çok adımlı modelleri sertifikalandıracak biçimde genişleten Uyarlanabilir Rastgeleleştirilmiş Yumuşatma [22] sayılabilir.

C. CNN Gürbüzlüğü

CNN'ler tarafında Madry vd. [14], PGD saldırılarıyla çekişmeli eğitimin güçlü deneysel gürbüzlük sağladığını göstermiştir. RobustBench lider tablosu [23] gürbüz doğruluğu mimariden bağımsız olarak izlemektedir; CIFAR-10 sıralamasının tepesini WideResNet türevleri tutmaktadır.

Model kapasitesinin ulaşılabilir gürbüzlükle ilişkili olduğu gösterilmiştir [14]; daha geniş ve derin ağlar daha iyi gürbüz doğruluk sergilemektedir. Mimariye özgü bulgular arasında atlama bağlantılarının çekişmeli transfer edilebilirlikteki rolü [24] ve çekişmeli eğitimin büyük ölçekte yol açtığı ayrık parti-normalizasyonu istatistikleri [25] sayılabilir; ilişkili olarak, yardımcı parti-normalizasyonu dalları çekişmeli örneklerin temiz doğruluğu artırmasına imkan vermektedir [26]. Çekişmeli eğitimin girdi-gradyan yapısının kendisini de yeniden biçimlendirdiği, daha algısal hizalı gradyanlar [27] ve daha seyrek öznitelik atıfları [28] ürettiği bilinmektedir.

D. Görü Dönüştürücüsü Gürbüzlüğü

Vaswani vd. [4] tarafından tanıtılan öz-dikkat mekanizması üzerine kurulan Görü Dönüştürücüleri [3], görüntüleri yama dizileri olarak işler; iç temsilleri CNN'lerden katman katman ölçülebilir biçimde ayrışır [29]. Bhojanapalli vd. [30], yeterli veriyle ön eğitildiklerinde ViT'lerin geniş bir pertürbasyon yelpazesinde en az ResNet'ler kadar gürbüz olduğunu bulmuştur. Bai vd. [6], dönüştürücülerin CNN'lerden daha gürbüz olup olmadığını sistematik olarak incelemiş; adil eğitim tarifleri altında çekişmeli gürbüzlükte üstün olmadıklarını, buna karşılık öz-dikkate atfedilen dağılım kayması gürbüzlüğünde öne geçtiklerini bulmuştur. Benz vd. [7], MLP-Mixer'i de içeren erken bir doğrudan karşılaştırma raporlamış ve farkları frekans tercihlerine bağlamıştır. Sonraki çalışmalar ViT'lerin özellikle gradyan tabanlı saldırılara karşı savunmasız kaldığını [8], yama hedefli saldırıların dikkat mekanizmasını doğrudan istismar ettiğini [31] ve dikkatın yama pertürbasyonları altında ölçülebilir biçimde kaydığını [32] ortaya koymuştur.

Shao vd. [9], ViT'leri beyaz kutu ve transfer ayarlarında CNN'lerden ve MLP-Mixer'lardan daha gürbüz bulmuş, özniteliklerinin daha az yüksek frekanslı içerik taşıdığını göstermiş ve çekişmeli eğitimin ViT'lere uygulanabildiğini ortaya koymuştur; ancak ön niteliğindeki CIFAR-10 koşusunda çekişmeli eğitilmiş ViT büyük bir CNN'i geçememiştir. ViT'lerin yaygın bozulmalara ve örtmelere karşı gürbüzlüğü de betimlenmiştir [33]. Daha yakın zamanda Jain vd. [34], ViT'lerdeki bir gradyan maskeleme biçimini dikkatteki softmax alt taşmasına (underflow) bağlamış ve PGD türü saldırıların bu yüzden ViT'lerde eksik kaldığını göstermiştir; yalnız PGD'ye dayanan ViT değerlendirmeleri için bir uyarı olan bu bulguya karşı AutoAttack, gradyansız Square bileşeniyle kısmi bir güvence sağlar. Düzeltilmiş saldırı üzerine kurdukları çekişmeli eğitim tarifi CIFAR-10 ve ImageNet-100'de mevcut ViT tariflerini geçmektedir; difüzyonla artırılmış çekişmeli eğitimle ViT'lerin küçük ölçekli veri kümelerinde WideResNet'leri geçebildiği bildirilmiştir [35]. Zhu vd. [36], gradyan normalizasyonu ölçekleme ve yüksek frekans uyarlamasıyla ViT'lere yönelik transfer edilebilir saldırıları güçlendirmiştir. CNN ile ViT gürbüzlüğünü tek bir değerlendirme protokolü altında davranışsal olarak karşılaştıran çalışmalar azdır.

E. Transfer Saldırıları

Çekişmeli örnekler modeller arasında sıklıkla transfer olur ve bu, kara kutu saldırılarını mümkün kılar [37]. Demontis vd. [38] transfer edilebilirliği iki etkene, hedef modelin içkin kırılganlığına ve vekil modelin karmaşıklığına bağlamakta ve onu iki modelin girdi gradyanlarının hizalanmasıyla ilişkilendirmektedir. Temel transfer çalışmaları transfer edilebilirliği zaten doğru sınıflandırılan örnekler üzerinde değerlendirmekte [39], standart saldırı makaleleri de başarı oranlarını aynı gerekçeyle koşullamaktadır [40]; transfer saldırılarının sistematik yeniden değerlendirmeleri de havuzu her modelin doğru sınıflandırdığı örneklerle sınırlamaktadır [41]. Yakın tarihli iki kıyaslama da aynı yönde ilerlemektedir: TA-Bench [42] otuzu aşkın transfer saldırısını ortak bir vekil ve kurban model havuzu üzerinde standartlaştırmakta, Yu vd. [43] ise transfer edilebilirliğin tek bir mimari ailesi içinde ölçüldüğünde dizgesel olarak abartıldığını bildirmekte ve çok hedefli bir sonucun nasıl puanlandığında ayrışan üç değerlendirme protokolü önermektedir: topluluğu tek bir hedef saymak, kaç hedefin kandırıldığını saymak ve hepsinin kandırılmasını istemek. TA-Bench puanlama kuralını sabit tutup saldırıyı ve model havuzunu değiştirmekte; Yu vd. puanlama kuralını hedef toplulaştırma ekseninde değiştirmektedir. Bu makale ise onu koşullama ekseninde değiştirmektedir: modeller, veri ve saldırı bütçesi sabittir; bu da koşullama kümesinin kendi katkısını yalıtmakta ve ortaya çıkan kestirimler arasındaki aritmetik bağıntıyı yazmayı mümkün kılmaktadır. Topluluk tasarımında Ravikumar vd. [44], transfer ölçümünü tam olarak modeller arasındaki doğruluk farklarını hesaba katmak için her iki modelin de doğru sınıflandırdığı örneklerle sınırlamaktadır; koşullu metriğimizin kontrol ettiği karıştırıcının aynısı.

Mahmood vd. [8], her-ikisi-doğru protokolüyle CNN'ler ile ViT'ler arasındaki transferi ölçmüş ve dikkat çekici ölçüde düşük CNN↔ViT transferi bulmuştur; Naseer vd. [10], ViT'lerde üretilen çekişmeli örneklerin geleneksel saldırılarla zayıf transfer ettiğini göstermiş ve ViT kaynaklı transferi iyileştirmek için öz-topluluk ve jeton arıtma önermiştir; Wei vd. [45] dikkat gradyanlarını atlayarak ve yama bazlı seyreltmeyle ViT kaynaklı transferi geliştirmiştir. Bunların üzerine Jeton Gradyanı Düzenlileştirme (TGR) [12], ViT'in dikkat bileşenlerini kullanarak transfer edilebilir örnekler üretmekte; Momentum Bütünleşik Gradyanlar (MIG) [46] hem ViT'lerde hem CNN'lerde gelişmiş transfer sağlamaktadır. Chen vd. [47], CNN'ler ile ViT'lerin farklı tümevarım önyargılarından yararlanan bir transfer saldırısı önermektedir; bu farkın ardındaki frekans tercihleri, CNN'lerin yüksek, ViT'lerin düşük frekanslı içeriğe yaslanması, Benz vd. [7] ve Shao vd. [9] tarafından belgelenmiştir. Waseda vd. [48] transfer sonuçlarını bir adım daha ayırmakta, hedefin kaynağın tam olarak aynı hatasını tekrarlayıp tekrarlamadığına göre sınıflandırmakta ve her iki durumun birbirine yakın modeller arasında bile görüldüğünü bildirmektedir.

F. Araştırma Boşluğu

Tekil çalışmalar CNN ve ViT gürbüzlüğünü ayrı ayrı incelemiş ve adil olmayan CNN ile dönüştürücü karşılaştırmalarının tuzaklarına daha önce dikkat çekilmiş olsa da [6], [49], mevcut karşılaştırmalı çalışmalar gürbüzlük skorlarını çoğunlukla tek başına, üstelik tutarsız pertürbasyon bütçeleri, saldırı yapılandırmaları veya model ölçekleriyle raporlamakta; karşılaştırmayı davranışsal analizle nadiren eşleştirmektedir. Yakın tarihli bir çalışma ViT ve CNN çekişmeli gürbüzlüğünü doğrudan karşılaştırmaktadır [50]; çalışmamız, tam test kümesinde AutoAttack ve eşleştirilmiş istatistiklerle değerlendirme yapması, transfer ölçümünü temiz doğruluk farklarına karşı kontrol etmesi ve karşılaştırmaya gradyan ile öznitelik düzeyinde davranışsal analizler eklemesiyle ayrışmaktadır.

Değerlendirme yöntembilimi literatürü, gürbüzlüğün nasıl ölçüldüğünün neye varıldığını belirlediğini defalarca göstermiştir: Carlini ve ark. [51] gürbüzlük değerlendirmesinin başarısızlık kiplerini derlemekte, Tramèr ve ark. [52] ise sabit saldırılar altında gürbüz sayılan savunmaların uyarlanabilir saldırılara yenildiğini göstermektedir. Bu çalışmalar saldırı gücüyle, yani ölçümün yeterince güçlü olup olmadığıyla ilgilidir. Bizim sorduğumuz soru dikeydir: saldırı gücü sabit tutulduğunda yalnızca *koşullama kümesi* sonucu ne kadar oynatır? Transfer değerlendirmesini modellerin doğru sınıflandırdığı örneklerle koşullamak yerleşik pratiktir [8], [39], [40], [44] ve tekil makaleler bir koşullama kümesi seçip devam etmektedir. Yu ve ark. da puanlama kuralını değiştirir, fakat başka bir eksende; koşullama kümesi seçiminin sonucu ne kadar etkilediğine dair kontrollü bir kestirim bilmiyoruz. Böyle bir kestirimi, geri kalan her şeyi sabit tutup yalnızca protokolü değiştirerek veriyoruz. Koşulsuz oranlardaki karıştırıcı bu durumda $r_{\text{ham}} - r_{\text{koş}} = e\,(1 - r_{\text{koş}})$ özdeşliği biçimini alır ve bilinen nitel bir uyarıyı yayımlanmış sonuçlara doğrudan uygulanabilir bir düzeltmeye dönüştürür.

Aynı tasarım, mimari karşılaştırmalarının akla getirmeye yatkın olduğu üç okumayı da test etmemize imkan verir: CNN gradyanlarının mekansal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini bozduğu ve dönüştürücüye özgü transfer saldırılarının [10], [12] mimariler arası transferi iyileştirdiği. Anılan çalışmalar yalnız üçüncüsünü ileri sürer; ilk ikisi yorumdur. Her birini doğrudan ölçüyoruz ve hiçbiri bizim kurulumumuzda geçerli çıkmıyor.

III. Yöntem

Şekil 1 tasarımı özetlemektedir. İki mimari, mimari başına üç bağımsız koşuyla tek bir eşleşmiş çekişmeli tarif altında eğitilmekte ve her değerlendirme tam test kümesinde örnek bazında kaydedilmektedir; böylece Bölüm III-F'teki dört koşullama protokolü hiçbir saldırı yeniden koşulmadan aynı kayıtlara uygulanabilmektedir. Aşağıdaki alt bölümler sırasıyla tehdit modelini, modelleri, saldırıları ve eğitim protokolünü sabitlemekte, ardından ölçümleri tanımlamaktadır.

A. Tehdit Modeli

Saldırganın girdi görüntülerini sınırlı bir bölge içinde pertürbe edebildiği standart L_∞ tehdit modelini ele alıyoruz:

$$\mathcal{B}_\epsilon(x) = \{x' : \|x' - x\|_\infty \le \epsilon\} \tag{3}$$

CIFAR-10 için yerleşik uzlaşımları izleyerek [11], [23] birincil pertürbasyon bütçesi olarak $\epsilon = 8/255 \approx 0{,}031$ kullanıyoruz; epsilon taraması analizi için $\epsilon \in \{2/255, 4/255, 16/255\}$ değerlerinde ek tam-test PGD-10 değerlendirmeleri yapılmaktadır.

Hem beyaz kutu (tam model erişimi) hem kara kutu (transfer saldırısı) senaryolarında değerlendirme yapıyoruz. Beyaz kutu saldırılarda saldırgan model mimarisi ve parametrelerine tam olarak hakimdir. Transfer saldırılarında çekişmeli örnekler bir kaynak modelde üretilir ve farklı bir hedef modelde değerlendirilir.

B. Model Mimarileri

a) CNN Modelleri: **ResNet-18** [5]: Artık bağlantılı, yaygın kullanılan bir taban CNN; 11,2M parametre içerir. CIFAR-10 için tasarlanmış standart mimariyi (7×7 yerine başlangıçta 3×3 evrişim) kullanıyoruz.

WideResNet-28-10 [53]: ResNet'in 36,5M parametreli daha geniş bir türevi; CIFAR-10'da çekişmeli gürbüzlük için sık başvurulan bir referans mimaridir. Gowal vd.'nin [54] RobustBench [23] üzerinden dağıtılan önceden eğitilmiş gürbüz kontrol noktasını kullanıyoruz. Bu model ek etiketsiz veriyle ve bizim standart çekişmeli eğitimimizden daha güçlü bir tarifle eğitildiğinden, eşleşmiş bir karşılaştırma değil bir referans noktası işlevi görmektedir.

b) Görü Dönüştürücüsü Modelleri: **ViT-Tiny**: `timm` kütüphanesindeki [55] ViT-Tiny mimarisini, girdileri çift doğrusal olarak 224×224'e büyüterek CIFAR-10'a uyarlıyoruz. Mimari 16×16 yamalar (görüntü başına 196 yama), 192 boyutlu gömmeler, her biri 3 dikkat başlı 12 dönüştürücü bloğu ve 4 MLP oranı kullanır; toplam 5,7M parametredir. Model CIFAR-10 üzerinde *sıfırdan* (ImageNet ön eğitimi olmadan) temel veri artırmayla (rastgele kırpma ve yatay çevirme) eğitilmekte, ardından çekişmeli ince ayara tabi tutulmaktadır. Küçük veri kümelerinde ViT gürbüzlüğünün eğitim tarifine duyarlı olduğu bilindiğinden [56], [57], mimari düzeyindeki sonuçlarımız en iyi şekilde eğitilmiş ViT'ler için değil, *bu temel eğitim tarifi altında* geçerli okunmalıdır.

C. Saldırı Yöntemleri

a) FGSM: Adım boyu pertürbasyon bütçesine eşit tek adımlı saldırı:

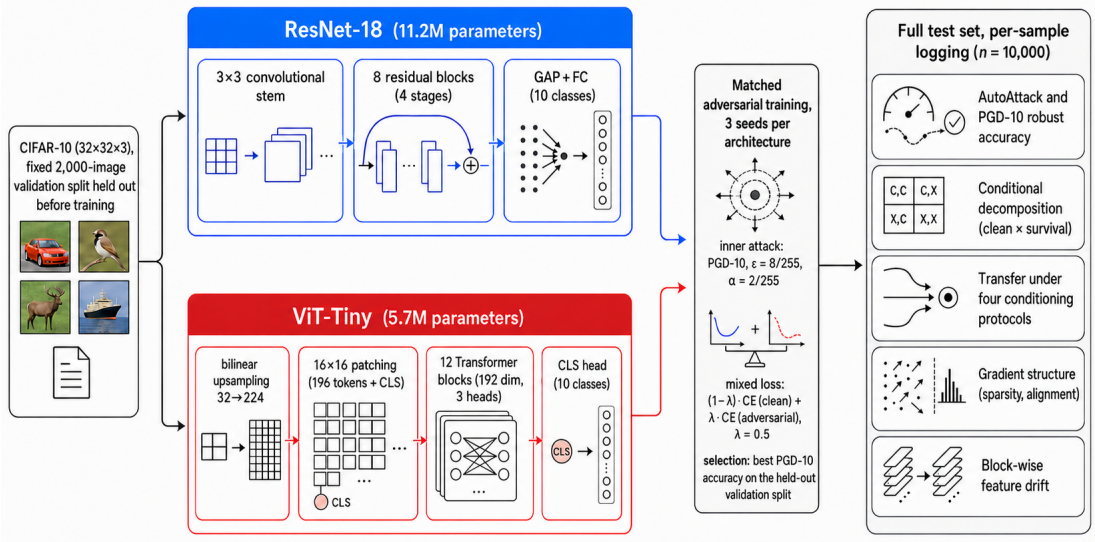
$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}_{CE}(f(x), y)) \tag{4}$$

b) PGD: Adım boyu $\alpha = 2/255$ ve rastgele başlangıçlı yinelemeli saldırı:

$$x^{t+1} = \Pi_{\mathcal{B}_\epsilon(x)} \left(x^t + \alpha \cdot \text{sign}(\nabla_{x^t} \mathcal{L}_{CE}(f(x^t), y)) \right) \tag{5}$$

burada $x^0 = x + \mathcal{U}(-\epsilon, \epsilon)$. Bu çalışma boyunca hem çekişmeli eğitimde hem değerlendirmede PGD-10 (10 yineleme) kullanılmaktadır (Tablo I).

c) AutoAttack: APGD-CE (çapraz entropi kayıplı Auto-PGD), APGD-T (hedefli DLR kayıplı Auto-PGD), FAB-T (hedefli Hızlı Uyarlanabilir Sınır saldırısı) ve Square (skor tabanlı kara kutu saldırısı) bileşenlerini birleştiren standartlaştırılmış topluluk saldırısı AutoAttack [16] kullanılmaktadır.



Şekil 1: Çalışmanın genel görünümü. Aynı CIFAR-10 bölmesi iki mimariyi, ResNet-18 ve ViT-Tiny'yi beslemekte; ikisi de mimari başına üç bağımsız koşuyla tek bir eşleşmiş çekişmeli tarif altında eğitilmekte ve her eğitimden önce ayrılmış bir doğrulama bölmesiyle seçilmektedir. Her değerlendirme tam test kümesinde örnek bazında kaydedilir; dört koşullama protokolünün aynı kayıtlara uygulanabilmesini sağlayan budur. Sağdaki beş ölçüm ailesi Bölüm IV'ün raporladıklarıdır.

D. Savunma Yöntemleri

a) Çekişmeli Eğitim (AT): Temiz ve çekişmeli kayıpları birleştiren karma bir çekişmeli eğitim amacı kullanıyoruz:

$$\mathcal{L} = (1-\lambda)\,\mathcal{L}_{CE}(f_\theta(x), y) + \lambda\,\mathcal{L}_{CE}(f_\theta(x_{adv}), y) \qquad (6)$$

burada $\lambda = 0{,}5$, standart sınıflandırma başarımı ile çekişmeli gürbüzlüğü dengeler. İç enbüyükleme, çekişmeli örnekleri PGD-10 ile üretir ($\alpha = 2/255$, $\epsilon = 8/255$); saldırı üretimi model eğitim kipindeyken yapılır, böylece saldırı üretimi ile parametre güncellemesi tutarlı parti-normalizasyonu istatistikleri görür; bu, Rice vd.'nin [58] referans gerçeklemesindeki uygulamadır. İki kaybı karıştırmak, gürbüzlük kazanılırken temiz doğruluğun korunmasına yardım eder, çünkü yalnızca çekişmeli örneklerle eğitim doğal başarımı düşürebilir. TRADES [17] gibi alternatif formülasyonlar kuramsal temelli ödünleşim mekanizmaları sunsa da, bu çalışma mimari etkileri savunmaya özgü etkileşimlerden yalıtmak için standart çekişmeli eğitime odaklanmaktadır.

E. Eğitim Protokolü

a) Temiz Eğitim: CNN'ler için SGD eniyileyici; başlangıç öğrenme oranı 0,1, kosinüs tavlama çizelgesi [59], ağırlık sönümü 5×10^{-4} ve 200 epok. ViT'ler için AdamW eniyileyici [60]; başlangıç öğrenme oranı 10^{-3}, kosinüs tavlama, ağırlık sönümü 0,05 ve 200 epok.

b) Çekişmeli Eğitim: Temiz eğitilmiş kontrol noktalarından başlayarak düşürülmüş öğrenme oranlarıyla ince ayar yapıyoruz: CNN'ler SGD ile 10^{-3} öğrenme oranı ve kosinüs tavlamayla en çok 100 epok; ViT'ler AdamW ile aynı öğrenme oranı ve çizelgeyle eğitilir. Gradyanlar küresel L_2 normu 10'a kırpılır ve kaybı sonlu olmayan partiler atlanır. Veri artırma, 4 piksel dolgulu rastgele kırpma ve yatay çevirmedir; tüm modeller $[0, 1]$ aralığında ham piksel girdisi tüketir (ortalama/std normalizasyonu yoktur) ve saldırılar ile epsilon bütçeleri doğrudan bu piksel uzayında işler. Eğitim parti boyu CNN için 128, ViT için 64'tür (değerlendirme parti boyları analize göre değişir). Erken durdurma 20 sabır ve 0,1 puanlık iyileşme eşiğiyle uygulanır.

c) Doğrulama Bölmesi ve Tekrarlar: Model seçimi ve erken durdurma, sabit 2.000 örneklik bir doğrulama bölmesindeki PGD-10 çekişmeli doğruluğuyla yürütülür. Bu bölme bir kez çekilir (tohum 777; indeksler kodla birlikte saklanır), çalışmadaki her model tarafından paylaşılır ve hem temiz hem çekişmeli aşamanın eğitim kümesinden çıkarılır; dolayısıyla hiçbir kontrol noktası, üzerinde eğitildiği veriyle seçilmez. Test kümesine yalnızca nihai art-değerlendirmelerde dokunulur. Tüm boru hattını (temiz ön eğitim + çekişmeli ince ayar) mimari başına üç kez, bağımsız tohumlarla tekrarlıyoruz (ResNet-18 için 1001 ile 1003, ViT-Tiny için 2001 ile 2003) ve koşuları indekse göre eşliyoruz; böylece her mimariler arası karşılaştırma aynı tekrar altında eğitilmiş modeller arasındadır. Tüm tablolar bu üç koşunun ortalamasını ve standart sapmasını raporlar.

Bölüm IV-A'teki bir karşılaştırma için, bu protokol benimsenmeden önce eğitilmiş ve doğrulama bölmesi temiz ön eğitimin parçası olmuş daha eski bir kontrol noktası çiftine de başvuruyoruz. Söz konusu kontrol noktaları yalnızca karşıtlık için yer alır: iki kontrol noktası kümesi arasındaki fark, tek koşuluk bir sonucun ne kadar hareket edebileceğine dair kendi başına kanıttır.

F. Değerlendirme Metrikleri

a) Temel Metrikler: Modelleri üç standart metrikle değerlendiriyoruz: temiz doğruluk (pertürbe edilmemiş test görüntülerinde sınıflandırma başarımı), gürbüz doğruluk (çekişmeli örneklerde başarım) ve saldırı başarı oranı (temizde doğru sınıflandırılan görüntülerin saldırı sonrası yanlışa dönen oranı). Beyaz kutu değerlendirmelerde ek olarak *ko-*

şullu yanıltma oranını (temizde doğru sınıflandırılan örneklerin saldırının devirdiği kesri) ve tümleyeni olan koşullu sağkalımı raporluyoruz. Örnek bazındaki kayıtlarımızda hem PGD hem AutoAttack, temizde yanlış sınıflandırılan örnekleri gürbüz olmayan saydığından, mutlak gürbüz doğruluk birebir gürbüz $=$ temiz $\times$ koşullu sağkalım olarak çarpanlarına ayrılır; bu, gürbüzlük farklarını temiz doğruluk bileşeni ile koşullu duyarlılık bileşenine ayırmamızı sağlar. Doğrulukları ayrıca *her ikisi doğru* altkümesinde (karşılaştırılan iki modelin de temizde doğru sınıflandırdığı örnekler) raporluyoruz; bu, ortak bir örnek kümesi üzerinde birebir eşleştirilmiş karşılaştırma sağlar.

b) Transfer Metrikleri: Transfer metriklerimiz, yalnızca koşullama kümesiyle ayrışan bir *koşullu yanıltma oranları* ailesidir. Ailenin taban üyesi *hedef doğru* oranıdır: hedef modelin temizde doğru sınıflandırdığı örnekler içinde, kaynak modelde üretilen çekişmeli örneklerle yanlışa dönenlerin oranı. Kaynak model f_S'ye karşı üretilen $\{x^S_{adv}\}$ örnekleri için hedef f_T'ye koşullu transfer oranı:

$$\text{KYO} = \frac{\sum_i \mathbf{1}[f_T(x_i) = y_i]\,\mathbf{1}[f_T(x^S_{adv,i}) \neq y_i]}{\sum_i \mathbf{1}[f_T(x_i) = y_i]} \tag{7}$$

Transfer değerlendirmesini doğru sınıflandırılan örneklerle koşullamak yerleşik pratiktir ve genellikle çalışmadaki her modelin doğru sınıflandırdığı örnekler üzerinde yapılır [8], [39]–[41], [44]; hedef-doğru oran bu havuzun tek yanlı gevşetmesidir ve koşullama en çok mimariler arası karşılaştırmalarda önem taşır: ham yanlış sınıflandırma oranı $\frac{1}{n}\sum_i \mathbf{1}[f_T(x^S_{adv,i}) \neq y_i]$ hedefin temiz hatasını içerir; temiz doğruluğu düşük bir hedef, saldırı hiç ek örnek devirmese bile transfere daha "kırılgan" görünür. Ham oranı, şeffaflık ve bu karıştırıcının boyutunu nicelemek için ikincil metrik olarak raporluyoruz. Koşullama kümesinin kendisi bir protokol seçimi olduğundan, iki alternatifi de raporluyoruz: kaynak ve hedefin ikisinin de doğru sınıflandırdığı örneklerle koşullayan *her ikisi doğru* protokolü [8], [44] ve saldırının kaynakta beyaz kutu anlamında başarılı olduğu hedef-doğru örneklerle koşullayan *başarılı kaynak* protokolü. Her ikisi de yerleşiktir. Başarılı kaynak oranı, Ravikumar ve ark.'nın [44] transfer edilebilirlik metriğidir: Denklem (1), hedefe transfer olan örnek sayısını kaynakta üretilen örnek sayısına bölmekte ve havuzu iki modelin de doğru sınıflandırdığı örneklerle sınırlamaktadır. Ayrıca bir transfer oranı "başarılı" çekişmeli örnekler üzerinden raporlandığında örtük olarak kullanılan protokol de budur. Yönlü iddialar için birincil tahmin olarak her ikisi doğru oranını alıyoruz, çünkü iki yönü de aynı örnekler üzerinde puanlar ve bu yüzden eşleştirilmiş çıkarımı destekler; diğer üçü baştan sona onun yanında raporlanır. Bölüm IV-B'in gösterdiği gibi bu protokoller nitel olarak farklı asimetri sonuçları verebilir; bu makaledeki her transfer sayısının protokolüyle birlikte verilmesinin nedeni de budur. Transfer oranları tam test kümesinde (10.000 örnek) örnek bazında kayıtla hesaplanır ve örnekler üzerinde yüzdelik bootstrap ile %95 güven aralıkları verilir (10.000 yeniden örnekleme).

c) Gradyan Analizi Metrikleri: Gradyan özelliklerini, büyüklükler değerlendirme parti boyundan bağımsız olsun diye örnek başına kayıplarla hesaplayarak üç tamamlayıcı metrik ailesiyle inceliyoruz. Gradyan normu ($\|\nabla_x \mathcal{L}\|_2$ ve $\|\nabla_x \mathcal{L}\|_\infty$) toplam duyarlılık büyüklüğünü ölçer. Gradyan seyrekliği, ölçekten bağımsız ölçülerle nicelenir: Hoyer seyrekliği, $|g|$'nin Gini katsayısı ve örnek maksimumunun %1'inin altındaki bileşen oranı, çünkü sabit mutlak eşikler gradyan ölçeğini yapıyla karıştırır; Hoyer ve Gini, Hurley ve Rickard'ın [61] biçimselleştirdiği ölçek-değişmezliği aksiyomlarını sağlar. Gradyan hizalanması, örnekler arasındaki ortalama ikili mutlak kosinüs benzerliğidir (500 analiz örneğinin tüm çiftleri üzerinden):

$$\text{Hizalanma} = \frac{1}{N(N-1)} \sum_{i \neq j} \left| \frac{\nabla_{x_i} \mathcal{L} \cdot \nabla_{x_j} \mathcal{L}}{\|\nabla_{x_i} \mathcal{L}\| \|\nabla_{x_j} \mathcal{L}\|} \right| \tag{8}$$

Mutlak kosinüsü kullanıyoruz, çünkü paylaşılan duyarlılık *eksenleri* işaretten bağımsız olarak saldırı geometrisi için önemlidir; evrensel pertürbasyon argümanlarının ek olarak gerektirdiği şey işaret tutarlılığı olduğundan işaretli ortalama kosinüsü de raporluyoruz; bu değer her model için sıfıra yakın çıkmaktadır (Bölüm IV-F). Yüksek mutlak hizalanma, girdiler arasında benzer pertürbasyon eksenlerine işaret eder.

d) Mekansal Lokalite Metrikleri: Seyreklik kaç gradyan bileşeninin büyük olduğunu ölçer ama bunların görüntüde nerede durduğu hakkında bir şey söylemez; bu yüzden mekansal yapıyı, kanal toplamı enerji haritası $e = \sum_c (\nabla_x \mathcal{L})^2_c$ (toplamı 1'e normalize) üzerinde ayrıca ölçüyoruz. Enerjinin %50'sini ve %90'ını toplayan en küçük piksel oranını (küçük değer = daha lokalize), e'nin piksel dağılımı olarak Shannon entropisini (düşük değer = daha lokalize) ve enerji bitişik piksellerde kümelendiğinde pozitif olan 4-komşuluklu Moran's I'yı raporluyoruz. Dördü de gradyan ölçeğinden bağımsızdır ve örnek başına hesaplanır; böylece iki mimari aynı girdiler üzerinde eşleştirilmiş testlerle karşılaştırılabilir.

e) Katman Analizi için Jeton Agregasyonu: Bir dönüştürücü bloğu jeton başına bir vektör üretir; bloğu özetlemek bir seçim gerektirir. Üçünü raporluyoruz: yalnız CLS jetonu, 196 yama jetonunun ortalaması ve tüm jetonların örnek başına düzleştirilmiş birleşimi. CNN'de her artık blok çıktısı mekansal boyutlar üzerinden düzleştirilir. ViT için üçünü birden raporluyoruz; çünkü Bölüm IV-G'ün gösterdiği gibi, farklı kayma büyüklükleri verirler ve minimumu farklı derinliklere yerleştirirler.

f) Dikkat Metrikleri: ViT için her bloğun softmax sonrası CLS$\rightarrow$yama dikkat satırını başlar üzerinden ortalayarak çıkarıyoruz. Dikkatin ne kadar geniş yayıldığını ölçen Shannon entropisini ve saldırı altındaki yer değiştirmesini (temiz ile çekişmeli dikkat dağılımları arasındaki, 1 ile sınırlı toplam varyasyon uzaklığı) raporluyoruz. İkisi de örnek başına hesaplanıp ortalanır; koşu başına $n = 1000$ örnek.

g) ViT'e Özgü Transfer Saldırısı: Transfer sonuçlarının mimariden bağımsız saldırılara bağlı olup olmadığını test etmek için kaynak örnekleri ek olarak Jeton Gradyanı Düzenlileştirme (TGR) [12] ile üretiyoruz; TGR, geri yayılım sırasında dikkat, QKV ve MLP yollarındaki jeton-gradyan tensörlerinin uç değerli girdilerini sıfırlar ve kalan gradyanı $\gamma = 0{,}5$ ile ölçekler. Gerçeklememiz yöntemi CIFAR-10 ViT sarmalayıcımıza ve bu makale boyunca kullanılan bütçeye ($\epsilon = 8/255$, $\alpha = 2/255$, 10 adım, momentum 1,0) uyarlamaktadır; özgün ImageNet varsayılanları kullanılmamıştır. Ürettiği sonuç negatif olduğundan sürümümüzün iki ayrıntısı

daha önem taşır. Üç yolun hepsine yol-başına ayarlamak yerine tek bir $\gamma = 0{,}5$ uyguluyor ve jetonlar arasında her (örnek, kanal) için tek bir maksimum ile tek bir minimum girdiyi sıfırlıyoruz; bütün jeton satır ve sütunlarını değil. Yayımlanmış düzenlileştirme şeması birebir yeniden gerçeklenmediği için aşağıdaki negatif sonuç yalnızca bizim uyarlamamızı bağlar; sonucu yayımlanmış haliyle yönteme genişletmek, özgün şemayla bir yineleme gerektirir. Düz MI-FGSM [40] örnekleri aynı koşuda aynı örnekler üzerinde üretilir; bu, birebir aynı bütçede eşleştirilmiş bir kontrol sağlar.

h) Öznitelik Bozunması Metrikleri: Çekişmeli pertürbasyonların ViT temsillerini katmanlar boyunca nasıl etkilediğini incelemek için her ℓ katmanında üç metrik hesaplıyoruz. Öznitelik kosinüs benzerliği, temsilin yönünün ne ölçüde korunduğunu ölçer:

$$\text{Benz}_\ell = \frac{h_\ell(x) \cdot h_\ell(x_{adv})}{\|h_\ell(x)\| \|h_\ell(x_{adv})\|} \tag{9}$$

burada h_ℓ, ℓ katmanındaki temsili göstermektedir. Öznitelik norm değişimi ise büyüklük etkilerini yakalar:

$$\Delta_\ell = \frac{\|h_\ell(x_{adv})\| - \|h_\ell(x)\|}{\|h_\ell(x)\|} \times 100\% \tag{10}$$

Öznitelik L_2 uzaklığı ($\|h_\ell(x) - h_\ell(x_{adv})\|_2$) mutlak sapmayı nicelemektedir.

G. İstatistiksel Doğrulama

Dört varyans kaynağını ayırıyor ve her birini geçerli olduğu yerde raporluyoruz. Mimari karşılaştırmaları eğitim koşusu varyansına bağlı olduğundan her tablo, mimari başına üç bağımsız koşunun ortalamasını ve standart sapmasını verir (Bölüm III-E). Saldırı başlatma varyansı, PGD-10'un sabit bir altkümede üç saldırı tohumuyla (42, 123, 456) yeniden koşulmasıyla ölçülür; değerlendirilen örnekler ve sıraları sabittir, tohumlar yalnızca saldırının rastgele başlangıcını değiştirir. Koşullama protokolleri arasındaki yayılım olan protokol varyansı gürültü değil sonuç olarak ele alınır (Bölüm IV-B). Dördüncü kaynak olan kontrol noktası seçimi varyansı, sabit bir yörüngeden son kontrol noktasını seçen çevrimdışı kuraldan (doğrulama bölmesi, erken durdurma sabrı ve eğri yumuşatması) doğar ve yörünge sabit tutularak on sekiz bileşim üzerinde ölçülür. Bölüm IV-I büyüklüklerini karşılaştırmaktadır.

Aynı örneklerin iki koşul altında puanlandığı her yerde eşleştirilmiş testler kullanılır: eşleştirilmiş ikili sonuçlar için McNemar'ın kesin testi, üç seyreklik ölçüsü için Holm düzeltmeli Wilcoxon işaretli sıra testi, farklar için eşleştirilmiş bootstrap güven aralıkları (10.000 yeniden örnekleme) ve her-ikisi-doğru transfer farkı için işaret çevirme permütasyon testi (20.000 permütasyon). Bu çalışmada iki çıkarım birimi mevcuttur ve farklı soruları yanıtlarlar. Örnek bazlı bir test, iki sabit kontrol noktasının değerlendirilen görüntülerde farklı olup olmadığını sorar; üç eğitim tekrarı üzerinden yapılan koşum düzeyi bir test ise mimarilerin farklı olup olmadığını. Mimari bir iddiayı yalnızca ikincisi destekler ve üç koşumla ikisinden çok daha zayıftır. Her testin yanında birimi anıyor, iddia mimari olduğu her yerde koşum düzeyini kullanıyor, iki birimin uyuşmadığı yerde ise iddiayı kayıranı değil ikisini birden raporluyoruz; bunun yaşandığı yer Bölüm IV-F'tir. Eşdeğerlik iddiaları iki tek yönlü test (TOST) ile ve ± 2 puanlık birincil marjla yapılır; bu marj karşılaştırmalardan önce PGD doğruluğundaki koşumlar arası değişimden sabitlenmiştir. Bu marj mutlak doğruluk için doğru, transfer asimetrisi için yanlış ölçektir: asimetrinin kendi koşumlar arası standart sapması $0{,}23$ puandır, dolayısıyla orada marj yaklaşık sekiz kat cömerttir ve TOST'u eşdeğerliği kabul etmeye doğru yanlılaştırır. Ön kayıtlı marjı veriyi gördükten sonra yeniden ayarlamak yerine koruyor ve her eşdeğerlik iddiasını ± 1 ve ± 3 puanda da raporluyoruz; kabul ettiğimiz tek eşdeğerlik olan SVHN, ± 1 puanda da geçerlidir. Tüm değerlendirme ve analiz betikleri rastgele tohumları sabitler (tohum 42, CUDA determinizm bayrakları dahil); dolayısıyla raporlanan her sayı, yayımlayacağımız boru hattından yeniden üretilebilir olacaktır.

Tablo I: CIFAR-10'da ana gürbüzlük sonuçları ($\epsilon = 8/255$); mimari başına üç bağımsız eğitim koşusu üzerinden ortalama±std. AA, standart takımla AutoAttack anlamına gelmektedir.

Model	Savunma	Param.	Temiz	FGSM	PGD-10	AA
CNN Modelleri						
ResNet-18	Yok	11,2M	95,25±0,15	40,29±1,77	0,03±0,03	–
ResNet-18	AT	11,2M	85,78±0,36	53,46±0,08	44,11±0,50	**37,93±0,14**
WRN-28-10	AT†	36,5M	89,48	70,91	66,92	62,76
Görü Dönüştürücüsü Modelleri						
ViT-Tiny	Yok	5,7M	80,09±0,60	6,10±1,47	0,05±0,05	–
ViT-Tiny	AT	5,7M	73,53±0,55	36,31±0,42	32,69±0,22	**29,14±0,40**

†Gowal vd.'nin [54] RobustBench [23] üzerinden dağıtılan gürbüz kontrol noktası; tek harici kontrol noktası olduğundan standart sapma yoktur. Temiz/FGSM/PGD-10: yerel tam-test değerlendirmelerimiz; AA: RobustBench raporlu değer (üzerinde AutoAttack yeniden koşulmadı).

IV. Deneyler

A. Gürbüzlük Karşılaştırması

Tablo I, değerlendirilen tüm modeller için ana gürbüzlük karşılaştırmasını sunmaktadır. Modellerimize ait her hücre, mimari başına üç bağımsız eğitim koşusunun ortalaması ve bu koşular üzerindeki standart sapmadır; her koşu 10.000 örneklik tam test kümesinde değerlendirilmiştir.

CNN her saldırı altında *mutlak* bir gürbüzlük üstünlüğü taşımaktadır: ResNet-18 AT, AutoAttack altında $\%37{,}93 \pm 0{,}14$ gürbüz doğruluğa ulaşırken ViT-Tiny AT $\%29{,}14 \pm 0{,}40$'ta kalmaktadır. Bir çiftin iki modeli de aynı 10.000 örnekte, örnek bazında kayıtla değerlendirildiğinden her koşu içinde McNemar'ın eşleştirilmiş testi uygulanabilir ve üç çiftte de CNN lehinedir (AutoAttack altında $p < 10^{-84}$, PGD-10 altında $p < 10^{-120}$). Çekişmeli eğitilmiş çiftte tohum düzeyindeki değişim raporlanan hiçbir doğrulukta 0,55 puanı aşmaz; dolayısıyla sıralama koşudan koşuya gürültü değildir. Savunmasız temel modeller FGSM altında daha çok değişmektedir (1,8 puana kadar), ancak hiçbir iddia onlara dayanmamaktadır. CNN ayrıca daha yüksek temiz doğruluğu korumaktadır ($\%85{,}78$'e karşı $\%73{,}53$; 12,3 puanlık fark); bu, ViT'leri küçük veri kümelerinde sıfırdan eğitmenin güçlüğünü yansıtır; Tablo II bu katkıyı koşullu duyarlılıktan ayırmaktadır. AutoAttack gürbüzlüğü iki mimaride de PGD-10'un altına düşmektedir (ResNet-18 için 6,2, ViT-Tiny için 3,6 puan).

Tablo II: Tam test kümesinde beyaz kutu gürbüzlüğünün koşullu ayrıştırması; üç koşu üzerinden ortalama±std. Alt blok, aynı büyüklükleri önceki tek koşuluk kontrol noktalarında tekrarlamaktadır.

Model	Koşullu yanıltma (%) PGD-10	AA	Her ikisi doğru gürbüz (%) PGD-10	AA
ResNet-18 AT	**48,58**±0,80	**55,78**±0,23	**59,86**±0,35	**51,89**±0,49
ViT-Tiny AT	55,53±0,50	60,37±0,33	46,11±0,59	41,15±0,39
Önceki tek koşu, doğrulama bölmesi temiz ön eğitimde görülmüş (n=7.260)				
ResNet-18 AT	52,15	58,16	**54,92**	**48,15**
ViT-Tiny AT	52,33	**56,46**	49,61	45,33

%62,76'daki WideResNet-28-10 referansı [54], kapasitenin, ek eğitim verisinin ve daha güçlü tarifin gürbüzlüğü mimari seçiminin ötesine ne kadar taşıdığını göstermektedir; bu modeli eşleşmiş çiftten ayrı tutuyoruz.

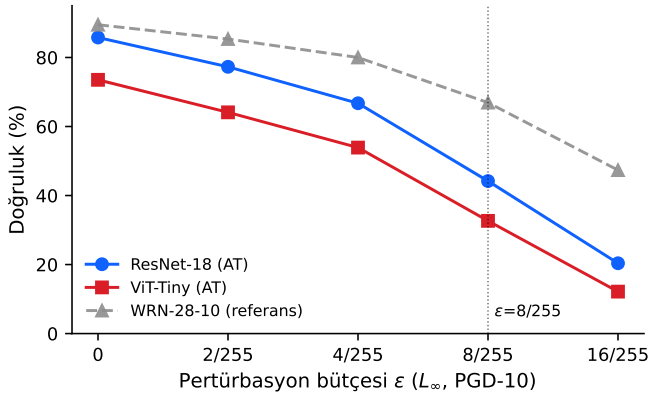
Tablo II, mutlak skorları temiz doğruluk ve koşullu duyarlılık bileşenlerine ayırmaktadır (Bölüm III-F). Temizde yanlış sınıflandırılan girdiler gürbüz olmayan sayıldığından ayrıştırma birebirdir: AutoAttack için CNN'de $85{,}78 \times 0{,}442 = 37{,}93$, ViT'te $73{,}53 \times 0{,}396 = 29{,}14$ okunur. İki çarpan da CNN lehinedir: 12,3 puan daha yüksek temiz doğruluktan başlar *ve* çözdüklerinin daha küçük bir kesrini kaybeder (koşullu yanıltma PGD-10 altında $48{,}58$'e karşı $\%55{,}53$; AutoAttack altında $55{,}78$'e karşı $\%60{,}37$). Çiftin iki modelinin de temizde doğru sınıflandırdığı $n = 7.061 \pm 68$ örnekte, yani birebir eşleştirilmiş bir karşılaştırmada, CNN 13,8 ve 10,7 puan öndedir (her koşuda McNemar $p < 10^{-67}$; bu sınır bu altkümede hesaplanmıştır ve yukarıda anılan tam küme sınırından zayıftır, aradaki fark büyük paydanın satın aldığı şeydir).

Ayrıştırma, iki çarpan aynı yönü gösterdiğinde bile raporlanmaya değerdir; çünkü aynı yönü göstermek zorunda değillerdir ve aralarındaki pay, ürettikleri sıralamadan daha az kararlıdır. Doğrulama bölmesini temiz ön eğitimin zaten görmüş olduğu ilk kontrol noktalarımız, aynı mutlak sıralamayı ama tersine bir koşullu okuma vermişti: PGD-10 altında ayırt edilemeyen (52,15'e karşı %52,33) ve AutoAttack altında hafifçe ViT lehine (58,16'ya karşı %56,46) yanıltma oranları; bu da CNN üstünlüğünün tamamen bir temiz doğruluk etkisi olduğu okumasını destekliyordu (Tablo II alt blok). Düzeltilmiş üç koşunun hiçbiri bu okumayı yeniden üretmemekte ve üç koşu birbiriyle, herhangi birinin önceki koşuyla uyuştuğundan çok daha yakından uyuşmaktadır. Tek bir neden yalıtamıyoruz; çünkü düzeltilmiş protokol doğrulama düzenini ve eğitim koşusunu aynı anda değiştirmiştir. Dikkat çekici biçimde basit bir veri miktarı açıklaması geçerli değildir: düzeltilmiş temiz modeller 2.000 daha az görüntü görmelerine karşın öncekilerden *daha iyidir* (ViT için $80{,}09 \pm 0{,}60$'a karşı $\%77{,}50$). Böyle bir atıf bu nedenle tek eğitim koşusundan çıkarılmamalıdır; tek başına raporlanan mutlak skor da işi hangi çarpanın yaptığını gizler.

Şekil 2, $\epsilon \in \{2/255, 4/255, 8/255, 16/255\}$ bütçelerinde tam test kümesindeki PGD-10 gürbüz doğruluğunu gösterir.

B. Transfer Saldırısı Analizi

Her tohum çifti için, kaynak modelde PGD-10 çekişmeli örnekleri üretiyor ve bunları tam test kümesinde bir hedefte



Şekil 2: Pertürbasyon bütçesine (ϵ) göre PGD-10 gürbüz doğruluğu; tam test kümesi, üç koşu ortalaması (± 1 std bantları). İki AT mimarisi de epsilon arttıkça benzer biçimlerle bozulmakta, CNN tutarlı bir marj korumaktadır.

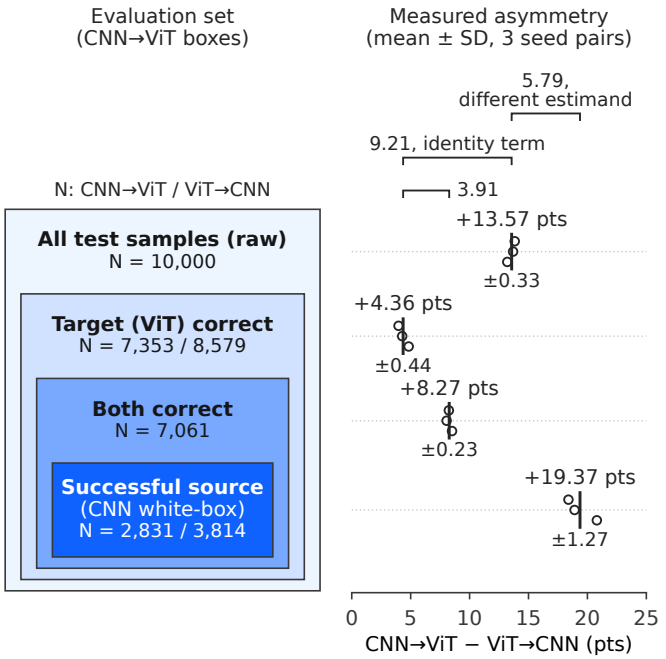
Tablo III: Koşulsuz oran ve üç yerleşik koşullama protokolü altında transfer asimetrisi (PGD-10, ϵ=8/255, tam test; üç tohum çifti üzerinden ortalama±std). En sağdaki sütun, önceki tek koşuluk kontrol noktalarında ölçülen farkı tekrarlamaktadır.

Protokol	CNN→ViT	ViT→CNN	Fark	Fark‡
Koşulsuz (ham)	41,02±0,55	27,45±0,27	+13,57±0,33	+8,27
Hedef doğru	19,87±0,18	15,51±0,59	+4,36±0,44	+0,63
Her ikisi doğru	18,25±0,17	9,98±0,31	+8,27±0,23	+5,33
Başarılı kaynak	36,39±0,76	17,02±0,52	+19,37±1,27	+11,17

‡Tek koşu; doğrulama bölmesi temiz ön eğitimde görülmüş.

değerlendiriyoruz. Sonuçlar örnek bazında kaydedildiğinden, aynı saldırı koşusu yeniden hesaplama olmadan birden çok koşullama protokolü altında puanlanabilir: protokoller yalnızca paydaya hangi örneklerin girdiğinde ayrışır (Bölüm III-F).

Paydalar protokoller arasında keskin biçimde değişmektedir. CNN→ViT ve ViT→CNN için sırasıyla koşullamasız 10.000/10.000, hedef doğruda 7.353/8.579, her ikisi doğruda 7.061 ortak örnek ve başarılı kaynakta 2.831/3.814'tür. Şekil 3, CNN→ViT yönü için dört kümeyi her birinin verdiği asimetrinin yanında çizmektedir. Fark sütununda verilen yayılım, tohum içi eşleştirilmiş farkın standart sapmasıdır; iki yön tohumlar boyunca birlikte değiştiğinden bu değer yön başına yayılımlardan geri hesaplanamaz ve Bölüm IV-I'te kullanılan eğitim koşusu referansıdır. Aynı modeller ve aynı veri üzerinde asimetri $+4{,}36 \pm 0{,}44$ ile $+19{,}37 \pm 1{,}27$ puan arasında değişmektedir; en büyük ve en küçük protokol tahmini arasındaki tohum-başına ortalama yayılım $15{,}01 \pm 0{,}84$ puandır ve uç kestirimler 4,4 kat oranında birbirinden ayrılır, oysa herhangi bir protokolün içindeki tohum düzeyi standart sapma 1,5 puanın altında kalır. Yayılımı ayrıştırmak için asimetrinin koşulsuz kestirimini eksen noktası alalım. Başarılı kaynak kestirimi onun $5{,}79$ puan üstündedir ve kaynağın kendi beyaz kutu başarısızlığına koşullandığı için farklı bir niceliği kestirir. Hedef doğru kestirimi ise $9{,}21$ puan altındadır ve bu açıklığın tamamı Denklem (11)'in kapalı formda öngördüğü paydır; hedefin temiz hatasını bilen bir okur onu birebir geri alabilir. İkisi yayılımın tamamını verir ($15{,}01$ puan; yuvarlanmış terimlerin



Şekil 3: Dört transfer protokolünün CNN→ViT yönündeki iç içe değerlendirme kümeleri (solda; kutular şematiktir, alanla orantılı değildir; N üç tohum çiftinin ortalamasıdır) ve her protokolün aynı modeller ve aynı veri üzerinde ölçtüğü asimetri, CNN→ViT eksi ViT→CNN (sağda; üç tohum çifti üzerinden eşleştirilmiş tohum-içi farkın ortalaması ± SS, tek tek tohum çiftleri içi boş işaretlerle). ViT→CNN kümeleri aynı sırayla iç içedir ($N = 10.000$, 8.579, 7.061 ve 3.814); koşulsuz ve her-ikisi-doğru kümeleri iki yönde aynıdır, diğer ikisi değildir. Köşeli ayraçlar $15{,}01$ puanlık yayılımın ayrışımını işaretler: $9{,}21$ puanlık terim Denklem (11)'in kapalı formdaki terimidir, $5{,}79$ puanlık terim farklı bir niceliği kestiren bir protokole aittir ve $3{,}91$ puan onaylanan iki protokolü birbirinden ayırır (terimler ayrı ayrı yuvarlanmıştır).

toplamı $15{,}00$'dır, çünkü her biri yuvarlanmamış ortalamalardan ayrı ayrı yuvarlanmıştır). Düzeltmeden sonra ayakta kalan şey, yönlü iddialar için onayladığımız ve birbirinden yalnızca kaynağın da doğru olmasının gerekip gerekmediğiyle ayrılan iki protokol arasındaki farktır: $3{,}91$ puan, yani iki mimariyi yeniden eğitmenin hareket ettirdiğinin hala iki katından fazlası. Bu artık CIFAR-100'de $5{,}97$, SVHN'de $0{,}65$ puandır. Eksen yapısı veri kümesine bağlıdır: CIFAR-100'de koşulsuz kestirim dördün en büyüğüdür, dolayısıyla oradaki $13{,}58$ puanlık yayılımın tamamı özdeşlik payıdır ve başarılı kaynak kestirimi bu aralığın içine düşer. Protokol, istatistiksel hükmü de belirlemektedir. Her iki yönü aynı örnekler üzerinde puanlayan ve bu yüzden eşleştirilmiş çıkarımı destekleyen her ikisi doğru protokolünde fark $8{,}27 \pm 0{,}24$ puandır; bu değerin tablodaki $\pm 0{,}23$'ten hafifçe farklı olmasının tek nedeni iki kestiricinin farklı olmasıdır. Her koşunun kendi eşleştirilmiş bootstrap GA'sı vardır ($[7{,}61;\ 9{,}44]$, $[7{,}10;\ 9{,}01]$ ve $[7{,}28;\ 9{,}20]$). Uç noktalarının ortalaması, kendi başına kapsama garantisi taşımayan ve üç aralığı yalnızca betimleyen $[7{,}33;\ 9{,}22]$'yi verir; koşum düzeyinde çıkarım için ise koşumlar arası t aralığı $[7{,}68;\ 8{,}86]$'dır. İşaret çevirme permütasyonu p değeri her tohumda 5×10^{-5}'in altındadır ve TOST üç marjın hiçbirinde (± 1, ± 2, ± 3 puan; her birinde $p = 1{,}0$) eşdeğerliği kuramamaktadır, çünkü aralık ± 3'ün tamamen dışında kalmaktadır. Önceki kontrol noktalarında ise aynı boru hattı, hedef doğru protokolü altında ± 2 puanda eşdeğerliği kabul etmişti.

Protokol adları alt seçimleri de açık bırakır. Başarılı kaynak protokolü, saldırının kaynakta başarılı olduğu örneklerle koşullamaktadır; bu ifadenin kaynağın temiz girdiyi doğru sınıflandırmasını gerektirip gerektirmediği ise transfer çalışmalarının nadiren yazdığı bir alt seçimdir. Bu makale daha sıkı okumayı raporlamaktadır: beyaz kutu başarısı, kaynağın temiz girdide doğru ve çekişmeli karşılığında yanlış olması demektir. Kaynağın zaten yanlış sınıflandırdığı örnekleri de içeri alan gevşek okumada ölçülen asimetri $+19{,}37$ puandan $+14{,}60$ puana, protokol yayılımı ise $15{,}01$ puandan $10{,}45$ puana inmektedir. Bu $4{,}77$ puanlık kayma, Tablo III'teki her protokolün koşumlar arası standart sapmasının üç katından büyüktür; diğer üç protokol ise tanım gereği değişmemektedir. Bu büyüklükte bir alt seçim protokolün adında görünmediği için, dört koşullama maskesinin tamamı yayımlanan kodda tek bir yerde tanımlanmaktadır.

Kararlı olan yöndür: CNN'de üretilen örnekler ViT'e, dört protokolün dördünde, üç tohumun üçünde ve momentum tabanlı MI-FGSM [40] altında da ($19{,}07 \pm 0{,}33$'e karşı $\%15{,}42 \pm 0{,}52$, hedef doğru; bu iki yönlü kontrol başka yerde kullanılan $\alpha = 2/255$'i değil saldırının kendi varsayılan adımı $\alpha = \epsilon/10$'u kullanır, ViT→CNN değerinin Tablo XI'deki eşleşmiş bütçeli değerden hafifçe ayrılmasının nedeni budur) tersinden daha iyi transfer olur; dolayısıyla etki PGD saldırısının bir artefaktı değildir. Büyüklüğü ve anlamlılığı, onlarla birlikte de her türlü eşdeğerlik iddiası protokole bağlıdır.

Yayılımın arkasındaki mekanizma bileşimseldir. Hedefin temizde çözdüğü ama kaynağın çözemediği örnekler, ortak çözülenlerden üç-dört kat daha kırılgandır ($41{,}2 \pm 0{,}8$ ve $\%59{,}1 \pm 1{,}7$ yanıltma; ortak kümede $10{,}0$ ve $\%18{,}3$) ve bu marjinal altkümeler, iki model temiz doğrulukta ayrıştığı için boyutça beş kat farklıdır (1.517 ± 102'ye karşı 291 ± 16). Hedef doğru koşullaması iki marjinal altkümeyi de içeri alır ve asimetrik boyutları iki oranı birbirine doğru çeker; her ikisi doğru koşullaması onları dışarıda bırakır ve yönlü fark yeniden ortaya çıkar. Bu açıklama dört protokolün üçünü kapsar. Başarılı kaynak protokolü farklı bir mekanizmayla sürülür ve iki sürücü ayrıştırıldığında yayılımın neye bağlı olduğu değişir: altı tohum-ve-veri-kümesi kümesinden gelen 18 yön çiftinde, dört protokollü asimetri yayılımı iki model arasındaki temiz hata farkı büyüdükçe *azalmaktadır* (eğim $-0{,}528$, küme bootstrap GA $[-0{,}664;\ -0{,}418]$); buna karşılık başarılı kaynak protokolü dışarıda bırakılarak hesaplanan yayılım aynı farkla *artmaktadır* (eğim $+0{,}431$, GA $[+0{,}333;\ +0{,}633]$). Başarılı kaynak oranı 18 çiftin 16'sında dördün ucudur ve en geniş protokol çifti hedef doğru ile başarılı kaynak arasındadır ($23{,}77$ puan ortalama açıklık, 18 yönün 13'ünde en geniş). Kaynak başarısıyla koşullama *kaynağın* kendi gürbüzlüğüne göre seçim yapar; bu, çiftin temiz doğruluk farkının bir fonksiyonu değildir ve ikinci, kısmen ters yönlü bir terim katmaktadır. Uydurmanın havuzu SVHN çiftini

dışarıda bırakmakta ve bu yönüyle ön kayıttan ayrılmaktadır. Ön kayıt SVHN'i uydurulan kola koymuş ve x ekseninde on iki puanın altındaki boş bandı dolduracak çift olarak adlandırmıştır; bağımsız bir tutarlılık kontrolüne atanması ise SVHN sonucu elde edildikten sonra yazılmıştır, dolayısıyla ön kayıtlı uydurma SVHN'i içeren uydurmadır. İki SVHN yönü eklendiğinde dört protokollü eğim $-0{,}133$'e gitmekte ve küme bootstrap güven aralığı $[-0{,}570;\ +0{,}469]$ sıfırı içermektedir; üç protokollü eğim ise işaretini de aralığını da korumaktadır ($+0{,}470$, GA $[+0{,}361;\ +0{,}665]$). Bu nedenle dört protokollü eğimi geri çekiyoruz; mekanizma iddiası, havuz sorusunu aşan ve Bölüm IV-I'e taşınan üç protokollü eğime dayanmaktadır.

Protokol yayılımını temiz hata farkına karşı, farklı biçimlerde hata veren iki yolla kalibre ediyoruz; iki yol dört protokolün üçünde uyuşmaktadır. *Kontrollü* kol, çiftin bir üyesini sabit tutup diğerini kendi eğitim yörüngesi boyunca taramakta; böylece mimari, tohum, veri kümesi ve saldırı bütçesi sabit kalırken fark değişmektedir (sekiz tohum-ve-veri-kümesi kümesinden 116 nokta). *Gözlemsel* kol ise final modelleri mimariler, tohumlar ve veri kümeleri arasında karşılaştırmakta, yani her şey aynı anda değişmektedir (altı kümeden 18 yön çifti). Her ikisinde çıkarım yörünge düzeyi küme bootstrap iledir; serbestlik derecesini nokta sayısı değil küme sayısı belirler ve kollar havuzlanmamaktadır. Bu aralıklar için iki uyarı geçerlidir. Altı ile sekiz küme varken yüzdelik küme bootstrap'i kapsamayı düşük tutar; dolayısıyla aşağıdaki aralıklar genişlik için alt sınır olarak okunmalıdır. Ayrıca WideResNet tek ve sabit bir dış kontrol noktasıdır ve altı gözlemsel kümenin altısında da, on sekiz yön çiftinin on ikisinde bulunur; yani bu kümeler tam bağımsız değildir. Onu dışarıda bırakan yalnız-çift duyarlılığı yanında raporlanmaktadır.

Başarılı kaynak protokolü dışarıda bırakıldığında iki kol uyuşmaktadır: ön kayıtlı havuzda kontrollü kol $+0{,}673$ (GA $[+0{,}602;\ +0{,}727]$), gözlemsel kol $+0{,}470$ (GA $[+0{,}361;\ +0{,}665]$) vermekte; işaret aynı, aralıklar örtüşüyor. Yukarıda geri çektiğimiz dört protokollü eğim ise hiçbir yönde karşılaştırma taşımaz: ön kayıtlı havuzda gözlemsel aralık $[-0{,}570;\ +0{,}469]$, kontrollü kolun $+0{,}273$ (GA $[+0{,}219;\ +0{,}371]$) değerini bütünüyle kapsar; yani kollar orada ne uyuşur ne uyuşmaz. Post-hoc karşıtlık, havuz seçiminin ne yaptığını gösterir. SVHN dışarıda bırakıldığında gözlemsel dört protokollü eğim $-0{,}528$'e (GA $[-0{,}664;\ -0{,}418]$) gitmekte ve kontrollü kolla örtüşmemekte; o havuz eşleşmiş mimari çiftine kısıtlandığında ise $-0{,}100$'e (GA $[-0{,}464;\ +0{,}092]$) gelmektedir. Hangi çiftlerin uydurmaya girdiğine bu kadar duyarlı bir nicelik, bir mekanizma iddiasının dayanağı olamaz. İddiayı taşıyan uyuşma üç protokollü olandır ve uydurduğumuz her havuzda geçerlidir. İki sınır geçerlidir. Gözlemsel kolun negatif eğimi x ekseninde $7{,}2$ puanlık ölçülmemiş bir boşluğun üzerinden uydurulmuştur, dolayısıyla bir eğilimi izlemek yerine birbirinden ayrık iki kümeyi karşılaştırmaktadır. Kontrollü kolun dört protokollü eğimi ise erken kontrol noktaları çıkarıldığında işaretini korumakta ama büyüklüğünü korumamaktadır: eşiklere göre $+0{,}201$ ile $+0{,}492$ arasında gezinmekte ve kendi aralığı $[+0{,}219;\ +0{,}371]$ bu aralığı kapsamamaktadır. En kararlı nicelik üç protokollü eğimdir ($0{,}661$ ile $0{,}673$).

1) Ham oranın ne kadarı hedefin temiz hatası?: Karıştırıcıyı nicelemek için analizi, WideResNet-28-10 referansını hem kaynak hem hedef olarak ekleyerek 3×3 matrise genişletiyoruz (Tablo IV). İki oran arasındaki ilişki bir korelasyondan daha güçlü çıkmaktadır: tek bir olgusal öncüle dayanan bir *özdeşliktir*.

Hedefin temiz hatasına e, koşulsuz orana r_{ham} ve hedef doğru koşullu orana $r_{\text{koş}}$ diyelim. Hedefin temiz girdide zaten yanlış sınıflandırdığı bir örnek pertürbasyondan sonra da yanlış kalıyorsa $r_{\text{ham}} = e + r_{\text{koş}}(1 - e)$ olur ve dolayısıyla

$$r_{\text{ham}} - r_{\text{koş}} = e\,(1 - r_{\text{koş}}). \tag{11}$$

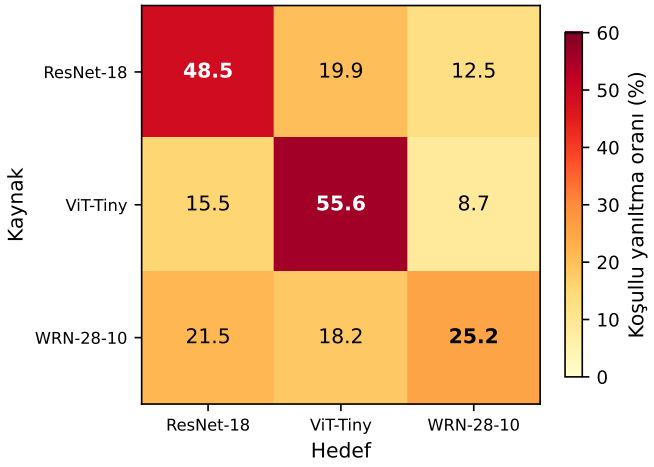
Ölçülen kısım öncüldür ve sıkı biçimde tutmaktadır: 36 köşegen dışı yönde (iki veri kümesi, üç tohum çifti, üç hedef, iki kaynak) temiz girdide yanlış sınıflandırılan bir örneğin saldırı altında da yanlış kalma olasılığı $0{,}989$ ile $1{,}000$ arasındadır. Denklem (11) bunun sonucunda ölçülen her koşulsuz oranı $0{,}41$ puandan küçük bir hatayla yeniden üretmektedir; ortalama mutlak artık $0{,}095$ puandır ve artık, açıklanan sapmanın en çok $\%1{,}39$'unu oluşturmaktadır.

Koşulsuz oranın koşullu orandan sapması dolayısıyla, yarım puanın altında bir artık dışında, $(1 - r_{\text{koş}})$ ile ölçeklenmiş hedef temiz hatasının kendisidir. Koşulsuz transfer oranları, üç hedefte rastlantısal olarak gözlediğimiz bir düzenlilik olarak değil, *yapısı gereği* ve öncülü sağlayan her çalışmada hedef zayıflığıyla kirlenmektedir. Öncülün kendisi ölçülebilir bir niceliktir. Temizde yanlış sınıflandırılan bir örneğin saldırı altında yanlış kalma olasılığına p dersek genel biçim $r_{\text{ham}} = e\,p + r_{\text{koş}}\,(1 - e)$ olur ve $p = 1$ olduğunda Denklem (11)'e indirgenir. $p < 1$ olduğunda Denklem (11) sapmayı tam olarak $e\,(1 - p)$ kadar abartır; yani öncül sağlanmadığında bir eşitlik değil bir üst sınırdır. Çekişmeli eğitilmiş hedeflerde p değerini $0{,}989$ ile $1{,}000$ arasında ölçüyoruz; düzeltme orada puanın onda birkaçı kadar bir hatayla kesindir. Transfer çalışmalarının çoğunun saldırdığı standart eğitilmiş hedeflerde ise düzeltme öncesi koşumlarımızda p değerini $0{,}88$'e kadar inerken gözlemledik; mertebe göstergesi olan bu değer mevcut boru hattının bir ölçümü değildir ve orada özdeşlik bir üst sınırdır. Cebirin kendisi yeni değildir. Bir kaynak-hedef çifti yerine tek bir model üzerine yazıldığında $r_{\text{ham}} = e + r_{\text{koş}}(1 - e)$, TRADES'in [17] doğal-artı-sınır ayrıştırmasıdır; orada bizim p'mize karşılık gelen öncül tanım gereği sağlanır, çünkü sınır terimi tedirginlik komşuluğu üzerinde bir varlık niceleyicisiyle tanımlanmıştır. Burada yeni olan, transfer ortamında öncülün tanımsal olmamasıdır: kaynakta üretilmiş sabit bir tedirginlik hedefin temiz hatasını ya korur ya korumaz, dolayısıyla p ölçülmesi gereken görgül bir nicelik haline gelir. Aynı sonuç bir korelasyon olarak ifade edilse ($r = 0{,}997$) eksik anlatılmış olurdu: bir niceliğin kendi baskın bileşeniyle bire yakın korelasyonu aritmetiktir ve özdeşlik yazıldığında böyle bir korelasyonun gerektirdiği küçük örneklem uyarısına gerek kalmaz.

Veri kümesine özgü kalan şey mekanizma değil orantı çarpanıdır. $(1 - r_{\text{koş}})$ saldırının ne kadar transfer edilebilir olduğuna bağlı olduğundan, uydurulan eğim CIFAR-10'da hedef hatasının puanı başına $0{,}762$, CIFAR-100'de $0{,}656$ puandır. Eğim bir sabit değil, ölçülen hedefler üzerinden bir

Tablo IV: 3×3 transfer matrisi (PGD-10, ϵ=8/255, tam test; üç tohum çifti üzerinden ortalama±std; WideResNet satır ve sütunu tek harici kontrol noktasını kullanır). Ham = koşulsuz yanıltma oranı, Koş. = hedef doğru koşullu oran. Köşegen girdileri beyaz kutu saldırılardır.

Kaynak	Hedef	Ham (%)	Koş. (%)
ResNet-18 AT	ResNet-18 AT	55,84±0,53	48,52±0,84
ResNet-18 AT	ViT-Tiny AT	41,07±0,58	19,93±0,20
ResNet-18 AT	WRN-28-10	21,69±0,09	12,48±0,10
ViT-Tiny AT	ResNet-18 AT	27,45±0,34	15,52±0,64
ViT-Tiny AT	ViT-Tiny AT	67,34±0,18	55,57±0,44
ViT-Tiny AT	WRN-28-10	18,25±0,12	8,65±0,14
WRN-28-10	ResNet-18 AT	32,63±0,14	21,48±0,31
WRN-28-10	ViT-Tiny AT	39,73±0,25	18,15±0,28
WRN-28-10	WRN-28-10	33,03	25,16



Şekil 4: Koşullu (hedef doğru) transfer yanıltma oranları; üç tohum çifti ortalaması. Bu protokol altında köşegen dışı asimetri $+4{,}4$ puandır; Tablo III, aynı büyüklüğün diğer protokoller altında ne kadar hareket ettiğini gösterir.

ortalamadır ve özdeşlik başka model havuzlarına her uygulandığında yeniden kestirilmelidir. Koşulsuz transfer oranları bu yüzden mimariler arası transfer edilebilirliği ölçmez; transfer edilebilirlik artı hedefin temiz zayıflığını, Denklem (11)'in açıkça gösterdiği bir oranda ölçer.

Koşullanmış matris Şekil 4'te verilmektedir. Üçüncü mimari, asimetrinin kendisini de yeniden çerçevelemektedir. İki yabancı kaynak üzerinden ortalandığında gelen koşullu transfer ResNet hedefi için %18,50, ViT hedefi için %19,04 ve WideResNet hedefi için %10,57'dir; bu, her hedefin kendi beyaz kutu koşullu yanıltma oranını (48,52, 55,57 ve %25,16) üç hedef üzerinde $r = 0{,}986$ ile izler. Bu kanıta göre CNN→ViT üstünlüğü, CNN'de üretilen pertürbasyonların içkin olarak daha transfer edilebilir olduğunun değil, daha zayıf hedefin bir özelliği olarak okunmalıdır: en gürbüz hedef, iki aileden gelen saldırıları neredeyse eşit ölçüde soğurmaktadır. Yalnızca üç hedefle bu korelasyon ancak yönlendirici olabilir.

C. Protokol Etkisi Genelleniyor mu? İkinci Bir Veri Kümesi

Yukarıdaki ölçüm tek bir veri kümesi üzerinde yapılmıştır ve yalnızca CIFAR-10'da var olan bir protokol etkisi genel

Tablo V: CIFAR-100 yinelemesi (mimari başına üç bağımsız eğitim koşusunun ortalaması±std, tam test kümesi, ϵ=8/255). Her iki model de Bölüm III-E'deki protokolle çekişmeli eğitilmiştir. Mutlak gürbüzlük iki mimaride de CIFAR-10'a göre düşüktür ve CNN'in ViT üzerindeki sıralaması değişmemiştir.

Model	Temiz (%)	PGD-10 (%)	AutoAttack (%)
ResNet-18 AT	63,86±1,05	19,30±0,32	15,04±0,54
ViT-Tiny AT	43,17±1,10	11,15±0,60	8,87±0,83

bir raporlama önerisini desteklemezdi. Bu nedenle tasarımın tamamını CIFAR-100 üzerinde yineledik: aynı mimariler, aynı tehdit modeli, aynı saldırı bütçesi, aynı üç tohumlu yapı, aynı dört protokol. Üç yönsel ön kestirim ile üç uç nokta bandı, bu veri kümesinden herhangi bir ölçüm mevcut olmadan önce salt eklemeli bir belgeye kaydedildi; böylece sonuç, ölçüldükten sonra yeniden yorumlanamazdı. Kayıt, eğitimin başlangıcından önce gelmemektedir; kayıt işlemesi, sayı bildiren ilk adımdan, epok 5'teki pilot kapısından altmış altı dakika öncedir.

Aynı dört protokol boyunca ölçülen CNN→ViT asimetrisi $+4{,}96 \pm 1{,}01$ puandan (hedef doğru) $+18{,}53 \pm 0{,}71$ puana (koşulsuz) uzanmakta; her ikisi doğru protokolünde $+10{,}92 \pm 0{,}34$, başarılı kaynak protokolünde $+17{,}50 \pm 0{,}92$ puandır. Tohum başına ortalama yayılım $13{,}83 \pm 1{,}30$ puandır; CIFAR-10'da bu değer $15{,}01 \pm 0{,}84$ olduğuna göre daha zor veri kümesi protokol etkisini aynı aralıkta bırakmakta, CIFAR-10 değerinin bir miktar altında tutmaktadır. Yön, CIFAR-10'da olduğu gibi on iki ölçümün tamamında pozitiftir (dört protokol $\times$ üç tohum çifti). Her ikisi doğru protokolünde eşleştirilmiş fark $10{,}92$ puandır. CIFAR-10'da olduğu gibi, verilen $[9{,}47;\ 12{,}35]$ aralığı üç tohumun kendi bootstrap uçlarının ortalamasıdır, kapsama garantisi olan bir aralık değildir; mimarilere dair bir iddiayla eşleşen koşumlar-arası t aralığı $[10{,}07;\ 11{,}77]$'dir. İşaret çevirme permütasyon p değeri her tohumda $20{,}000$ permütasyonun çözünürlüğünün altındadır ve TOST sınanan hiçbir marjda eşdeğerliği kuramamaktadır.

Üç ön kestirimin biri doğrulanmış, biri bağlayıcı saydığımız okumada tutmamış, üçüncüsü ise bu tasarımda sınanamamıştır. İşaretin korunacağı ön kestirimi doğrulanmıştır $(12/12)$. Protokol yayılımının daha zor veri kümesinde büyüyeceği ön kestirimi, CIFAR-10 yayılımına karşı bir karşılaştırma olarak kaydedilmiş ve o tarihte bu değer $10{,}45$ puan diye anılmıştı. Bu sayısal eşiğe karşı kestirim tutmaktadır $(13{,}83 > 10{,}45)$; Bölüm IV-B'in başarılı kaynak tanımı altında CIFAR-10 yayılımının bugünkü değerine karşı ise tutmamaktadır $(13{,}83 < 15{,}01)$. Kaydın adlandırdığı şey sayı değil CIFAR-10 yayılımı olduğundan bunu bir başarısızlık sayıyoruz. İki veri kümesi protokol etkisini zorluğa göre sıralamak yerine aynı aralığa yerleştirmektedir; yani önerdiğimiz mekanizma etkinin büyüklüğünü öngörmekte, bu iki veri kümesi arasındaki sıralamasını öngörmemektedir. Üçüncüsü, koşulsuz oranın koşullu orandan sapmasının hedefin temiz hatasıyla birlikte büyüyeceğini öngörüyordu. Ölçülen eğim, öngörüldüğü gibi pozitiftir: hedef hatasının puanı başına $+0{,}656$ puan. Ancak CIFAR-100'de üç hedeften ikisinin temiz hatası yalnızca $0{,}21$ puan farklıdır (36,15 ve 36,36); dolayısıyla korelasyon üç

değil *iki* etkin küme üzerinden hesaplanmakta ve değeri (altı yön üzerinde $r = 0{,}931$, hedef düzeyinde $0{,}974$) iki noktalı bir karşıtlığa dayanmaktadır. Ölçüm ön kestirimi *sınamadan* onunla *tutarlıdır* ve üçüncü bir doğrulama sayılmaz.

Kayıtlı uç noktalardan biri tutmamıştır: çekişmeli eğitilmiş ViT için temiz doğruluğu $\%33$ ile 40 bandında öngörmüş, $\%43{,}17 \pm 1{,}10$ ölçtük. Band, çekişmeli eğitimin temiz doğruluk bedelinin iki mimaride aynı oranda ölçekleneceği varsayımıyla türetilmişti. Ölçekleşmiyor: ViT çekişmeli eğitim altında temiz ön eğitim doğruluğunun $0{,}885$'ini korurken ResNet $0{,}802$'sini korumuştur. Protokol iddiasının dayandığı iki çekişmeli uç nokta ise bantlarının içinde kalmıştır (PGD-10 öngörü $\%10$ ile 14, ölçüm $11{,}15$; AutoAttack öngörü $\%8$ ile 11, ölçüm $8{,}87$).

Koşullama, paydaya hangi örneklerin gireceğini değiştirdiği için sınıf karışımını da değiştirir; dolayısıyla bir asimetri ilkece bileşim artefaktı olabilir, ama değildir. Her yönün oranını bir bileşim bileşenine ve bir oran bileşenine ayrıştırıyoruz. Hedef doğru protokolünde bileşim etkisi üç tohum çiftinde $-1{,}249$, $-1{,}330$ ve $-1{,}065$ puandır; yani asimetrinin $\%17{,}4$ ile 29,7'si kadar ve *negatiftir*: sınıf karışımı dengelenseydi asimetri küçülmez, büyürdü. Başarılı kaynak protokolünde etki küçüktür ve üç tohumun üçünde de pozitiftir ($+0{,}527$, $+0{,}435$ ve $+0{,}382$ puan; asimetrinin $\%2{,}1$ ile 3,1'i kadar). Koşulsuz ve her ikisi doğru protokollerinde tam olarak sıfırdır; bu, ayrıştırmanın geçmesi gereken aritmetik sağlama testidir.

Sonucun iki nitelemesi vardır; birincisi, iki çekişmeli bandın en yakın tohum düzeyi kenarında $0{,}22$ puanlık (AutoAttack) ve $0{,}48$ puanlık (PGD-10) marjlarla tutmuştur. Bu marjlar, *aynı veri kümesindeki* kontrol noktası seçimi gürültüsünden küçüktür: eğitim koşusu sabit tutulup CIFAR-100 yörüngelerinde erken durdurma sabrı ile eğri yumuşatması tarandığında raporlanan PGD-10 doğruluğu $0{,}18$ ile $1{,}83$ puan arasında oynamaktadır (ortalama $0{,}86$). Aynı dokuz hücreli tarama CIFAR-10'da doğrulama bölmesi başına $0{,}54$ ile $2{,}83$ puan vermekte; Bölüm IV-I'te anılan on sekiz hücreli değer ise daha da büyüktür, çünkü bölmeyi de değiştirmektedir ve CIFAR-100 protokolünde o boyut yoktur. Bantlar tutmuştur, ama kaydedildikleri veri kümesinin seçim gürültüsüne eşit ya da ondan küçük marjlarla. İkincisi, çekişmeli eğitilmiş kontrol noktasını seçmekte kullanılan doğrulama bölmesi, temiz ön eğitimde de kullanılmış olan bölmedir. Tercih, iki veri kümesi karşılaştırılabilir kalsın diye CIFAR-10 protokolünden devralınmıştır ve Bölüm IV-I bunun neye mal olup neye mal olmadığını raporlamaktadır.

D. Mimarilerin Eşitlendiği Üçüncü Bir Veri Kümesi

CIFAR-10 ve CIFAR-100, iki mimariyi temiz doğrulukta birbirinden hayli uzağa yerleştirmektedir (yaklaşık 12 ve 21 puan). SVHN [62] öyle değildir (karşılaştırma için CIFAR-100 mutlak değerleri Tablo V'te verilmektedir): aynı tarifle çekişmeli eğitildiklerinde ResNet $\%94{,}27 \pm 0{,}70$, ViT $\%92{,}42 \pm 0{,}56$ temiz doğruluğa ulaşmakta, yani fark $1{,}85$ puanda kalmaktadır. PGD-10 altındaki gürbüz doğruluklar $55{,}52 \pm 0{,}64$ ve $52{,}30 \pm 0{,}10$'dur. Açıklamamız en özgül öngörüsünü bu rejim için yapar ve bu öngörü CIFAR sonuçlarına ters düşer: temiz doğruluk farkı neredeyse kapandığında yönün kendisi protokole bağlı hale gelmelidir.

Tablo VI: SVHN'de dört protokol altında transfer asimetrisi (PGD-10, ϵ=8/255, tam test kümesi n=26.032; iki tohum çiftinin ortalaması$\pm$std; yalnız iki mimari olduğu için üçüncü mimari kontrolü yoktur). CIFAR-10 ve CIFAR-100'den farklı olarak işaret dört satırda aynı değildir.

Protokol	**CNN→ViT**	**ViT→CNN**	**Fark**
Koşulsuz (ham)	31,89	31,49	$+0{,}39 \pm 0{,}08$
Hedef doğru	26,32	27,33	$-1{,}00 \pm 0{,}22$
Her ikisi doğru	25,36	25,70	$-0{,}35 \pm 0{,}01$
Başarılı kaynak	61,38	58,69	$+2{,}70 \pm 0{,}40$

Mimariler eşitlendiğinde işarete protokol karar vermektedir. Dört protokolün ikisi CNN üstünlüğü, ikisi ViT üstünlüğü bildirmektedir (Tablo VI). Yönlü iddialar için benimsediğimiz iki protokol, hedef doğru ile her ikisi doğru, birbiriyle uyuşmakta ve ikisi de ViT lehine çıkmaktadır; işaret değişimi bunları koşulsuz orandan ve başarılı kaynak oranından ayırmaktadır. Koşulsuz orandaki çevrilme Denklem (11)'den aritmetik olarak çıkar: burada ViT hedefinin temiz hatası CNN'inkini yaklaşık iki puan aşmaktadır ve bu, $-1{,}00$'lik koşullu farkı $+0{,}39$'luk ham farka taşımaya yetmektedir. Dolayısıyla ham oran raporlamak yayımlanmış bir karşılaştırmanın işaretini çevirebilir ve özdeşlik bunun ne zaman olacağını önceden söylemektedir. İki yönü özdeş örnekler üzerinde puanladığı için birincil saydığımız her ikisi doğru protokolünde fark $-0{,}35$ puandır; işaret çevirme permütasyon p değeri $0{,}105$ ve TOST eşdeğerliği, denediğimiz en dar marj dahil (± 1 puan, $p = 0{,}0007$) üç marjın üçünde de *kabul edilmektedir*. Kabul bir niteleme gerektirir. SVHN iki tohum çiftiyle koşulmuştur, dolayısıyla verilen $[-0{,}76;\ +0{,}07]$ aralığı iki tohumun bootstrap uçlarının ortalamasıdır ve koşumlar-arası bir aralık mevcut değildir: iki koşumla koşumlar-arası standart sapma tek bir karşıtlıktan kestirilir ve bilgi taşımaz. Eşdeğerlik bu yüzden koşum-içi karşılaştırmaya ve iki koşumun yakın uyuşmasına ($-0{,}34$ ve $-0{,}36$) dayanmaktadır; iki koşum koşumlar-arası değişimi sınırlayamaz. Yalnızca başarılı kaynak oranını raporlayan bir çalışma SVHN'de $2{,}70$ puanlık bir CNN üstünlüğü duyururdu; yalnızca hedef doğru oranını raporlayan bir çalışma ise $1{,}00$ puanlık bir ViT üstünlüğü.

SVHN'deki davranış mekanizmayla tutarlıdır. SVHN'de protokol yayılımı $3{,}70 \pm 0{,}62$ puandır; CIFAR-10'da $15{,}01 \pm 0{,}84$, CIFAR-100'de $13{,}83 \pm 1{,}30$ puandır; temiz doğruluk farkları ise sırasıyla $1{,}85$, ≈ 12 ve ≈ 21 puandır. İlişki üçü arasında tekdüze değildir: en büyük fark en büyük yayılımı vermemekte, CIFAR-100 CIFAR-10'un bir miktar altında kalmaktadır. Veri kümelerini burada ayıran şey eşitlenmeye yakın çifttir. Yayılım yeterince küçüldüğünde ise asimetrinin kendisini aşamamakta ve işaret, mimarilerin değil protokolün bir özelliği haline gelmektedir. Bölüm IV-B'de kararlı diye raporladığımız yön, *iki modelin temiz doğrulukta ayrıştığı rejimde* kararlıdır ve her iki CIFAR veri kümesi de o rejimde bulunmaktadır.

SVHN, önceden sabitlenmiş indirgenmiş bir yapılandırmayla koşulmuştur: üç yerine iki tohum çifti, 50 epok çekişmeli eğitim, AutoAttack yok ve üçüncü mimari yok. Sonuncusu, Bölüm IV-B1'teki 3×3 karıştırıcı kontrolünün burada kurulamayacağı anlamına gelir ve onun SVHN içi bir sürü-

Tablo VII: Aynı kontrol noktaları, L_2 bütçesi (ϵ=0,5; üç tohum çiftinin ortalaması±std). PGD-L2 tam test kümesini, AutoAttack-L2 ise ön kayıtlı 5.000 örneklik bir altkümeyi kullanır; bu yüzden temiz sütunu tam küme değerinden bir miktar farklıdır ve ikisi aynı örneklerden gelmez.

Model	Temiz	PGD-L2	Temiz (5k)	AA-L2
ResNet-18 AT	85,78	63,78±0,38	85,33	60,61±0,42
ViT-Tiny AT	73,53	51,72±0,23	73,61	49,85±0,20

münü kurmuyoruz.

E. Protokol Etkisi Tehdit Modeli Değişince Ayakta Kalıyor mu?

Buraya kadarki her ölçüm tek bir tehdit modelinin içinde yapılmıştır. Protokol etkisinin L_∞'ye özgü bir artefakt olup olmadığını sınamak için aynı CIFAR-10 kontrol noktalarını $\epsilon = 0{,}5$'lik bir L_2 bütçesi altında yeniden değerlendirdik ve üç yönsel ön kestirimi, herhangi bir L_2 çıktısına bakmadan önce kaydettik. Modeller L_∞ ile eğitilmiştir; dolayısıyla bu ölçüm L_2 gürbüzlüğünü değil, protokolün sonucu nasıl etkilediğini yoklamakta ve aşağıdaki mutlak değerler L_2 ile eğitilmiş referanslarla karşılaştırılamamaktadır.

Norm değişince protokol yayılımı $10{,}92$ puana küçülmekte (L_∞ altında $15{,}01$), ama hem ön kayıtın koyduğu iki puanlık tabanın hem de koşumlar arası standart sapmanın çok üstünde kalmakta ve işaret on iki ölçümün tamamında pozitif çıkmaktadır; kayıtlı ilk iki ön kestirim böylece tutmaktadır. Üçüncü kestirim, koşulsuz oranın koşullu orandan sapmasının hedefin temiz hatasıyla artacağı, Denklem (11) sağlandığı sürece yanlışlanamaz: sapma zaten $e\,(1 - r_{\text{koş}})$'dir, dolayısıyla e ile yapısı gereği artar ve uydurulan $+0{,}914$ eğimi bir şeyi sınamak yerine $1 - r_{\text{koş}}$'u kestirmektedir. Her durumda korelasyon yerine eğimi raporluyoruz, çünkü on sekiz yön yalnızca yedi ayrık hedef hatası değeri almakta, bunların altısı aynı sabit WideResNet'ten gelmektedir. Ön kestirim özdeşlik yazılmadan önce kaydedilmişti ve şimdi özdeşliğin örneklem dışı bir sınaması işlevini görmektedir; ön kestirim Bölüm IV-C'te de aynı konumdadır. Dört protokolün (Tablo VII) bildirdiği asimetriler $+13{,}03 \pm 0{,}81$ (koşulsuz), $+2{,}12 \pm 0{,}18$ (hedef doğru), $+4{,}07 \pm 0{,}36$ (her ikisi doğru) ve $+12{,}06 \pm 0{,}23$ (başarılı kaynak) şeklindedir. Mutlak gürbüzlük her iki saldırı altında da CNN'in ViT üzerindeki sıralamasını korumakta, McNemar $p < 10^{-57}$ her tohum çiftinde sağlanmaktadır.

Ölçülen eğim özdeşliğin öngördüğü değerle uyuşur. Koşullu oranlar bu L_2 bütçesi altında L_∞'dekinden çok daha düşüktür (kabaca $\%2$ ile 9'a karşı $\%9$ ile 22), dolayısıyla özdeşlik *daha dik* bir eğim öngörür; ölçülen $0{,}914$ tam da olması gereken yerdedir; aynı modellerde L_∞ altında bu değer $0{,}762$ idi. Orantı çarpanı, Bölüm IV-B1'te belirtildiği gibi saldırı bütçesine bağlıdır.

F. Gradyan Karakteristikleri

Girdi duyarlılığındaki mimari farkları betimlemek için, iki mimarinin gradyan özelliklerini, ana ViT hattımızdaki $32 \to 224$ büyütmenin etkisini yalıtan CIFAR'a özgü bir ViT kontrolüyle (32×32 girdi, 4×4 yama, büyütme yok; aynı çekişmeli amaç işleviyle, ancak Bölüm III-E'te anlatılan sabit bölme protokolü benimsenmeden önce eğitilmiş) birlikte analiz ediyoruz. Tablo VIII, ölçekten bağımsız seyreklik ölçüleriyle (Bölüm III-F) temel istatistikleri özetler; gradyanlar, normlar değerlendirme parti boyuna bağlı olmasın diye örnek başına kayıplarla hesaplanır. Oradaki hizalanma, tüm $500 \times 499/2$ örnek çifti üzerindeki ortalama mutlak kosinüs benzerliğidir ve ölçekten bağımsız seyreklik metriklerindeki her ResNet ile ViT farkı, her koşuda örnek başına eşleştirilmiş Wilcoxon testlerinde anlamlıdır.

Tablo VIII: Örnek başına kayıp gradyanlarından hesaplanan gradyan karakteristikleri (koşu başına n=500 test örneği; üç koşu üzerinden ortalama±std).

Metrik	ResNet-18 AT	ViT-Tiny AT	ViT (yerel)‡
Hoyer seyrekliği	**0,4928**±0,0120	0,4561±0,0055	0,405
Gini katsayısı	**0,6498**±0,0089	0,6099±0,0051	0,571
Maks. %1 altı kesir	**%34,8**±2,1	%26,8±0,9	%17,9
Hizalanma (mutlak)	0,0378±0,0009	**0,0562**±0,0004	0,079
Hizalanma (işaretli)	0,0014	0,0005	–

‡CIFAR'a özgü ViT kontrolü (4×4 yama, büyütme yok; 5,4M parametre); sabit bölme protokolünden önceye ait, test kümesinde seçilmiş tek kontrol noktası; yalnızca büyütme etkisinin işareti için eklenmiştir, nicel karşılaştırma için değil.

Üç ölçekten bağımsız seyreklik ölçüsünün üçünde de CNN gradyanları ViT gradyanlarından daha seyrektir ve sıralama, tohum düzeyi standart sapmaları farktan en az üç kat küçük kalarak her koşuda yeniden üretilmektedir. İki çıkarım birimimizin uyuşmadığı tek yer burasıdır, bu yüzden ikisini de raporluyoruz. Koşum içinde, aynı 500 örnek iki modelde de ölçüldüğünde, örnek başına eşleştirilmiş testler üç ölçüde de üç koşuda da sıfır hipotezini reddetmektedir (Wilcoxon işaretli sıra, baştan sona Holm düzeltmeli $p < 10^{-11}$; eşleştirilmiş Cohen d 0,32 ile 1,23 arasında); bu, bu kontrol noktalarının bu görüntülerde farklı olduğunu kurar. Mimari bir iddianın gerektirdiği ve Tablo IX'in kullandığı koşum düzeyinde ise üç eşleştirilmiş koşum Gini, %1 altı kesir ve Hoyer için sırasıyla $0{,}036$, $0{,}042$ ve $0{,}067$ ham p değeri vermekte, üç ölçü üzerinden Holm düzeltmesi bunları $0{,}108$'e çıkarmaktadır. Sıralama üç koşumun üçünde ve her ölçüde tutarlıdır ve açıklık koşumlar arası standart sapmanın birkaç katıdır; ancak üç koşumla, üç ölçünün neredeyse eşdoğrusal olması nedeniyle burada tutucu kalan bir düzeltmeden sonra $\alpha = 0{,}05$ eşiğini geçmemektedir. Bu nedenle seyreklik sonucunu anlamlı değil yeniden üretilebilir olarak raporluyoruz. Aşağıdaki hizalanma farkı koşum düzeyinde anlamlılığa ulaşmaktadır ($p = 0{,}0009$) ve tartışmaya bu temelde taşıdığımız gradyan sonucu odur. Sıralama mimarinin değil çekişmeli eğitimin ürünüdür: aynı koşuların temiz eğitilmiş karşılıklarında daha seyrek model *ViT'tir* (Hoyer $0{,}380 \pm 0{,}009$'a karşı $0{,}347 \pm 0{,}002$); yani çekişmeli eğitim CNN gradyanlarını çok daha güçlü seyrekleştirmektedir; bu, Chalasani vd.'nin [28] çekişmeli eğitilmiş modeller için bildirdiği daha seyrek öznitelik atıflarıyla uyumludur. Yerel çözünürlüklü ViT kontrolü her ölçüde büyütülmüş ViT'ten daha az seyrektir; dolayısıyla sıralama $32 \to 224$ büyütmenin artefaktı değildir. Örnekler arası hizalanma ViT'te mutlak kosinüste daha yüksektir ve temiz eğitilmiş çift bu farkı zaten göstermektedir ($0{,}058$'e karşı $0{,}029$); dolayısıyla bu fark mimariden gelir ve savunmadan önce de vardır. ***İşaretli***

Tablo IX: Girdi gradyanlarının mekansal lokalitesi (koşu başına n=500 örnek; üç koşu üzerinden ortalama±std). Eşleştirilmiş farklar aynı örnekler üzerinde hesaplanır. Çıkarım koşum düzeyindedir: p, üç koşumun ortalama farkları üzerinde tek örneklem t testidir ve dört ölçüye Holm düzeltmesi uygulanmıştır; böylece çıkarımın birimi iddianın birimiyle eşleşir. Düşük alan ve entropi daha lokalize, yüksek Moran's I daha kümeli demektir.

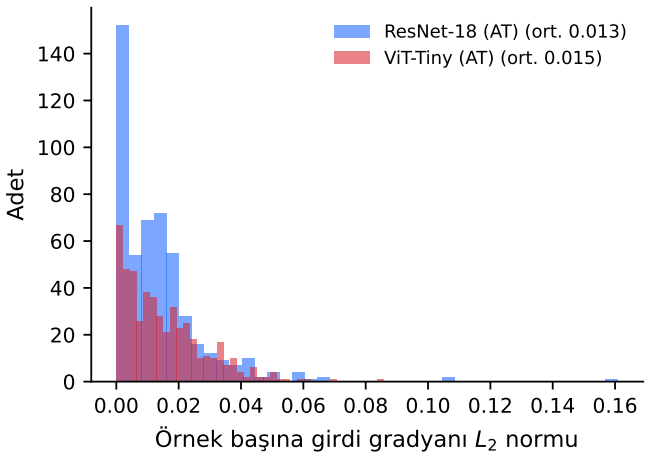
Ölçüt	ResNet-18	ViT-Tiny	Fark	p
%50 enerji alanı	0,0378±0,0017	0,0397±0,0010	−0,0019	0,54
%90 enerji alanı	0,2345±0,0078	0,2570±0,0067	−0,0224	0,40
Mekansal entropi (nat)	5,2014±0,0387	5,2524±0,0197	−0,0509	0,54
Moran's I	0,4141±0,0132	0,3941±0,0024	+0,0200	0,47

ortalama kosinüs ise iki modelde de sıfıra yakındır ($\leq 0{,}0014$): örnekler duyarlılık eksenlerini paylaşır ama tutarlı bir yönü paylaşmaz; dolayısıyla hizalanma farkı ucuz evrensel pertürbasyonlar için kanıt sayılamaz.

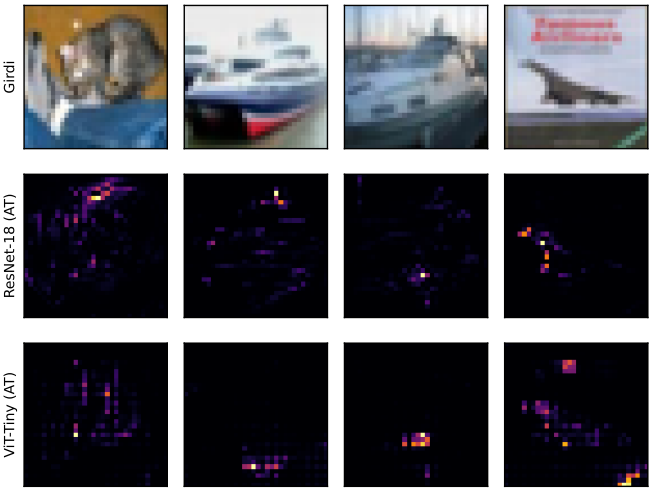
Bu gradyan sonuçları, analizimizin hangi kontrol noktası kümesinin kullanıldığına duyarsız olan tek parçasıdır: Tablo VIII'teki her büyüklük, önceki tek koşuluk kontrol noktalarında ölçülen *sıralamayı* yeniden üretmektedir; sekiz niceliğin altısında değerin kendisi buradaki tohum düzeyi standart sapmadan fazla oynasa da hiçbir gradyan yapısı farkı işaret değiştirmemektedir; Bölüm IV-A'in koşullu ayrıştırmasının aksine.

1) Seyreklik mekansal lokalite değildir: Seyreklik ölçüleri kaç gradyan bileşeninin büyük olduğunu yanıtlar; bu bileşenlerin görüntüde bir arada durup durmadığını değil. Ayrım önemlidir; çünkü daha-seyrek-CNN sonucu mekansal bir okumaya davet çıkarır; gradyanların nesne bölgelerinde daha "lokalize" ya da "yoğunlaşmış" olduğu düşünülür. Okuma belirli bir çalışmaya bağlı değildir; bir seyreklik sonucunun doğal yorumudur ve kendi önceki şekillerimiz de onu teşvik etmişti. Okumayı aynı gradyanlar üzerinde, kanal toplamı enerji haritasının dört ölçekten bağımsız betimleyicisiyle doğrudan sınıyoruz: gradyan enerjisinin %50'sini ve %90'ını taşıyan en küçük piksel oranı, normalize enerji haritasının mekansal entropisi ve enerji bitişik piksellerde kümelendiğinde pozitif olan 4-komşuluklu Moran's I.

Sonuç negatiftir (Tablo IX). Dört ölçütün hiçbiri koşum düzeyinde anlamlı fark göstermez. En büyükleri olan, enerjinin %90'ını taşıyan alan, CNN için görüntü alanının iki puanı kadar *daha küçük* bir alana işaret eder ve düzeltmeden sonra ayakta kalmaz. Aynı birimde karşılaştırıldığında mekansal ölçüler seyreklik ölçülerinden daha az tutarlıdır da. Seyreklik sıralaması her koşuda ve her ölçüde tutarlıyken mekansal sıralama dört ölçünün ikisinde koşumlar boyunca kararlı değildir; üç koşumla iki aile de koşum düzeyi düzeltmesini geçemese bile bu fark önemlidir. Tek bir koşum içindeki örnek bazlı testler burada da çok daha küçük p değerlerine ulaşır, ama yalnızca iki sabit kontrol noktasının bu 500 görüntüde farklı olup olmadığını sorarlar. Komşuluk kümelenmesi iki mimaride esasen özdeştir. İki ölçü ailesi bu yüzden uyuşmamaktadır. Çekişmeli eğitilmiş CNN gradyanları kütlelerinin daha büyük kısmını daha az piksele yerleştirir, ama bu pikseller ViT'inkilerden mekansal olarak daha kümeli değildir. CNN



Şekil 5: İki mimaride örnek başına gradyan L_2 normlarının dağılımı. Aynı girdiler için enerji haritaları Şekil 6'te verilmektedir.



Şekil 6: Aynı girdiler üzerinde CNN ve ViT gradyan enerji haritalarının karşılaştırması. Farklar Tablo VIII'teki seyreklik ölçüleriyle nicelenir; Tablo IX, görünür yapının mekansal kümelenme farkına karşılık gelmediğini gösterir.

gradyanlarının mekansal olarak lokalize olduğu betimlemeleri ölçümlerimizce desteklenmemektedir; kendi iddialarımızı seyreklikle sınırlıyoruz.

Şekil 5, ölçekten bağımsız seyreklik ölçülerinin yakalamadığı örnek başına gradyan L_2 normlarının dağılımını ekler.

Şekil 6 karşılık gelen büyüklük haritalarını göstermektedir; altyazısında belirtildiği gibi bu haritalar lokaliteyi değil seyrekliği resmeder.

G. Görü Dönüştürücülerinde Öznitelik Kayması

Şimdi çekişmeli hasarın derinlik boyunca nerede biriktiğini ölçüyor, temiz eğitilmiş ViT'lerin katman bazlı temsil analizlerini [29] çekişmeli eğitilmiş ortama taşıyoruz. Ölçümdeki iki tasarım seçimi yanıtı etkilediğinden ikisini de değiştiriyoruz: örneklem boyutu (tek küçük parti yerine koşu başına

Tablo X: Her modelin kendi beyaz kutu PGD-10 saldırısı altında blok bazlı temizden çekişmeliye kosinüs benzerliği (koşu başına n=1000; üç koşu üzerinden ortalama±std). ViT sütunları yalnızca blok jetonlarının nasıl toplandığında ayrışır.

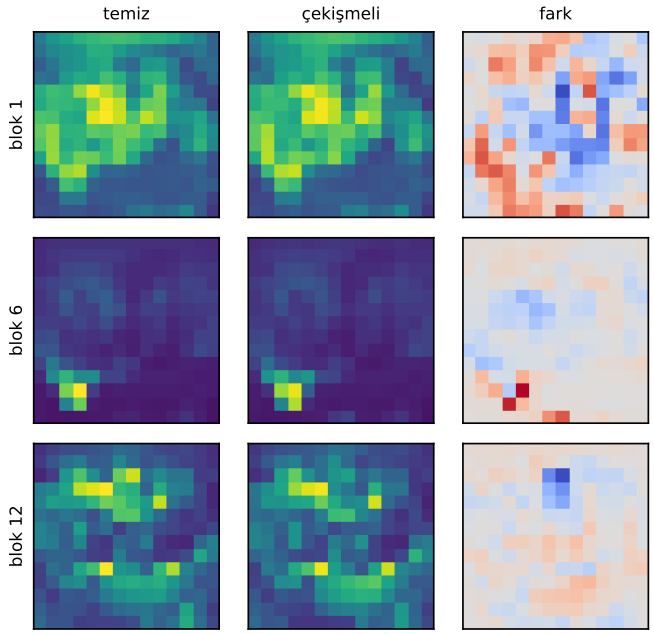
ViT-Tiny AT				ResNet-18 AT	
Blok	**CLS**	**Yama ort.**	**Tüm jetonlar**	**Blok**	**Kosinüs**
1	0,9993	0,9980	0,9927	layer1.0	0,9951
2	0,9950	0,9959	0,9901	layer1.1	0,9918
3	0,9902	0,9940	0,9881	layer2.0	0,9879
4	0,9873	0,9919	0,9861	layer2.1	0,9853
5	0,9845	0,9904	0,9847	layer3.0	0,9753
6	0,9814	0,9894	0,9835	layer3.1	0,9607
7	0,9782	0,9885	0,9826	layer4.0	**0,8777**
8	0,9743	0,9875	0,9816	layer4.1	0,9108
9	0,9703	**0,9870**	0,9809		
10	0,9661	0,9872	0,9805		
11	**0,9604**	0,9874	**0,9803**		
12	0,9663	0,9915	0,9837		

$n = 1000$) ve bir dönüştürücü bloğunu özetlemekte kullanılan jeton agregasyonu (Bölüm III-F).

Mimariler hasarın *birikip birikmediğinde* değil *nerede* biriktiğinde ayrışmaktadır. ViT'te kayma kademeli ve sığdır: benzerlik 11. bloktaki minimuma kadar tekdüze azalır ve çıkışta hafifçe toparlanır; öznitelik normları baştan sona temiz değerlerinin %0,45'i içinde kalır, yani pertürbasyon temsili yeniden ölçeklemek yerine döndürmektedir. CNN'de hasar yoğunlaşmıştır: ilk üç aşama az kaybeder, ardından son artık aşamanın ilk bloğu $-\%13{,}14 \pm 1{,}89$'luk norm daralmasıyla birlikte $0{,}8777 \pm 0{,}0181$'e çöker; son blok temsili kısmen onarır ($0{,}9108 \pm 0{,}0060$, norm $+\%5{,}84 \pm 3{,}53$). CNN'de çekişmeli hasar geç, yerel ve büyüklük değiştiren bir olaydır; ViT'te dağıtık, yalnızca yön değiştiren bir dönmedir. Önceki kontrol noktalarımızda CNN profili son bloğa dek monoton düşmüş, toparlanma göstermemişti; dolayısıyla ViT profilinin aksine CNN eğrisinin biçimi tarife bağlı okunmalıdır.

Agregasyon seçimi de ölçülen profili belirgin biçimde değiştirmektedir. Kendi minimumlarında CLS yolu, yama jetonu ortalamasının yaklaşık üç katı kadar kaymakta ($0{,}9604$'e karşı $0{,}9870$; $1 - \cos$ cinsinden oran $3{,}05$) ve iki özet minimumu farklı derinliklere yerleştirmektedir (blok 11'e karşı blok 9). Sınıflandırıcının okuduğu şey blok çıkışındaki CLS jetonu olduğundan bu farkın kendisi bir sonuçtur: pertürbasyon sınıflandırma yoluna yoğunlaşırken ortalama yama temsili görece korunmaktadır. Özetin alındığı tensör, en az agregasyon kadar önemlidir. Artık blok çıkışı yerine MLP alt-blok çıkışında okunduğunda aynı üç özet blok 10'da $0{,}9343$ CLS minimumu, blok 8'de $0{,}9840$ yama jetonu minimumu ve $4{,}12$ oranı vermektedir: kayma daha büyük görünmekte, derinlikler yer değiştirmekte ve alt blok, sınıflandırıcının okuduğu tensör olmamaktadır. Dolayısıyla farklı makalelerden katman bazlı kayma eğrileri, hem agregasyon hem de alındıkları tensör belirtilmedikçe karşılaştırılamaz.

Blok bazlı profiller Tablo X'te verilmektedir. Dikkat ölçümü negatiftir. Çekişmeli pertürbasyon, CLS dikkat dağılımının entropisini ölçülebilir biçimde değiştirmemektedir: koşu başına $n = 1000$ örnek üzerinde, katman başına ortalama entropi değişimi mutlak değerce en çok $0{,}005$ nattır (katman ortalamaları 4,9 nat civarındayken) ve tohum düzeyi standart

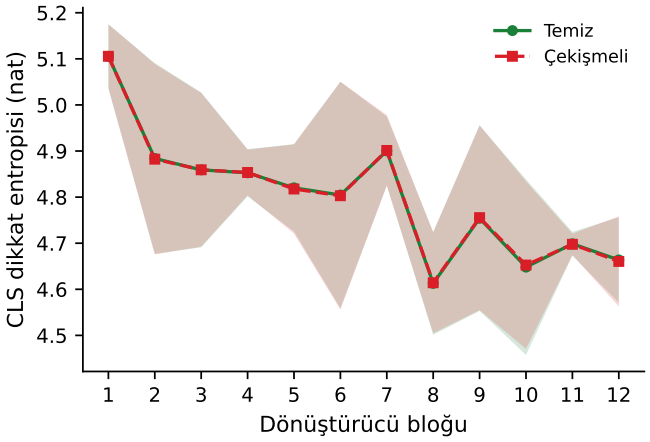


Şekil 7: Çekişmeli saldırı altında ViT katmanları boyunca CLS jetonu dikkat haritaları (softmax sonrası, başlar üzerinden ortalanmış). Her satır farklı bir katmanı (1, 6, 12) gösterir; sütunlar temiz dikkat, çekişmeli dikkat ve farklarıdır. Gösterilen tek bir örnektir; dikkat kaymasındaki derinlik eğilimi metinde koşum başına $n = 1000$ örnek üzerinden nicel olarak verilmektedir.

sapma aynı mertebededir. Bunu reddedememe olarak değil eşdeğerlik olarak ifade ediyoruz: katman ortalamasının yüzde biri olan ve veriden değil ölçünün ölçeğinden sabitlenen $\pm 0{,}05$ nat marjıyla TOST, on iki katmanın on ikisinde de eşdeğerliği kabul etmektedir; en zayıfı $p = 0{,}006$. Derinlikle büyüyen şey dikkat haritasının *yer değiştirmesidir*: ilk katmanda $0{,}028$ toplam varyasyondan son katmanda $0{,}084$'e çıkmaktadır; toplam varyasyon 1 ile sınırlı olduğundan mutlak olarak küçüktür. Saldırı dikkatı hafifçe yeniden yönlendirmekte, ama ne genişletmekte ne keskinleştirmektedir; Şekil 8 üst üste binen katman başına eğrileri vermektedir. Analizin 8 örneklik bir figür partisiyle hesaplanan önceki bir sürümü, daha büyük ölçümün desteklemediği görünür bir dikkat etkisi izlenimi vermişti; dolayısıyla çekişmeli saldırının dikkati bozduğuna dair her iddia, dile getirilmeden önce bu örneklem boyutunda sınanmalıdır.

Kayma büyüklüğü saldırı başarısını da öngörmemektedir. Örnekler, saldırının tahmini devirip devirmediğine göre bölündüğünde, ViT'te devrilen ve devrilmeyen örneklerin son blok kosinüs benzerliği istatistiksel olarak ayırt edilemezdir ($0{,}9895$'e karşı $0{,}9877$); CNN'de beklenen yönde küçük bir fark vardır ($0{,}9058$'e karşı $0{,}9143$). Öznitelik kayması, bu yüzden, temsilin nasıl hareket ettiğinin bir betimlemesidir; tahminin değişip değişmeyeceğinin yeterli istatistiği değildir.

Şekil 7, temsili bir örnek için 1., 6. ve 12. katmanlardaki CLS dikkat haritalarını görselleştirir. Yer değiştirme ölçümüyle uyumludur, çünkü geç katmanlar daha çok hareket eder; ancak bu türden tek örnekli paneller kolayca fazla yorumlanır: 1.000 örnek üzerindeki toplam entropi değişimi sıfırdır, yani görünür



Şekil 8: Temiz ve çekişmeli girdiler için CLS dikkat dağılımının katman başına entropisi; koşum başına $n = 1000$ örnek, üç koşum ortalaması ve ± 1 std bandı. Dikkat haritalarının kendisi Şekil 7'te verilmektedir.

farklar yayılmayı değil yeniden yönlendirmeyi yansıtır. Yama pertürbasyonları altındaki dikkat kayması etkileri [32] ve dikkat mekanizmasını doğrudan hedefleyen saldırılar [31], burada incelenen L_∞ sınırlı pertürbasyonlardan farklı bir rejimde işler.

Sondan bir önceki katmanın geometrisini de ölçüyoruz; bunu doğrudan özgün öznitelik uzayında yapıyoruz, çünkü düşük boyutlu bir gömme nitel aşırı yorumu davet ederdi (koşu başına n=500; beyaz kutu; üç koşu üzerinden ortalama$\pm$std). Saldırı, sınıf yapısını en güçlü biçimde *CNN'de* çökertmektedir: temizde eğitilmiş 5-NN etiket tutarlılığı $\%87{,}3 \pm 2{,}6$'dan $\%51{,}3 \pm 1{,}8$'e, siluet skoru $0{,}196 \pm 0{,}010$'dan $-0{,}032 \pm 0{,}004$'e iner ve göreli sınıf merkezi kayması $0{,}238 \pm 0{,}012$'ye karşı ViT'te $0{,}083 \pm 0{,}004$'tür; ViT'in uzayı temiz girdilerde bile zayıf sınıf ayrımı gösterir (siluet $-0{,}021 \pm 0{,}005$; 5-NN tutarlılığı $\%61{,}1 \pm 1{,}4$, saldırıda $\%48{,}5 \pm 1{,}4$). Toplu ölçüler açısından CNN'in iyi ayrışmış temiz öznitelik uzayı beyaz kutu saldırıyla ağır biçimde bozulurken ViT'in sınıf yapısı baştan daha zayıftır ve daha az hareket eder; bu, gürbüzlük hakkında değil geometri hakkında bir ifadedir, zira daha yüksek gürbüz doğruluğu yine de CNN korumaktadır.

H. ViT'e Özgü Bir Transfer Saldırısı Tabloyu Değiştiriyor mu?

Buraya kadarki tüm transfer sonuçları, ViT'i genel türevlenebilir bir model olarak ele alan gradyan saldırılarını kullanmaktadır. Doğal bir itiraz, dönüştürücü yapısı için tasarlanmış saldırıların daha iyi transfer ettiği bildirildiğinden, ViT yönünün bu seçim tarafından cezalandırıldığıdır. İtirazı, kaynak modelde geri yayılım sırasında dikkat, QKV ve MLP yollarındaki uç değerli jeton gradyanlarını bastıran Jeton Gradyanı Düzenlileştirme (TGR) [12] ile doğrudan test ediyoruz. Gerçeklememiz bir uyarlamadır: özgün yöntem standart eğitilmiş ImageNet ViT'lerini hedefler; biz aynı mekanizmayı CIFAR-10 ViT-Tiny sarmalayıcımıza, makale boyunca kullanılan bütçeyle uyguluyoruz (Bölüm III-C); eşleştirilmiş kontrol olarak aynı koşuda düz MI-FGSM üretilmektedir.

Tablo XI: Eşleşmiş bütçede TGR [12] ve düz MI-FGSM altında ViT$\rightarrow$CNN transferi (koşu başına n=10.000; üç koşu üzerinden ortalama$\pm$std).

Ölçüt (%)	**TGR**	**MI-FGSM**
Kaynakta beyaz kutu (ham)	51,56±0,80	**66,43**±0,29
Transfer, hedef doğru	12,70±0,41	**15,71**±0,60
Transfer, her ikisi doğru	7,93±0,42	**10,08**±0,30

TGR bu rejimde transferi iyileştirmemekte; kötüleştirmektedir (Tablo XI). Düzenlileştirme kaynak tarafında tasarlandığı gibi davranır ve 14,9 puanlık beyaz kutu gücünden vazgeçer; ancak bu takas hedefte karşılığını bulmaz: koşullu transfer hedef doğru protokolünde 3,0, her ikisi doğruda 2,2 puan düşer. Her-ikisi-doğru altkümesindeki eşleştirilmiş McNemar testleri her koşuda MI-FGSM lehinedir ($p = 6{,}1 \times 10^{-10}$, $1{,}1 \times 10^{-27}$, $7{,}0 \times 10^{-34}$); yani bu bir tohum etkisi değildir.

Kurulumumuz TGR'nin tasarlandığı kurulumdan, her biri önemli olabilecek üç noktada ayrılır: hedefler çekişmeli eğitilmiştir, TGR yerel ImageNet girdileri için kurulmuşken buradaki veri model içinde büyütülen 32×32 CIFAR-10 görüntüleridir ve kaynak 5,7M parametreli bir ViT-Tiny'dir. Destekleyebildiğimiz iddia, TGR'nin transfer üstünlüğünün bu rejime taşınmadığıdır; yöntemin daha genel olarak başarısız olup olmadığı bu deneyin gösterebileceklerinin ötesindedir. Bu makale açısından önemli sonuç şudur: Bölüm IV-B'te raporlanan CNN$\rightarrow$ViT asimetrisi, mimariden bağımsız saldırılar kullanmanın bir artefaktı değildir; ViT yönüne dönüştürücüye özgü bir saldırı vermek onu zayıflatmaktadır.

I. Varyans Kaynakları

Yukarıdaki karşılaştırmaları dört varyans kaynağı ilgilendirmektedir. Saldırı başlatma stokastisitesi ihmal edilebilirdir: PGD-10'u sabit 1.000 örneklik altkümede üç saldırı tohumuyla yeniden koşmak temiz doğruluğu hiç değiştirmez (yükleyici karıştırmaz) ve gürbüz doğruluğu CNN'de $0{,}05$, ViT'te $0{,}00$ puanlık standart sapmayla oynatır. Eğitim koşusu varyansı daha büyüktür ama yine küçüktür: mimari başına üç bağımsız koşuda, çekişmeli eğitilmiş çift için standart sapma temiz doğrulukta en çok $0{,}55$, PGD-10'da $0{,}50$ puandır (Tablo I).

Protokol etkisini doğrudan bu iki sayıyla karşılaştırmak bir ölçek hatası olurdu; çünkü protokol etkisi transfer asimetrisi üzerinde, yukarıdaki iki sayı ise mutlak doğruluk üzerinde ölçülmektedir. Bu nedenle protokol ve eğitim koşusu etkilerini *aynı* nicelik olan köşegen dışı asimetri üzerinde ve mutlak birimlerle niceliyoruz. Sabit bir tohum çiftinde yalnızca koşullama protokolünü değiştirmek asimetriyi $15{,}01 \pm 0{,}84$ puan oynatmaktadır. Bu değer tohum-başına açıklıkların ortalamasıdır; burada protokol ortalamalarının açıklığıyla çakışmakta, çünkü uç protokoller üç tohumun üçünde de aynıdır, CIFAR-100'de ise ayrışmaktadır ($13{,}83$'e karşı $13{,}58$), çünkü orada aynı değildir. Aynı asimetriyi, her iki mimariyi sıfırdan yeniden eğitmek ise yalnızca $0{,}23$ ile $1{,}27$ puanlık standart sapmayla oynatmaktadır; değer hangi protokol altında ölçüldüğüne bağlıdır (Tablo III, Fark sütunu). Makalenin dayandığı sıralama budur: on beş puanlık bir ölçüm etkisine karşı $1{,}5$ puanın altında bir eğitim etkisi.

Bu iki yayılımın oranını manşete koymuyoruz. Üç koşumla payda iki serbestlik derecesi taşır; dolayısıyla herhangi bir tek oran için χ^2 aralığı çok geniştir: başarılı-kaynak protokolünde oran $0{,}8$ ile $9{,}9$ arasında uzanır ve *birimi içerir*. Duyarlılık olarak raporlandığında oran, yayılım ölçüleri ve referans protokoller boyunca $5{,}2$ ile $32{,}6$ arasında değişmekte, birincil saydığımız her-ikisi-doğru protokolünde benzeri-benzeriyle karşılaştırmada $28{,}3$ olmaktadır. İki uyarı oranı daha da sınırlar: en büyük asimetriyi veren protokol aynı zamanda en büyük koşumlar arası standart sapmayı taşımakta, yani pay ile payda bağımsız olmamakta; ve üç koşum tek doğrulama bölmesini paylaştığından payda bölmeler arası varyansı dışarıda bırakmakta, bu da oranı bir üst sınır yapmaktadır. İkisini de atlatan şey mutlak karşılaştırmadır; iddiayı taşıyan da kat değeri değil odur.

Dördüncü kaynak, genellikle örtük bırakılan çevrimdışı kontrol noktası seçimi protokolüdür. Bir eğitim yörüngesi tamamen sabit tutulup yalnızca son kontrol noktasının nasıl seçildiği değiştirildiğinde, yani hangi doğrulama bölmesi, hangi erken durdurma sabrı ve argmaks öncesinde doğrulama eğrisinin yumuşatılıp yumuşatılmadığı (on sekiz bileşim), raporlanan PGD-10 doğruluğu ResNet'te tohum başına $2{,}62$ ile $2{,}85$, ViT'te $1{,}58$ ile $2{,}09$ puan oynamaktadır. Bu hücrelerde diskteki ağırlıklar özdeştir; yalnızca içlerinden birini seçen kural farklıdır. Bu yayılımın yaklaşık yarısı üç boyuttan yalnız birinden gelmektedir. Argmaks öncesinde doğrulama eğrisini yumuşatmak, üç ResNet koşumunun üçünde ve üç ViT koşumunun ikisinde test PGD-10 doğruluğunu monoton biçimde düşürmektedir; yani sistematik olarak daha kötü bir kuraldır. Çalışmaların fiilen değiştirdiği bölme ve sabır seçimleriyle sınırlandığında yayılım ResNet'te tohum düzeyi standart sapmanın $1{,}09$ katına, ViT'te $1{,}42$ katına inmektedir. İki değeri de veriyoruz: büyüğü belgelenmemiş bir ön işleme adımının ekleyebileceğini, küçüğü belgelenmiş bir protokolün yine de açık bıraktığını ölçmektedir. Bu yayılımı mutlak birimlerle raporluyor ve bilinçli olarak tohum düzeyi yayılıma oran biçiminde vermiyoruz; çünkü o oran, on sekiz hücreden hangisinin referans alındığına bağlıdır: on sekizinin tamamı tarandığında ResNet'te $0{,}67$ ile $3{,}38$, ViT'te $0{,}63$ ile $7{,}38$ arasında değişmekte, bazı referanslarda birin altına inip karşılaştırmayı tersine çevirmektedir.

CIFAR-100 koşuları bir karşı ağırlık sağlar: kendi protokolümüzün seçtiği epok üç ResNet tohumu arasında 25 epok kaymakta, buna karşılık ortaya çıkan test PGD-10 standart sapması $0{,}32$ puanda kalmaktadır. Seçim *yolu* oynaktı, seçilen *sonuç* değildi. Seçim tercihleri raporlanan bir sayıyı eğitim tohumundan daha fazla oynatabilir ya da neredeyse hiç oynatmayabilir; hangisinin gerçekleşeceği mimariye değil yörüngenin platosuna bağlıdır. Her iki durumda da seçim kuralı yöntem bölümünde belirtilmelidir.

Hesaplama Ayrıntıları: Burada raporlanan eğitim koşuları ve analizler NVIDIA RTX 5090 (32GB) üzerinde yürütülmüştür; Tablo II'deki karşılaştırmada kullanılan önceki tek koşuluk kontrol noktaları RTX 5060 Ti (16GB) üzerinde eğitilmişti. Tüm koşular PyTorch 2.6.0, CUDA 12.8 ve deterministik cuDNN ayarlarıyla yapılmıştır. AutoAttack değerlendirmesi, standart yapılandırmayla (APGD-CE, APGD-T, FAB-T, Square) 10.000 örneklik tam test kümesinde, örnek bazında kayıtla, tohumlanmış 1.000 örneklik parçalar halinde koşulmuştur. Üç tohumlu eğitim boru hattı toplam 21,7 GPU-saat gerektirmiştir.

V. Tartışma

A. Ölçümlerin Gösterdikleri

Merkezi sonuç bir yayılım sıralamasıdır: transfer asimetrisinin kendisi üzerinde ölçüldüğünde, her iki mimariyi sıfırdan yeniden eğitmek onu $0{,}23$ ile $1{,}27$ puanlık standart sapmayla oynatırken, yalnızca koşullama protokolünü değiştirmek $15{,}01 \pm 0{,}84$ puan oynatmaktadır (Bölüm IV-I). Farklı bir nicelik üzerinde ölçek fikri vermek üzere: bir saldırıyı yeni bir rastgele başlangıçla yeniden koşmak mutlak gürbüz doğruluğu yaklaşık $0{,}05$ puan, yeniden eğitmek ise çekişmeli eğitilmiş çifti en çok $0{,}55$ puan oynatır. Ölçüm seçiminin on beş puan oynattığı, yeniden eğitmenin ise bir puan oynattığı bir büyüklük mimarilerin kararlı bir özelliği değildir ve protokol olmadan raporlandığında neredeyse hiçbir şey iletmez.

Bir itiraz kendi terimleriyle yanıtlanmayı hak ediyor: dört protokol dört farklı niceliği kestirir, dolayısıyla aralarındaki mesafe bir varyans değildir ve ona varyans demek bir kategori hatası olurdu. Katılıyoruz; mimarilerin, protokollerin hatayla kestirdiği tek bir gerçek asimetrisi olduğunu varsaymıyoruz. İddiamız okuyucunun neyi geri kazanabildiğiyle ilgilidir. Bir çalışma protokolü adlandırmadan tek bir sayı raporladığında okuyucu dört nicelikten hangisinin kestirildiğini söyleyemez ve ölçtüğümüz yayılım o belirsizliğin büyüklüğü, yani adlandırmamanın maliyetinin bir üst sınırıdır. Koşullamanın kendisi yerleşik pratik olmayı sürdürmektedir [39], [40], [44] ve gereklidir; mesele, koşullama kümesi seçiminin sonuçla birlikte, ana metinde raporlanması gerektiğidir.

Bizim yönümüzün doğru yön olup olmadığı ayrı bir sorudur. Bizimkiyle karşılaştırılabilir bir her ikisi doğru protokolü altında Mahmood ve ark. [8] farklı bir mimari çiftinde ters yönü raporlamakta, dönüştürücüye doğru transferi ondan dışarı olan transferden zayıf bulmaktadır; Benz vd. [7] ile Shao vd. [9] de kendi model kümelerinde aynı sıralamayı bildirmektedir. Mekanizmamız bu sonuçlarla uyumludur: asimetriyi, CNN'de üretilen pertürbasyonların özel bir gücüyle değil hedefin kendi kırılganlığıyla ilişkilendiriyoruz, ki bu Demontis vd.'nin [38] saptadığı iki etkenden ilkidir, ve Mahmood ve ark.'nın çiftinde zayıf hedef olan taraf bizimkinden farklıdır. Bunu düzgün sınamak, ortak bir protokol altında yön başına temiz doğruluklarını gerektirirdi; talep ettiğimiz raporlama budur ve mekanizmaya doğrudan bir dış sınav sağlardı.

Dört protokol birbirinin yerine geçmez ve her birinin savunulabilir bir kullanımı vardır. Koşulsuz oran mimari karşılaştırması için hiç kullanılmamalıdır: 3×3 matrisimiz, koşullu orandan sapmasının hedefin temiz hatasının $(1 - r_{\text{koş}})$ ile ölçeklenmiş haline cebirsel olarak eşit olduğunu gösterir; yani transfer edilebilirliği değil, bilinen bir oranda hedef zayıflığını ölçer. Hedef doğru protokolü bu karıştırıcıyı giderir ama kaynağın kendisinin çözemediği örnekleri kabul eder; bu marjinal altkümeler son derece kırılgan ve asimetrik boyutlu olduğundan iki yönü, temiz doğruluk farkına bağlı bir miktarda birbirine doğru çeker. Her ikisi doğru protokolü iki yönü özdeş örnekler üzerinde puanlar ve dördü içinde eşleştirilmiş

çıkarımı destekleyen tek protokoldür; birincil tahmin olarak onu bu yüzden alıyoruz. Başarılı kaynak protokolü farklı bir soruyu yanıtlar: zaten işe yaramış bir saldırı ne kadar taşınır. Daha büyük değeri, kaynak başarısıyla koşullamanın güçlü pertürbasyonları seçmesini yansıtır.

Dört protokol ve üç eğitim koşusu boyunca CNN'de üretilen örnekler *her iki CIFAR veri kümesinde* ViT'e tersinden daha iyi transfer olmakta, CIFAR-10'da yön MI-FGSM altında da korunmaktadır. Temiz doğruluk farkının $1{,}85$ puan olduğu SVHN'de (CIFAR veri kümelerinde $12{,}3$ ve $20{,}7$) iki protokol CNN üstünlüğü, ikisi ViT üstünlüğü bildirmekte, birincil her ikisi doğru protokolü ise $-0{,}35$ puan vermekte ve eşdeğerlik kabul edilmektedir (Bölüm IV-D). Yön bu nedenle eşitlenmemiş rejimin bir özelliğidir: orada protokol etkinin ne kadar büyük göründüğünü ve eşdeğerliğin kabul edilip edilmediğini değiştirir, modeller eşitlendiğinde ise işareti de değiştirir. Üç hedefli analiz yönü CNN pertürbasyonlarından özel bir şey beklemeden açıklar, çünkü gelen transfer her hedefin kendi beyaz kutu kırılganlığını izler ($r = 0{,}986$); dönüştürücüye özgü bir saldırının [12] ViT yönünü kurtaramaması da aynı açıklamaya uyar. Üç hedefle bu korelasyon yönlendiricidir; onu kesinleştirmek daha büyük bir model havuzu gerektirir.

Koşullu ayrıştırma, mutlak gürbüzlüğü temiz doğruluk çarpanı ile koşullu duyarlılık çarpanına ayırır. Düzeltilmiş koşularımızda ikisi de CNN lehinedir; ayrıştırma ile manşet uyuşur. Önceki kontrol noktalarımızda uyuşmuyorlardı: koşullu duyarlılık PGD-10 altında eşleşik, AutoAttack altında hafifçe ViT lehine görünüyordu. Mutlak sıralama iki kontrol noktası kümesinde de özdeş olduğundan, yalnızca mutlak doğruluğu raporlayan bir makale hiçbir değişiklik görmezdi; tek koşudan ayrıştırma raporlayan bir makale ise tekrarlanmayan mekanizma düzeyinde bir sonuç çıkarırdı.

Seyreklik mekansal lokalite değildir: çekişmeli eğitilmiş CNN gradyanları kütlenin daha büyük kısmını daha az bileşene yoğunlaştırır (Hoyer $0{,}4928$'e karşı $0{,}4561$, her koşuda tutarlı; örnek bazlı $p < 10^{-11}$, koşum düzeyinde düzeltmeden sonra $p = 0{,}108$); ama aynı gradyanların dört mekansal betimleyicisi, bu bileşenlerin görüntüdeki dizilişinde karşılık gelen bir fark göstermez. CNN gradyanlarının mekansal olarak lokalize olduğu betimlemeleri bu yüzden ayrı kanıt ister; seyreklik ölçüleri [61] bunu sağlamaz.

Çekişmeli pertürbasyon CLS dikkat entropisini ölçülebilir biçimde değiştirmez. $n = 1000$'de katman başına entropi değişimi en çok $0{,}005$ nattır; dikkat haritaları ise küçük ve derinlikle artan bir miktarda yer değiştirir. Yama saldırılarıyla elde edilen dikkat kayması sonuçları [31], [32] farklı bir tehdit modeline aittir ve ölçüm olmadan L_∞ sınırlı pertürbasyonlara genellenmemelidir.

ViT'e özgü bir transfer saldırısı burada ViT kaynaklı transferi iyileştirmez. TGR [12] 14,9 puan beyaz kutu gücüne mal olmakta ve bunun hiçbirini hedefte geri vermemektedir. Sonuç bu rejime özgüdür, çünkü hedeflerimiz çekişmeli eğitilmiş, verimiz CIFAR ölçeğindedir.

İki davranışsal fark bağımsız kontrol noktası kümelerinde tekrarlanmakta ve protokol sorusundan etkilenmemektedir. CNN girdi gradyanları üç ölçekten bağımsız ölçünün üçünde de daha seyrektir, bu sıralamayı çekişmeli eğitim yaratır (temiz eğitilmiş çiftte tersidir) ve örnekler arası hizalanma ViT'te mutlak kosinüste daha yüksekken işaretli ortalama iki modelde de sıfıra yakındır. Örnekler böylece duyarlılık eksenlerini paylaşır ama yönleri paylaşmaz; ölçümümüzü bir evrensel pertürbasyon iddiasından [63] ayıran da budur. Derinlik profilleri de farklıdır: CNN'de hasar son artık aşamada yoğunlaşırken ViT'te temsilin bir dönmesi olarak kademeli biçimde birikir. ViT'in ölçülen profilinin jeton agregasyonuna bağlı olması, yani CLS yolunun yama ortalamasının yaklaşık üç katı kayması, katman bazlı çalışmalar için kendi başına bir raporlama gerekliliğidir.

B. Raporlama Gereklilikleri

Ölçümlerden, mimariler arası gürbüzlük çalışmaları için birkaç gereklilik çıkmaktadır.

Çalışmalar koşullama protokolünü belirtmeli ve paydaya hangi örneklerin girdiğini raporlamalıdır. Yönlü bir iddia kuruluyorsa, iki yönü özdeş örnekler üzerinde puanlayan bir protokol yeğlenmeli, böylece eşleştirilmiş çıkarım mümkün olmalıdır. Koşulsuz transfer oranları mimari karşılaştırması olarak raporlanmamalıdır. Hedefler temiz doğrulukta ayrışıyorsa ham oran, transfer edilebilirlik ile hedef zayıflığının bilinen bir karışımıdır, $r_{\text{ham}} - r_{\text{koş}} = e\,(1 - r_{\text{koş}})$; bu bağıntı cebirsel bir özdeşlik olduğundan düzeltme, yayımlanmış ham oranlara hiçbir şey yeniden koşulmadan uygulanabilir.

Çalışmalar skorun yanında ayrıştırmayı da raporlamalıdır. Mutlak gürbüzlük, temiz doğruluk ile koşullu duyarlılığın çarpımına birebir ayrışır ve manşeti hangi çarpanın taşıdığı tek başına skordan geri elde edilemez. Sıralama iddiaları mekanizma iddialarından ayrılmalıdır: bizim sıralamalarımız kontrol noktası kümeleri arasında kararlı kalmış, mekanizma atfımız kalmamıştır, dolayısıyla mekanizma iddiaları daha çok eğitim koşusu taşımalıdır. Katman bazlı analizlerde agregasyon belirtilmelidir, çünkü aynı blokların yalnızca CLS, yama ortalaması ve tüm jetonlar üzerinden özetleri farklı kayma büyüklükleri ve farklı minimumlar vermektedir. Dikkat iddiaları da son olarak gerçekçi bir örneklem boyutunda sınanmalıdır: raporladığımız dikkat sıfır sonucu küçük bir şekil yığınında pozitif görünmüştü.

Bu kıyaslamada eşleşmiş standart çekişmeli eğitim altında iki aile arasında seçim yapan uygulayıcılar için: CNN daha yüksek mutlak gürbüz doğruluk vermekte ve üstünlük ölçtüğümüz her görünümde korunmaktadır. %62,76'daki WideResNet referansı, ek veriyle ve daha güçlü bir tarifle eğitilmiş daha büyük bir modelin [54] gürbüzlüğü bu iki aile arasındaki seçimden daha ileri taşıdığını göstermektedir.

C. Sınırlılıklar

Çalışmanın kapsamı sonuçlarını belirli biçimlerde sınırlar.

Protokol duyarlılığı sonucu üç veri kümesi ve tek model çifti üzerinde ölçülmüştür. CIFAR-100'de yayılım CIFAR-10 değerine yakındır ($13{,}83 \pm 1{,}30$'a karşı $15{,}01 \pm 0{,}84$ puan) ve işaret on iki ölçümün tamamında korunmaktadır (Bölüm IV-C). Dolayısıyla etki CIFAR'a özgü değildir; ancak büyüklüğü veri kümeleri arasında temiz doğruluk farkını izlememektedir: CIFAR-100'de fark açık ara daha büyük, yayılım ise bir miktar daha küçüktür. Önerdiğimiz mekanizma bir farkın bir yayılım ürettiğini öngörmekte, yayılımın veri

kümeleri arasında nasıl sıralanacağını öngörmemektedir. Açıklama yine de eksiktir: dört protokolün üçü için geçerlidir; başarılı kaynak protokolü ise *kaynağın* gürbüzlüğüne bağlı ikinci bir sürücü ekler ve bu sürücü genel ilişkiyi tersine çevirecek kadar güçlüdür (Bölüm IV-B). Her iki bağımlılığın işlevsel biçimini de güvenle belirtemiyoruz: kestirimler altı tohum-ve-veri-kümesi kümesine dayanmaktadır ve havuzumuzdaki küçük farklı çiftlerin tamamı harici WideResNet'i içerdiğinden, küçük temiz doğruluk farkı ile farklı eğitim tarifi burada birbirinden ayrılamamaktadır. Değişen temiz doğruluk farklarına sahip birden çok mimari çiftini tarayan bir çalışma, bu ölçümleri bir kalibrasyon eğrisine dönüştürecektir.

İki kontrol noktası kümesi arasındaki farkların nedenini yalıtamıyoruz. Düzeltilmiş protokol, doğrulama düzenini değiştirmiş ve aynı anda yeni bir eğitim koşusu üretmiştir. Veri miktarı açıklaması dışlanmıştır (düzeltilmiş temiz modeller daha az veriyle daha iyidir); ancak seçim sızıntısını olağan koşudan koşuya değişimden ayırmak, özdeş veriyle sızıntılı ve sızıntısız seçim altında eğiten bir ablasyon gerektirir. Karşıtlık, tek koşuluk mekanizma iddialarının kırılgan olduğuna dair kanıttır; sızıntıyı ölçmez.

Bu makaledeki her model tek bir tehdit modelinin içinde eğitilmiştir: $\epsilon = 8/255$ ile L_∞. Aynı kontrol noktalarını bir L_2 bütçesi altında değerlendirdik ve protokol yayılımı ayakta kaldı; $15{,}01$ puana karşı $10{,}92$ puan (Bölüm IV-E); ancak bu sınama L_2 gürbüzlüğünü değil, protokolün sonucu nasıl etkilediğini yoklar ve mutlak değerleri L_2 ile eğitilmiş referanslarla karşılaştırılamaz. Etkinin, başka bir norm altında *eğitilmiş* modeller için de geçerli olup olmadığı burada sınanmamıştır.

Mimari başına üç koşu tohum varyansını sınırlar ama tarif uzayını taramaz; küçük veri kümelerinde ViT çekişmeli eğitiminin tarife duyarlı olduğu bilinmektedir [56], [57] ve Wang vd.'nin [64] difüzyonla üretilmiş veri tarifiyle eğitilen bir ViT'in CIFAR-10'da WideResNet'leri geçtiği bildirilmiştir [35]. ViT sonuçlarımız ulaşılabilir en iyi ViT gürbüzlüğünü değil, temel çekişmeli eğitimi betimler. ViT-Tiny hattı 32×32 girdileri model içinde 224×224'e büyütür; CIFAR'a özgü kontrolümüz gradyan sıralamasının büyütme artefaktı olmadığını gösterir, ama bu kontrol kapasite ve yama boyutunda farklıdır; dolayısıyla ikinci bir eşleşmiş çift sağlamadan karıştırıcıyı kalibre eder. İki model parametre sayısında da ayrışır (11,2M'ye karşı 5,7M); mutlak farkın mimariye atfı bu yüzden kısmi kalır. TGR sonucumuz da son olarak yöntemin yayımlanmış kurulumunun yeniden üretiminden değil, bir uyarlamasından gelmektedir.

D. Gelecek Yönelimler

En doğrudan uzantı, protokol duyarlılığı ölçümünü genel bir ölçüme dönüştürmektir: kontrollü temiz doğruluk farklarına sahip mimari çiftlerini tarayıp protokoller arası yayılımın bu farkla nasıl ölçeklendiğini ölçmek. İlişki, üç hedefli korelasyonumuzun önerdiği kadar düzenliyse, yayımlanmış ham oran asimetrilerinin atılmak yerine yeniden yorumlanmasına imkan veren bir düzeltme sağlar.

İki doğal uzantı zaten bu makalenin parçasıdır. Sızıntı ablasyonu altı tam bütçeli yörünge üzerinde yürütülmüş ve sızıntının kontrol noktası seçimine etkisini saptamamıştır; başlangıçta konan sorunun daha zayıf bir sürümünü yanıtlar, çünkü tedavi tek bir doğrulama bölmesine uygulanmıştır ve o tasarımda bölme kimliği ile sızıntı birbirinden ayrıştırılamaz. Ablasyonun verdiği ise Bölüm IV-I'te raporlanan seçim protokolü yayılımıdır. Diğer uzantı ikinci veri kümesidir (Bölüm IV-C). Açık kalan, kapasitesi eşlenmiş çifttir (örneğin ViT-Small'a karşı ResNet-50); böyle bir çift, ayakta kalan davranışsal farkların, yani seyreklik sıralamasıyla derinlik profillerinin, ailelerin mi yoksa bu küçük modellerin mi özelliği olduğunu sınayacaktır.

VI. Sonuç

CNN ile Görü Dönüştürücüsü gürbüzlük karşılaştırmalarındaki uyuşmazlığın ne kadarının modellerden değil ölçümden geldiğini sorduk ve bunu, geri kalan her şeyi sabit tutup yalnızca karşılaştırmanın nasıl puanlandığını değiştirerek yanıtladık.

Ölçüm hükmediyor: özdeş çekişmeli eğitilmiş ResNet-18 ve ViT-Tiny çiftlerinde, mimariler arası transfer asimetrisi dört koşullama protokolü boyunca $+4{,}4$ ile $+19{,}4$ puan arasında değişirken her iki mimariyi sıfırdan yeniden eğitmek aynı niceliği $1{,}5$ puandan az oynatır. Bu $15{,}01$ puanlık yayılım, türettiğimiz bir özdeşliğin kapalı formda kaldırdığı $9{,}21$ puan ile farklı bir niceliği kestiren bir protokolden gelen $5{,}79$ puana ayrılır. Düzeltmeden sonra iki savunulabilir protokol arasında kalan $3{,}91$ puanlık gerçek takdir, bir raporlama ölçütünün ele alması gereken kısımdır. Koşulsuz oranlar böyle bir karşılaştırma için hiçbir biçimde geçerli temel değildir: WideResNet-28-10 referansının eklendiği 3×3 matriste, koşullu oranlardan sapmaları, hedefin temiz hatasının bir eksi koşullu oranla ölçeklenmiş haline cebirsel olarak eşittir; bu özdeşlik 36 ölçülen yönde $0{,}41$ puandan küçük bir hatayla tutar ve ölçülen öncülü sağlayan yayımlanmış herhangi bir ham orana uygulanabilir. CIFAR-100 yinelemesi ile kontrol noktası seçimi ablasyonu aynı yönü gösterir: makalelerin nadiren raporladığı ölçüm tercihleri, raporlanan etkilerle aynı mertebededir. Yön, her iki CIFAR veri kümesinde protokoller, tohumlar ve saldırı aileleri boyunca kararlıdır; ancak veri kümeleri boyunca değildir: aynı tarifin iki mimariyi temiz doğrulukta yalnızca $1{,}85$ puan ayırdığı SVHN'de dört protokolün ikisi işareti tersine çevirir ve birincil protokol eşdeğerliği kabul eder. Başka bir deyişle yön, modeller eşitlenmemişken geçerlidir ve üç hedefli analizimiz onu hedefin kendi kırılganlığıyla ($r = 0{,}986$) ilişkilendirir.

Koşullu ayrıştırma, mutlak gürbüzlüğü temiz doğruluk çarpanı ile koşullu duyarlılık çarpanına ayırır. Düzeltilmiş koşularımızda ikisi de CNN lehinedir; ancak mutlak sıralaması özdeş olan önceki bir kontrol noktası kümesinde iki çarpan arasındaki pay farklıydı.

Üç okuma doğrudan ölçümden sağ çıkamamıştır: çekişmeli eğitilmiş CNN gradyanları daha seyrektir ama mekansal olarak daha lokalize değildir; CLS dikkat entropisi $n = 1000$'de L_∞ saldırısı altında değişmez; dönüştürücüye özgü bir transfer saldırısı bu rejimde transfer kazancı sağlamaz. Bunlardan yalnızca üçüncüsü yayımlanmış bir iddiadır; ilk ikisi kendi önceki şekillerimizin davet ettiği yorumlardır. İki davranışsal fark ise bağımsız kontrol noktası kümelerinde tekrarlanarak ayakta kalmıştır: çekişmeli eğitimin yarattığı gradyan seyrekliği sıralaması ve CNN'de geç katmanlarda yoğunlaşan, ViT'te derinlik boyunca yayılan çekişmeli hasarın derinlik profili.

Bu ölçümlerden, ilk ikisi en önemli olan kısa bir raporlama gereklilikleri kümesi damıttık: koşullama protokolünü belirtin ve eşleştirilmiş olanları yeğleyin; koşulsuz transfer oranlarını mimari karşılaştırması olarak sunmayın. Çalışmamız üç veri kümesini ve tek bir model çiftini kapsadığından protokol etkisinin başka mimari çiftlerindeki boyutu kalibre edilmeyi bekler. Etkinin arkasındaki mekanizma, yani hedefler arasındaki eşitsiz temiz doğruluk farkı, kurulumumuza özgü değildir. Protokol karşılaştırmasının yeniden üretilip genişletilebilmesi için tam boru hattı, örnek bazında kayıtlar ve analiz betikleri kabul sonrasında yayımlanacaktır.

Veri ve Kod Erişilebilirliği

Bu çalışmadaki deneyler, herkese açık olan CIFAR-10 ve CIFAR-100 veri kümeleri [11] ile SVHN veri kümesini [62] kullanmaktadır. Önceden eğitilmiş WideResNet-28-10 ağırlıkları RobustBench kıyaslamasından [23], [54] alınmıştır. Kabul sonrasında analiz hattını, bu makaledeki her tabloyu ve şekli üreten betikleri, örnek bazında değerlendirme kayıtlarını, sabit doğrulama bölmesi indekslerini ve tohum listelerini yayımlayacağız; bunlar burada raporlanan her sayıyı yeniden üretmeye yetmektedir, çünkü dört koşullama protokolünün tamamı örnek bazındaki kayıtlardan hesaplanmaktadır ve protokol karşılaştırması yeniden eğitim gerektirmeden tekrarlanabilmektedir. Bu arşivin anonimleştirilmiş bir kopyası, inceleme sırasında hakemlerin erişimine `[ANONYMOUS-ARCHIVE-URL]` adresinde açıktır; böylece protokol karşılaştırması kabulden sonra değil, kabulden önce denetlenebilir. Eğitilmiş kontrol noktaları yaklaşık 40 GB tutmaktadır ve yazarlardan istek üzerine sağlanmaktadır.

Teşekkür

Yazarlar, hesaplama kaynakları için Fırat Üniversitesi Yazılım Mühendisliği Bölümü'ne teşekkür eder.

Yazarlar bu çalışmanın hazırlanması sırasında Claude (Anthropic) kullanmıştır. Araç, makale metninin tüm bölümlerinin yazımına ve gözden geçirilmesine ve makaleyle birlikte yayımlanan analiz ve denetim betiklerinin gerçeklenmesine yardımcı olmuştur. Çalışmanın tasarımı, deney protokolü ve tüm sonuçlar yazarlara aittir; yazarlar raporlanan her sayıyı yayımlanan artefaktlarla doğrulamıştır.

Kaynaklar

[1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, "Intriguing properties of neural networks," in *Proc. International Conference on Learning Representations (ICLR)*, 2014.

[2] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and harnessing adversarial examples," in *Proc. International Conference on Learning Representations (ICLR)*, 2015.

[3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[6] Y. Bai, J. Mei, A. L. Yuille, and C. Xie, "Are transformers more robust than CNNs?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 26 831–26 843.

[7] P. Benz, S. Ham, C. Zhang, A. Karjauv, and I. S. Kweon, "Adversarial robustness comparison of vision transformer and MLP-Mixer to CNNs," in *Proc. British Machine Vision Conference (BMVC)*, 2021.

[8] K. Mahmood, R. Mahmood, and M. van Dijk, "On the robustness of vision transformers to adversarial examples," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 7818–7827.

[9] R. Shao, Z. Shi, J. Yi, P.-Y. Chen, and C.-J. Hsieh, "On the adversarial robustness of vision transformers," *Transactions on Machine Learning Research*, 2022.

[10] M. Naseer, K. Ranasinghe, S. Khan, F. S. Khan, and F. Porikli, "On improving adversarial transferability of vision transformers," in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[11] A. Krizhevsky and G. Hinton, "Learning multiple layers of features from tiny images," University of Toronto, Tech. Rep., 2009.

[12] J. Zhang, Y. Huang, W. Wu, and M. R. Lyu, "Transferable adversarial attacks on vision transformers with token gradient regularization," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 16 415–16 424.

[13] c. Şahin and O. Yıldırım, "A behavioral comparison of adversarially trained ResNet-18 and ViT-Tiny on CIFAR-10: Transfer metrics, gradient structure, and block-wise feature drift," in *Proc. ATEEC 2026*, 2026, preliminary version of the present study; submitted.

[14] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, "Towards deep learning models resistant to adversarial attacks," in *Proc. International Conference on Learning Representations (ICLR)*, 2018.

[15] N. Carlini and D. Wagner, "Towards evaluating the robustness of neural networks," in *Proc. IEEE Symposium on Security and Privacy (SP)*, 2017, pp. 39–57.

[16] F. Croce and M. Hein, "Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks," in *Proc. International Conference on Machine Learning (ICML)*, 2020, pp. 2206–2216.

[17] H. Zhang, Y. Yu, J. Jiao, E. Xing, L. El Ghaoui, and M. Jordan, "Theoretically principled trade-off between robustness and accuracy," in *Proc. International Conference on Machine Learning (ICML)*, 2019, pp. 7472–7482.

[18] Y. Wang, D. Zou, J. Yi, J. Bailey, X. Ma, and Q. Gu, "Improving adversarial robustness requires revisiting misclassified examples," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[19] C. Guo, M. Rana, M. Cisse, and L. van der Maaten, "Countering adversarial images using input transformations," in *Proc. International Conference on Learning Representations (ICLR)*, 2018.

[20] J. Cohen, E. Rosenfeld, and Z. Kolter, "Certified adversarial robustness via randomized smoothing," in *Proc. International Conference on Machine Learning (ICML)*, 2019, pp. 1310–1320.

[21] F. Tramèr, A. Kurakin, N. Papernot, I. Goodfellow, D. Boneh, and P. McDaniel, "Ensemble adversarial training: Attacks and defenses," in *Proc. International Conference on Learning Representations (ICLR)*, 2018.

[22] S. Lyu, S. Shaikh, F. Shpilevskiy, E. Shelhamer, and M. Lécuyer, "Adaptive randomized smoothing: Certified adversarial robustness for multi-step defences," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 37, 2024, pp. 134 043–134 074.

[23] F. Croce, M. Andriushchenko, V. Sehwag, E. Debenedetti, N. Flammarion, M. Chiang, P. Mittal, and M. Hein, "RobustBench: a standardized adversarial robustness benchmark," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2021.

[24] D. Wu, Y. Wang, S.-T. Xia, J. Bailey, and X. Ma, "Skip connections matter: On the transferability of adversarial examples generated with ResNets," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[25] C. Xie and A. Yuille, "Intriguing properties of adversarial training at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[26] C. Xie, M. Tan, B. Gong, J. Wang, A. L. Yuille, and Q. V. Le, "Adversarial examples improve image recognition," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 816–825.

[27] D. Tsipras, S. Santurkar, L. Engstrom, A. Turner, and A. Madry, "Robustness may be at odds with accuracy," in *Proc. International Conference on Learning Representations (ICLR)*, 2019.

[28] P. Chalasani, J. Chen, A. R. Chowdhury, X. Wu, and S. Jha, "Concise explanations of neural networks using adversarial training," in *Proc. International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 1383–1391.

[29] M. Raghu, T. Unterthiner, S. Kornblith, C. Zhang, and A. Dosovitskiy, "Do vision transformers see like convolutional neural networks?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34. Curran Associates, Inc., 2021, pp. 12 116–12 128.

[30] S. Bhojanapalli, A. Chakrabarti, D. Glasner, D. Li, T. Unterthiner, and A. Veit, "Understanding robustness of transformers for image classification," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 211–10 221.

[31] Y. Fu, S. Zhang, S. Wu, C. Wan, and Y. Lin, "Patch-Fool: Are vision transformers always robust against adversarial perturbations?" in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[32] J. Gu, V. Tresp, and Y. Qin, "Are vision transformers robust to patch perturbations?" in *Proc. European Conference on Computer Vision (ECCV)*, ser. Lecture Notes in Computer Science, vol. 13672. Springer, 2022, pp. 404–421.

[33] S. Paul and P.-Y. Chen, "Vision transformers are robust learners," in *Proc. AAAI Conference on Artificial Intelligence (AAAI)*, vol. 36, no. 2, 2022, pp. 2071–2081.

[34] S. Jain and T. Dutta, "Towards understanding and improving adversarial robustness of vision transformers," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 24 736–24 745.

[35] J. Wu, Z. Song, X. Zhang, S. Xie, L. Lin, and K. Wang, "Vision transformers beat WideResNets on small scale datasets adversarial robustness," in *Proc. AAAI Conference on Artificial Intelligence (AAAI)*, vol. 39, no. 1, 2025, pp. 886–894.

[36] Z. Zhu, X. Wang, Z. Jin, J. Zhang, and H. Chen, "Enhancing transferable adversarial attacks on vision transformers through gradient normalization scaling and high-frequency adaptation," in *Proc. International Conference on Learning Representations (ICLR)*, 2024.

[37] N. Papernot, P. McDaniel, and I. Goodfellow, "Transferability in machine learning: from phenomena to black-box attacks using adversarial samples," *arXiv preprint arXiv:1605.07277*, 2016.

[38] A. Demontis, M. Melis, M. Pintor, M. Jagielski, B. Biggio, A. Oprea, C. Nita-Rotaru, and F. Roli, "Why do adversarial attacks transfer? Explaining transferability of evasion and poisoning attacks," in *Proc. 28th USENIX Security Symposium (USENIX Security 19)*, 2019, pp. 321–338.

[39] Y. Liu, X. Chen, C. Liu, and D. Song, "Delving into transferable adversarial examples and black-box attacks," in *Proceedings of the 5th International Conference on Learning Representations (ICLR)*, 2017.

[40] Y. Dong, F. Liao, T. Pang, H. Su, J. Zhu, X. Hu, and J. Li, "Boosting adversarial attacks with momentum," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 9185–9193.

[41] Z. Zhao, H. Zhang, R. Li, R. Sicre, L. Amsaleg, M. Backes, Q. Li, Q. Wang, and C. Shen, "Revisiting transferable adversarial images: Systemization, evaluation, and new insights," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 48, no. 1, pp. 765–780, 2026.

[42] Q. Li, Y. Guo, W. Zuo, and H. Chen, "Towards evaluating transfer-based attacks systematically, practically, and fairly," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023, pp. 41 707–41 726.

[43] W. Yu, J. Gu, Z. Li, and P. Torr, "Reliable evaluation of adversarial transferability," in *Proc. IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2025, pp. 797–810.

[44] D. Ravikumar, S. Kodge, I. Garg, and K. Roy, "TREND: Transferability-based robust ENsemble design," *IEEE Transactions on Artificial Intelligence*, vol. 4, no. 3, pp. 534–548, 2023.

[45] Z. Wei, J. Chen, M. Goldblum, Z. Wu, T. Goldstein, and Y.-G. Jiang, "Towards transferable adversarial attacks on vision transformers," in *Proc. AAAI Conference on Artificial Intelligence (AAAI)*, vol. 36, no. 3, 2022, pp. 2668–2676.

[46] W. Ma, Y. Li, X. Jia, and W. Xu, "Transferable adversarial attack for both vision transformers and convolutional networks via momentum integrated gradients," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4607–4616.

[47] Z. Chen, C. Xu, H. Lv, S. Liu, and Y. Ji, "Understanding and improving adversarial transferability of vision transformers and convolutional neural networks," *Information Sciences*, vol. 648, p. 119474, 2023.

[48] F. Waseda, S. Nishikawa, T.-N. Le, H. H. Nguyen, and I. Echizen, "Closer look at the transferability of adversarial examples: How they fool different models differently," in *Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2023, pp. 1360–1368.

[49] F. Pinto, P. H. S. Torr, and P. K. Dokania, "An impartial take to the CNN vs Transformer robustness contest," in *Proc. European Conference on Computer Vision (ECCV)*, ser. Lecture Notes in Computer Science, vol. 13673. Cham: Springer, 2022, pp. 466–480.

[50] K. Ali, M. S. Bhatti, A. Saeed, A. Athar, M. A. Al Ghamdi, S. H. Almotiri, and S. Akram, "Adversarial robustness of vision transformers versus convolutional neural networks," *IEEE Access*, vol. 12, pp. 105 281–105 293, 2024.

[51] N. Carlini, A. Athalye, N. Papernot, W. Brendel, J. Rauber, D. Tsipras, I. Goodfellow, A. Madry, and A. Kurakin, "On evaluating adversarial robustness," *arXiv preprint arXiv:1902.06705*, 2019.

[52] F. Tramèr, N. Carlini, W. Brendel, and A. Madry, "On adaptive attacks to adversarial example defenses," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.

[53] S. Zagoruyko and N. Komodakis, "Wide residual networks," in *Proc. British Machine Vision Conference (BMVC)*. BMVA Press, 2016, pp. 87.1–87.12.

[54] S. Gowal, C. Qin, J. Uesato, T. Mann, and P. Kohli, "Uncovering the limits of adversarial training against norm-bounded adversarial examples," *arXiv preprint arXiv:2010.03593*, 2020.

[55] R. Wightman, "PyTorch image models," https://github.com/huggingface/pytorch-image-models, 2019, formerly hosted at github.com/rwightman/pytorch-image-models.

[56] E. Debenedetti, V. Sehwag, and P. Mittal, "A light recipe to train robust vision transformers," in *Proc. IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2023, pp. 225–253.

[57] Y. Mo, D. Wu, Y. Wang, Y. Guo, and Y. Wang, "When adversarial training meets vision transformers: Recipes from training to architecture," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 18 599–18 611.

[58] L. Rice, E. Wong, and J. Z. Kolter, "Overfitting in adversarially robust deep learning," in *Proc. International Conference on Machine Learning (ICML)*, 2020, pp. 8093–8104.

[59] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. International Conference on Learning Representations (ICLR)*, 2017.

[60] ——, "Decoupled weight decay regularization," in *Proc. International Conference on Learning Representations (ICLR)*, 2019.

[61] N. Hurley and S. Rickard, "Comparing measures of sparsity," *IEEE Transactions on Information Theory*, vol. 55, no. 10, pp. 4723–4741, Oct. 2009.

[62] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, "Reading digits in natural images with unsupervised feature learning," in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.

[63] S.-M. Moosavi-Dezfooli, A. Fawzi, O. Fawzi, and P. Frossard, "Universal adversarial perturbations," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 86–94.

[64] Z. Wang, T. Pang, C. Du, M. Lin, W. Liu, and S. Yan, "Better diffusion models further improve adversarial training," in *Proc. International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 36 246–36 263.