

Ölçüm Protokolü Sonucu Belirler: CNN ile Görü Dönüştürücüsü Çekişmeli Gürbüzlük Karşılaştırmalarının Yöntembilimsel Bir İncelemesi

The Measurement Protocol Decides the Conclusion: A Methodological Study of CNN and Vision Transformer Adversarial

Robustness Comparisons

Çağrı Şahin ve Özal Yıldırım

Özet—Mimari aileleri arasındaki çekişmeli gürbüzlük karşılaştırmaları birbiriyle çelişen sonuçlar bildirmekte ve bu anlaşmazlık genellikle modellere, eğitim tariflerine ya da veri kümelerine bağlanmaktadır. Bu çalışmada, anlaşmazlığın kayda değer bir kısmının ölçüm protokolünün kendisinden geldiğini gösteriyoruz. Mimari başına üç bağımsız eğitim koşumu, örnek bazında kayıtlı tam test kümesi değerlendirmesi ve her eğitimden önce ayrılmış sabit bir doğrulama bölmesi kullanan çekişmeli eğitilmiş ResNet-18 ve ViT-Tiny çiftlerinde modelleri, veriyi, tehdit modelini ve saldırı bütçesini sabit tutup yalnızca gürbüzlüğün ve transferin nasıl puanlandığını değiştiriyoruz. Dört yerleşik koşullama protokolü altında ölçülen CNN’den ViT’e transfer asimetrisi CIFAR-10’da 4,4 ile 19,4 puan arasında değişmekte, oysa iki mimariyi sıfırdan yeniden eğitmek aynı büyüklüğü 1,5 puandan az oynatmaktadır; üstelik bir eşdeğerlik testinin kabul mü ret mi edileceğine protokol karar vermektedir. Aynı tasarımın CIFAR-100’de yinelenmesi yayılımı aynı aralıkta bırakmakta ve on iki ölçümün tamamında işareti korumaktadır. Aynı tarifi iki mimariyi temiz doğrulukta yalnızca 1,85 puan ayırdığı SVHN’de ise dört protokolün ikisi CNN, ikisi ViT üstünlüğü bildirmektedir: modeller eşitlendiğinde ölçüm seçimi yalnızca raporlanan asimetrisinin büyüklüğüne değil işaretine de karar vermektedir. Üç mimarili bir kontrol, koşulsuz oranların koşullu oranlardan sapmasının hedefin temiz hatasıyla yalnızca ilişkili olmadığını, ona cebirsel olarak eşit olduğunu göstermektedir; dolayısıyla ham transfer oranları yapısı gereği hedef yayıflığıyla kirlenmektedir. Eğitim yörüngesini sabit tutup yalnızca çevrimdışı kontrol noktası seçim kuralını değiştiren ek bir ablasyon, neredeyse hiç raporlanmayan dördüncü bir varyans kaynağı eklemektedir. Bu alanda yaygın üç iddia da doğrudan ölçüm altında yinelenmemektedir. Çalışmayı, mimariler arası gürbüzlük çalışmaları için raporlama gereklilikleriyle kapatıyoruz.

Anahtar Kelimeler—Çekişmeli gürbüzlük, değerlendirme yöntembilimi, derin öğrenme güvenliği, evrişimli sinir ağları, görüş dönüştürücüsü, tekrarlanabilirlik, transfer saldırıları

I. GİRİŞ

Derin sinir ağları, küçük bir norm bütçesiyle sınırlı kalırken yüksek güvenle yanlış sınıflandırmaya yol açan, özenle üretilmiş pertürbasyonlar olan çekişmeli örneklerle (adversarial

examples) karşı savunmasızdır [1], [2]. Görü Dönüştürücüler (Vision Transformer, ViT) [3], [4] evrişimli sinir ağlarının (CNN) [5] yanında baskın bir mimari aile hâline gelince doğal bir soru ortaya çıkmıştır: hangi aile daha gürbüzdür ve neden?

Literatür bu soruya tutarsız yanıtlar vermektedir. Bai vd. [6] eşleşmiş eğitim tarifleri altında dönüştürücülerin CNN’leri geçmediğini, Benz vd. [7] ise standart eğitilmiş modellerde ViT’lerin daha gürbüz olduğunu bildirmektedir; mimariler arası transfer çalışmaları da saldırıların CNN’den ViT’e mi yoksa tersine mi daha kolay taşındığı konusunda uyuşmamaktadır [8]–[10]. Bu uyuşmazlıklar genellikle model, eğitim tarifi veya veri kümesi farklarına atfedilir ve standart tepki, eşleşmiş bir tarif altında karşılaştırma yapmaktır.

Bu makale farklı bir gözlemde bulunmaktadır. Modeller, veri, tehdit modeli ve saldırı bütçesinin tamamı sabit tutulduğunda bile sonuç, nadiren raporlanan bir seçime bağlı kalmaktadır: *ölçüm protokolü*. Transfer çalışmaları paydaya hangi örneklerin gireceğine karar vermek zorundadır (tüm test örnekleri mi, hedefin doğru sınıflandırdıkları mı, her iki modelin de doğru sınıflandırdıkları mı, yoksa kaynak saldırının başarılı olduğu örnekler mi); gürbüzlük karşılaştırmaları da mutlak bir skor mu raporlayacaklarına yoksa onu temiz doğruluk ve koşullu duyarlılık bileşenlerine mi ayıracaklarına karar vermek zorundadır. Bu seçimler genellikle raporlama ayrıntısı sayılır. Biz bunların sonucun parçası olduğunu gösteriyoruz.

Kurulumumuz, ölçüm sorusunu yalıtılabilmek için bilinçli olarak dardır. CIFAR-10 [11] üzerinde ResNet-18 ile ViT-Tiny’yi eşleşmiş bir amaç fonksiyonu ve tehdit modeliyle çekişmeli eğitiyoruz; mimari başına üç bağımsız eğitim koşusu yapılmakta ve *her* eğitim aşamasından önce ayrılmış sabit bir doğrulama bölmesi kullanılmaktadır, dolayısıyla hiçbir model gördüğü veriyle seçilmemektedir. Tüm değerlendirmeler, örnek bazında sonuç kaydıyla tam test kümesinde koşturmaktadır; bu, eşleştirilmiş istatistikleri mümkün kılar: aynı örnekler, saldırıyı yeniden koşturmadan farklı protokoller altında yeniden ağırlıklandırılabilir. Ardından modelleri değil protokolü değiştiriyor ve sonucun ne kadar hareket ettiğini ölçüyoruz.

Mimari karşılaştırma makalelerinde tekrar eden üç iddiayı da yorum olarak değil, ölçülebilir hipotez olarak ele alıyoruz: CNN girdi gradyanlarının mekânsal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini (attention)

Çağrı Şahin, Muş Alparslan Üniversitesi Yazılım Mühendisliği Bölümü’ndedir (49250 Muş, Türkiye) ve ayrıca Fırat Üniversitesi Yazılım Mühendisliği Bölümü’nde doktora öğrencisidir (23119 Elazığ, Türkiye).

Özal Yıldırım, Fırat Üniversitesi Yazılım Mühendisliği Bölümü’ndedir, 23119 Elazığ, Türkiye.

Sorumlu yazar: Çağrı Şahin (e-posta: c.sahin@alparslan.edu.tr).

bozduğu ve ViT'e özgü transfer saldırılarının mimariler arası transferi iyileştirdiği. Her biri, amaca özel bir ölçümle doğrulan test edilmektedir.

Katkılarımız şunlardır. Önce protokol duyarlılığını niceliyoruz. Aynı modeller ve aynı veri üzerinde, ölçülen mimariler arası transfer asimetrisi dört yerleşik koşullama protokolü boyunca +4,4 ile +19,4 puan arasında değişmektedir; bu 4,4 katlık bir yayılımdır, buna karşılık her iki mimariyi sıfırdan yeniden eğitmek aynı niceliği 1,5 puandan az oynatmaktadır. Protokol, bir eşdeğerlik testinin kabul mü ret mi edileceğine karar vermekte; asimetrisinin yönü ise büyüklüğünün aksine kararlı kalmaktadır. Tasarımın tamamı CIFAR-100 üzerinde tekrarlandığında tohum başına ortalama protokol yayılımı $13,83 \pm 1,30$ puan olmakta, yani CIFAR-10 değerine yakın kalmakta ve işaret on iki ölçümün tamamında korunmaktadır. Bir eğitim yörüngesi sabit tutulup yalnızca çevrimdışı kontrol noktası seçimi kuralı değiştirildiğinde raporlanan PGD-10 doğruluğu 1,58 ile 2,85 puan arasında oynamakta; bu da seçimi tohumlar, saldırılar ve protokollerin yanında raporlanması gereken bir varyans kaynağı hâline getirmektedir.

Ardından koşulsuz transfer oranlarının karıştırıcı içerdiğini gösteriyor ve bunu niceliyoruz. WideResNet-28-10 referansının eklendiği 3×3 transfer matrisinde, ham oranların koşullu oranlardan sapması ampirik bir korelasyon değil bir özdeşliktir. Hedefin zaten yanlış sınıflandırdığı örnekler pertürbasyonla neredeyse hiç kurtulmadığı için (36 yönde 0,989 ile 1,000 arasında), ham oran, temiz hata artı bir eksi o hatayla ölçeklenmiş koşullu orana 0,41 puandan küçük bir farkla eşittir. Gelen transfer ayrıca kaynak mimarisini değil hedefin kendi kırılabilirliğini izlemektedir (üç hedef üzerinde $r = 0,986$); bu da asimetriyi güçlü CNN saldırılarının değil, daha zayıf hedefin bir özelliği olarak yeniden çerçevelemektedir. Koşullu ayrıştırma tabloyu tamamlamaktadır: mutlak gürbüzlük, temiz doğruluk ile koşullu duyarlılığın çarpımına birebir ayrışır ve ikisini birden raporlamak önemlidir, çünkü mutlak sıralama değişmediği hâlde iki çarpan arasındaki pay önceki tek koşuluk kontrol noktalarımız ile üç yeni koşu arasında değişmiştir.

Üç negatif sonuç raporluyoruz. Ölçekten bağımsız seyreklik farkları mekânsal lokalite farkına karşılık gelmemektedir; dört mekânsal ölçütten üçü sıfır sonuç vermiştir. CLS dikkat entropisi $n = 1000$ 'de saldırı altında ölçülebilir biçimde değişmemektedir. ViT'e özgü bir transfer saldırısı olan Jeton Gradyanı Düzenleştirme (TGR) [12] bu rejimde transfer kazancı sağlamamakta, eşleşmiş bütçede düz MI-FGSM'ye yenilmektedir. İki davranışsal fark ise ayakta kalmaktadır. Gradyan seyrekliği farkları bağımsız kontrol noktası kümelerinde tekrarlanmakta, mimariden değil çekişmeli eğitimden kaynaklanmakta ve yalnızca mutlak kosinüste var olan bir hizalanma farkıyla birlikte gelmektedir. Çekişmeli hasar iki mimaride nitel olarak farklı derinliklerde birikmektedir ve ölçülen kayma profili, hesaplamada kullanılan jeton (token) agregasyonuna bağlıdır.

Çalışmayı, bu ölçümlerden çıkan kısa bir raporlama gereklilikleri listesiyle kapatıyoruz.

Bu çalışmanın ön sürümü ATEEC 2026'ya gönderilmiştir [13]. O sürüm koşullu ayrıştırmayı, dört protokolü transfer karşılaştırmasını, gradyan yapısı ölçümlerini ve blok bazlı kayma profillerini yalnızca CIFAR-10 üzerinde raporlar ve

bunları ön sonuç olarak niteler. Bu makale iki veri kümesi daha, ikinci bir tehdit modeli, Bölüm IV'teki cebirsel özdeşlik, kontrol noktası seçimi ablasyonu, dönüştürücüye özgü transfer saldırısı ve ön kayıtlı analiz protokolünü ekler; ayrıca önceki sürümün bir iddiasını düzeltir: mimariler temiz doğrulukta eşitlendiğinde asimetrisinin yönü kararlı değildir.

Bölüm II çekişmeli değerlendirme pratiğini ve mimari karşılaştırma çalışmalarını gözden geçirmektedir. Bölüm III eğitim protokolünü, koşullama protokollerini ve ölçümleri tanımlamaktadır. Bölüm IV sonuçları raporlamakta, Bölüm V çıkarımları ve sınırlılıkları tartışmakta, Bölüm VI çalışmayı sonuçlandırmaktadır.

II. İLGİLİ ÇALIŞMALAR

A. Çekişmeli Saldırılar

Çekişmeli saldırılar, yanlış sınıflandırmaya yol açan en küçük pertürbasyonları bulmayı amaçlar. Hızlı Gradyan İşaret Yöntemi (FGSM) [2], kayıp gradyanının işaretini izleyerek pertürbasyonu tek adımda üretir; pertürbasyon büyüklüğü L_∞ normu altında sınırlıdır. İzdüşümlü Gradyan İnişi (PGD) [14] FGSM'yi yinelemeli eniyilemeyle genişletir: birden çok gradyan-işaret adımı atar ve her adımdan sonra ϵ -topuna geri izdüşüm yapar (biçimsel tanımlar Bölüm III-C).

Carlini-Wagner (C&W) saldırısı [15] çekişmeli örnek üretimini bir eniyileme problemi olarak kurar; genellikle daha yüksek başarı oranlarına ulaşır ancak hesaplama maliyeti artar. Daha yakın tarihli AutoAttack [16], güvenilir bir gürbüzlük değerlendirmesi sağlamak için birden çok saldırı stratejisini (APGD-CE, APGD-T, FAB-T, Square) birleştirir ve kıyaslamada fiilî standart hâline gelmiştir.

B. Savunma Mekanizmaları

Çekişmeli eğitim (adversarial training, AT) [14] en etkili savunma olmayı sürdürmektedir; modeli her partide üretilen çekişmeli örneklerle eğitir:

$$\min_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\max_{\|\delta\|_\infty \leq \epsilon} \mathcal{L}(f_{\theta}(x + \delta), y) \right] \quad (1)$$

TRADES [17], doğal doğruluk ile gürbüzlük arasında kuiramsal temelli bir ödünleşim sunar:

$$\mathcal{L}_{\text{TRADES}} = \mathcal{L}_{\text{CE}}(f(x), y) + \beta \cdot \text{KL}(f(x) \| f(x_{\text{adv}})) \quad (2)$$

burada β ödünleşim parametresidir.

MART [18], yanlış sınıflandırılan örnekleri eğitim sırasında vurgulayarak ele alır. Diğer yaklaşımlar arasında girdi dönüşümü [19], rastgeleleştirilmiş yumuşatma yoluyla sertifikalı savunmalar [20] ve topluluk yöntemleri [21] bulunur. Sertifikalı gürbüzlükteki güncel gelişmeler arasında, çok adımlı savunmalarla sertifika yarıçaplarını iyileştiren Uyarlanabilir Rastgeleleştirilmiş Yumuşatma [22] sayılabilir.

C. CNN Gürbüzlüğü

CNN mimarilerinin çekişmeli gürbüzlüğü kapsamlı biçimde incelenmiştir. Madry vd. [14], PGD saldırılarıyla çekişmeli eğitimin güçlü deneysel gürbüzlük sağladığını göstermiştir. RobustBench lider tablosu [23] en güncel CNN gürbüzlüğü

izlemektedir; CIFAR-10'da en yüksek gürbüz doğruluğa WideResNet türevleri ulaşmaktadır.

Model kapasitesinin ulaşılabilir gürbüzlkle ilişkili olduğu gösterilmiştir [14]; daha geniş ve derin ağlar daha iyi gürbüz doğruluk sergilemektedir. Mimariye özgü bulgular arasında atlama bağlantılarının çekişmeli transfer edilebilirlikteki rolü [24] ve çekişmeli eğitimin büyük ölçekte yol açtığı ayrık parti-normalizasyonu istatistikleri [25] sayılabilir; ilişkili olarak, yardımcı parti-normalizasyonu dalları çekişmeli örneklerin temiz doğruluğu artırmasına imkân vermektedir [26]. Çekişmeli eğitimin girdi-gradyan yapısının kendisini de yeniden biçimlendirdiği, daha algısal hizalı [27] ve daha seyrek [28] gradyanlar ürettiği bilinmektedir.

D. Görü Dönüştürücüsü Gürbüzlüğü

Vaswani vd. [4] tarafından tanıtılan öz-dikkat mekanizması üzerine kurulan Görü Dönüştürücüsü [3], görüntüleri yama dizileri olarak işler; iç temsilleri CNN'lerden katman katman ölçülebilir biçimde ayrıştır [29]. İlk çalışmalar, küresel alıcı alan sayesinde ViT'lerin bazı içkin gürbüzlük özellikleri sergilediğini öne sürmüştür [30]. Bai vd. [6], dönüştürücülerin CNN'lerden daha gürbüz olup olmadığını sistematik olarak incelemiş; adil eğitim tarifleri altında çekişmeli gürbüzlükte üstün olmadıklarını, buna karşılık öz-dikkate atfedilen dağılım kayması gürbüzlüğünde öne geçtiklerini bulmuştur. Benz vd. [7], MLP-Mixer'i de içeren erken bir doğrudan karşılaştırma raporlamış ve farkları frekans tercihlerine bağlamıştır. Sonraki çalışmalar ViT'lerin özellikle gradyan tabanlı saldırılara karşı savunmasız kaldığını [8], yama hedefli saldırıların dikkat mekanizmasını doğrudan istismar ettiğini [31] ve dikkatin yama pertürbasyonları altında ölçülebilir biçimde kaydığını [32] ortaya koymuştur.

Shao vd. [33], çekişmeli eğitimin ViT gürbüzlüğünü artırabildiğini ve ViT özniteliklerinin yüksek frekanslı içeriğe daha az dayandığını göstermiştir; eğitim kararsızlığı kaynaklı güçlükler ise sürmektedir. ViT'lerin yaygın bozulmalara ve örtmelere karşı gürbüzlüğü de betimlenmiştir [34]. Daha yakın zamanda Jain vd. [35], ViT'e özgü eğitim güçlüklerini ele alan AAS-AT yöntemini önermiş; difüzyonla artırılmış çekişmeli eğitimle ViT'lerin küçük ölçekli veri kümelerinde WideResNet'leri geçebildiği bildirilmiştir [36]. Zhu vd. [37], gradyan normalizasyonu ölçekleme ve yüksek frekans uyarlamasıyla ViT'lere yönelik transfer edilebilir saldırıları güçlendirmiştir. Bu ilerlemelere karşın, birleşik değerlendirme çerçeveleri altında kapsamlı CNN ile ViT davranışsal karşılaştırmaları sınırlı kalmaktadır.

E. Transfer Saldırıları

Çekişmeli örnekler modeller arasında sıklıkla transfer olur ve bu, kara kutu saldırılarını mümkün kılar [38]. Transfer edilebilirlik; model mimarisi, eğitim verisi ve saldırı yöntemi gibi etkenlere bağlıdır [39]. Temel transfer çalışmaları transfer edilebilirliği zaten doğru sınıflandırılan örnekler üzerinde değerlendirmekte [40], standart saldırı makaleleri de başarı oranlarını aynı gerekçeyle koşullamaktadır [41]; güncel değerlendirme kılavuzları bu tür protokol seçimlerini açık hâle getirmektedir [42]. Yakın tarihli iki kıyaslama da aynı yönde

ilerlemektedir: TA-Bench [43] otuzu aşkın transfer saldırısını ortak bir vekil ve kurban model havuzu üzerinde standartlaştırmakta, Yu vd. [44] ise transfer edilebilirliğin tek bir mimari ailesi içinde ölçüldüğünde dizgesel olarak abartıldığını bildirmekte ve buna karşılık üç değerlendirme protokolü önermektedir. Her ikisi de puanlama kuralını sabit tutup saldırıyı ve model havuzunu değiştirmektedir. Bu makale bunun tersini yapmaktadır: modeller, veri ve saldırı bütçesi sabittir, yalnızca puanlama kuralı değişmektedir; bu da protokolün kendi katkısını yalıtmakta ve ortaya çıkan kestirimler arasındaki aritmetik bağıntıyı yazmayı mümkün kılmaktadır. Topluluk tasarımında Ravikumar vd. [9], transfer ölçümünü tam olarak modeller arasındaki doğruluk farklarını hesaba katmak için her iki modelin de doğru sınıflandırdığı örneklerle sınırlamaktadır; koşullu metriğimizin kontrol ettiği karıştırıcının aynı.

CNN'ler ile ViT'ler arasındaki mimariler arası transfer artan ilgi görmektedir. Mahmood vd. [8], her-ikisi-doğru protokolüyle mimariler arası transferi ölçmüş ve dikkat çekici ölçüde düşük CNN $\leftrightarrow$ ViT transferi bulmuştur; Naseer vd. [10], ViT'lerde üretilen çekişmeli örneklerin geleneksel saldırılarla zayıf transfer ettiğini göstermiş ve ViT kaynaklı transferi iyileştirmek için öz-topluluk ve jeton arıtma önermiştir; Wei vd. [45] dikkat gradyanlarını atlayarak ve yama bazlı seyreltmeyle ViT kaynaklı transferi geliştirmiştir. Bunların üzerine Jeton Gradyanı Düzenleştirme (TGR) [12], ViT'in dikkat bileşenlerini kullanarak transfer edilebilir örnekler üretmekte; Momentum Bütünleşik Gradyanlar (MIG) [46] hem ViT'lerde hem CNN'lerde gelişmiş transfer sağlamaktadır. Chen vd. [47], mimariler arası transferi etkileyen etkenleri sistematik olarak incelemekte ve mimari tümevarım önyargılarının (CNN'lerin yüksek, ViT'lerin düşük frekanslı bilgiyi tercih etmesi) transfer başarısını önemli ölçüde etkilediğini bulmaktadır. Waseda vd. [48] transfer sonuçlarını bir adım daha ayırmakta, hedefin kaynağın tam olarak aynı hatasını tekrarlayıp tekrarlamadığına göre sınıflandırmakta ve her iki durumun birbirine yakın modeller arasında bile görüldüğünü bildirmektedir. Bu transfer örüntülerini anlamak, gürbüz topluluk sistemleri geliştirmek ve gerçek dünya saldırı senaryolarını değerlendirmek için önemlidir.

F. Araştırma Boşluğu

Tekil çalışmalar CNN ve ViT gürbüzlüğünü ayrı ayrı incelemiş ve adil olmayan CNN ile dönüştürücü karşılaştırmalarının tuzaklarına daha önce dikkat çekilmiş olsa da [6], [49], mevcut karşılaştırmalı çalışmalar gürbüzlük skorlarını çoğunlukla tek başına, üstelik tutarsız pertürbasyon bütçeleri, saldırı yapılandırmaları veya model ölçekleriyle raporlamakta; karşılaştırmayı davranışsal analizle eşleştirmemektedir. Yakın tarihli bir çalışma ViT ve CNN çekişmeli gürbüzlüğünü doğrudan karşılaştırmaktadır [50]; çalışmamız, tam test kümesinde Auto-Attack ve eşleştirilmiş istatistiklerle değerlendirme yapması, transfer ölçümünü temiz doğruluk farklarına karşı kontrol etmesi ve karşılaştırmaya gradyan ile öznitelik düzeyinde davranışsal analizler eklemesiyle ayrılmaktadır.

Değerlendirme yöntemibilimi literatürü, gürbüzlüğün nasıl ölçüldüğünün neye varıldığını belirlediğini defalarca göstermiştir: Carlini ve ark. [51] gürbüzlük değerlendirmesinin başarısızlık kiplerini derlemekte, Tramèr ve ark. [52] ise sabit

saldırıları altında gürbüz sayılan savunmaların uyarlanabilir saldırılara yenildiğini göstermektedir. Bu çalışmalar saldırı gücüyle, yani ölçümün yeterince güçlü olup olmadığıyla ilgilidir. Bizim sorduğumuz soru dikeydir ve görebildiğimiz kadarıyla ölçülmemiştir: saldırı gücü sabit tutulduğunda yalnızca *puanlama kuralı* sonucu ne kadar oynatır? Çalışmamız bu soruyu doğrudan ele almakta ve onu inceleme nesnesi hâline getirmektedir. Transfer değerlendirmesini doğru sınıflandırılan örneklerle koşullamak yerleşik pratiktir [8], [9], [40], [41] ve tekil makaleler bir protokol seçip devam etmektedir. Eksik olan, bu seçimin ne kadar önemli olduğuna dair kontrollü bir tahmindir. Bunu; modelleri, veriyi, tehdit modelini ve saldırı bütçesini sabit tutup yalnızca protokolü değiştirerek sağlıyor ve ölçülen asimetrisinin dört protokol boyunca $15,01 \pm 0,84$ puan oynadığını buluyoruz; bu, 4,4 katlık bir yayılımdır. Buna karşılık her iki mimariyi yeniden eğitmek aynı niceliği 1,5 puandan az oynatmaktadır. Ayrıca koşulsuz oranlardaki karıştırıcının bir eğilim değil bir özdeşlik olduğunu gösteriyoruz ($r_{\text{ham}} - r_{\text{koş}} = e(1 - r_{\text{koş}})$; 36 yönde 0,41 puandan küçük hatayla doğrulandı). Bu, bilinen nitel bir uyarıyı yayımlanmış sonuçlara doğrudan uygulanabilir bir düzeltmeye dönüştürmektedir.

Bu literatürde tekrar eden ve tasarımıımızın varsaymak yerine test etmeye imkân verdiği üç iddia daha vardır: CNN gradyanlarının mekânsal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini bozduğu ve dönüştürücüye özgü transfer saldırılarının [10], [12] mimariler arası transferi iyileştirdiği. Her birini doğrudan ölçüyoruz ve hiçbirini bizim kurulumumuzda geçerli çıkmıyor; bu sonuçları raporluyoruz, çünkü protokole duyarlı bir karşılaştırmanın kaldıramayacağı şey tam da bu türden test edilmemiş bir varsayımdır.

III. YÖNTEM

A. Tehdit Modeli

Saldırganın girdi görüntülerini sınırlı bir bölge içinde pertürbe edebildiği standart L_∞ tehdit modelini ele alıyoruz:

$$\mathcal{B}_\epsilon(x) = \{x' : \|x' - x\|_\infty \leq \epsilon\} \quad (3)$$

CIFAR-10 için yerleşik uzlaşımları izleyerek [11], [23] birincil pertürbasyon bütçesi olarak $\epsilon = 8/255 \approx 0,031$ kullanıyoruz; epsilon taraması analizi için $\epsilon \in \{2/255, 4/255, 16/255\}$ değerlerinde ek tam-test PGD-10 değerlendirmeleri yapılmaktadır.

Hem beyaz kutu (tam model erişimi) hem kara kutu (transfer saldırısı) senaryolarında değerlendirme yapıyoruz. Beyaz kutu saldırılarda saldırgan model mimarisi ve parametrelerine tam olarak hâkimdir. Transfer saldırılarında çekişmeli örnekler bir kaynak modelde üretilir ve farklı bir hedef modelde değerlendirilir.

B. Model Mimarileri

a) *CNN Modelleri*: **ResNet-18** [5]: Artık bağlantılı, yaygın kullanılan bir taban CNN; 11,2M parametre içerir. CIFAR-10 için tasarlanmış standart mimariyi (7×7 yerine başlangıçta 3×3 evrişim) kullanıyoruz.

WideResNet-28-10 [53]: ResNet'in 36,5M parametrelili daha geniş bir türevi; CIFAR-10'da çekişmeli gürbüzlük için

en güncel mimariyi temsil eder. Goyal vd.'nin [54] RobustBench [23] üzerinden dağıtılan önceden eğitilmiş gürbüz kontrol noktasını kullanıyoruz; bu model ek etiketsiz veriyle ve bizim standart çekişmeli eğitimimizden daha güçlü bir tarifile eğitildiğinden, eşleşmiş bir karşılaştırma değil bir referans noktası işlevi görmektedir.

b) *Görü Dönüştürücüsü Modelleri*: **ViT-Tiny**: *timmm* kütüphanesindeki [55] ViT-Tiny mimarisini, girdileri çift doğrusal olarak 224×224 'e büyütürük CIFAR-10'a uyarlıyoruz. Mimari 16×16 yamalar (görüntü başına 196 yama), 192 boyutlu gömmeler, her biri 3 dikkat başlı 12 dönüştürücü bloğu ve 4 MLP oranı kullanır; toplam 5,7M parametredir. Model CIFAR-10 üzerinde *sıfırdan* (ImageNet ön eğitimi olmadan) temel veri artırmayla (rastgele kırpmaya ve yatay çevirme) eğitilmekte, ardından çekişmeli ince ayara tabi tutulmaktadır. Küçük veri kümelerinde ViT gürbüzlüğünün eğitim tarifine duyarlı olduğu bilindiğinden [56], [57], mimari düzeyindeki sonuçlarımız en iyi şekilde eğitilmiş ViT'ler için değil, *bu temel eğitim tarihi altında* geçerli okunmalıdır.

C. Saldırı Yöntemleri

a) *FGSM*: Adım boyu pertürbasyon bütçesine eşit tek adımlı saldırı:

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}_{CE}(f(x), y)) \quad (4)$$

b) *PGD*: Adım boyu $\alpha = 2/255$ ve rastgele başlangıçlı yinelemeli saldırı:

$$x^{t+1} = \Pi_{\mathcal{B}_\epsilon(x)}(x^t + \alpha \cdot \text{sign}(\nabla_{x^t} \mathcal{L}_{CE}(f(x^t), y))) \quad (5)$$

burada $x^0 = x + \mathcal{U}(-\epsilon, \epsilon)$. Bu çalışma boyunca hem çekişmeli eğitimde hem değerlendirmede PGD-10 (10 yineleme) kullanılmaktadır (Tablo I).

c) *AutoAttack*: APGD-CE (çapraz entropi kayıplı Auto-PGD), APGD-T (hedefli DLR kayıplı Auto-PGD), FAB-T (hedefli Hızlı Uyarlanabilir Sınır saldırısı) ve Square (skor tabanlı kara kutu saldırısı) bileşenlerini birleştiren standartlaştırılmış topluluk saldırısı AutoAttack [16] kullanılmaktadır. Bu topluluk, gürbüzlük değerlendirmesi için standartlaştırılmış güçlü bir kıyaslamadır.

D. Savunma Yöntemleri

a) *Çekişmeli Eğitim (AT)*: Temiz ve çekişmeli kayıpları birleştiren karma bir çekişmeli eğitim amacı kullanıyoruz:

$$\mathcal{L} = (1 - \lambda) \mathcal{L}_{CE}(f_\theta(x), y) + \lambda \mathcal{L}_{CE}(f_\theta(x_{adv}), y) \quad (6)$$

burada $\lambda = 0,5$, standart sınıflandırma başarımları ile çekişmeli gürbüzlüğü dengeler. İç enbüyükleme, çekişmeli örnekleri PGD-10 ile üretir ($\alpha = 2/255$, $\epsilon = 8/255$); saldırı üretimi model eğitim kipindeyken yapılır, böylece saldırı üretimi ile parametre güncellemesi tutarlı parti-normalizasyonu istatistikleri görür ve standart çekişmeli eğitim gerçeklemeleri izlenir [58]. Pratikte yaygın benimsenen bu karma amaç, gürbüzlük kazanılırken temiz doğruluğun korunmasına yardım eder; yalnızca çekişmeli örneklerle eğitim doğal başarımları düşürebilir. TRADES [17] gibi alternatif formülasyonlar kuramsal temelli ödünleşim mekanizmaları sunsa da, bu çalışma mimari etkileri savunmaya özgü etkileşimlerden yalıtılmak için standart çekişmeli eğitime odaklanmaktadır.

E. Eğitim Protokolü

a) *Temiz Eğitim*: CNN'ler için SGD eniyileycisi; başlangıç öğrenme oranı 0,1, kosinüs tavlama çizelgesi [59], ağırlık sönümü 5×10^{-4} ve 200 epok. ViT'ler için AdamW eniyileycisi [60]; başlangıç öğrenme oranı 10^{-3} , kosinüs tavlama, ağırlık sönümü 0,05 ve 200 epok.

b) *Çekişmeli Eğitim*: Temiz eğitilmiş kontrol noktalarından başlayarak düşürülmüş öğrenme oranlarıyla ince ayar yapıyoruz: CNN'ler SGD ile 10^{-3} öğrenme oranı ve kosinüs tavlama ile en çok 100 epok; ViT'ler AdamW ile aynı öğrenme oranı ve çizelgeyle eğitilir. Gradyanlar küresel L_2 normu 10^4 'a kırılır ve kaybı sonlu olmayan partiler atlanır. Veri artırma, 4 piksel dolgu rastgele kırma ve yatay çevirmedir; tüm modeller $[0, 1]$ aralığında ham piksel girdisi tüketir (ortalama/std normalizasyonu yoktur) ve saldırılar ile epsilon bütçeleri doğrudan bu piksel uzayında işler. Eğitim parti boyu CNN için 128, ViT için 64'tür (değerlendirme parti boyları analize göre değişir). Erken durdurma 20 sabır ve 0,1 puanlık iyileşme eşliğiyle uygulanır.

c) *Doğrulama Bölmesi ve Tekrarlar*: Model seçimi ve erken durdurma, sabit 2.000 örneklik bir doğrulama bölmesindeki PGD-10 çekişmeli doğruluğuyla yürütülür. Bu bölme bir kez çekilir (tohum 777; indeksler kodla birlikte saklanır), çalışmadaki her model tarafından paylaşılır ve hem temiz hem çekişmeli aşamanın eğitim kümesinden çıkarılır; dolayısıyla hiçbir kontrol noktası, üzerinde eğitildiği veriyle seçilmez. Test kümesine yalnızca nihai art-değerlendirmelerde dokunulur. Tüm boru hattını (temiz ön eğitim + çekişmeli ince ayar) mimari başına üç kez, bağımsız tohumlarla tekrarlıyoruz (ResNet-18 için 1001 ile 1003, ViT-Tiny için 2001 ile 2003) ve koşulları indekse göre eşliyoruz; böylece her mimariler arası karşılaştırma aynı tekrar altında eğitilmiş modeller arasındadır. Tüm tablolar bu üç koşulun ortalamasını ve standart sapmasını raporlar.

Bölüm IV-A'teki bir karşılaştırma için, bu protokol benimsenmeden önce eğitilmiş ve doğrulama bölmesi temiz ön eğitimin parçası olmuş daha eski bir kontrol noktası çiftine de başvuruyoruz. Bunları sonuç olarak değil, açıkça bir karışıklık olarak raporluyoruz; çünkü iki kontrol noktası kümesi arasındaki fark, tek koşul bir sonucun ne kadar hareket edebileceğine dair kendi başına kanıttır.

F. Değerlendirme Metrikleri

a) *Temel Metrikler*: Modelleri üç standart metrikle değerlendiriyoruz: temiz doğruluk (pertürbe edilmemiş test görüntülerinde sınıflandırma başarıımı), gürbüz doğruluk (çekişmeli örneklerde başarıım) ve saldırı başarı oranı (temizde doğru sınıflandırılan görüntülerin saldırı sonrası yanlış dönen oranı). Beyaz kutu değerlendirmelerde ek olarak *koşullu yanılma oranını* (temizde doğru sınıflandırılan örneklerin saldırının devirdiği kesri) ve tümleyen olan koşullu sağkalımı raporluyoruz. Örnek bazındaki kayıtlarımızda hem PGD hem AutoAttack, temizde yanlış sınıflandırılan örnekleri gürbüz olmayan saydığından, mutlak gürbüz doğruluk birebir gürbüz = temiz $\times$ koşullu sağkalım olarak çarpanlarına ayrılır; bu, gürbüzlük farklarını temiz doğruluk bileşeni ile koşullu duyarlılık bileşenine ayırmamızı sağlar. Son olarak *her ikisi*

doğru altkümesindeki (karşılaştırılan iki modelin de temizde doğru sınıflandırdığı örnekler) doğrulukları raporluyoruz; bu, ortak bir örnek kümesi üzerinde birebir eşleştirilmiş karşılaştırma sağlar.

b) *Transfer Metrikleri*: Birincil transfer metriğimiz *koşullu yanılma oranıdır*: hedef modelin temizde doğru sınıflandırdığı örnekler içinde, kaynak modelde üretilen çekişmeli örneklerle yanlış dönenlerin oranı. Kaynak model f_S 'ye karşı üretilen $\{x_{adv}^S\}$ örnekleri için hedef f_T 'ye koşullu transfer oranı:

$$KYO = \frac{\sum_i \mathbf{1}[f_T(x_i) = y_i] \mathbf{1}[f_T(x_{adv,i}^S) \neq y_i]}{\sum_i \mathbf{1}[f_T(x_i) = y_i]} \quad (7)$$

Transfer değerlendirmesini doğru sınıflandırılan örneklerle koşullamak yerleşik pratiktir [8], [9], [40]–[42] ve mimariler arası karşılaştırmalarda zorunludur: ham yanlış sınıflandırma oranı $\frac{1}{n} \sum_i \mathbf{1}[f_T(x_{adv,i}^S) \neq y_i]$ hedefin temiz hatasını içerir; temiz doğruluğu düşük bir hedef, saldırı hiç ek örnek devirmese bile transfere daha "kırılgan" görünür. Ham oranı, şeffaflık ve bu karıştırıcının boyutunu nicellemek için ikincil metrik olarak raporluyoruz. Koşullama kümesinin kendisi bir protokol seçimi olduğundan, iki yerleşik alternatifi de raporluyoruz: kaynak ve hedefin ikisinin de doğru sınıflandırdığı örneklerle koşullayan *her ikisi doğru* protokolü [8], [9] ve saldırının kaynaktan beyaz kutu anlamında başarılı olduğu hedef-doğru örneklerle koşullayan *başarılı kaynak* protokolü. Bölüm IV-B'in gösterdiği gibi bu protokoller nitel olarak farklı asimetri sonuçları verebilir; bu yüzden protokolü bir gerçekleştirme ayrıntısı değil, raporlanan sonucun parçası olarak ele alıyoruz. Transfer oranları tam test kümesinde (10.000 örnek) örnek bazında kayıtlı hesaplanır ve örnekler üzerinde yüzdelik bootstrap ile %95 güven aralıkları verilir (10.000 yeniden örnekleme).

c) *Gradyan Analizi Metrikleri*: Gradyan özelliklerini, büyüklükler değerlendirme parti boyundan bağımsız olsun diye örnek başına kayıplarla hesaplayarak üç tamamlayıcı metrik ailesiyle inceliyoruz. Gradyan normu ($\|\nabla_x \mathcal{L}\|_2$ ve $\|\nabla_x \mathcal{L}\|_\infty$) toplam duyarlılık büyüklüğünü ölçer. Gradyan seyrekliği, ölçekten bağımsız ölçülerle nicelenir: Hoyer seyrekliği, $|g|$ 'nin Gini katsayısı ve örnek maksimumunun %1'inin altındaki bileşen oranı, çünkü sabit mutlak eşikler gradyan ölçeğini yapıyla karıştırır; Hoyer ve Gini, Hurley ve Rickard'ın [61] biçimselleştirdiği ölçek-değişmezliği aksiyomlarını sağlar. Gradyan hizalanması, örnekler arasındaki ortalama ikili mutlak kosinüs benzerliğidir (500 analiz örneğinin tüm çiftleri üzerinden):

$$\text{Hizalanma} = \frac{1}{N(N-1)} \sum_{i \neq j} \left| \frac{\nabla_{x_i} \mathcal{L} \cdot \nabla_{x_j} \mathcal{L}}{\|\nabla_{x_i} \mathcal{L}\| \|\nabla_{x_j} \mathcal{L}\|} \right| \quad (8)$$

Mutlak kosinüsü kullanıyoruz, çünkü paylaşılan duyarlılık *eksenleri* işaretten bağımsız olarak saldırı geometrisi için önemlidir; evrensel pertürbasyon argümanlarının ek olarak gerektirdiği şey işaret tutarlılığı olduğundan işaretli ortalama kosinüsü de raporluyoruz; bu değer her model için sifıra yakın çıkmaktadır (Bölüm IV-F). Yüksek mutlak hizalanma, girdiler arasında benzer pertürbasyon eksenlerine işaret eder.

d) *Mekânsal Lokalite Metrikleri*: Seyreklik kaç gradyan bileşeninin büyük olduğunu ölçer ama bunların görüntüde nerede durduğunu hakkında bir şey söylemez; bu yüzden mekânsal yapıyı, kanal toplamı enerji haritası $e = \sum_c (\nabla_x \mathcal{L})_c^2$ (toplamı 1'e normalize) üzerinde ayrıca ölçüyoruz. Enerjinin %50'sini ve %90'ını toplayan en küçük piksel oranını (küçük değer = daha lokalize), e 'nin piksel dağılımı olarak Shannon entropisini (düşük değer = daha lokalize) ve enerji bitişik piksellerde kümelenildiğinde pozitif olan 4-komşuluklu Moran's I 'yı raporluyoruz. Dördü de gradyan ölçeğinden bağımsızdır ve örnek başına hesaplanır; böylece iki mimari aynı girdiler üzerinde eşleştirilmiş testlerle karşılaştırılabilir.

e) *Katman Analizi için Jeton Agregasyonu*: Bir dönüş-türücü bloğu jeton başına bir vektör üretir; bloğu özetlemek bir seçim gerektirir. Üçünü raporluyoruz: yalnız CLS jetonu, 196 yama jetonunun ortalaması ve tüm jetonların örnek başına düzleştirilmiş birleşimi. CNN'de her artık blok çıktısı mekânsal boyutlar üzerinden düzleştirilir. ViT için üçünü birden raporluyoruz; çünkü Bölüm IV-G'ün gösterdiği gibi, farklı kayma büyüklükleri verirler ve minimumu farklı derinliklere yerleştirirler.

f) *Dikkat Metrikleri*: ViT için her bloğun softmax sonrası CLS→yama dikkat satırını başlar üzerinden ortalayarak çıkarıyoruz. Dikkatin ne kadar geniş yayıldığını ölçen Shannon entropisini ve saldırı altındaki yer değiştirmesini (temiz ile çekişmeli dikkat dağılımları arasındaki, 1 ile sınırlı toplam varyasyon uzaklığı) raporluyoruz. İkisi de örnek başına hesaplanıp ortalanan; koşu başına $n = 1000$ örnek.

g) *ViT'e Özgü Transfer Saldırısı*: Transfer sonuçlarının mimariden bağımsız saldırılara bağlı olup olmadığını test etmek için kaynak örnekleri ek olarak Jeton Gradyanı Düzenleştirme (TGR) [12] ile üretiyoruz; TGR, geri yayılım sırasında dikkat, QKV ve MLP yollarındaki jeton-gradyan tensörlerinin uç değerli girdilerini sıfırlar ve kalan gradyanı $\gamma = 0,5$ ile ölçekler. Gerçeklememiz yöntemi CIFAR-10 ViT sarmalayıcımıza ve bu makale boyunca kullanılan bütçeye ($\epsilon = 8/255$, $\alpha = 2/255$, 10 adım, momentum 1,0) uyarlanmaktadır; özgün ImageNet varsayılanları kullanılmamıştır ve bu yüzden bir uyarılma olarak raporlanmaktadır. Düz MI-FGSM [41] örnekleri aynı koşuda aynı örnekler üzerinde üretilir; bu, birebir aynı bütçede eşleştirilmiş bir kontrol sağlar.

h) *Öznitelik Bozunması Metrikleri*: Çekişmeli pertürbasyonların ViT temsillerini katmanlar boyunca nasıl etkilediğini incelemek için her ℓ katmanında üç metrik hesaplıyoruz. Öznitelik kosinüs benzerliği, temsilin yönünün ne ölçüde korunduğunu ölçer:

$$\text{Benz}_\ell = \frac{h_\ell(x) \cdot h_\ell(x_{adv})}{\|h_\ell(x)\| \|h_\ell(x_{adv})\|} \quad (9)$$

burada h_ℓ , ℓ katmanındaki temsili göstermektedir. Öznitelik norm değişimi ise büyüklük etkilerini yakalar:

$$\Delta_\ell = \frac{\|h_\ell(x_{adv})\| - \|h_\ell(x)\|}{\|h_\ell(x)\|} \times 100\% \quad (10)$$

Öznitelik L_2 uzaklığı ($\|h_\ell(x) - h_\ell(x_{adv})\|_2$) mutlak sapmayı nicelemektedir.

Tablo I: CIFAR-10'da ana gürbüzlük sonuçları ($\epsilon = 8/255$); mimari başına üç bağımsız eğitim koşusu üzerinden ortalama $\pm$ std. AA, standart takımla AutoAttack anlamına gelmektedir.

Model	Savunma	Param.	Temiz	FGSM	PGD-10	AA
<i>CNN Modelleri</i>						
ResNet-18	Yok	11,2M	95,25±0,15	40,29±1,77	0,03±0,03	–
ResNet-18	AT	11,2M	85,78±0,36	53,46±0,08	44,11±0,50	37,93±0,14
WRN-28-10	AT [†]	36,5M	89,48	70,91	66,92	62,76
<i>Görü Dönüştürücüsü Modelleri</i>						
ViT-Tiny	Yok	5,7M	80,09±0,60	6,10±1,47	0,05±0,05	–
ViT-Tiny	AT	5,7M	73,53±0,55	36,31±0,42	32,69±0,22	29,14±0,40

[†]Gowal vd.'nin [54] RobustBench [23] üzerinden dağıtılan gürbüz kontrol noktası; tek harici kontrol noktası olduğundan standart sapma yoktur.

Temiz/FGSM/PGD-10: yerel tam-test değerlendirmelerimiz; AA: RobustBench raporlu değer (üzerinde AutoAttack yeniden koşulmadı).

G. İstatistiksel Doğrulama

Dört varyans kaynağını ayırıyor ve her birini geçerli olduğu yerde raporluyoruz. Mimari karşılaştırmalarını ilgilendiren *eğitim koşusu varyansıdır*: her tablo, mimari başına üç bağımsız koşunun ortalamasını ve standart sapmasını verir (Bölüm III-E). *Saldırı başlatma varyansı*, PGD-10'un sabit bir altkümede üç saldırı tohumuyla (42, 123, 456) yeniden koşulmasıyla ölçülür; değerlendirilen örnekler ve sıraları sabittir, tohumlar yalnızca saldırının rastgele başlangıcını değiştirir. *Protokol varyansı*, koşullama protokolleri arasındaki yayılımıdır ve gürültü değil sonuç olarak ele alınır (Bölüm IV-B). *Kontrol noktası seçimi varyansı*, sabit bir yörüngeden son kontrol noktasını seçen çevrimdışı kuralın (doğrulama bölmesi, erken durdurma sabrı ve eğri yumuşatması) ürettiği yayılımdır; yörünge sabit tutularak on sekiz bileşim üzerinde ölçülür. Bölüm IV-I büyüklüklerini karşılaştırmaktadır.

Aynı örneklerin iki koşul altında puanlandığı her yerde eşleştirilmiş testler kullanılır: eşleştirilmiş ikili sonuçlar için McNemar'ın kesin testi, üç seyreklik ölçüsü için Holm düzeltmeli Wilcoxon işaretli sıra testi, farklar için eşleştirilmiş bootstrap güven aralıkları (10.000 yeniden örnekleme) ve her-ikisi-doğru transfer farkı için işaret çevirme permütasyon testi (20.000 permütasyon). Eşdeğerlik iddiaları iki tek yönlü test (TOST) ile yapılır. Birincil marj ± 2 puandır ve karşılaştırmalardan önce, PGD doğruluğundaki koşumlar arası değişimden küçük farkların pratikte eşdeğer sayılması ilkesiyle sabitlemiştir; her eşdeğerlik iddiası ayrıca ± 1 ve ± 3 puanda da raporlanır, böylece hüküm marja karşı okunabilir. Tüm değerlendirme ve analiz betikleri rastgele tohumları sabitler (tohum 42, CUDA determinizm bayrakları dâhil); dolayısıyla raporlanan her sayı, yayımlanan boru hattından yeniden üretilebilir.

IV. DENEYLER

A. Gürbüzlük Karşılaştırması

Tablo I, değerlendirilen tüm modeller için ana gürbüzlük karşılaştırmalarını sunmaktadır. Modellerimize ait her hücre, mimari başına üç bağımsız eğitim koşulunun ortalaması ve bu koşullar üzerindeki standart sapmadır; her koşu 10.000 örneklik tam test kümesinde değerlendirilmiştir.

CNN her saldırı altında *mutlak* bir gürbüzlük üstünlüğü taşımaktadır: ResNet-18 AT, AutoAttack altında %37,93 $\pm$ 0,14


Tablo II: Tam test kümesinde beyaz kutu gürbüzlüğüne koşullu ayrıştırması; üç koşu üzerinden ortalama $\pm$ std. Alt blok, aynı büyüklükleri önceki tek koşuluk kontrol noktalarında tekrarlamaktadır.

Model	Koşullu yanılma (%)		Her ikisi doğru gürbüz (%)	
	PGD-10	AA	PGD-10	AA
ResNet-18 AT	48,58 $\pm$ 0,80	55,78 $\pm$ 0,23	59,86 $\pm$ 0,35	51,89 $\pm$ 0,49
ViT-Tiny AT	55,53 $\pm$ 0,50	60,37 $\pm$ 0,33	46,11 $\pm$ 0,59	41,15 $\pm$ 0,39
<i>Önceki tek koşu, doğrulama bölümü temiz ön eğitimde görülmüş (n=7.260)</i>				
ResNet-18 AT	52,15	58,16	54,92	48,15
ViT-Tiny AT	52,33	56,46	49,61	45,33


gürbüz doğruluğa ulaşırken ViT-Tiny AT %29,14 $\pm$ 0,40'ta kalmaktadır. Bir çiftin iki modeli de aynı 10.000 örnekte, örnek bazında kayıtlı değerlendirildiğinden her koşu içinde McNemar'ın eşleştirilmiş testi uygulanabilir; test üç çiftte de CNN lehine kesindir (AutoAttack altında $p < 10^{-84}$, PGD-10 altında $p < 10^{-120}$). Tohum düzeyindeki değişim, çekişmeli eğitilmiş çift için baştan sona küçüktür (raporlanan hiçbir büyüklükte 0,55 puanı aşmaz); dolayısıyla sıralama koşudan koşuya gürbüzünün ürünü değildir. Savunmasız temel modeller FGSM altında daha çok değişmektedir (1,8 puana kadar), ancak hiçbir iddia onlara dayanmamaktadır. CNN ayrıca daha yüksek temiz doğruluğu korumaktadır (%85,78'e karşı %73,53; 12,3 puanlık fark); bu, ViT'leri küçük veri kümelerinde sıfırdan eğitmenin güçlüğünü yansıtır; Tablo II bu katkıyı koşullu duyarlılıktan ayırmaktadır. AutoAttack gürbüzlüğü iki mimaride de PGD-10'un tutarlı biçimde altındadır (ResNet-18 için 6,2, ViT-Tiny için 3,6 puan); bu, daha güçlü topluluğun değerini doğrular. %62,76'daki WideResNet-28-10 referansı [54], kapasitenin, ek eğitim verisinin ve daha güçlü tarifi birlikte gürbüzlüğü mimari seçiminin ötesine ne kadar taşıdığını göstermektedir; bu modeli eşleşmiş çiftten görsel ve analitik olarak ayrı tutuyoruz.

Tablo II, mutlak skorları temiz doğruluk ve koşullu duyarlılık bileşenlerine ayırmaktadır (Bölüm III-F). Temizde yanlış sınıflandırılan girdiler gürbüz olmayan sayıldığından ayrıştırma birebirdir: AutoAttack için CNN'de $85,78 \times 0,442 = 37,93$, ViT'te $73,53 \times 0,396 = 29,14$ okunur. İki çarpan da CNN lehinedir: 12,3 puan daha yüksek temiz doğruluktan başlar ve çözdüklerinin daha küçük bir kesrini kaybeder (koşullu yanılma PGD-10 altında 48,58'e karşı %55,53; AutoAttack altında 55,78'e karşı %60,37). Çiftin iki modelinin de temizde doğru sınıflandırdığı $n = 7.061 \pm 68$ örnekte oluşan ve bu nedenle ortak girdiler üzerinde birebir eşleştirilmiş bir karşılaştırma sağlayan ortak çözülen altkümede CNN 13,8 ve 10,7 puan öndedir (her koşulda McNemar $p < 10^{-84}$).

Ayrıştırma, iki çarpan aynı yönü gösterdiğinde bile raporlanmaya değerdir; çünkü aynı yönü göstermek zorunda değildir ve aralarındaki pay, ürettikleri sıralamadan daha az kararlıdır. Doğrulama bölümünü temiz ön eğitimin zaten görmüş olduğu ilk kontrol noktalarımız, aynı mutlak sıralamayı ama tersine bir koşullu okuma vermişti: PGD-10 altında ayırt edilemeyen (52,15'e karşı %52,33) ve AutoAttack altında hafifçe ViT lehine (58,16'ya karşı %56,46) yanılma oranları; bu da CNN üstünlüğünün tamamen bir temiz doğruluk etkisi olduğu okumasını destekliyordu (Tablo II alt blok). Düzeltilmiş üç



Şekil 1: Tam CIFAR-10 test kümesinde $\epsilon = 8/255$ 'te temiz, PGD-10 ve AutoAttack doğrulukları (üç koşu ortalaması; hata çubukları ± 1 std). WRN-28-10'un AutoAttack çubuğu RobustBench tarafından raporlanan değerdir.




Şekil 2: Pertürbasyon bütçesine (ϵ) göre PGD-10 gürbüz doğruluğu; tam test kümesi, üç koşu ortalaması (± 1 std bantları). İki AT mimarisi de epsilon arttıkça benzer biçimlerle bozulmakta, CNN tutarlı bir marj korumaktadır.

koşunun hiçbirisi bu okumayı yeniden üretmemekte ve üç koşu birbiriyle, herhangi birinin önceki koşuyla uyduğundan çok daha yakından uyumaktadır. Tek bir neden yalıtıyoruz; çünkü düzeltilmiş protokol doğrulama düzenini ve eğitim koşusunu aynı anda değiştirmiştir. Dikkat çekici biçimde basit bir veri miktarı açıklaması geçerli değildir: düzeltilmiş temiz modeller 2.000 daha az görüntü görmelerine karşın öncekilerden *daha iyidir* (ViT için $80,09 \pm 0,60$ 'a karşı %77,50). Savunulabilir sonuç, bir mekanizmadan daha dar ve daha yararlıdır: bu türden bir atıf tek eğitim koşusundan çıkarılmamalıdır ve yalnızca mutlak skoru raporlayan bir makale, işi hangi çarpanın yaptığını gizler.

Şekil 1 bu gürbüzlük farkını mimariler boyunca görselleştirir. Pertürbasyon büyüklüğünün etkisini anlamak için Şekil 2, $\epsilon \in \{2/255, 4/255, 8/255, 16/255\}$ bütçelerinde tam test kümesindeki PGD-10 gürbüz doğruluğunu gösterir.

Şekil 3, çekişmeli pertürbasyonların ve model tahminleri üzerindeki etkilerinin görsel örneklerini vermektedir.



Şekil 3: Her modele kendi beyaz kutu PGD-10 saldırısı ve bir CNN→ViT transfer saldırısı; her biri farklı bir test görüntüsü üzerinde, temiz tahmin, 10× büyütülmüş pertürbasyon ve çekişmeli tahminle. Pertürbasyonlar $\epsilon=8/255$ ile sınırlıdır ve bu ölçekte görsel olarak silik kalmaktadır.

Tablo III: Koşulsuz oran ve üç yerleşik koşullama protokolü altında transfer asimetrisi (PGD-10, $\epsilon=8/255$, tam test; üç tohum çifti üzerinden ortalama $\pm$ std). En sağdaki sütun, önceki tek koşuluk kontrol noktalarında ölçülen farkı tekrarlamaktadır.

Protokol	CNN→ViT	ViT→CNN	Fark	Fark [‡]
Koşulsuz (ham)	41,02 $\pm$ 0,55	27,45 $\pm$ 0,27	+13,57 $\pm$ 0,33	+8,27
Hedef doğru	19,87 $\pm$ 0,18	15,51 $\pm$ 0,59	+4,36 $\pm$ 0,44	+0,63
Her ikisi doğru	18,25 $\pm$ 0,17	9,98 $\pm$ 0,31	+8,27 $\pm$ 0,23	+5,33
Başarılı kaynak	36,39 $\pm$ 0,76	17,02 $\pm$ 0,52	+19,37 $\pm$ 1,27	+11,17

[‡]Tek koşu; doğrulama bölümü temiz ön eğitimde görülmüş.

B. Transfer Saldırısı Analizi

Bu bölüm makalenin merkezi ölçümünü içermektedir. Her tohum çifti için, kaynak modelde PGD-10 çekişmeli örnekleri üretiyor ve bunları tam test kümesinde bir hedefte değerlendiriyoruz. Sonuçlar örnek bazında kaydedildiğinden, aynı saldırı koşusu yeniden hesaplama olmadan birden çok koşullama protokolü altında puanlanabilir: protokoller yalnızca paydaya hangi örneklerin girdiğinde ayrışır (Bölüm III-F).

Paydalar protokoller arasında keskin biçimde değişmektedir. CNN→ViT ve ViT→CNN için sırasıyla koşullamasız 10.000/10.000, hedef doğrudan 7.353/8.579, her ikisi doğrudan 7.061 ortak örnek ve başarılı kaynaktan 2.831/3.814 tür. Fark sütununda verilen yayılım, tohum içi eşleştirilmiş farkın standart sapmasıdır; iki yön tohumlar boyunca birlikte değiştiğinden bu değer yön başına yayılımlardan geri hesaplanamaz ve Bölüm IV-I’te kullanılan eğitim koşusu referansıdır. Sonuç şudur: ölçülen büyüklüğe model değil protokol hükmetmektedir. Aynı modeller ve aynı veri üzerinde asimetri +4,36 $\pm$ 0,44 ile +19,37 $\pm$ 1,27 puan arasında değişmektedir; en büyük ve en küçük protokol tahmini arasındaki tohum-başına ortalama yayılım 15,01 $\pm$ 0,84 puandır (4,4 kat), oysa herhangi bir protokolün içindeki tohum düzeyi standart sapma 1,5 puanın altında kalır. Protokol, istatistiksel hükmü de belirlemektedir. Her iki yönü aynı örnekler üzerinde puanlayan ve bu yüzden eşleştiri-

rilmiş çıkarımı destekleyen her ikisi doğru protokolünde fark 8,27 $\pm$ 0,24 puandır; eşleştirilmiş bootstrap GA [7,33; 9,22], her tohumda işaret çevirme permütasyonu $p < 5 \times 10^{-5}$ ve TOST eşdeğerliği üç marjın üçünde de (± 1 , ± 2 ve ± 3 puan; her birinde $p = 1,0$) reddedilir. Önceki kontrol noktalarında ise aynı boru hattı, hedef doğru protokolü altında ± 2 puanda eşdeğerliği kabul etmişti. Bu sayıların yalnızca birini gören bir okur, mimarilerin farklı olup olmadığı hakkında farklı bir sonuca varırdı.

Bir protokolün adı tek başına bir tanım değildir. Başarılı kaynak protokolü, saldırının kaynaktan başarılı olduğu örneklerle koşullamaktadır; bu ifadenin kaynağın temiz girdiyi doğru sınıflandırmasını gerektirip gerektirmediği ise transfer çalışmalarının nadiren yazdığı bir alt seçimdir. Bu makale daha sıkı okumayı raporlamaktadır: beyaz kutu başarısı, kaynağın temiz girdide doğru ve çekişmeli karşılığında yanlış olması demektir. Kaynağın zaten yanlış sınıflandırdığı örnekleri de içeri alan gevşek okumada ölçülen asimetri +19,37 puandan +14,60 puana, protokol yayılımı ise 15,01 puandan 10,45 puana inmektedir. Bu 4,77 puanlık kayma, Tablo III’teki her protokolün koşumlar arası standart sapmasının üç katından büyüktür; diğer üç protokol ise tanım gereği değişmemektedir. Bu büyüklükte bir alt seçim protokolün adında görünmediği için, dört koşullama maskesinin tamamı yayımlanan kodda tek bir yerde tanımlanmaktadır.

Kararlı olan yöndür. CNN’de üretilen örnekler ViT’e, dört protokolün dördünde, üç tohumun üçünde ve momentum tabanlı MI-FGSM [41] altında da (19,07 $\pm$ 0,33’e karşı %15,42 $\pm$ 0,52, hedef doğru) tersinden daha iyi transfer olmaktadır; dolayısıyla etki PGD saldırısının bir artefaktı değildir. Büyüklük, anlamlılığı ve her türlü eşdeğerlik iddiası protokole bağlıdır; işaret değildir.

Yayımların arkasındaki mekanizma bileşimseldir. Hedefin temizde çözdüğü ama kaynağın çözemediği örnekler, ortak çözümlenlerden üç-dört kat daha kırılgandır (41,2 $\pm$ 0,8 ve %59,1 $\pm$ 1,7 yanılma; ortak kümede 10,0 ve %18,3) ve bu marjinal altkümeler, iki model temiz doğrulukta ayrıştığı için boyutça beş kat farklıdır (1.517 $\pm$ 102’ye karşı 291 $\pm$ 16). Hedef doğru koşullaması iki marjinal altkümeyi de içeri alır ve asimetrik boyutları iki oranı birbirine doğru çeker; her ikisi doğru koşullaması onları dışarıda bırakır ve yönlü fark yeniden ortaya çıkar. Bu açıklama dört protokolün üçünü kapsar. Başarılı kaynak protokolü farklı bir mekanizmayla sürülür ve iki sürücü ayrıştırıldığında yayılımın neye bağlı olduğu değişir: altı tohum-ve-veri-kümesi kümesinden gelen 18 yön çiftinde, dört protokollü asimetri yayılımı iki model arasındaki temiz hata farkı büyüdükçe *azalmaktadır* (eğim $-0,528$, küme bootstrap GA $[-0,664; -0,418]$); buna karşılık başarılı kaynak protokolü dışarıda bırakılarak hesaplanan yayılım aynı farkla *artmaktadır* (eğim +0,431, GA $[+0,333; +0,633]$). Başarılı kaynak oranı 18 çiftin 12’sinde dördün en küçüğü, 4 çiftte daha en büyüğüdür; yani 16 çiftte uçtur Ortalama açıklığı en büyük olan protokol çifti hedef doğru ile başarılı kaynak arasındadır (23,77 puan) ve bu çift 18 yönün 13’ünde en geniştir; kalan beşinde, ki hepsi CIFAR-100’dedir, uçtaki protokol koşulsuz orandır. Kaynak başarısıyla koşullama *kaynağın* kendi gürbüzlüğüne göre seçim yapar; bu, çiftin temiz doğruluk farkının bir fonksiyonu değildir ve dolayısıyla ikinci, kısmen ters yönlü bir

terim katmaktadır. Bu uydurmanın havuzu ön kayıta sabitlenen havuzdur; ön kayıt SVHN çiftini uydurulan noktalara değil bağımsız bir tutarlılık kontrolüne atamaktadır. Temiz hata farkı iki puanın altında kalan ve x ekseninin başka türlü boş olan bir bandına düşen iki SVHN yönü eklendiğinde dört protokollü eğim $-0,133$ 'e gitmekte ve küme bootstrap güven aralığı $[-0,570; +0,469]$ sıfırı içermektedir; üç protokollü eğim ise hem işaretini hem aralığını korumaktadır. Bu duyarlılığı içeri almak yerine raporluyoruz, çünkü dört protokollü eğimin ne kadar ince bir dayanağı olduğunu göstermektedir.

İki kol üç protokolde uyuşmaktadır. Protokol yayılımını temiz hata farkına karşı, farklı biçimlerde hata veren iki yolla kalibre ediyoruz. *Kontrollü* kol, çiftin bir üyesini sabit tutup diğerini kendi eğitim yörüngesi boyunca taramakta; böylece mimari, tohum, veri kümesi ve saldırı bütçesi sabit kalırken fark değişmektedir (sekiz tohum-ve-veri-kümesi kümesinden 116 nokta). *Gözlemsel* kol ise final modelleri mimariler, tohumlar ve veri kümeleri arasında karşılaştırmakta, yani her şey aynı anda değişmektedir (altı kümeden 18 yön çifti). Her ikisinde çıkarım yörünge düzeyi küme bootstrap iledir; serbestlik derecesini nokta sayısı değil küme sayısı belirler ve kollar havuzlanmamaktadır. Bu aralıklar için iki uyarı geçerlidir. Altı ile sekiz küme varken yüzdelik küme bootstrap'i kapsamayı düşük tutar; dolayısıyla aşağıdaki aralıklar kesin değil, genişlik için alt sınır olarak okunmalıdır. Ayrıca WideResNet tek ve sabit bir dış kontrol noktasıdır ve altı gözlemsel kümenin altısında da, on sekiz yön çiftinin on ikisinde bulunur; yani bu kümeler tam bağımsız değildir. Onu dışarıda bırakan yalnız çift duyarlılığı yanında raporlanmaktadır.

Başarılı kaynak protokolü dışarıda bırakıldığında iki kol $+0,673$ (GA $[+0,602; +0,727]$) ve $+0,431$ (GA $[+0,333; +0,633]$) eğimleri vermektedir: işaret aynı, aralıklar örtüşüyor. Dahil edildiğinde kontrollü kol $+0,273$ (GA $[+0,219; +0,371]$), gözlemsel kol $-0,528$ (GA $[-0,664; -0,418]$) vermektedir. Bileşim, bu uyuşmazlığın büyük kısmını açıklamakta ama onu kapatmamaktadır. Kontrollü kol WideResNet içermez; gözlemsel kol aynı mimari çiftine kısıtlandığında dört protokollü eğimi $-0,528$ 'den $-0,100$ 'e gelmekte (GA $[-0,464; +0,092]$), yani aralık sıfırı içermekte ama kontrollü kolun aralığıyla hâlâ örtüşmemektedir. Dolayısıyla iki kol üç protokollü eğimde uyuşmakta, dört protokollüde uyuşmamaktadır; mekanizma iddiasının dayandığı sıralama da budur. Bununla birlikte iki sınır yazılmalıdır: gözlemsel kolun negatif eğimi x ekseninde 7,2 puanlık ölçülmemiş bir boşluğun üzerinden uydurulmuştur, dolayısıyla bir eğilimi izlemek yerine birbirinden ayrık iki kümeyi karşılaştırmaktadır; kontrollü kolun eğimi ise erken kontrol noktaları çıkarıldığında ayakta kalmaktadır (eşiklere göre $+0,201$ ile $+0,492$ arasında) ve en kararlı nicelik üç protokollü eğimdir ($0,661$ ile $0,673$).

1) *Ham oranın ne kadarı hedefin temiz hatası?*: Karşıtıcıyı tartışmak yerine doğrudan nicelemek için analizi, WideResNet-28-10 referansını hem kaynak hem hedef olarak ekleyerek 3×3 matrise genişletiyoruz (Tablo IV). İki oran arasındaki ilişki bir korelasyondan daha güçlü çıkmaktadır: tek bir olgusal öncüle dayanan bir *özdeşlik*dir.

Hedefin temiz hatasına e , koşulsuz orana r_{ham} ve hedef doğru koşullu orana $r_{\text{koş}}$ diyelim. Hedefin temiz girdide zaten

yanlış sınıflandırdığı bir örnek pertürbasyondan sonra da yanlış kalıyorsa $r_{\text{ham}} = e + r_{\text{koş}}(1 - e)$ olur ve dolayısıyla

$$r_{\text{ham}} - r_{\text{koş}} = e(1 - r_{\text{koş}}). \quad (11)$$

Ölçülen kısım öncüdür ve sıkı biçimde tutmaktadır: 36 köşegen dışı yönde (iki veri kümesi, üç tohum çifti, üç hedef, iki kaynak) temiz girdide yanlış sınıflandırılan bir örneğin saldırı altında da yanlış kalma olasılığı 0,989 ile 1,000 arasındadır. Denklem (11) bunun sonucunda ölçülen her koşulsuz oranı 0,41 puandan küçük bir hatayla yeniden üretmektedir; ortalama mutlak artış 0,095 puandır ve artık, açıklanan sapmanın en çok %1,39'unu oluşturmaktadır.


Bu, iddianın konumunu değiştirir ve güçlendirir. Koşulsuz oranın koşullu orandan saptması, verimizde hedefin temiz hatasıyla yalnızca ilişkili değildir; yarım puanın altında bir artış dışında $(1 - r_{\text{koş}})$ ile ölçeklenmiş *o hatanın kendisidir*. Koşulsuz transfer oranları, üç hedefte rastlantısal olarak gözlediğimiz bir düzenlilik olarak değil, *yapısı gereği* ve öncülü sağlayan her çalışmada hedef zayıflığıyla kirlenmektedir. Öncülün kendisi ölçülebilir bir niceliktir ve varsayılmak yerine ölçülmelidir. Temizde yanlış sınıflandırılan bir örneğin saldırı altında yanlış kalma olasılığına p dersek genel biçim $r_{\text{ham}} = e(1 - p) + r_{\text{koş}}(1 - e)$ olur ve $p = 1$ olduğunda Denklem (11)'e indirgenir. Çekişmeli eğitilmiş hedeflerde p değerini 0,989 ile 1,000 arasında ölçüyoruz; düzeltme orada puanın onda birkaçı kadar bir hatayla kesindir. Transfer çalışmalarının çoğunun saldırdığı standart eğitilmiş hedeflerde ise kendi önceki koşullarımızda p değerini 0,88'e kadar inerken gözlemledik; orada özdeşlik bir eşitlik değil bir üst sınırdır. Bu sonucu daha önce bir Pearson korelasyonu olarak ifade etmiştik (üç hedeften gelen altı yön üzerinde $r = 0,997$) ve bu ifade sonucu olduğundan zayıf göstermekteydi: bir niceliğin kendi baskın bileşeniyle bire yakın korelasyonu aritmetiktir ve özdeşlik yazıldığında onun gerektirdiği küçük örneklem uyarısına gerek kalmaz.

Veri kümesine özgü kalan şey mekanizma değil orantı çarpanıdır. $(1 - r_{\text{koş}})$ saldırının ne kadar transfer edilebilir olduğuna bağlı olduğundan, uydurulan eğim CIFAR-10'da hedef hatasının puanı başına 0,762, CIFAR-100'de 0,656 puandır. Bu bir doğa sabiti değil, ölçülen hedefler üzerinden bir ortalama; özdeşlik başka model havuzlarına uygulanırken varsayılmamalı, yeniden kestirilmelidir. Koşulsuz transfer oranları bu yüzden mimariler arası transfer edilebilirliği ölçmez; transfer edilebilirlik artı hedefin temiz zayıflığını, Denklem (11)'in açıkça gösterdiği bir oranda ölçer.

Koşulllanmış matris Şekil 4'te verilmektedir. Üçüncü mimari, asimetrisinin kendisini de yeniden çerçevelemektedir. İki yabancı kaynak üzerinden ortalandığında gelen koşullu transfer ResNet hedefi için %18,50, ViT hedefi için %19,04 ve WideResNet hedefi için %10,57'dir; bu, her hedefin kendi beyaz kutu koşullu yanıltma oranını (48,52, 55,57 ve %25,16) üç hedef üzerinde $r = 0,986$ ile izler. Bu kanıtı göre CNN→ViT üstünlüğü, CNN'de üretilen pertürbasyonların içkin olarak daha transfer edilebilir olduğunun değil, daha zayıf hedefin bir özelliği olarak okunmalıdır: en gürbüz hedef, iki aileden gelen saldırıları neredeyse eşit ölçüde soğurmaktadır. Yalnızca üç hedefle bu korelasyon kesin değil yönlendiricidir ve öyle raporlanmaktadır.

Tablo IV: 3×3 transfer matrisi (PGD-10, $\epsilon=8/255$, tam test; üç tohum çifti üzerinden ortalama $\pm$ std; WideResNet satır ve sütunu tek harici kontrol noktasını kullanır). Ham = koşulsuz yanılma oranı, Koş. = hedef doğru koşullu oran. Köşegen girdileri beyaz kutu saldırılardır.

Kaynak	Hedef	Ham (%)	Koş. (%)
ResNet-18 AT	ResNet-18 AT	55,84 $\pm$ 0,53	48,52 $\pm$ 0,84
ResNet-18 AT	ViT-Tiny AT	41,07 $\pm$ 0,58	19,93 $\pm$ 0,20
ResNet-18 AT	WRN-28-10	21,69 $\pm$ 0,09	12,48 $\pm$ 0,10
ViT-Tiny AT	ResNet-18 AT	27,45 $\pm$ 0,34	15,52 $\pm$ 0,64
ViT-Tiny AT	ViT-Tiny AT	67,34 $\pm$ 0,18	55,57 $\pm$ 0,44
ViT-Tiny AT	WRN-28-10	18,25 $\pm$ 0,12	8,65 $\pm$ 0,14
WRN-28-10	ResNet-18 AT	32,63 $\pm$ 0,14	21,48 $\pm$ 0,31
WRN-28-10	ViT-Tiny AT	39,73 $\pm$ 0,25	18,15 $\pm$ 0,28
WRN-28-10	WRN-28-10	33,03	25,16



Şekil 4: Koşullu (hedef doğru) transfer yanılma oranları; üç tohum çifti ortalaması. Bu protokol altında köşegen dışı asimetri +4,4 puandır; Tablo III, aynı büyüklüğün diğer protokoller altında ne kadar hareket ettiğini gösterir.

Tablo V: CIFAR-100 yinelemesi (mimari başına üç bağımsız eğitim koşusunun ortalaması $\pm$ std, tam test kümesi, $\epsilon=8/255$). Her iki model de Bölüm III-E’deki protokolle çekişmeli eğitilmiştir. Mutlak gürbüzlük iki mimaride de CIFAR-10’a göre düşüktür ve CNN’in ViT üzerindeki sıralaması değişmemiştir.

Model	Temiz (%)	PGD-10 (%)	AutoAttack (%)
ResNet-18 AT	63,86 $\pm$ 1,05	19,30 $\pm$ 0,32	15,04 $\pm$ 0,54
ViT-Tiny AT	43,17 $\pm$ 1,10	11,15 $\pm$ 0,60	8,87 $\pm$ 0,83

C. Protokol Etkisi Genelleniyor mu? İkinci Bir Veri Kümesi

Yukarıdaki ölçüm tek bir veri kümesi üzerinde yapılmıştır ve yalnızca CIFAR-10’da var olan bir protokol etkisi genel bir raporlama önerisini desteklemezdi. Bu nedenle tasarımın tamamını CIFAR-100 üzerinde yineledik: aynı mimariler, aynı tehdit modeli, aynı saldırı bütçesi, aynı üç tohumlu yapı, aynı dört protokol. Koşumdan önce üç yönsel ön kestirim ile üç uç nokta bandını salt eklemeli bir belgeye kaydettik; böylece sonuç, ölçüldükten sonra yeniden yorumlanamazdı.

Aynı dört protokol boyunca ölçülen CNN $\rightarrow$ ViT asimetrisi $+4,96 \pm 1,01$ puandan (hedef doğru) $+18,53 \pm 0,71$

puana (koşulsuz) uzanmakta; her ikisi doğru protokolünde $+10,92 \pm 0,34$, başarılı kaynak protokolünde $+17,50 \pm 0,92$ puandır. Tohum başına ortalama yayılım $13,83 \pm 1,30$ puandır; CIFAR-10’da bu değer $15,01 \pm 0,84$ olduğuna göre daha zor veri kümesi protokol etkisini daraltmamakta, aynı aralıktadır bırakmaktadır. Yön, CIFAR-10’da olduğu gibi on iki ölçümün tamamında pozitifdir (dört protokol $\times$ üç tohum çifti). Her ikisi doğru protokolünde eşleştirilmiş fark 10,92 puan, bootstrap güven aralığı [9,47; 12,35], işaret çevirme permütasyon p değeri her tohumda 20,000 permütasyonun çözünürlüğünün altında ve eşdeğerlik sınanan her marjda reddedilmiştir.

Üç ön kestirimin biri doğrulanmış, biri bağlayıcı saydığımız okumada tutmamış, üçüncüsü ise bu tasarımda sınanamamıştır. İşaretin korunacağı ön kestirimi doğrulanmıştır (12/12). Protokol yayılımının daha zor veri kümesinde büyüyeceği ön kestirimi, CIFAR-10 yayılımına karşı bir karşılaştırma olarak kaydedilmiş ve o tarihte bu değer 10,45 puan diye anılmıştı. Bu sayısal eşiğe karşı kestirim tutmaktadır ($13,83 > 10,45$); Bölüm IV-B’in başarılı kaynak tanımı altında CIFAR-10 yayılımının bugünkü değerine karşı ise tutmamaktadır ($13,83 < 15,01$). Kestirimi kurtaracak okumayı değil, tutmadığını raporluyoruz; çünkü kayıt sayıyı değil CIFAR-10 yayılımını adlandırmıştı. İki veri kümesi protokol etkisini zorluğa göre sıralamak yerine aynı aralığa yerleştirmektedir; yani önerdiğimiz mekanizma etkinin büyüklüğünü öngörmekte, bu iki veri kümesi arasındaki sıralamasını öngörmemektedir. Üçüncüsü, koşulsuz oranın koşullu orandan sapmasının hedefin temiz hatasıyla birlikte büyüyeceğini öngörüyordu. Ölçülen eğim, öngörüldüğü gibi pozitifdir: hedef hatasının puanı başına $+0,656$ puan. Ancak CIFAR-100’de üç hedeften ikisinin temiz hatası yalnızca 0,21 puan farklıdır (36,15 ve 36,36); dolayısıyla korelasyon üç değil *iki* etkin küme üzerinden hesaplanmakta ve değeri (altı yön üzerinde $r = 0,931$, hedef düzeyinde 0,974) iki noktalı bir karşıtlığa dayanmaktadır. Ölçüm ön kestirimle tutarlıdır ancak onu *sınamaz*; bu yüzden üçüncü bir doğrulama olarak değil, böyle raporlanmaktadır.

Kayıtlı uç noktalardan biri tutmamıştır. Çekişmeli eğitilmiş ViT için temiz doğruluğu %33 ile 40 bandında öngörmüş, %43,17 $\pm$ 1,10 ölçtük. Band, çekişmeli eğitimin temiz doğruluk bedelinin iki mimaride aynı oranda ölçekleneceği varsayımıyla türetilmişti. Ölçekleşmiyor: ViT çekişmeli eğitim altında temiz ön eğitim doğruluğunun 0,885’ini korurken ResNet 0,802’sini korumuştur. Protokol iddiasının dayandığı iki çekişmeli uç nokta ise bantlarının içinde kalmıştır (PGD-10 öngörü %10 ile 14, ölçüm 11,15; AutoAttack öngörü %8 ile 11, ölçüm 8,87).

Sınıf bileşimi asimetrisi üretmemektedir. Koşullama, payda hangi örneklerin gireceğini değiştirdiği için sınıf karışımını da değiştirir; ilkece bir asimetri bileşim artefaktı olabilir. Her yönün oranını bir bileşim bileşenine ve bir oran bileşenine ayırıyoruz. Hedef doğru protokolünde bileşim etkisi üç tohum çiftinde $-1,249$, $-1,330$ ve $-1,065$ puandır; yani asimetrisinin %12,9 ile 18,6’sı kadar ve *negatif*: sınıf karışımı dengelenseydi asimetri küçülmez, büyüdü. Başarılı kaynak protokolünde etki küçüktür ve üç tohumun üçünde de pozitifdir ($+0,527$, $+0,435$ ve $+0,382$ puan; asimetrisinin %2,1 ile 3,1’i kadar). Koşulsuz ve her ikisi doğru protokollerinde tam olarak sıfırdır; bu, ayrıştırmanın geçmesi gereken aritmetik sağlama

Tablo VI: SVHN’de dört protokol altında transfer asimetrisi (PGD-10, $\epsilon=8/255$, tam test kümesi $n=26.032$; iki tohum çiftinin ortalaması $\pm$ std; yalnız iki mimari olduğu için üçüncü mimari kontrolü yoktur). CIFAR-10 ve CIFAR-100’den farklı olarak işaret dört satırda aynı değildir.

Protokol	CNN $\rightarrow$ ViT	ViT $\rightarrow$ CNN	Fark
Koşulsuz (ham)	31,89	31,49	+0,39 $\pm$ 0,08
Hedef doğru	26,32	27,33	-1,00 $\pm$ 0,22
Her ikisi doğru	25,36	25,70	-0,35 $\pm$ 0,01
Başarılı kaynak	61,38	58,69	+2,70 $\pm$ 0,40

testidir.

Bu sonuçla birlikte okunması gereken iki nitelme vardır. Birincisi, iki çekişmeli band en yakın tohum düzeyi kenarında 0,22 puanlık (AutoAttack) ve 0,48 puanlık (PGD-10) marjlarla tutmuştur. Bu marjlar, *aynı veri kümesindeki* kontrol noktası seçimi gürültüsünden küçüktür: eğitim koşusu sabit tutulup CIFAR-100 yörüngelerinde erken durdurma sabrı ile eğri yumuşatması tarandığında raporlanan PGD-10 doğruluğu 0,18 ile 1,83 puan arasında oynamaktadır (ortalama 0,86). Aynı dokuz hücreli tarama CIFAR-10’da doğrulama bölmesi başına 0,54 ile 2,83 puan vermekte; Bölüm IV-I’te anılan on sekiz hücreli değer ise daha da büyüktür, çünkü bölmeyi de değiştirmektedir ve CIFAR-100 protokolünde o boyut yoktur. Bantlar tutmuştur, ama kaydedildikleri veri kümesinin seçim gürültüsüne eşit ya da ondan küçük marjlarla; okur ön kaydı buna göre tartmalıdır. İkincisi, çekişmeli eğitilmiş kontrol noktasını seçmekte kullanılan doğrulama bölmesi, temiz ön eğitimde de kullanılmış olan bölmedir. Bu tercih, iki veri kümesi karşılaştırılabilir kalsın diye CIFAR-10 protokolünden bilinçli olarak devralınmıştır ve Bölüm IV-I bunun neye mal olup neye mal olmadığını raporlamaktadır.

D. Mimarilerin Eşitlendiği Üçüncü Bir Veri Kümesi

CIFAR-10 ve CIFAR-100, iki mimariyi temiz doğrulukta birbirinden hayli uzağa yerleştirmektedir (yaklaşık 11 ve 21 puan). SVHN [62] öyle değildir (karşılaştırma için CIFAR-100 mutlak değerleri Tablo V’te verilmektedir): aynı tarifle çekişmeli eğitildiklerinde ResNet %94,27 $\pm$ 0,70, ViT %92,42 $\pm$ 0,56 temiz doğruluğa ulaşmakta, yani fark 1,85 puanda kalmaktadır. PGD-10 altındaki gürbüz doğruluklar 55,52 $\pm$ 0,64 ve 52,30 $\pm$ 0,10’dur. Tezimizin en keskin öngöründe bulunduğu rejim budur ve öngörü, önceki bölümleri okuyanın bekleyeceği yönde değildir.

Mimariler eşitlendiğinde işarete protokol karar vermektedir. Dört protokolün ikisi CNN üstünlüğü, ikisi ViT üstünlüğü bildirmektedir (Tablo VI). Bu ayırım keyfi değildir. Yönlü iddialar için benimsediğimiz iki protokol, hedef doğru ile her ikisi doğru, birbiriyle uyuşmakta ve ikisi de ViT lehine çıkmaktadır; işaret değişimi bunları koşulsuz orandan ve başarılı kaynak oranından ayırmaktadır. Üstelik koşulsuz orandaki çevrilme Denklem (11)’in aritmetik sonucudur: burada ViT hedefinin temiz hatası CNN’inkini yaklaşık iki puan aşmaktadır ve bu, -1,00’lik koşullu farkı +0,39’luk ham farka taşımaya yetmektedir. Dolayısıyla ham oran raporlamak yayımlanmış bir karşılaştırmanın işaretini çevirebilir ve özdeşlik bunun ne zaman olacağını önceden söylemektedir. İki yönü özdeş

Tablo VII: Aynı kontrol noktaları, L_2 bütçesi ($\epsilon=0,5$; üç tohum çiftinin ortalaması $\pm$ std). PGD-L2 tam test kümesini, AutoAttack-L2 ise ön kayıtlı 5.000 örneklik bir altkümeyle kullanır; bu yüzden temiz sütunu tam küme değerinden bir miktar farklıdır ve ikisi aynı örneklerden gelmez.

Model	Temiz	PGD-L2	Temiz (5k)	AA-L2
ResNet-18 AT	85,78	63,78 $\pm$ 0,38	85,33	60,61 $\pm$ 0,42
ViT-Tiny AT	73,53	51,72 $\pm$ 0,23	73,61	49,85 $\pm$ 0,20

örnekler üzerinde puanladığı için birincil saydığımız her ikisi doğru protokolünde fark -0,35 puan, eşleştirilmiş bootstrap güven aralığı [-0,77; +0,06], işaret çevirme permütasyon p değeri 0,105 ve TOST eşdeğerliği, denediğimiz en dar marj dâhil (± 1 puan, $p = 0,0007$) üç marjın üçünde de *kabul edilmektedir*. Yalnızca başarılı kaynak oranını raporlayan bir çalışma SVHN’de 2,70 puanlık bir CNN üstünlüğü duyururdu; yalnızca hedef doğru oranını raporlayan bir çalışma ise 1,00 puanlık bir ViT üstünlüğü. İkisi de aritmetik olarak doğru olurdu ve hiçbirini diğerince yeniden üretilemezdi.

Bu davranış mekanizmaya aykırı değil, onunla tutarlıdır. SVHN’de protokol yayılımı 3,70 $\pm$ 0,62 puandır; CIFAR-10’da 15,01 $\pm$ 0,84, CIFAR-100’de 13,83 $\pm$ 1,30 puandır; temiz doğruluk farkları ise sırasıyla 1,85, ≈ 11 ve ≈ 21 puandır. İlişki üçü arasında tekdüze değildir: en büyük fark en büyük yayılımı vermemekte, CIFAR-100 CIFAR-10’un bir miktar altında kalmaktadır. Veri kümelerini burada ayıran şey, eşitlenmeye yakın çift ile diğerleri arasındaki uzaklıktır; eşitlenmemiş ikisi arasındaki sıralama değil. Yayılım yeterince küçüldüğünde ise asimetrisinin kendisini aşmamakta ve işaret, mimarilerin değil protokolün bir özelliği hâline gelmektedir. Bölüm IV-B’de kararlı diye raporladığımız yön, *iki modelin temiz doğrulukta ayrıştığı rejimde* kararlıdır ve her iki CIFAR veri kümesi de o rejimde bulunmaktadır.

SVHN, önceden sabitlenmiş indirgenmiş bir yapılandırma ile koşulmuştur: üç yerine iki tohum çifti, 50 epok çekişmeli eğitim, AutoAttack yok ve üçüncü mimari yok. Sonuncusu, Bölüm IV-B1’teki 3×3 karıştırıcı kontrolünün burada kurulamayacağı anlamına gelir ve onun SVHN içi bir sürümünü kurmuyoruz.

E. Protokol Etkisi Tehdit Modeli Değişince Ayakta Kalıyor mu?

Buraya kadarki her ölçüm tek bir tehdit modelinin içinde yapılmıştır. Protokol etkisinin L_∞ ’ye özgü bir artefakt olup olmadığını sınamak için aynı CIFAR-10 kontrol noktalarını $\epsilon = 0,5$ ’lik bir L_2 bütçesi altında yeniden değerlendirdik ve üç yönsel ön kestirimi, herhangi bir L_2 çıkışına bakmadan önce kaydettik. Modeller L_∞ ile eğitilmiştir; dolayısıyla bu ölçüm L_2 gürbüzlüğü değil *ölçüm eksenini* yoklamakta ve aşağıdaki mutlak değerler L_2 ile eğitilmiş referanslarla karşılaştırılmamaktadır.

Kayıtlı üç ön kestirimin üçü de tutmaktadır. Protokol yayılımı L_2 altında 10,92 puandır; L_∞ altında 15,01 idi. Yani norm değişince küçülmekte, ama ön kayıtlı koyduğu iki puanlık tabanın çok üstünde ve koşullar arası standart sapmadan bir mertebe büyük kalmaktadır. İşaret on iki ölçümün tamamında

Tablo VIII: Örnek başına kayıp gradyanlarından hesaplanan gradyan karakteristikleri (koşu başına $n=500$ test örneği; üç koşu üzerinden ortalama $\pm$ std).

Metrik	ResNet-18 AT	ViT-Tiny AT	ViT (yerel) [‡]
Hoyer seyrekliği	0,4928 $\pm$ 0,0120	0,4561 $\pm$ 0,0055	0,405
Gini katsayısı	0,6498 $\pm$ 0,0089	0,6099 $\pm$ 0,0051	0,571
Maks. %1 altı kesir	%34,8 $\pm$ 2,1	%26,8 $\pm$ 0,9	%17,9
Hizalanma (mutlak)	0,0378 $\pm$ 0,0009	0,0562 $\pm$ 0,0004	0,079
Hizalanma (işaretli)	0,0014	0,0005	–

[‡]CIFAR’a özgü ViT kontrolü (4×4 yama, büyütme yok; 5,4M parametre); sabit bölme protokolünden önceye ait, test kümesinde seçilmiş tek kontrol noktası; yalnızca büyütme etkisinin işareti için eklenmiştir, nicel karşılaştırma için değil.

pozitif ve koşulsuz oranın koşullu orandan sapması hâlâ hedefin temiz hatasıyla artmaktadır (eğim $+0,914$; korelasyon yerine eğimi raporluyoruz, çünkü on sekiz yön yalnızca yedi ayrık hedef hatası değeri almakta ve bunların altısı aynı sabit WideResNet’ten gelmektedir, dolayısıyla bunlar üzerinde bir korelasyon Bölüm IV-B’in anlattığı biçimde kesinliği abartırdı). Dört protokolün (Tablo VII) bildirdiği asimetrikler $+13,03 \pm 0,81$ (koşulsuz), $+2,12 \pm 0,18$ (hedef doğru), $+4,07 \pm 0,36$ (her ikisi doğru) ve $+12,06 \pm 0,23$ (başarılı kaynak) şeklindedir. Mutlak gürbüzlük her iki saldırı altında da CNN’in ViT üzerindeki sıralamasını korumakta, McNemar $p < 10^{-57}$ her tohum çiftinde sağlanmaktadır.

Eğim, özdeşliği örneklem dışında da doğrulamaktadır. Denklem (11), eğimin hedefler üzerinden ortalananmış $1 - r_{\text{koş}}$ değerine eşit olmasını öngörür. Koşullu oranlar bu L_2 bütçesi altında L_∞ ’dekenden çok daha düşüktür (kabaca %2 ile 9’a karşı %9 ile 22), dolayısıyla özdeşlik *daha dik* bir eğim öngörür; ölçülen 0,914 tam da olması gereken yeredir; aynı modellerde L_∞ altında bu değer 0,762 idi. Orantı çarpanı bir sabit değil, saldırı bütçesinin bir özelliğidir; Bölüm IV-B1 bunu zaten belirtmektedir.

F. Gradyan Karakteristikleri

Girdi duyarlılığındaki mimari farkları betimlemek için, iki mimarinin gradyan özelliklerini, ana ViT hattımızdaki $32 \rightarrow 224$ büyütmenin etkisini yalıtın CIFAR’a özgü bir ViT kontrolüyle (32×32 girdi, 4×4 yama, büyütme yok; aynı çekişmeli amaç işleviyle, ancak Bölüm III-E’te anlatılan sabit bölme protokolü benimsenmeden önce eğitilmiş) birlikte analiz ediyoruz. Tablo VIII, ölçekten bağımsız seyreklik ölçüleriyle (Bölüm III-F) temel istatistikleri özetler; gradyanlar, normlar değerlendirme parti boyuna bağlı olmasın diye örnek başına kayıplarla hesaplanır. Oradaki hizalanma, tüm $500 \times 499/2$ örnek çifti üzerindeki ortalama mutlak kosinüs benzerliğidir ve ölçekten bağımsız seyreklik metriklerindeki her ResNet ile ViT farkı, her koşuda örnek başına eşleştirilmiş Wilcoxon testlerinde anlamlıdır; Holm düzeltmeli $p < 10^{-11}$ ve eşleştirilmiş Cohen d değeri 0,32 ile 1,23 arasındadır.

Üç ölçekten bağımsız seyreklik ölçüsünün üçünde de CNN gradyanları ViT gradyanlarından daha seyrektir ve sıralama, tohum düzeyi standart sapmaları farktan en az üç kat küçük kalarak her koşuda yeniden üretilmektedir. Aynı 500 örnek iki modelde de ölçüldüğünden farklar örnek başına eşleştirilmiş istatistiklerle test edilir: üçü de üç koşuda da anlamlıdır (Wilcoxon işaretli sıra, baştan sona Holm düzeltmeli

Tablo IX: Girdi gradyanlarının mekânsal lokalitesi (koşu başına $n=500$ örnek; üç koşu üzerinden ortalama $\pm$ std). Eşleştirilmiş farklar aynı örnekler üzerinde hesaplanır. Çıkarım koşum düzeyindedir: p , üç koşumun ortalama farkları üzerinde tek örneklem t testidir ve dört ölçüye Holm düzeltmesi uygulanmıştır; böylece çıkarımın birimi iddianın birimiyle eşleşir. Düşük alan ve entropi daha lokalize, yüksek Moran’s I daha kümeli demektir.


Ölçüt	ResNet-18	ViT-Tiny	Fark	p
%50 enerji alanı	0,0378 $\pm$ 0,0017	0,0397 $\pm$ 0,0010	–0,0019	0,54
%90 enerji alanı	0,2345 $\pm$ 0,0078	0,2570 $\pm$ 0,0067	–0,0224	0,40
Mekânsal entropi (nat)	5,2014 $\pm$ 0,0387	5,2524 $\pm$ 0,0197	–0,0509	0,54
Moran’s I	0,4141 $\pm$ 0,0132	0,3941 $\pm$ 0,0024	+0,0200	0,47

$p < 10^{-11}$; eşleştirilmiş Cohen d 0,32 ile 1,23 arasında). Sıralama mimarinin değil çekişmeli eğitimin ürünüdür: aynı koşulların temiz eğitilmiş karşılıklarında daha seyrek model ViT’tir (Hoyer 0,380 $\pm$ 0,009’a karşı 0,347 $\pm$ 0,002); yani çekişmeli eğitim CNN gradyanlarını çok daha güçlü seyrektirmektedir [28] ile tutarlı olarak. Yerel çözünürlüklü ViT kontrolü her ölçüde büyütülmüş ViT’ten daha az seyrektir; dolayısıyla sıralama $32 \rightarrow 224$ büyütmenin artefaktı değildir. Örnekler arası hizalanma ViT’te mutlak kosinüste daha yüksektir ve temiz eğitilmiş çift bu farkı zaten göstermektedir (0,058’e karşı 0,029); bu da onu savunmanın değil mimarinin bir özelliği yapar. İşaretli ortalama kosinüs ise iki modelde de sıfıra yakındır ($\leq 0,0014$): örneklerin paylaştığı şey duyarlılık eksenleridir, tutarlı yönler değil; dolayısıyla hizalanma farkı ucuz evrensel pertürbasyonlar için kanıt sayılamaz.


Bu gradyan sonuçları, analizimizin hangi kontrol noktası kümesinin kullanıldığına duyarsız olan tek parçasıdır: Tablo VIII’teki her büyüklük, önceki tek koşuluk kontrol noktalarında ölçülen değeri raporlanan standart sapmalar içinde yeniden üretmektedir; Bölüm IV-A’in koşullu ayrıştırmasının aksine.

1) *Seyreklik mekânsal lokalite değildir*: Seyreklik ölçüleri kaç gradyan bileşeninin büyük olduğunu yanıtlar; bu bileşenlerin görüntüde bir arada durup durmadığını değil. Ayrım önemlidir; çünkü daha-seyrek-CNN sonucu mekânsal bir okumaya davet çıkarır; gradyanların nesne bölgelerinde daha “lokalize” ya da “yoğunlaşmış” olduğu düşünülür. Bu okumayı belirli bir çalışmaya atfetmiyoruz; sınadık, çünkü bir seyreklik sonucunun doğal yorumu budur ve kendi önceki şekillerimiz de onu teşvik etmişti. Bu okuma, bu ölçülerin destekleyemeyeceği bir iddia içerir. Bu yüzden mekânsal yapıyı aynı gradyanlar üzerinde, kanal toplamı enerji haritasının dört ölçekten bağımsız betimleyicisiyle doğrudan ölçüyoruz: gradyan enerjisinin %50’sini ve %90’ını taşıyan en küçük piksel oranı, normalize enerji haritasının mekânsal entropisi ve enerji bitişik piksellerde kümelenişinde pozitif olan 4-komşuluklu Moran’s I .

Sonuç negatiftir (Tablo IX). Dört ölçütün hiçbirisi koşum düzeyinde anlamlı fark göstermez. En büyükleri olan, enerjinin %90’ını taşıyan alan, CNN için görüntü alanının iki puanı kadar *daha küçük* bir alana işaret eder ve düzeltmeden sonra ayakta kalmaz; bu da $p < 10^{-11}$ ’de anlamlı olan Hoyer farkının yanında marjinal bir etkidir. Tek bir koşum içindeki



Şekil 5: İki mimaride örnek başına gradyan L_2 normlarının dağılımı. Aynı girdiler için enerji haritaları Şekil 6’te verilmektedir.



Şekil 6: Aynı girdiler üzerinde CNN ve ViT gradyan enerji haritalarının karşılaştırması. Farklar Tablo VIII’teki seyreklik ölçüleriyle nicelenir; Tablo IX, görünür yapının mekânsal kümelenme farkına karşılık gelmediğini gösterir.

örnek bazlı testler bu ölçülerde çok daha küçük p değerlerine ulaşır, ama farklı bir soruyu yanıtlarlar, yani iki sabit kontrol noktasının bu 500 görüntüde farklı olup olmadığını; üstelik dört ölçünün ikisinde işaret koşumlar boyunca kararlı değildir. Komşuluk kümelenmesi iki mimaride esasen özdeştir. İki ölçü ailesi bu yüzden uyuşmamaktadır ve uyumsuzluk bilgilendiricidir: çekişmeli eğitilmiş CNN gradyanları kütlelerinin daha büyük kısmını daha az piksele yerleştirir, ama bu pikseller ViT’inkilerden mekânsal olarak daha kümeli değildir. CNN gradyanlarının mekânsal olarak lokalize olduğu betimlemeleri ölçümlerimizce desteklenmemektedir; kendi iddialarımızı seyreklikle sınırılıyor.

Şekil 5, bu gradyan farkları için görsel kanıt sağlar.

Tablo X: Her modelin kendi beyaz kutu PGD-10 saldırısı altında blok bazlı temizden çekişmeliye kosinüs benzerliği (koşu başına $n=1000$; üç koşu üzerinden ortalama $\pm$ std). ViT sütunları yalnızca blok jetonlarının nasıl toplandığında ayrışır.

Blok	ViT-Tiny AT			ResNet-18 AT	
	CLS	Yama ort.	Tüm jetonlar	Blok	Kosinüs
1	0,9964	0,9990	0,9975	layer1.0	0,9951
2	0,9893	0,9954	0,9911	layer1.1	0,9918
3	0,9785	0,9928	0,9821	layer2.0	0,9879
4	0,9709	0,9877	0,9734	layer2.1	0,9853
5	0,9652	0,9870	0,9719	layer3.0	0,9753
6	0,9596	0,9873	0,9712	layer3.1	0,9607
7	0,9497	0,9870	0,9698	layer4.0	0,8777
8	0,9414	0,9840	0,9663	layer4.1	0,9108
9	0,9353	0,9850	0,9675		
10	0,9343	0,9877	0,9696		
11	0,9352	0,9912	0,9753		
12	0,9779	0,9955	0,9884		

G. Görü Dönüştürücülerinde Öznitelik Kayması

Şimdi çekişmeli hasarın derinlik boyunca nerede biriktiğini ölçüyor, temiz eğitilmiş ViT’lerin katman bazlı temsil analizlerini [29] çekişmeli eğitilmiş ortama taşıyoruz. Bu ölçümde genellikle örtük bırakılan iki tasarım seçimi önemli çıkmaktadır, bu yüzden ikisini de değiştiriyoruz: örneklem boyutu (tek küçük parti yerine koşu başına $n = 1000$) ve bir dönüştürücü bloğunu özetlemekte kullanılan jeton agregasyonu. ViT için yalnız CLS jetonunu, 196 yama jetonunun ortalamasını ve tüm jetonların düzleştirilmiş birleşimini; CNN için mekânsal boyutlar üzerinden düzleştirilmiş her blok çıktısını raporluyoruz.

Bundan iki sonuç çıkmaktadır. Birincisi, iki mimari hasarın birikip birikmediğinde değil *nerede* biriktiğinde ayrışmaktadır. ViT’te kayma kademeli ve sığdır: benzerlik 8 ile 10. bloklar civarındaki bir minimuma doğru düzenli biçimde azalır ve çıkışa doğru toparlanır; öznitelik normları baştan sona temiz değerlerinin %0,7’si içinde kalır, yani pertürbasyon temsili yeniden ölçeklemek yerine döndürmektedir. CNN’de hasar yoğunlaşmıştır: ilk üç aşama az kaybeder, ardından son artık aşamanın ilk bloğu $-0,13,14 \pm 1,89$ ’luk norm daralmasıyla birlikte $0,8777 \pm 0,0181$ ’e çöker; son blok temsili kısmen onarır ($0,9108 \pm 0,0060$, norm $+0,5,84 \pm 3,53$). CNN’de çekişmeli hasar geç, yerel ve büyüklük değiştiren bir olaydır; ViT’te dağıtık, yalnızca yön değiştiren bir dönmedir. Önceki kontrol noktalarımızda CNN profilinin son bloğa dek monoton düştüğünü, toparlanma göstermediğini not ediyoruz; dolayısıyla ViT profilinin aksine CNN eğrisinin biçimi tarife bağlı okunmalıdır.

İkincisi, agregasyon seçimi ölçülen profili önemli ölçüde değiştirmektedir. Kendi minimumlarında CLS yolu, yama jetonu ortalamasının yaklaşık dört katı kadar kaymakta ($0,9343$ ’e karşı $0,9840$; $1 - \cos$ cinsinden oran 4,1) ve iki özet, minimumu farklı derinliklere bile yerleştirmektedir (blok 10’a karşı blok 8). Sınıflandırıcının okuduğu şey CLS jetonu olduğundan bu bir ayrıntı değil bir sonuçtur: pertürbasyon sınıflandırma yoluna yoğunlaşırken ortalama yama temsili görece korunmaktadır. Bu ayrıca, farklı makalelerden katman bazlı kayma eğrilerinin, agregasyon belirlenmedikçe doğrudan karşılaştırılmayacağı anlamına gelir.


Blok bazlı profiller Tablo X'te verilmektedir. Üçüncü bir ölçüm negatiftir. Çekişmeli pertürbasyon, CLS dikkat dağılımının entropisini ölçülebilir biçimde değiştirmemektedir: koşu başına $n = 1000$ örnek üzerinde, katman başına ortalama entropi değişimi mutlak değerce en çok 0,005 nattır (katman ortalamaları 4,9 nat civarındayken) ve tohum düzeyi standart sapma aynı mertebededir. Bunu reddedememe olarak değil eşdeğerlik olarak ifade ediyoruz: katman ortalamasının yüzde biri olan ve veriden değil ölçünün ölçeğinden sabitlenen $\pm 0,05$ nat marjıyla TOST, on iki katmanın on ikisinde de eşdeğerliği kabul etmektedir; en zayıf $p = 0,006$. Derinlikle büyüyen şey dikkat haritasının *yer değiştirmesidir*: ilk katmanda 0,028 toplam varyasyondan son katmanda 0,084'e çıkmaktadır; toplam varyasyon 1 ile sınırlı olduğundan mutlak olarak küçüktür. Saldırı dikkatini hafifçe yeniden yönlendirmekte, ama ne genişletmekte ne keskinleştirmektedir. Bunu açıkça işaretliyoruz; çünkü bu analizin 8 örneklik bir figür partisiyle hesaplanan önceki bir sürümü, daha büyük ölçümün desteklemediği görünür bir dikkat etkisi izlenimi vermişti; çekişmeli saldırının dikkati bozduğuna dair her iddia, dile getirilmeden önce bu örneklem boyutunda sınanmalıdır. Bunu literatürdeki belirli bir çalışmaya karşı değil, kendi ön sürümümüze karşı söylüyoruz.

Son olarak kayma büyüklüğü saldırı başarısını öngörmektedir. Örnekler, saldırının tahmini devirip devirmediğine göre bölündüğünde, ViT'te devrilen ve devrilmeyen örneklerin son blok kosinüs benzerliği istatistiksel olarak ayırt edilemezdir (0,9895'e karşı 0,9877); CNN'de beklenen yönde küçük bir fark vardır (0,9058'e karşı 0,9143). Öznitelik kayması, bu yüzden, temsili nasıl hareket ettiğinin bir betimlemesidir; tahminin değişip değişmeyeceğinin yeterli istatistiği değildir.


Nicel ölçümleri tamamlayıcı olarak Şekil 7, temsili bir örnek için 1., 6. ve 12. katmanlardaki CLS dikkat haritalarını görselleştirir. Görselleştirme yukarıdaki yer değiştirme ölçümüyle tutarlıdır, çünkü geç katmanlar erken katmanlardan daha çok hareket eder; ancak bu türden tek örnekli dikkat panellerinin kolayca fazla yorumlandığına dikkat çekiyoruz: 1.000 örnek üzerindeki toplam entropi değişimi sıfırdır, yani görünür farklar yayılmayı değil yeniden yönlendirmeyi yansıtır. Yama pertürbasyonları altındaki dikkat kayması etkileri [32] ve dikkat mekanizmasını doğrudan hedefleyen saldırılar [31], burada incelenen L_∞ sınırlı pertürbasyonlardan farklı bir rejimde işler.

Şekil 8, temsili bir örneğin temiz ve çekişmeli CLS dikkatini katman başına entropi eğrileriyle birlikte gösterir; iki entropi eğrisi üst üste binmektedir; yukarıda raporlanan sıfır sonucun görsel biçimi budur.

Şekil 9, sondan bir önceki katman öznitelik uzaylarının gösterim amaçlı bir t-SNE gömmesini verir. t-SNE gömmeleri hiperparametrelere duyarlı olduğundan ve nitel aşırı yorumu davet ettiğinden, tüm iddiaları özgün öznitelik uzayında hesaplanan metriklerle dayandırıyoruz (koşu başına $n=500$; her model beyaz kutu saldırıya uğratılmış; üç koşu üzerinden ortalama $\pm$ std). Saldırı, sınıf yapısını en güçlü biçimde CNN'de çökertmektedir: temizde eğitilmiş 5-NN etiket tutarlılığı $\%87,3 \pm 2,6$ 'dan $\%51,3 \pm 1,8$ 'e düşer, siluet skoru $0,196 \pm 0,010$ 'dan $-0,032 \pm 0,004$ 'e iner, sınıf içi/sınıflar arası uzaklık oranı $0,511 \pm 0,013$ 'ten $0,847 \pm 0,003$ 'e çıkar ve görsel sınıf merkezi kayması $0,238 \pm 0,012$ 'dir. ViT'in




Şekil 7: Çekişmeli saldırı altında ViT katmanları boyunca CLS jetonu dikkat haritaları (softmax sonrası, başlar üzerinden ortalananmış). Her satır farklı bir katmanı (1, 6, 12) gösterir; sütunlar temiz dikkat, çekişmeli dikkat ve farklarıdır. Gösterilen tek bir örnektir; dikkat kaymasındaki derinlik eğilimi metinde koşum başına $n = 1000$ örnek üzerinden nicel olarak verilmektedir.



Şekil 8: Temiz ve çekişmeli girdiler için CLS dikkat dağılımının katman başına entropisi; koşum başına $n = 1000$ örnek, üç koşum ortalaması ve ± 1 std bandı. Dikkat haritalarının kendisi Şekil 7'te verilmektedir.

sondan bir önceki uzayı temiz girdilerde bile zayıf sınıf ayrımı gösterir (siluet $-0,021 \pm 0,005$; 5-NN tutarlılığı $\%61,1 \pm 1,4$, saldırıda $\%48,5 \pm 1,4$ 'e düşer) ve merkezleri çok daha az kayar ($0,083 \pm 0,004$). Ölçülebilir ifade şudur: CNN'in iyi ayırmış temiz öznitelik uzayı beyaz kutu saldırıyla ağır biçimde bozulurken, ViT'in sınıf yapısı baştan daha zayıftır ve bu toplu ölçülerde daha az hareket eder; bu, gürbüzlük hakkında değil geometri hakkında bir ifadedir, zira daha yüksek gürbüz doğruluğu yine de CNN korumaktadır.



Şekil 9: Temiz örnekler (daireler) ve her modelin kendi beyaz kutu PGD-10 çekişmeli örnekleri (üçgenler) için sondan bir önceki katman özneteliklerinin gösterim amaçlı t-SNE gömmesi; ResNet-18 (sol) ve ViT-Tiny (sağ). t-SNE yalnızca yönlendirme içindir; nicel karşılaştırma metinedir.

Tablo XI: Eşleşmiş bütçede TGR [12] ve düz MI-FGSM altında ViT→CNN transferi (koşu başına $n=10.000$; üç koşu üzerinden ortalama $\pm$ std).

Ölçüt (%)	TGR	MI-FGSM
Kaynakta beyaz kutu (ham)	51,56 $\pm$ 0,80	66,43$\pm$0,29
Transfer, hedef doğru	12,70 $\pm$ 0,41	15,71$\pm$0,60
Transfer, her ikisi doğru	7,93 $\pm$ 0,42	10,08$\pm$0,30

H. ViT'e Özgü Bir Transfer Saldırısı Tabloyu Değiştiriyor mu?

Buraya kadarki tüm transfer sonuçları, ViT'i genel türevlenebilir bir model olarak ele alan gradyan saldırılarını kullanmaktadır. Doğal bir itiraz, dönüştürücü yapısı için tasarlanmış saldırıların daha iyi transfer ettiği bildirildiğinden, ViT yönünün bu seçim tarafından cezalandırıldığıdır. İtirazı, kaynak modelde geri yayılım sırasında dikkat, QKV ve MLP yollarındaki uç değerli jeton gradyanlarını bastıran Jeton Gradyanı Düzenleştirme (TGR) [12] ile doğrudan test ediyoruz. Gerçeklememiz bir uyarımadır: özgün yöntem standart eğitilmiş ImageNet ViT'lerini hedefler; biz aynı mekanizmayı CIFAR-10 ViT-Tiny sarmalayıcımıza uyguluyor ve saldırı bütçesini ImageNet varsayılanları yerine makalenin geri kalanıyla eşliyoruz ($\epsilon = 8/255$, $\alpha = 2/255$, 10 adım, momentum 1,0). Kontrol olarak aynı koşuda düz MI-FGSM örnekleri üretilir; böylece karşılaştırma özdeş örnekler ve özdeş bütçe üzerinde eşleştirilmiştir.

TGR bu rejimde transferi iyileştirmemekte; kötüleştirmektedir (Tablo XI). Düzenleştirme kaynak tarafında tasarlandığı gibi davranır ve 14,9 puanlık beyaz kutu gücünden vazgeçer; ancak bu takas hedefte karşılığını bulmaz: koşullu transfer hedef doğru protokolünde 3,0, her ikisi doğru 2,2 puan düşer. Her-ikisi-doğru altkümesindeki eşleştirilmiş McNemar testleri her koşuda MI-FGSM lehine kesindir ($p = 6,1 \times 10^{-10}$, $1,1 \times 10^{-27}$, $7,0 \times 10^{-34}$); yani bu bir tohum etkisi değildir.

Sonucu dar tutuyoruz. Kurulumumuz, TGR'nin tasarlandığı kurulumdan her biri önemli olabilecek üç noktada ayrılır: hedefler standart değil çekişmeli eğitilmiştir, veri yerel ImageNet değil model içinde büyütülen 32×32 CIFAR-10 görüntüleridir ve kaynak 5,7M parametrelili bir ViT-Tiny'dir. Destekleyebildiğimiz iddia, TGR'nin transfer üstünlüğünün bu rejime taşınmadığıdır; yöntemin genel olarak başarısız olduğu değil.

Bu makale açısından önemli sonuç şudur: Bölüm IV-B'te raporlanan CNN→ViT asimetrisi, mimariden bağımsız saldırılar kullanmanın bir artefaktı değildir; ViT yönüne dönüştürücüye özgü bir saldırı vermek onu güçlendirmemekte, zayıflatmaktadır.

I. Varyans Kaynakları

Yukarıdaki karşılaştırmaları dört varyans kaynağı ilgilendirmektedir. Saldırı başlatma stokastisitesi ihmal edilebilir: PGD-10'u sabit 1.000 örneklik altkümede üç saldırı tohumuyla yeniden koşmak temiz doğruluğu hiç değiştirmez (yükleyici karıştırmaz) ve gürbüz doğruluğu CNN'de 0,05, ViT'te 0,00 puanlık standart sapmayla oynatır. Eğitim koşusu varyansı daha büyüktür ama yine küçüktür: mimari başına üç bağımsız koşuda, çekişmeli eğitilmiş çift için standart sapma temiz doğrulukta en çok 0,55, PGD-10'da 0,50 puandır (Tablo I).

Protokol etkisini doğrudan bu iki sayıyla karşılaştırmak bir ölçek hatası olurdu; çünkü protokol etkisi transfer asimetrisi üzerinde, yukarıdaki iki sayı ise mutlak doğruluk üzerinde ölçülmektedir. Bu nedenle protokol ve eğitim koşusu etkilerini aynı nicelik olan köşegen dışı asimetri üzerinde ve mutlak birimlerle niceliyoruz. Sabit bir tohum çiftinde yalnızca koşullama protokolünü değiştirmek asimetriyi $15,01 \pm 0,84$ puan oynatmaktadır. Bu değer tohum-başına açıklıkların ortalama-sıdır ve burada protokol ortalamalarının açıklığıyla çakışmaktadır, çünkü uç protokoller üç tohumun üçünde de aynıdır: üstte başarılı kaynak, altta hedef doğru. CIFAR-100'de ise iki değer ayrılmaktadır (13,83'e karşı 13,58), çünkü orada uç protokol tohumlar arasında değişmektedir. Aynı asimetriyi, her iki mimariyi sıfırdan yeniden eğitmek ise yalnızca 0,23 ile 1,48 puanlık standart sapmayla oynatmaktadır; değer hangi protokol altında ölçüldüğüne bağlıdır (Tablo III, Fark sütunu). Makalenin dayandığı sıralama budur: on beş puanlık bir ölçüm etkisine karşı 1,5 puanın altında bir eğitim etkisi.

Bu iki yayılımın oranını bilerek manşete koymuyoruz. Üç koşumla payda iki serbestlik derecesi taşır; dolayısıyla herhangi bir tek oran için χ^2 aralığı çok geniştir: dördü içinde en büyük koşumlar arası standart sapmaya sahip başarılı-kaynak protokolünde oranın %95 aralığı 0,8 ile 9,9 arasında uzanır ve *birimi içerir*. Tahmin olarak değil duyarlılık olarak raporlandığında oran, yayılım ölçüleri ve referans protokoller boyunca 5,2 ile 32,6 arasında değişmekte ve birincil saydığımız her-ikisi-doğru protokolünde benzeri-benzeriyle standart sapma karşılaştırmasında 28,3 olmaktadır. İki uyarı oranı daha da sınırlar. En büyük asimetriyi veren protokol aynı zamanda en büyük koşumlar arası standart sapmayı taşımaktadır; yani pay ile payda bağımsız değildir. Ayrıca üç koşumun tamamı, eğitimden önce çekilen tek doğrulama bölmesini paylaştığından bu standart sapma bölmeleri arası varyansı dışarıda bırakır; bu da oranı bir üst sınır yapar. Bu aralığın genişliğini ve iki uyarıyı da atlatan şey mutlak karşılaştırmadır; iddiayı taşıyan da kat değeri değil odur. Bu sıralama makalenin savının nicel hâlidir: protokol belirtilmemişse okur, gerçek bir mimari farkı bir ölçüm seçiminden ayırt edemez.

Dördüncü kaynak, genellikle örtük bırakılan çevrimdışı kontrol noktası seçimi protokolüdür. Bir eğitim yörüngesi tamamen sabit tutulup yalnızca son kontrol noktasının nasıl seçildiği değiştirildiğinde, yani hangi doğrulama bölmesi,

hangi erken durdurma sabrı ve argmaks öncesinde doğrulama eğrisinin yumuşatılıp yumuşatılmadığı (on sekiz bileşim), raporlanan PGD-10 doğruluğu ResNet'te tohum başına 2,62 ile 2,85, ViT'te 1,58 ile 2,09 puan oynamaktadır. Bu hücrelerde diskteki ağırlıklar özdeştir; yalnızca içlerinden birini seçen kural farklıdır. Bu yayılımın yaklaşık yarısı üç boyuttan yalnız birinden gelmektedir. Argmaks öncesinde doğrulama eğrisini yumuşatmak, üç ResNet koşumunun üçünde ve üç ViT koşumunun ikisinde test PGD-10 doğruluğunu monoton biçimde düşürmektedir; yani yansız bir seçenek değil, sistematik olarak daha kötü bir kuraldır. Çalışmaların fiilen değiştirdiği bölme ve sabır seçimleriyle sınırlandığında yayılım ResNet'te tohum düzeyi standart sapmanın 1,09 katına, ViT'te 1,42 katına inmektedir. İki değeri de veriyoruz: büyüğü belgelenmemiş bir ön işleme adımının ekleyebileceğini, küçüğü belgelenmiş bir protokolün yine de açık bıraktığını ölçmektedir. Bu yayılımı mutlak birimlerle raporluyor ve bilinçli olarak tohum düzeyi yayılıma oran biçiminde vermiyoruz; çünkü o oran, on sekiz hücreden hangisinin referans alındığına bağlıdır: on sekizinin tamamı tarandığında ResNet'te 0,67 ile 3,38, ViT'te 0,63 ile 7,38 arasında değişmekte, bazı referanslarda birin altına inip karşılaştırmayı tersine çevirmektedir.

Hemen yanına bir karşı ağırlık konmalıdır. CIFAR-100'de kendi protokolümüzün seçtiği epok üç ResNet tohumu arasında 25 epok kaymakta, buna karşılık ortaya çıkan test PGD-10 standart sapması 0,32 puanda kalmaktadır. Seçim *yolu* oynaktı, seçilen *sonuç* değildi. İki gözlem birbirinden ayrı genellenemez: seçim tercihleri raporlanan bir sayıyı eğitim tohumundan daha fazla oynatabilir, neredeyse hiç oynamayabilir de; hangisinin gerçekleşeceği mimarinin değil, yörüngenin platosunun bir özelliğidir. Raporlama açısından pratik sonuç iki durumda da aynıdır: seçim kuralı sonucun bir parçasıdır ve yöntem bölümüne yazılmalıdır.

Hesaplama Ayrıntıları: Burada raporlanan eğitim koşulları ve analizler NVIDIA RTX 5090 (32GB) üzerinde yürütülmüştür; Tablo II'deki karşılaştırmada kullanılan önceki tek koşuluk kontrol noktaları RTX 5060 Ti (16GB) üzerinde eğitilmişti. Tüm koşullar PyTorch 2.6.0, CUDA 12.8 ve deterministik cuDNN ayarlarıyla yapılmıştır. AutoAttack değerlendirmesi, standart yapılandırmayla (APGD-CE, APGD-T, FAB-T, Square) 10.000 örneklik tam test kümesinde, örnek bazında kayıtlı, tohumlanmış 1.000 örneklik parçalar hâlinde koşulmuştur. Üç tohumlu eğitim boru hattı toplam 21,7 GPU-saat gerektirmiştir.

V. TARTIŞMA

A. Ölçümlerin Gösterdikleri

Merkezî sonuç bir yayılım sıralamasıdır. Transfer asimetrisinin kendisi üzerinde ölçüldüğünde, her iki mimariyi sıfırdan yeniden eğitmek onu 0,23 ile 1,48 puanlık standart sapmayla oynatırken, yalnızca koşullama protokolünü değiştirmek $15,01 \pm 0,84$ puan oynatmaktadır (Bölüm IV-I). İki yayılımı kat değeri olarak değil mutlak birimlerle veriyoruz; çünkü üç koşumla o oranın aralığı bir manşeti taşıyamayacak kadar geniştir. Farklı bir nicelik üzerinde ölçek fikri vermek üzere: bir saldırıyı yeni bir rastgele başlangıçla yeniden koşturmak mutlak gürbüz doğruluğu yaklaşık 0,05 puan, yeniden eğitmek

ise çekişmeli eğitilmiş çifti en çok 0,55 puan oynatır. Ölçüm seçiminin on beş puan oynattığı, yeniden eğitmenin ise bir puan oynattığı bir büyüklük mimarilerin kararlı bir özelliği değildir ve protokol olmadan raporlandığında neredeyse hiçbir şey iletmez.

Bir itiraz kendi terimleriyle yanıtlanmayı hak ediyor. Dört protokol dört farklı niceliği kestirir; dolayısıyla aralarındaki mesafe bir varyans değildir ve ona varyans demek bir kategori hatası olurdu. Katılıyoruz; mimarilerin, protokollerin hatayla kestirdiği tek bir gerçek asimetrisi olduğunu iddia etmiyoruz. İddiamız okuyucunun neyi geri kazanabildiğiyle ilgilidir. Bir çalışma protokolü adlandırmadan tek bir sayı raporladığında okuyucu dört nicelikten hangisinin kestirildiğini söyleyemez ve ölçtüğümüz yayılım, o belirsizliğin büyüklüğüdür. Bu, tek bir kestiricinin yayılımı değil, adlandırmamanın okuyucuya maliyetinin bir üst sınırıdır; protokolün sonuca ait olmasının nedeni de budur. Bu, koşullamaya karşı bir argüman değildir; doğru sınıflandırılan örneklerle koşullamak yerleşik pratiktir [9], [40], [41] ve gerekli olmaya devam etmektedir; asıl argüman, seçimin dipnota değil sonuca ait olduğuna dair bir argümandır.

Bu, bizim yönümüzün doğru yön olduğuna dair bir argüman da değildir. Bizimkiyle karşılaştırılabilir bir her ikisi doğru protokolü altında Mahmood ve ark. [8] farklı bir mimari çiftinde ters yönü raporlamakta; dönüştürücüye doğru transferi ondan dışarı olan transferden zayıf bulmaktadır. Mekanizmamız bununla uyumludur: asimetriyi, CNN'de üretilen pertürbasyonların özel bir gücüyle değil hedefin kendi kırılabilirliğiyle ilişkilendiriyoruz ve onların çiftinde zayıf hedef olan taraf bizimkinden farklıdır. Bunu düzgün sınamak, ortak bir protokol altında yön başına temiz doğruluklarını gerektirirdi; ki bu tam da talep ettiğimiz raporlamadır ve mekanizmanın adını koyabileceğimiz en keskin dış sınavıdır.

Dört protokol birbirinin yerine geçmez ve her birinin savunulabilir bir kullanımı vardır. Koşulsuz oran mimari karşılaştırması için hiç kullanılmamalıdır: 3×3 matrisimiz, koşullu orandan sapmasının hedefin temiz hatasının $(1 - r_{\text{koş}})$ ile ölçeklenmiş hâline cebirsel olarak eşit olduğunu gösterir; yani transfer edilebilirliği değil, bilinen bir oranda hedef zayıflığını ölçer. Hedef doğru protokolü bu karıştırıcıyı giderir ama kaynağın kendisinin çözemediği örnekleri kabul eder; bu marjinal altkümeler aşırı kırılabilir ve asimetrik boyutlu olduğundan iki yönü, temiz doğruluk farkına bağlı bir miktarda birbirine doğru çeker. Her ikisi doğru protokolü iki yönü özdeş örnekler üzerinde puanlar ve dördü içinde eşleştirilmiş çıkarımı destekleyen tek protokoldür; birincil tahmin olarak onu bu yüzden alıyoruz. Başarılı kaynak protokolü farklı bir soruyu yanıtlar: zaten işe yarayan bir saldırı ne kadar taşınır. Daha büyük değeri, kaynak başarısıyla koşullamanın güçlü pertürbasyonları seçmesini yansıtır.

Dört protokol, üç eğitim koşusu ve iki saldırı ailesi (PGD-10 ve MI-FGSM) boyunca, CNN'de üretilen çekişmeli örnekler *her iki CIFAR veri kümesinde* ViT'e tersinden daha iyi transfer olmaktadır. Aynı tariflerle çekişmeli eğitimin iki mimariyi 11 ya da 21 puan değil yalnızca 1,85 puan ayırdığı SVHN'de ise bu artık doğru değildir: iki protokol CNN üstünlüğü, iki protokol ViT üstünlüğü bildirmekte ve birincil her ikisi doğru protokolünde fark $-0,35$ puan olup eşdeğerlik kabul edilmektedir

(Bölüm IV-D). Yön, mimarilerin değil eşitlenmemiş rejimin bir özelliğidir. Eşitlenmemiş rejim içinde protokoller arasında değişen yalnızca etkinin ne kadar büyük görüldüğü ve bir eşdeğerlik testinin onu kabul edip etmediğidir; modeller eşitlendiğinde işaret de değişmektedir. Üç hedefli analizimiz bu yön için CNN pertürbasyonlarının özel olmasını gerektirmeyen bir okuma önermektedir: gelen transfer her hedefin kendi beyaz kutu kırılganlığını izler (üç hedef üzerinde $r = 0,986$) ve en gürbüz hedef iki aileden gelen saldırıları neredeyse eşit soğurur. Bu okumaya göre asimetri, hangi modelin daha zayıf hedef olduğuna dair bir ifadedir; dönüştürücüye özgü bir saldırının [12] ViT yönünü kurtaramaması da bununla tutarlıdır. Üç hedefle korelasyon yönlendiricidir; kesinleştirmek daha büyük bir model havuzu gerektirir.

Koşullu ayrıştırma, mutlak gürbüzlüğü temiz doğruluk çarpanı ile koşullu duyarlılık çarpanına ayırır. Düzeltilmiş koşullarımızda ikisi de CNN lehinedir; ayrıştırma ile manşet uyuşur. Önceki kontrol noktalarımızda uyuşmuyorlardı: koşullu duyarlılık PGD-10 altında eşleşik, AutoAttack altında hafifçe ViT lehine görünüyordu. Mutlak sıralama iki kontrol noktası kümesinde de özdeş olduğundan, yalnızca mutlak doğruluğu raporlayan bir makale hiçbir değişiklik görmezdi; tek koşudan ayrıştırma raporlayan bir makale ise tekrarlanmayan mekanizma düzeyinde bir sonuç çıkarırdı. Pratik ders şudur: mekanizma iddiaları sıralama iddialarından daha çok eğitim koşusu ister ve ikisine aynı kanıt ağırlığı verilmemelidir.

Seyreklik mekânsal lokalite değildir. Çekişmeli eğitilmiş CNN gradyanları külenin daha büyük kısmını daha az bileşene yoğunlaştırır (Hoyer 0,4928'e karşı 0,4561, eşleştirilmiş $p < 10^{-11}$); ama aynı gradyanların dört mekânsal betimleyicisi, bu bileşenlerin görüntüdeki dizilişinde karşılık gelen bir fark göstermez. CNN gradyanlarının mekânsal olarak lokalize olduğu betimlemeleri bu yüzden ayrı kanıt ister; seyreklik ölçüleri [61] bunu sağlamaz.

Çekişmeli pertürbasyon CLS dikkat entropisini ölçülebilir biçimde değiştirmez. $n = 1000$ 'de katman başına entropi değişimi en çok 0,005 natır; dikkat haritaları ise küçük ve derinlikle artan bir miktarda yer değiştirir. Yama saldırılarıyla elde edilen dikkat kayması sonuçları [31], [32] farklı bir tehdit modeline aittir ve ölçüm olmadan L_∞ sınırlı pertürbasyonlara genellenmemelidir.

ViT'e özgü bir transfer saldırısı burada ViT kaynaklı transferi iyileştirmez. TGR [12] 14,9 puan beyaz kutu gücüne mal olmakta ve bunun hiçbirini hedefte geri vermemektedir. Bunu rejime özgü bir negatif sonuç olarak raporluyoruz; hedeflerimiz çekişmeli eğitilmiş, verimiz CIFAR ölçeğindedir ve tam da bu türden tek bir test edilmemiş varsayımın, protokole duyarlı bir karşılaştırmaya taşıyacağı yük yüzünden.

İki davranışsal fark bağımsız kontrol noktası kümelerinde tekrarlanmakta ve protokol sorusundan etkilenmemektedir. Gradyan yapısı farklıdır: CNN girdi gradyanları üç ölçekten bağımsız ölçünün üçünde de daha seyrek, bu sıralamayı mimari değil çekişmeli eğitim yaratır (temiz eğitilmiş çiftte tersidir) ve örnekler arası hizalanma ViT'te mutlak kosinüste daha yüksekken işaretli ortalama iki modelde de sıfıra yakındır; örnekler yönleri değil duyarlılık eksenlerini paylaşır; ölçümü-müzü bir evrensel pertürbasyon iddiasından [63] ayıran ayırım budur. Derinlik profilleri farklıdır: CNN'de çekişmeli hasar son

artık aşamaya sıkışmış geç, yerel, büyüklük değiştiren bir olay; ViT'te dağıttık, yalnızca yön değiştiren bir dönmedir. ViT'in ölçülen profilinin jeton agregasyonuna bağlı olması, yani CLS yolunun yama ortalamasının üç katı kayması, katman bazlı çalışmalar için kendi başına bir raporlama gerekliliğidir.

B. Raporlama Gereklilikleri

Yukarıdaki ölçümler, mimariler arası gürbüzlük çalışmaları için kısa ve somut bir gereklilikler kümesi ortaya koymaktadır.

Çalışmalar koşullama protokolünü belirtmeli ve paydaya hangi örneklerin girdiğini raporlamalıdır. Yönlü bir iddia kuruluyorsa, iki yönü özdeş örnekler üzerinde puanlayan bir protokol yeğlenmeli, böylece eşleştirilmiş çıkarım mümkün olmalıdır. Koşulsuz transfer oranları mimari karşılaştırmaları olarak raporlanmamalıdır. Hedefler temiz doğrulukta ayrışıyor olsa ham oran, transfer edilebilirlik ile hedef zayıflığının bilinen bir karışımıdır, $r_{\text{ham}} - r_{\text{koş}} = e(1 - r_{\text{koş}})$; bu uydurulmuş bir ilişki değil bir özdeşlik olduğundan düzeltme, yayımlanmış ham oranlara hiçbir şey yeniden koşulmadan uygulanabilir.

Çalışmalar ayrıca yalnızca skoru değil ayrıştırmayı da raporlamalıdır. Mutlak gürbüzlük, temiz doğruluk ile koşullu duyarlılığın çarpımına birebir ayrışır ve manşeti hangi çarpanın taşıdığı asıl ilgi çekici kısımdır; bu, tek başına skordan geri elde edilemez. Sıralama iddiaları mekanizma iddialarından ayrılmalıdır: bizim sıralamalarımız kontrol noktası kümeleri arasında kararlı kalmış, mekanizma atfımız kalmamıştır, dolayısıyla mekanizma iddiaları daha çok eğitim koşusu taşınmalıdır. Katman bazlı analizlerde agregasyon belirtilmelidir, çünkü aynı blokların yalnızca CLS, yama ortalaması ve tüm jetonlar üzerinden özetleri farklı kayma büyüklükleri ve farklı minimumlar vermektedir. Son olarak dikkat ve lokalite iddiaları gerçekçi bir örneklem boyutunda sınanmalıdır, çünkü raporladığımız iki sıfır sonucun ikisi de küçük bir şekil yığımında pozitif görünecekti.

Bu kıyaslamada eşleşmiş standart çekişmeli eğitim altında iki aile arasında seçim yapan uygulayıcılar için: CNN daha yüksek mutlak gürbüz doğruluk vermekte ve üstünlük ölçtüğümüz her görünümde korunmaktadır. %62,76'daki WideResNet referansı, tarif, kapasite ve ek verinin birlikte [54] gürbüzlüğü mimari seçiminden daha ileri taşıdığını göstermektedir; gürbüzlük stratejisi olarak mimari seçimine yatırım yapmadan önce tartılmaya değer.

C. Sınırlılıklar

Çalışmamız bilinçli olarak dardır ve bu darlık sonuçları belirli biçimlerde sınırlar.

Protokol duyarlılığı sonucu üç veri kümesi ve tek model çifti üzerinde ölçülmüştür. CIFAR-100'de yayılım CIFAR-10 değerine yakındır ($13,83 \pm 1,30$ 'a karşı $15,01 \pm 0,84$ puan) ve işaret on iki ölçümün tamamında korunmaktadır (Bölüm IV-C). Dolayısıyla etki CIFAR'a özgü değildir; ancak büyüklüğü veri kümeleri arasında temiz doğruluk farkını izlememektedir: CIFAR-100'de fark açık ara daha büyük, yayılım ise bir miktar daha küçüktür. Önerdiğimiz mekanizma bir farkın bir yayılım ürettiğini öngörmekte, yayılımın veri kümeleri arasında nasıl sıralanacağını öngörmemektedir. Ancak bu açıklama eksiktir

ve sloganı değil sınırı yazıyoruz: dört protokolün üçü için geçerlidir; başarılı kaynak protokolü ise *kaynağın* gürbüzlüğüne bağlı ikinci bir sürücü ekler ve bu sürücü genel ilişkiyi tersine çevirecek kadar güçlüdür (Bölüm IV-B). Her iki bağımlılığın işlevsel biçimini de güvenle belirtemiyoruz: kestirimler altı tohum-ve-veri-kümesi kümesine dayanmaktadır ve havuzumuzdaki küçük farklı çiftlerin tamamı harici WideResNet'i içerdiğinden, küçük temiz doğruluk farkı ile farklı eğitim tarifi burada birbirinden ayırlanamamaktadır. Değişen temiz doğruluk farklarına sahip birden çok mimari çiftini tarayan bir çalışma, bu ölçümleri bir kalibrasyon eğrisine dönüştürecektir.

İki kontrol noktası kümesi arasındaki farkların nedenini yalıtamıyoruz. Düzeltilmiş protokol, doğrulama düzenini değiştirmiş ve aynı anda yeni bir eğitim koşusu üretmiştir. Veri miktarı açıklaması dışlanmıştır (düzeltilmiş temiz modeller daha az veriyle daha iyidir); ancak seçim sızıntısını olağan koşudan koşuya değişimden ayırmak, özdeş veriyle sızıntılı ve sızıntısız seçim altında eğiten bir ablasyon gerektirir. Karşıtlığı sızıntının ölçümü olarak değil, tek koşuluk mekanizma iddialarının kırılganlığına dair kanıt olarak raporluyoruz.

Bu makaledeki her model tek bir tehdit modelinin içinde eğitilmiştir: $\epsilon = 8/255$ ile L_∞ . Aynı kontrol noktalarını bir L_2 bütçesi altında değerlendirdik ve protokol yayılımı ayakta kaldı; 15,01 puana karşı 10,92 puan (Bölüm IV-E); ancak bu sınama L_2 gürbüzlüğüne değil ölçüm eksenini yoklar ve mutlak değerleri L_2 ile eğitilmiş referanslarla karşılaştırılmaz. Etkinin, başka bir norm altında *eğitilmiş* modeller için de geçerli olup olmadığı burada sınanmamıştır.

Mimari başına üç koşu tohum varyansını sınırlar ama tarif uzayını taramaz; küçük veri kümelerinde ViT çekışmeli eğitiminin tarife duyarlı olduğu bilinmektedir [56], [57] ve difüzyonla üretilmiş sentetik veriyle ViT'lerin CIFAR-10'da WideResNet'leri geçtiği bildirilmiştir [36], [64]. ViT sonuçlarımız ulaşılabilir en iyi ViT gürbüzlüğüne değil, temel çekışmeli eğitimi betimler. ViT-Tiny hattı 32×32 girdileri model içinde 224×224 'e büyütür; CIFAR'a özgü kontrolümüz gradyan sıralamasının büyütme artefaktı olmadığını gösterir, ama bu kontrol kapasite ve yama boyutunda farklıdır; dolayısıyla karıştırıcıyı kalibre eder, ikinci bir eşleşmiş çift sağlamaz. İki model parametre sayısında da ayrışır (11,2M'ye karşı 5,7M); mutlak farkın mimariye atfı bu yüzden kısmi kalır. Son olarak tek bütçeli bir L_∞ tehdit modeli değerlendiriyoruz ve TGR sonucumuz, yöntemin yayımlanmış kurulumunun yeniden üretimi değil bir uyarlamasıdır.

D. Gelecek Yönelimler

En doğrudan uzantı, protokol duyarlılığı ölçümünü genel bir ölçüme dönüştürmektir: kontrollü temiz doğruluk farklarına sahip mimari çiftlerini tarayıp protokoller arası yayılımın bu farkla nasıl ölçeklendiğini ölçmek. İlişki, üç hedefli korelasyonumuzun önerdiği kadar düzenliyse, yayımlanmış ham oran asimetrisinin atılmak yerine yeniden yorumlanmasına imkân veren bir düzeltme sağlar.

Daha önce gelecek çalışma diye sıraladığımız uzantılardan ikisi bu arada koşulmuştur; hem neyi karara bağladıklarını hem neyi bağlamadıklarını kaydediyoruz. Sızıntı ablasyonu altı tam bütçeli yörünge üzerinde yürütülmüş ve sızıntının kontrol

noktası seçimine etkisini *saptamamıştır*; başlangıçta konan sorunun daha zayıf bir sürümünü yanıtlar, çünkü tedavi tek bir doğrulama bölmesine uygulanmıştır ve o tasarımda bölme kimliği ile sızıntı birbirinden ayrıştırılmaz. Bilgi verici yan ürünü, Bölüm IV-I'te raporlanan seçim protokolü yayılımıdır. İkinci veri kümesi de koşulmuştur (Bölüm IV-C). Açık kalan, kapasitesi eşlenmiş çifttir (örneğin ViT-Small'a karşı ResNet-50); bu, ayakta kalan davranışsal farkların, yani seyreklik sıralaması ile derinlik profillerinin, ailelerin mi yoksa bu küçük modellerin mi özelliği olduğunu test edecektir.

VI. SONUÇ

CNN ile Görü Dönüştürücüsü gürbüzlük karşılaştırmalarının uyuşmazlığın ne kadarının modellerden değil ölçümden geldiğini sorduk ve bunu; modelleri, veriyi, tehdit modelini ve saldırı bütçesini sabit tutup yalnızca karşılaştırmının nasıl puanlandığını değiştirerek yanıtladık.

Ölçüm hükmediyor. Özdeş çekışmeli eğitilmiş ResNet-18 ve ViT-Tiny çiftlerinde, mimariler arası transfer asimetrisi dört yerleşik koşullama protokolü boyunca $+4,4$ ile $+19,4$ puan arasında değişmektedir; bu, 4,4 katlık bir yayılımdır. Buna karşılık her iki mimariyi sıfırdan yeniden eğitmek aynı niceliği 1,5 puandan az oynatmaktadır. Protokol, bir eşdeğerlik testinin kabul mü ret mi edileceğine karar vermektedir. Koşulsuz oranlar böyle bir karşılaştırma için hiçbir biçimde geçerli temel değildir: WideResNet-28-10 referansının eklenildiği 3×3 matriste, koşullu oranlardan sapmaları, hedefin temiz hatasının bir eksi koşullu oranla ölçeklenmiş hâline cebirsel olarak eşittir; bu özdeşlik 36 ölçülen yönde 0,41 puandan küçük bir hatayla tutmakta ve ölçülen öncülü sağlayan yayımlanmış herhangi bir ham orana uygulanabilmektedir. Aynı tasarım CIFAR-100 üzerinde koşulduğunda yayılım CIFAR-10 değerine yakın kalmakta ($13,83 \pm 1,30$ puan); yörüngeyi sabitleyip yalnızca kontrol noktası seçimi kuralını değiştiren bir ablasyon ise raporlanan gürbüz doğruluğu 1,58 ile 2,85 puan oynatmaktadır. Yani genellikle örtük bırakılan ölçüm tercihleri, raporlanan etkilerle aynı mertebededir. Yön, her iki CIFAR veri kümesinde protokoller, tohumlar ve saldırı aileleri boyunca karardır; ancak veri kümeleri boyunca değildir: aynı tarifi iki mimariyi temiz doğrulukta yalnızca 1,85 puan ayırdığı SVHN'de dört protokolün ikisi işareti tersine çevirmekte ve birincil protokol eşdeğerliği kabul etmektedir. Ayakta kalan şey bir sıralamadan daha dar ve daha kullanışlıdır: yön, modeller eşitlenmemişken geçerlidir ve üç hedefli analizimiz onu CNN'de üretilen pertürbasyonların özel bir gücünden çok hedefin kendi kırılganlığıyla ($r = 0,986$) ilişkilendirmektedir.

Koşullu ayrıştırma, mutlak gürbüzlüğü temiz doğruluk çarpanı ile koşullu duyarlılık çarpanına ayırır. Düzeltilmiş koşullarımızda ikisi de CNN lehinedir; ancak mutlak sıralaması özdeş olan önceki bir kontrol noktası kümesinde iki çarpan arasındaki pay farklıydı. Bu, mekanizma düzeyindeki iddiaların sıralama düzeyindeki iddialardan daha kırılgan olduğunu ve desteklenmek için daha çok eğitim koşusu gerektirdiğini gösterir.

Bu literatürde yaygın üç iddia doğrudan ölçümden sağ çıkamamıştır: çekışmeli eğitilmiş CNN gradyanları daha seyrek ama mekânsal olarak daha lokalize değildir; CLS dikkat

entropisi $n = 1000$ 'de L_∞ saldırısı altında değişmemektedir; dönüştürücüye özgü bir transfer saldırısı bu rejimde transfer kazancı sağlamamaktadır. İki davranışsal fark ise bağımsız kontrol noktası kümelerinde tekrarlanarak ayakta kalmıştır: mimarinin değil çekişmeli eğitimin yarattığı gradyan seyrekliği sıralaması ile çekişmeli hasarın derinlik profili, yani CNN'de geç, yerel ve büyüklük değiştiren bir olay; ViT'te dağıtık, yalnızca yön değiştiren bir dönme.

Bu ölçümlerden, ilk ikisi en önemli olan kısa bir raporlama gereklilikleri kümesi damıttık: koşullama protokolünü belirtin ve eşleştirilmiş olanları yeğleyin; koşulsuz transfer oranlarını mimari karşılaştırması olarak sunmayın. Çalışmamız üç veri kümesini ve tek bir model çiftini kapsamaktadır; dolayısıyla protokol etkisinin başka mimari çiftlerindeki boyutu kalibre edilmeyi beklemektedir. Etkinin arkasındaki mekanizma, yani hedefler arasındaki eşitsiz temiz doğruluk farkı, kurulumumuza özgü değildir. Protokol karşılaştırmasının yeniden üretilip genişletilebilmesi için tam boru hattı, örnek bazında kayıtlar ve analiz betikleri kabul sonrasında yayımlanacaktır.

VERİ VE KOD ERIŞİLEBİLİRLİĞİ

Bu çalışmadaki deneyler, herkese açık olan CIFAR-10 ve CIFAR-100 veri kümeleri [11] ile SVHN veri kümesini [62] kullanmaktadır. Önceden eğitilmiş WideResNet-28-10 ağırlıkları RobustBench kıyaslamasından [23], [54] alınmıştır. Kabul sonrasında analiz hattını, bu makaledeki her tabloyu ve şekli üreten betikleri, örnek bazında değerlendirme kayıtlarını, sabit doğrulama bölmesi indekslerini ve tohum listelerini yayımlayacağız; bunlar burada raporlanan her sayıyı yeniden üretmeye yetmektedir, çünkü dört koşullama protokolünün tamamı örnek bazındaki kayıtlardan hesaplanmaktadır ve protokol karşılaştırması yeniden eğitim gerektirmeden tekrarlanabilmektedir. Eğitilmiş kontrol noktaları yaklaşık 36 GB tutmaktadır ve yazarlardan istek üzerine sağlanmaktadır.

TEŞEKKÜR

Yazarlar, hesaplama kaynakları için Fırat Üniversitesi Yazılım Mühendisliği Bölümü'ne teşekkür eder.

KAYNAKLAR

- [1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, "Intriguing properties of neural networks," in *International Conference on Learning Representations*, 2014.
- [2] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and harnessing adversarial examples," in *International Conference on Learning Representations*, 2015.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations*, 2021.
- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [6] Y. Bai, J. Mei, A. L. Yuille, and C. Xie, "Are transformers more robust than cnns?" in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 26 831–26 843.
- [7] P. Benz, S. Ham, C. Zhang, A. Karjauv, and I. S. Kweon, "Adversarial robustness comparison of vision transformer and MLP-Mixer to CNNs," in *Proceedings of the 32nd British Machine Vision Conference (BMVC)*, 2021.
- [8] K. Mahmood, R. Mahmood, and M. Van Dijk, "On the robustness of vision transformers to adversarial examples," in *IEEE/CVF International Conference on Computer Vision*, 2021, pp. 7838–7847.
- [9] D. Ravikumar, S. Kodge, I. Garg, and K. Roy, "TREND: Transferability-based robust ENsemble design," *IEEE Transactions on Artificial Intelligence*, vol. 4, no. 3, pp. 534–548, 2023.
- [10] M. Naseer, K. Ranasinghe, S. Khan, F. S. Khan, and F. Porikli, "On improving adversarial transferability of vision transformers," in *International Conference on Learning Representations*, 2022.
- [11] A. Krizhevsky, G. Hinton *et al.*, "Learning multiple layers of features from tiny images," University of Toronto, Tech. Rep., 2009.
- [12] J. Zhang, Y. Huang, W. Wu, and M. R. Lyu, "Transferable adversarial attacks on vision transformers with token gradient regularization," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 16 415–16 424.
- [13] c. Şahin and O. Yıldırım, "A behavioral comparison of adversarially trained ResNet-18 and ViT-Tiny on CIFAR-10: Transfer metrics, gradient structure, and block-wise feature drift," in *Proc. ATEEC 2026*, 2026, preliminary version of the present study; submitted.
- [14] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, "Towards deep learning models resistant to adversarial attacks," in *International Conference on Learning Representations*, 2018.
- [15] N. Carlini and D. Wagner, "Towards evaluating the robustness of neural networks," in *IEEE Symposium on Security and Privacy (SP)*, 2017, pp. 39–57.
- [16] F. Croce and M. Hein, "Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks," in *International Conference on Machine Learning*, 2020, pp. 2206–2216.
- [17] H. Zhang, Y. Yu, J. Jiao, E. Xing, L. El Ghaoui, and M. Jordan, "Theoretically principled trade-off between robustness and accuracy," in *International Conference on Machine Learning*, 2019, pp. 7472–7482.
- [18] Y. Wang, D. Zou, J. Yi, J. Bailey, X. Ma, and Q. Gu, "Improving adversarial robustness requires revisiting misclassified examples," in *International Conference on Learning Representations*, 2020.
- [19] C. Guo, M. Rana, M. Cisse, and L. Van Der Maaten, "Countering adversarial images using input transformations," in *International Conference on Learning Representations*, 2018.
- [20] J. Cohen, E. Rosenfeld, and Z. Kolter, "Certified adversarial robustness via randomized smoothing," in *International Conference on Machine Learning*, 2019, pp. 1310–1320.
- [21] F. Tramèr, A. Kurakin, N. Papernot, I. Goodfellow, D. Boneh, and P. McDaniel, "Ensemble adversarial training: Attacks and defenses," in *International Conference on Learning Representations*, 2018.
- [22] S. Lyu, S. Shaikh, F. Shpilevskiy, E. Shelhamer, and M. Lécuyer, "Adaptive randomized smoothing: Certified adversarial robustness for multi-step defences," in *Advances in Neural Information Processing Systems*, vol. 37, 2024.
- [23] F. Croce, M. Andriushchenko, V. Schweg, E. Debenedetti, N. Flammarion, M. Chiang, P. Mittal, and M. Hein, "RobustBench: a standardized adversarial robustness benchmark," in *NeurIPS Datasets and Benchmarks Track*, 2021.
- [24] D. Wu, Y. Wang, S.-T. Xia, J. Bailey, and X. Ma, "Skip connections matter: On the transferability of adversarial examples generated with ResNets," in *International Conference on Learning Representations (ICLR)*, 2020.
- [25] C. Xie and A. Yuille, "Intriguing properties of adversarial training at scale," in *International Conference on Learning Representations (ICLR)*, 2020.
- [26] C. Xie, M. Tan, B. Gong, J. Wang, A. L. Yuille, and Q. V. Le, "Adversarial examples improve image recognition," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 819–828.
- [27] D. Tsipras, S. Santurkar, L. Engstrom, A. Turner, and A. Madry, "Robustness may be at odds with accuracy," in *International Conference on Learning Representations (ICLR)*, 2019.
- [28] P. Chalasani, J. Chen, A. R. Chowdhury, X. Wu, and S. Jha, "Concise explanations of neural networks using adversarial training," in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 1383–1391.
- [29] M. Raghu, T. Unterthiner, S. Kornblith, C. Zhang, and A. Dosovitskiy, "Do vision transformers see like convolutional neural networks?" in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 12 116–12 128.
- [30] S. Bhojanapalli, A. Chakrabarti, D. Glasner, D. Li, T. Unterthiner, and A. Veit, "Understanding robustness of transformers for image classification," in *IEEE/CVF International Conference on Computer Vision*, 2021, pp. 10 231–10 241.

- [31] Y. Fu, S. Zhang, S. Wu, C. Wan, and Y. Lin, "Patch-Fool: Are vision transformers always robust against adversarial perturbations?" in *International Conference on Learning Representations (ICLR)*, 2022.
- [32] J. Gu, V. Tresp, and Y. Qin, "Are vision transformers robust to patch perturbations?" in *Computer Vision – ECCV 2022*, ser. Lecture Notes in Computer Science, vol. 13672. Springer, 2022, pp. 404–421.
- [33] R. Shao, Z. Shi, J. Yi, P.-Y. Chen, and C.-J. Hsieh, "On the adversarial robustness of vision transformers," *Transactions on Machine Learning Research*, 2022.
- [34] S. Paul and P.-Y. Chen, "Vision transformers are robust learners," in *AAAI Conference on Artificial Intelligence*, 2022, pp. 2071–2081.
- [35] S. Jain and T. Dutta, "Towards understanding and improving adversarial robustness of vision transformers," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 24736–24745.
- [36] J. Wu, Z. Song, X. Zhang, S. Xie, L. Lin, and K. Wang, "Vision transformers beat WideResNets on small scale datasets adversarial robustness," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 1, 2025, pp. 886–894.
- [37] Z. Zhu, X. Wang, Z. Jin, J. Zhang, and H. Chen, "Enhancing transferable adversarial attacks on vision transformers through gradient normalization scaling and high-frequency adaptation," in *International Conference on Learning Representations*, 2024.
- [38] N. Papernot, P. McDaniel, and I. Goodfellow, "Transferability in machine learning: from phenomena to black-box attacks using adversarial samples," *arXiv preprint arXiv:1605.07277*, 2016.
- [39] A. Demontis, M. Melis, M. Pintor, M. Jagielski, B. Biggio, A. Oprea, C. Nita-Rotaru, and F. Roli, "Why do adversarial attacks transfer? explaining transferability of evasion and poisoning attacks," in *28th USENIX Security Symposium*, 2019, pp. 321–338.
- [40] Y. Liu, X. Chen, C. Liu, and D. Song, "Delving into transferable adversarial examples and black-box attacks," in *Proceedings of the 5th International Conference on Learning Representations (ICLR)*, 2017.
- [41] Y. Dong, F. Liao, T. Pang, H. Su, J. Zhu, X. Hu, and J. Li, "Boosting adversarial attacks with momentum," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 9185–9193.
- [42] Z. Zhao, H. Zhang, R. Li, R. Sicre, L. Amsaleg, M. Backes, Q. Li, Q. Wang, and C. Shen, "Revisiting transferable adversarial images: Systemization, evaluation, and new insights," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 48, no. 1, pp. 765–780, 2026.
- [43] Q. Li, Y. Guo, W. Zuo, and H. Chen, "Towards evaluating transfer-based attacks systematically, practically, and fairly," in *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [44] W. Yu, J. Gu, Z. Li, and P. Torr, "Reliable evaluation of adversarial transferability," in *IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2025, pp. 797–810.
- [45] Z. Wei, J. Chen, M. Goldblum, Z. Wu, T. Goldstein, and Y.-G. Jiang, "Towards transferable adversarial attacks on vision transformers," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 36, no. 3, 2022, pp. 2668–2676.
- [46] W. Ma, Y. Li, X. Jia, and W. Xu, "Transferable adversarial attack for both vision transformers and convolutional networks via momentum integrated gradients," in *IEEE/CVF International Conference on Computer Vision*, 2023, pp. 4630–4639.
- [47] Z. Chen, C. Xu, H. Lv, S. Liu, and Y. Ji, "Understanding and improving adversarial transferability of vision transformers and convolutional neural networks," *Information Sciences*, vol. 648, p. 119474, 2023.
- [48] F. Waseda, S. Nishikawa, T.-N. Le, H. H. Nguyen, and I. Echizen, "Closer look at the transferability of adversarial examples: How they fool different models differently," in *IEEE/CVF Winter Conference on Applications of Computer Vision*, 2023, pp. 1360–1368.
- [49] F. Pinto, P. H. S. Torr, and P. K. Dokania, "An impartial take to the CNN vs Transformer robustness contest," in *Computer Vision – ECCV 2022*, ser. Lecture Notes in Computer Science, vol. 13673. Cham: Springer, 2022, pp. 466–480.
- [50] K. Ali, M. S. Bhatti, A. Saeed, A. Athar, M. A. Al Ghamdi, S. H. Almotiri, and S. Akram, "Adversarial robustness of vision transformers versus convolutional neural networks," *IEEE Access*, vol. 12, pp. 105281–105293, 2024.
- [51] N. Carlini, A. Athalye, N. Papernot, W. Brendel, J. Rauber, D. Tsipras, I. Goodfellow, A. Madry, and A. Kurakin, "On evaluating adversarial robustness," *arXiv preprint arXiv:1902.06705*, 2019.
- [52] F. Tramèr, N. Carlini, W. Brendel, and A. Madry, "On adaptive attacks to adversarial example defenses," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [53] S. Zagoruyko and N. Komodakis, "Wide residual networks," in *Proceedings of the British Machine Vision Conference (BMVC)*. BMVA Press, 2016, pp. 87.1–87.12.
- [54] S. Gowal, C. Qin, J. Uesato, T. Mann, and P. Kohli, "Uncovering the limits of adversarial training against norm-bounded adversarial examples," *arXiv preprint arXiv:2010.03593*, 2020.
- [55] R. Wightman, "Pytorch image models," <https://github.com/rwightman/pytorch-image-models>, 2019.
- [56] E. Debenedetti, V. Schwag, and P. Mittal, "A light recipe to train robust vision transformers," in *IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2023, pp. 225–253.
- [57] Y. Mo, D. Wu, Y. Wang, Y. Guo, and Y. Wang, "When adversarial training meets vision transformers: Recipes from training to architecture," in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 18599–18611.
- [58] L. Rice, E. Wong, and J. Z. Kolter, "Overfitting in adversarially robust deep learning," in *International Conference on Machine Learning*, 2020, pp. 8093–8104.
- [59] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *International Conference on Learning Representations (ICLR)*, 2017.
- [60] —, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019.
- [61] N. Hurlley and S. Rickard, "Comparing measures of sparsity," *IEEE Transactions on Information Theory*, vol. 55, no. 10, pp. 4723–4741, Oct. 2009.
- [62] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, "Reading digits in natural images with unsupervised feature learning," in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- [63] S.-M. Moosavi-Dezfooli, A. Fawzi, O. Fawzi, and P. Frossard, "Universal adversarial perturbations," in *IEEE Conference on Computer Vision and Pattern Recognition*, 2017, pp. 1765–1773.
- [64] Z. Wang, T. Pang, C. Du, M. Lin, W. Liu, and S. Yan, "Better diffusion models further improve adversarial training," in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 36246–36263.