Koşullama Kümesi Ölçülen Transfer Asimetrisini Belirler: CNN ile Görü Dönüştürücüsü Gürbüzlük Karşılaştırmaları için Kesin Bir Düzeltme ve Kaynak Etkisi Okuması

The Conditioning Set Decides the Measured Transfer Asymmetry: An Exact Correction and a Source-Effect Reading for CNN versus Vision Transformer Robustness Comparisons

Çağrı Şahin ve Özal Yıldırım

***Özet*—CNN ile ViT arasındaki transfer çalışmaları hangi örnekleri puanladıklarını belirtmekte, ancak incelenen çalışmaların hiçbiri bu koşullama kümesini değiştirmemektedir. Bu çalışmada kümenin ağırlığı çekişmeli eğitilmiş ResNet-18 ve ViT-Tiny modelleri üzerinde ölçülmüştür (her mimari için üç koşu, tam CIFAR-10 test kümesi, örnek bazında kayıt). Modeller, veri ve saldırı sabitken dört koşullama protokolü CNN'den ViT'e transfer asimetrisini $4{,}4$ ile $19{,}4$ puan arasına yerleştirmekte, yeniden eğitim aynı asimetriyi en çok $2{,}4$ puan oynatmaktadır (koşumlar arası standart sapma $0{,}23$ ile $1{,}27$). Koşulsuz kestirim, toplam olasılık yasasının öngördüğü yerde, hedef doğru kestirimin $9{,}21$ puan üstündedir. Temizde yanlış sınıflandırılan örneklerin yanlış kalacağını söyleyen öncül p, bu çalışmanın çekişmeli eğitilmiş hedeflerinde $0{,}989$ ile $1{,}000$ arasındadır; standart eğitilmiş hedeflerde ise $0{,}88$'e inmekte ve orada $p = 1$ varsayımı $1{,}6$ puana kadar hata vermektedir. Onaylanan iki protokol $3{,}91$ puan ayrışmakta (koşum düzeyinde %95 aralık $[3{,}12;\ 4{,}70]$), farklı bir niceliği kestiren başarılı kaynak puanlaması ise her ikisi doğru kestiriminin $11{,}10$ puan üstünde kalmaktadır. Yön bu ViT-Tiny modelinin bir kaynak etkisidir; hedef doğru matrislere yapılan toplamsal uydurmalar $-2{,}03$ ve $-6{,}19$ puanlık hedef terimlerine karşı $+5{,}13$ (CIFAR-10) ve $+9{,}54$ puanlık (CIFAR-100) kaynak terimleri vermektedir. Özdeşlik terimi temiz doğruluk farkını izlemektedir. Üç protokollü yayılım eşlenmeye yakın SVHN çiftlerinde $1{,}49$ ve $1{,}30$, aralarında $0{,}47$ puan bulunan standart eğitilmiş bir çiftte $0{,}19$ puandır ve havuzun 28 çiftinde temiz farkın puanı başına $0{,}87$ puan artmaktadır. Başarılı kaynak fazlası küçülmemektedir (aralarında $0{,}21$ puan bulunan iki gürbüz WideResNet'te $9{,}03$ puan). Kontrol noktası seçimi yayılımı yaklaşık iki puan oynatmaktadır. Üç okuma daha doğrudan ölçümde doğrulanmamakta ve çalışma raporlama gereklilikleriyle sonuçlandırılmaktadır.**

***Anahtar Kelimeler*—Çekişmeli gürbüzlük, değerlendirme yöntembilimi, derin öğrenme güvenliği, evrişimli sinir ağları, görü dönüştürücüsü, tekrarlanabilirlik, transfer saldırıları**

Çağrı Şahin, Muş Alparslan Üniversitesi Yazılım Mühendisliği Bölümü'ndedir (49250 Muş, Türkiye) ve ayrıca Fırat Üniversitesi Yazılım Mühendisliği Bölümü'nde doktora öğrencisidir (23119 Elazığ, Türkiye).

Özal Yıldırım, Fırat Üniversitesi Yazılım Mühendisliği Bölümü'ndedir, 23119 Elazığ, Türkiye.

Sorumlu yazar: Çağrı Şahin (e-posta: c.sahin@alparslan.edu.tr).

I. GIRIŞ

Derin sinir ağları, küçük bir norm bütçesiyle sınırlı kalırken yüksek güvenle yanlış sınıflandırmaya yol açan, özenle üretilmiş pertürbasyonlar olan çekişmeli örneklere (adversarial examples) karşı savunmasızdır [1], [2]. Görü Dönüştürücüleri (Vision Transformer, ViT) [3], [4] evrişimli sinir ağlarının (CNN) [5] yanında baskın bir mimari aile haline geldikçe hangi ailenin daha gürbüz olduğu ve bunun nedeni sorusu doğal olarak gündeme gelmiştir.

Literatür bu soruya tutarsız yanıtlar vermektedir. Bai vd. [6] eşleşmiş eğitim tarifleri altında dönüştürücülerin CNN'leri geçmediğini bildirirken Benz vd. [7] standart eğitilmiş modellerde ViT'lerin daha gürbüz olduğunu bildirmiştir. Transfer çalışmaları buna kendi uyuşmazlıklarını eklemektedir. Bu çalışmaların birçoğu saldırıların ViT'den CNN'e, tersine göre daha kolay taşındığını bildirmekte [7]–[9], Naseer vd. [10] ise ViT üzerinde üretilen pertürbasyonların geleneksel saldırılar altında zayıf transfer ettiğini bulmaktadır; bu makalede ölçülen yön ilk grubunkinin tersidir ve Bölüm V bu noktaya geri dönmektedir. Bu uyuşmazlıklar genellikle model, eğitim tarifi veya veri kümesi farklarına atfedilmekte ve olağan yanıt, karşılaştırmayı eşleşmiş bir tarif altında yapmak olmaktadır.

Ancak modeller, veri, tehdit modeli ve saldırı bütçesinin tamamı sabit tutulduğunda bile bir transfer oranı, Bölüm II'de incelenen çalışmaların belirttiği ama değiştirmediği bir seçime, paydaya hangi örneklerin gireceğini belirleyen *koşullama kümesine* bağlı kalmaktadır. Aday kümeler tüm test örnekleri, hedefin doğru sınıflandırdığı örnekler, iki modelin de doğru sınıflandırdığı örnekler ve kaynak saldırının başarılı olduğu örneklerdir. Mahmood vd. [8], Ravikumar vd. [11] ve Zhao vd. [12] kullandıkları kümeyi adlandırıp onunla ilerlemektedir. Bu yaklaşım sağlıklı bir uygulamadır, ancak aynı modellerde farklı bir kümenin sonucu ne kadar değiştireceği sorusunu açık bırakmaktadır. Gürbüzlük karşılaştırmaları da benzer bir seçimle, mutlak bir skor ile bu skorun temiz doğruluk ve koşullu duyarlılık bileşenlerine ayrıştırılması arasındaki seçimle karşı karşıyadır.

Bu soruyu yalıtabilmek için kurulum küçük tutulmuştur.

CIFAR-10 [13] üzerinde ResNet-18 ve ViT-Tiny, temiz ön eğitimin ardından karma kayıplı PGD çekişmeli ince ayardan oluşan tek bir eşleşmiş tarifle eğitilmiştir. Mimari başına üç bağımsız eğitim koşusu yapılmış ve *her* eğitim aşamasından önce sabit bir doğrulama bölmesi ayrılmıştır; böylece hiçbir model gördüğü veriyle seçilmemektedir. Tüm değerlendirmeler tam test kümesinde örnek bazında sonuç kaydıyla yürütüldüğünden aynı saldırı sonuçları, saldırı yeniden koşulmadan her protokol altında yeniden puanlanabilmektedir. Modeller sabitken yalnızca protokol değiştirilmektedir. Sonradan eklenen iki ölçüm yeni bir eğitim gerektirmemektedir: aynı boru hattının temiz eğitilmiş kontrol noktaları standart eğitilmiş bir WideResNet-28-10 ile birlikte kullanılmış, ayrıca RobustBench [14] gürbüz kontrol noktalarını da içeren sekiz modelli bir havuz kurulmuştur.

Mimari karşılaştırmaları üç okumayı da akla getirmektedir ve bu çalışmada üçü de ölçülebilir hipotez olarak ele alınmıştır. Bunlar CNN girdi gradyanlarının mekansal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini (attention) bozduğu ve ViT'e özgü transfer saldırılarının mimariler arası transferi iyileştirdiği okumalarıdır. Yalnızca sonuncusu yayımlanmış bir iddiadır; ilk ikisi bir seyreklik sonucunun ya da küçük bir dikkat şekli kümesinin kolayca düşündürdüğü yorumlardır ve yazarların önceki şekilleri de aynı yorumu düşündürmüştür.

Çalışmanın ilk katkısı, sabit modeller üzerinde protokol duyarlılığının ölçülmesidir. Dört koşullama protokolü boyunca CNN'den ViT'e transfer asimetrisi $+4{,}36$ ile $+19{,}37$ puan arasında değişirken, tek bir protokolün içinde iki mimariyi yeniden eğitmek aynı niceliği en çok $2{,}41$ puanlık bir aralıkta oynatmaktadır. CIFAR-10'da bu aralık iki uzaklıktan oluşmaktadır. Farklı bir niceliği kestiren başarılı kaynak protokolü her ikisi doğru kestiriminin $11{,}10$ puan üstünde yer almakta, bu çalışmada onaylanan iki protokol olan hedef doğru ile her ikisi doğru ise birbirinden $3{,}91$ puan ayrılmaktadır (koşum düzeyinde %95 aralık $[3{,}12;\ 4{,}70]$). Koşulsuz kestirim aralığın içinde, hedef doğru kestirimin $9{,}21$ puan üstünde yer almaktadır; hedeflerin temiz hataları, koşullu oranlar ve ölçülen öncül bilindiğinde Bölüm III-F'teki özdeşlik onu tam bu konuma yerleştirmektedir. Bir eşdeğerlik iddiasının kurulup kurulamayacağı da protokole bağlıdır (Bölüm IV-D2).

İkinci katkı koşulsuz oranlara ilişkindir. Bu oranların hedef doğru orandan sapması, TRADES ayrışımının [15] transfer karşılığı olan temel bir özdeşlikten çıkmaktadır ve bu çalışmada özdeşliğin öncülü ölçülmüştür. Öncül p, hedefin zaten yanlış sınıflandırdığı bir örneğin aktarılan pertürbasyon altında da yanlış kalma olasılığıdır. Çekişmeli eğitilmiş hedeflerde p, 36 yönde $0{,}989$ ile $1{,}000$ arasında kaldığından düzeltme puanın onda birkaçı içinde kesindir. Standart eğitilmiş hedeflerde ise p $0{,}877$'ye inmekte ve $p = 1$ biçimi koşulsuz oranı $1{,}58$ puana kadar ıskalamaktadır; orada p ölçülerek genel biçimin kullanılması gerekmektedir.

Üçüncü katkı yönün kaynağını belirlemektir. Bir WideResNet-28-10'un eklendiği 3×3 transfer matrislerinde hedef doğru oranlara uydurulan toplamsal kaynak-artı-hedef modeli asimetriyi kaynağa yüklemektedir. Bu çalışmanın ViT-Tiny modelinde üretilen örnekler dış model dahil her hedefe daha kötü taşınmakta, ViT ise *daha az* kırılgan hedef olmaktadır (kaynak terimleri CIFAR-10 ve CIFAR-100'de $+5{,}13$ ve $+9{,}54$ puan, hedef terimleri $-2{,}03$ ve $-6{,}19$). Kaynak terimi her koşullu protokolde işaretini korurken hedef terimi protokole bağlıdır ve CIFAR-10'da her ikisi doğru protokolü altında sıfırdan ayırt edilememektedir; dolayısıyla yön en iyi, bu ViT-Tiny modelinin ürettiği örneklerin bir özelliği olarak okunmaktadır. Aynı matrisler ham oranlarla okunduğunda ViT daha zayıf hedef gibi görünmektedir, çünkü ham oranlar onun temiz hatasını da taşımaktadır. Mahmood vd.'nin [8] 8×8 matrislerinde ise kaynak terimi ViT lehinedir ve bu çalışmayla aynı yönü gösteren CIFAR-100 çiftleri bu yöne hedef terimi üzerinden ulaşmaktadır.

Dördüncü katkı, özdeşlikten çıkan ve verilerin yalnızca özdeşlik terimi için doğruladığı bir eşlenmiş çift öngörüsüdür. Koşulsuz, hedef doğru ve her ikisi doğru kestirimleri temiz hatalarla orantılı terimlerle birbirinden ayrıldığından bu kestirimlerin yayılımı, mimariler ne olursa olsun çiftin temiz doğruluk farkıyla ölçeklenmeli ve temiz doğrulukta eşlenmiş çiftlerde kaybolmalıdır. Verilerin eklediği şey türetilmiş değil ölçülmüştür. İncelenen her çekişmeli eğitilmiş hedefte p en az $0{,}984$'tür, her ikisi doğru kestirimi 60 model çiftinin 57'sinde diğer ikisinin arasında yer almaktadır ve başarılı kaynak terimi farkla ilişkisizdir. Buna uygun olarak üç protokollü yayılım, iki modelin temiz doğrulukta $1{,}84$ puan ayrıldığı SVHN'de $1{,}49$ ve $1{,}30$ puan, aralarında $0{,}47$ puan bulunan standart eğitilmiş ResNet-18 ile WideResNet-28-10 çiftinde $0{,}19$ puandır; sekiz modelli havuzun 28 çiftinde ise temiz farkın puanı başına $0{,}872$ puan artmaktadır. Başarılı kaynak fazlası küçülmemektedir; aralarında $0{,}21$ puan bulunan iki gürbüz WideResNet-28-10 kontrol noktasının dört protokollü yayılımı hâlâ $9{,}03$ puandır. Kontrol noktası seçim kuralı temiz farkı yaklaşık $1{,}7$ puan, dört protokollü yayılımı ise yaklaşık iki puan oynatmakta ve yönü değiştirmemektedir.

Mutlak gürbüzlük her saldırı altında CNN lehinedir ve birebir temiz doğruluk ile koşullu duyarlılık çarpanlarına ayrışmaktadır; mevcut koşularda iki çarpan da CNN lehine olsa da daha önceki bir kontrol noktası kümesinde aralarındaki pay farklı çıkmıştır. Üç okuma daha doğrudan ölçümde doğrulanmamaktadır ve Bölüm IV-G bunları birlikte raporlamaktadır. Çekişmeli eğitilmiş CNN gradyanları daha seyrektir ama mekansal olarak daha lokalize değildir, CLS dikkat entropisi saldırı altında değişmemektedir ve ViT'e özgü bir transfer saldırısı bu rejimde kazanç sağlamamaktadır. Bu ölçümlerden çıkan raporlama gereklilikleri Bölüm V-B'te bir araya getirilmiştir.

Bu çalışmanın ön sürümü ATEEC 2026'ya gönderilmiştir [16]. O sürüm koşullu ayrıştırmayı, dört protokollü transfer karşılaştırmasını, gradyan yapısı ölçümlerini ve blok bazlı kayma profillerini yalnızca CIFAR-10 üzerinde raporlamakta ve bunları ön sonuç olarak nitelemektedir. Bu makale iki veri kümesi daha, ikinci bir tehdit modeli, Bölüm III-F'teki özdeşliği ölçülmüş öncülüyle birlikte, kaynak-hedef ayrıştırmasını, standart eğitilmiş hedefleri ve bir dış model havuzunu, kontrol noktası seçiminin çözümlemesini, dönüştürücüye özgü transfer saldırısını ve ölçümden önce kaydedilen bir analiz protokolünü eklemektedir. Ayrıca önceki sürümün bir iddiası düzeltilmiştir; mimariler temiz doğrulukta eşlendiğinde asimetrinin yönü kararlı değildir.

Bölüm II'de çekişmeli değerlendirme pratiği ve mimari karşılaştırma çalışmaları gözden geçirildikten sonra Bölüm III eğitim protokolünü, koşullama protokollerini ve ölçümleri tanımlamakta, Bölüm IV ise sonuçları vermektedir. Çıkarımlar ve sınırlılıklar Bölüm V'da, sonuç Bölüm VI'da yer almaktadır.

II. İLGILI ÇALIŞMALAR

A. Çekişmeli Saldırılar

Çekişmeli saldırılar yanlış sınıflandırmaya yol açan küçük pertürbasyonları aramaktadır. Hızlı Gradyan İşaret Yöntemi (FGSM) [2] bir L_∞ bütçesi içinde kayıp gradyanının işareti boyunca tek bir adım atmakta, İzdüşümlü Gradyan İnişi (PGD) [17] ise bu adımı yineleyerek her adımdan sonra ϵ-topuna geri izdüşüm yapmaktadır (Bölüm III-C). Carlini ve Wagner saldırısı [18] aramayı bir eniyileme problemi olarak kurmaktadır. APGD-CE, APGD-T, FAB-T ve Square saldırılarından oluşan bir topluluk olan AutoAttack [19] ise güvenilir gürbüzlük değerlendirmesinde fiili standart haline gelmiştir.

B. Savunma Mekanizmaları

Eğitim sırasında üretilen en kötü durum pertürbasyonları üzerindeki kaybı en küçükleyen çekişmeli eğitim [17], en etkili deneysel savunma olmayı sürdürmektedir. TRADES [15] gürbüz hatayı doğal bir terim ile bir sınır terimine ayırarak ikisi arasındaki ödünleşimi açıkça kurmakta, MART [20] ise eğitim sırasında yanlış sınıflandırılan örneklere daha fazla ağırlık vermektedir. Diğer savunmalar girdiyi dönüştürmekte [21], gürbüzlüğü rastgeleleştirilmiş yumuşatmayla sertifikalandırmakta [22] ya da topluluklara dayanmaktadır [23]; Uyarlanabilir Rastgeleleştirilmiş Yumuşatma [24] rastgeleleştirilmiş yumuşatmayı test zamanında uyarlanan çok adımlı modellere genişletmektedir.

C. CNN Gürbüzlüğü

CNN'ler tarafında Madry vd. [17], PGD saldırılarıyla çekişmeli eğitimin güçlü deneysel gürbüzlük sağladığını göstermiştir. RobustBench lider tablosu [14] gürbüz doğruluğu mimariler boyunca izlemektedir ve CIFAR-10 sıralamasının tepesini WideResNet türevleri tutmaktadır.

Model kapasitesinin ulaşılabilir gürbüzlükle ilişkili olduğu gösterilmiştir [17]; daha geniş ve derin ağlar daha iyi gürbüz doğruluk sergilemektedir. Mimariye özgü bulgular arasında atlama bağlantılarının çekişmeli transfer edilebilirlikteki rolü [25] ve çekişmeli eğitimin büyük ölçekte yol açtığı ayrık parti-normalizasyonu istatistikleri [26] sayılabilir; ilişkili olarak, yardımcı parti-normalizasyonu dalları çekişmeli örneklerin temiz doğruluğu artırmasına imkân vermektedir [27]. Çekişmeli eğitimin girdi-gradyan yapısının kendisini de yeniden biçimlendirdiği, daha algısal hizalı gradyanlar [28] ve daha seyrek öznitelik atıfları [29] ürettiği bilinmektedir.

D. Görü Dönüştürücüsü Gürbüzlüğü

Vaswani vd. [4] tarafından tanıtılan öz-dikkat mekanizması üzerine kurulan Görü Dönüştürücüleri [3], görüntüleri yama dizileri olarak işlemektedir; iç temsilleri CNN'lerden katman katman ölçülebilir biçimde ayrışmaktadır [30]. Bhojanapalli vd. [31], yeterli veriyle ön eğitildiklerinde ViT'lerin geniş bir pertürbasyon yelpazesinde en az ResNet'ler kadar gürbüz olduğunu bulmuştur. Bai vd. [6] dönüştürücülerin CNN'lerden daha gürbüz olup olmadığını sistematik olarak incelemiş ve adil eğitim tarifleri altında çekişmeli gürbüzlükte üstün olmadıklarını, buna karşılık öz-dikkate atfedilen dağılım kayması gürbüzlüğünde öne geçtiklerini bulmuştur. Benz vd. [7], MLP-Mixer'i de içeren erken bir doğrudan karşılaştırma raporlamış ve farkları frekans tercihlerine bağlamıştır. Sonraki çalışmalar ViT'lerin özellikle gradyan tabanlı saldırılara karşı savunmasız kaldığını [8], yama hedefli saldırıların dikkat mekanizmasını doğrudan istismar ettiğini [32] ve dikkatin yama pertürbasyonları altında ölçülebilir biçimde kaydığını [33] ortaya koymuştur.

Shao vd. [9], ViT'leri beyaz kutu ve transfer ayarlarında CNN'lerden ve MLP-Mixer'lardan daha gürbüz bulmuş, özniteliklerinin daha az yüksek frekanslı içerik taşıdığını göstermiş ve çekişmeli eğitimin ViT'lere uygulanabildiğini ortaya koymuştur; ancak ön niteliğindeki CIFAR-10 koşusunda çekişmeli eğitilmiş ViT büyük bir CNN'i geçememiştir. ViT'lerin yaygın bozulmalara ve örtmelere karşı gürbüzlüğü de betimlenmiştir [34]. Daha yakın zamanda Jain vd. [35], ViT'lerdeki bir gradyan maskeleme biçimini dikkatteki softmax alt taşmasına (underflow) bağlamış ve PGD türü saldırıların bu yüzden ViT'lerde eksik kaldığını göstermiştir; yalnız PGD'ye dayanan ViT değerlendirmeleri için bir uyarı olan bu bulguya karşı AutoAttack, gradyansız Square bileşeniyle kısmi bir güvence sağlamaktadır. Düzeltilmiş saldırı üzerine kurdukları çekişmeli eğitim tarifi CIFAR-10 ve ImageNet-100'de mevcut ViT tariflerini geçmektedir; difüzyonla artırılmış çekişmeli eğitimle ViT'lerin küçük ölçekli veri kümelerinde WideResNet'leri geçebildiği de bildirilmiştir [36]. Zhu vd. [37], gradyan normalizasyonu ölçekleme ve yüksek frekans uyarlamasıyla ViT'lere yönelik transfer edilebilir saldırıları güçlendirmiştir. CNN ile ViT gürbüzlüğünü tek bir değerlendirme protokolü altında davranışsal olarak karşılaştıran çalışmalar ise azdır.

E. Transfer Saldırıları

Çekişmeli örnekler modeller arasında sıklıkla transfer olmakta ve bu durum kara kutu saldırılarını mümkün kılmaktadır [38]. Demontis vd. [39] transfer edilebilirliği iki etkene, hedef modelin içkin kırılganlığına ve vekil modelin karmaşıklığına bağlamakta ve onu iki modelin girdi gradyanlarının hizalanmasıyla ilişkilendirmektedir. Temel transfer çalışmaları transfer edilebilirliği zaten doğru sınıflandırılan örnekler üzerinde değerlendirmekte [40], standart saldırı makaleleri de başarı oranlarını aynı gerekçeyle koşullamaktadır [41]; transfer saldırılarının sistematik yeniden değerlendirmeleri de havuzu her modelin doğru sınıflandırdığı örneklerle sınırlamaktadır [12]. Yakın tarihli iki kıyaslama da aynı yönde ilerlemektedir. TA-Bench [42] otuzu aşkın transfer saldırısının karşılaştırmasını ortak bir vekil ve kurban model havuzu üzerinde standartlaştırmakta, Yu vd. [43] ise transfer edilebilirliğin tek bir mimari ailesi içinde ölçüldüğünde dizgesel olarak abartıldığını bildirmekte ve çok hedefli bir sonucun nasıl puanlandığında ayrışan üç değerlendirme protokolü önermektedir:

topluluğu tek bir hedef saymak, kaç hedefin kandırıldığını saymak ve hepsinin kandırılmasını istemek. TA-Bench puanlama kuralını sabit tutup saldırıyı ve model havuzunu değiştirmekte, Yu vd. ise puanlama kuralını hedef toplulaştırma ekseninde değiştirmektedir. Bu makalede puanlama kuralı koşullama ekseninde değiştirilmekte, modeller, veri ve saldırı bütçesi ise sabit tutulmaktadır; bu tasarım koşullama kümesinin kendi katkısını yalıtmakta ve ortaya çıkan kestirimler arasındaki aritmetik bağıntının yazılmasını mümkün kılmaktadır. Topluluk tasarımında Ravikumar vd. [11], modeller arasındaki doğruluk farklarını hesaba katmak amacıyla transfer ölçümünü her iki modelin de doğru sınıflandırdığı örneklerle sınırlamaktadır; böylece denetlenen karıştırıcı, bu çalışmadaki koşullu metriğin kontrol ettiği karıştırıcının aynısıdır.

Mahmood vd. [8], her ikisi doğru protokolüyle CNN'ler ile ViT'ler arasındaki transferi ölçmüş ve dikkat çekici ölçüde düşük CNN↔ViT transferi bulmuştur; Naseer vd. [10], ViT'lerde üretilen çekişmeli örneklerin geleneksel saldırılarla zayıf transfer ettiğini göstermiş ve ViT kaynaklı transferi iyileştirmek için öz-topluluk ve jeton arıtma önermiştir; Wei vd. [44] ise dikkat gradyanlarını atlayarak ve yama bazlı seyreltmeyle ViT kaynaklı transferi geliştirmiştir. Bunların üzerine Jeton Gradyanı Düzenlileştirme (TGR) [45], ViT'in dikkat bileşenlerini kullanarak transfer edilebilir örnekler üretmekte; Momentum Bütünleşik Gradyanlar (MIG) [46] hem ViT'lerde hem CNN'lerde gelişmiş transfer sağlamaktadır. Chen vd. [47], CNN'ler ile ViT'lerin farklı tümevarım önyargılarından yararlanan bir transfer saldırısı önermektedir; bu farkın ardındaki frekans tercihleri, yani CNN'lerin yüksek, ViT'lerin düşük frekanslı içeriğe yaslanması, Benz vd. [7] ve Shao vd. [9] tarafından belgelenmiştir. Waseda vd. [48] transfer sonuçlarını hedefin kaynağın tam olarak aynı hatasını tekrarlayıp tekrarlamadığına göre bir adım daha ayırmakta ve her iki durumun birbirine yakın modeller arasında bile görüldüğünü bildirmektedir.

F. Araştırma Boşluğu

Tekil çalışmalar CNN ve ViT gürbüzlüğünü ayrı ayrı incelemiş ve adil olmayan CNN ile dönüştürücü karşılaştırmalarının tuzaklarına daha önce dikkat çekilmiş olsa da [6], [49], mevcut karşılaştırmalı çalışmalar gürbüzlük skorlarını çoğunlukla tek başına, üstelik tutarsız pertürbasyon bütçeleri, saldırı yapılandırmaları veya model ölçekleriyle raporlamakta ve karşılaştırmayı davranışsal analizle nadiren eşleştirmektedir. Bu dergide yayımlanan yakın tarihli bir çalışma ViT ve CNN çekişmeli gürbüzlüğünü doğrudan karşılaştırmaktadır [50]. Bu çalışma ise tam test kümesinde AutoAttack ve eşleştirilmiş istatistiklerle değerlendirme yapması, transfer ölçümünü temiz doğruluk farklarına karşı kontrol etmesi ve karşılaştırmaya gradyan ile öznitelik düzeyinde davranışsal analizler eklemesiyle ondan ayrışmaktadır.

Değerlendirme yöntembilimi literatürü, gürbüzlüğün nasıl ölçüldüğünün varılan sonucu belirlediğini defalarca göstermiştir. Carlini vd. [51] gürbüzlük değerlendirmesinin başarısızlık kiplerini derlemiş, Tramèr vd. [52] ise sabit saldırılar altında gürbüz sayılan savunmaların uyarlanabilir saldırılara yenildiğini göstermiştir. Bu çalışmalar saldırı gücüyle, yani ölçümün yeterince güçlü olup olmadığıyla ilgilidir. Saldırı gücü sabit tutulduğunda yalnızca *koşullama kümesinin* sonucu ne kadar oynattığı sorusu ise bu eksene diktir. Transfer değerlendirmesini modellerin doğru sınıflandırdığı örneklerle koşullamak yerleşik bir pratiktir [8], [11], [40], [41] ve bu çalışmaların her biri kendi koşullama kümesini belirtip onunla ilerlemektedir; Yu vd. puanlama kuralını değiştirmekte, ancak bunu başka bir eksende yapmaktadır. Burada anılan çalışmaların hiçbiri koşullama kümesini sabit modeller üzerinde değiştirmemektedir ve bu makalede kullanılan tasarım tam olarak budur. Koşulsuz oranlardaki karıştırıcı bu tasarımda toplam olasılık yasasından çıkmaktadır. Hedefin yanlış sınıflandırdığı örnekler yanlış kaldığında $r_{\text{ham}} - r_{\text{koş}} = e\,(1 - r_{\text{koş}})$ olur ve bu bağıntı TRADES'in [15] doğal-artı-sınır ayrışımının transfer karşılığıdır. Transfer ortamında bu ayrışımın öncülü görgül bir niceliktir ve bu çalışmada ölçülmüştür; bağıntı böylece bilinen nitel bir uyarıyı, öncülün sağlandığı her durumda yayımlanmış ham oranlara uygulanabilen bir düzeltmeye dönüştürmektedir.

Aynı tasarım, mimari karşılaştırmalarının akla getirmeye yatkın olduğu üç okumanın da sınanmasına imkân vermektedir: CNN gradyanlarının mekansal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini bozduğu ve dönüştürücüye özgü transfer saldırılarının [10], [45] mimariler arası transferi iyileştirdiği. Anılan çalışmalarda yalnızca üçüncüsü ileri sürülmektedir; ilk ikisi yorumdur. Her biri doğrudan ölçülmüş ve hiçbiri bu kurulumda geçerli çıkmamıştır.

III. YÖNTEM

Şekil 1 tasarımı özetlemektedir. İki mimari, mimari başına üç bağımsız koşuyla tek bir eşleşmiş çekişmeli tarif altında eğitilmekte ve her değerlendirme tam test kümesinde örnek bazında kaydedilmektedir; böylece her analizin içinde Bölüm III-F'teki dört koşullama protokolü, saldırı yeniden koşulmadan aynı kayıtlara uygulanabilmektedir. Aşağıdaki alt bölümler sırasıyla tehdit modelini, modelleri, saldırıları ve eğitim protokolünü sabitlemekte, ardından ölçümleri tanımlamaktadır.

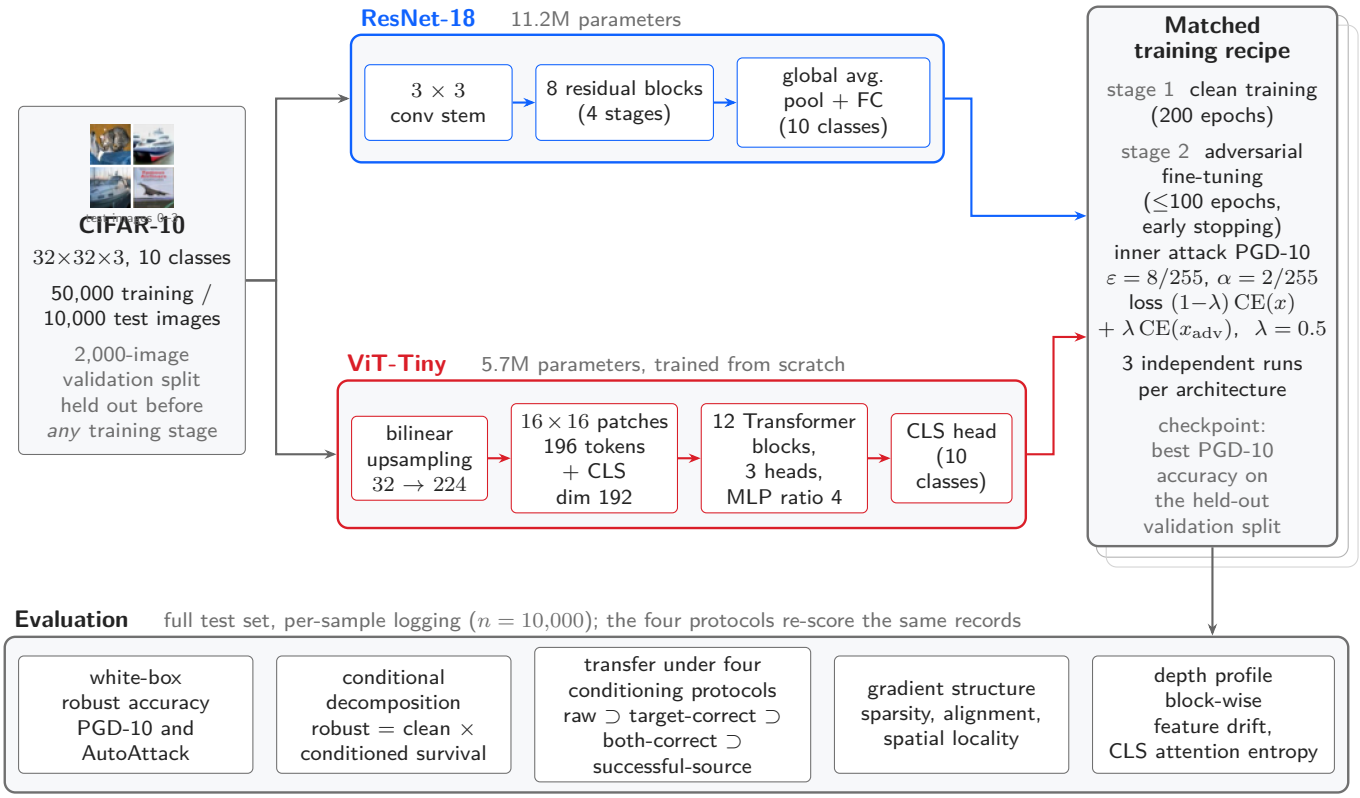
A. Tehdit Modeli

Saldırganın girdi görüntülerini sınırlı bir bölge içinde pertürbe edebildiği standart L_∞ tehdit modeli ele alınmaktadır:

$$\mathcal{B}_\epsilon(x) = \{x' : \|x' - x\|_\infty \leq \epsilon\} \tag{1}$$

CIFAR-10 için yerleşik uzlaşımlar izlenerek [13], [14] birincil pertürbasyon bütçesi olarak $\epsilon = 8/255 \approx 0{,}031$ kullanılmakta, epsilon taraması analizi için de $\epsilon \in \{2/255, 4/255, 16/255\}$ değerlerinde ek tam test PGD-10 değerlendirmeleri yapılmaktadır.

Değerlendirme hem beyaz kutu (tam model erişimi) hem kara kutu (transfer saldırısı) senaryolarında yapılmaktadır. Beyaz kutu saldırılarda saldırgan model mimarisini ve parametrelerini tam olarak bilmektedir. Transfer saldırılarında ise çekişmeli örnekler bir kaynak modelde üretilmekte ve farklı bir hedef modelde değerlendirilmektedir.



Replications and controls. The whole design is repeated on CIFAR-100 (three runs per architecture) and SVHN (two runs); the CIFAR-10 checkpoints are re-evaluated under an L_2 budget ($\varepsilon = 0.5$); a RobustBench WideResNet-28-10 checkpoint enters only as the third model of the 3×3 transfer matrix; the checkpoint-selection rule is varied on a fixed training trajectory.

Şekil 1: Çalışmanın genel görünümü. Aynı CIFAR-10 bölmesi iki mimariyi, ResNet-18 ve ViT-Tiny'yi beslemekte; ikisi de mimari başına üç bağımsız koşuyla tek bir eşleşmiş çekişmeli tarif altında eğitilmekte ve her eğitimden önce ayrılmış bir doğrulama bölmesiyle seçilmektedir. Her değerlendirme tam test kümesinde örnek bazında kaydedilmektedir ve dört koşullama protokolünün aynı kayıtlara uygulanabilmesini sağlayan da bu kayıttır. Alt sıradaki beş ölçüm ailesi Bölüm IV'te raporlananlardır; altlarındaki şerit yineleme ayarlarını ve kontrolleri sıralamaktadır.

B. Model Mimarileri

a) CNN Modelleri: ResNet-18 [5], artık ağın CIFAR-10 türevidir; 7×7 giriş katmanı yerine başlangıçta 3×3 bir evrişim kullanmakta ve 11,2M parametre içermektedir. 36,5M parametreli WideResNet-28-10 [53], CIFAR-10'da çekişmeli gürbüzlük için olağan referans mimaridir ve bu çalışmada Gowal vd.'nin [54] RobustBench [14] üzerinden dağıtılan gürbüz kontrol noktası kullanılmıştır. Bu model ek etiketsiz veriyle ve buradaki tariften daha güçlü bir tarifle eğitildiğinden eşleşmiş bir karşılaştırma değil, bir referans noktası işlevi görmektedir. Bölüm IV-E, aralarında standart eğitilmiş bir WideResNet-28-10'un da bulunduğu başka RobustBench kontrol noktalarını yeni bir eğitim yapmadan eklemektedir.

b) Görü Dönüştürücüsü Modelleri: ViT-Tiny, `timm` kütüphanesinden [55] alınmış ve girdiler çift doğrusal olarak 224×224'e büyütülerek CIFAR-10'a uyarlanmıştır. Mimari 16×16 yamalar (görüntü başına 196 yama), 192 boyutlu gömmeler, her biri 3 dikkat başlı 12 dönüştürücü bloğu ve 4 MLP oranı kullanmakta, toplam 5,7M parametre içermektedir. Model CIFAR-10 üzerinde *sıfırdan* (ImageNet ön eğitimi olmadan) temel veri artırmayla (rastgele kırpma ve yatay çevirme) eğitilmekte, ardından çekişmeli ince ayara tabi tutulmaktadır. Küçük veri kümelerinde ViT gürbüzlüğünün eğitim tarifine duyarlı olduğu bilindiğinden [56], [57], mimari düzeyindeki sonuçlar en iyi şekilde eğitilmiş ViT'ler için değil, *bu temel eğitim tarifi altında* geçerli olarak okunmalıdır.

C. Saldırı Yöntemleri

a) FGSM: Adım boyu pertürbasyon bütçesine eşit tek adımlı saldırıdır:

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}_{CE}(f(x), y)) \tag{2}$$

b) PGD: Adım boyu $\alpha = 2/255$ ve rastgele başlangıçlı yinelemeli saldırıdır:

$$x^{t+1} = \Pi_{\mathcal{B}_\epsilon(x)} \left(x^t + \alpha \cdot \text{sign}(\nabla_{x^t} \mathcal{L}_{CE}(f(x^t), y)) \right) \tag{3}$$

burada $x^0 = x + \mathcal{U}(-\epsilon, \epsilon)$'dir. Bu çalışma boyunca hem çekişmeli eğitimde hem değerlendirmede PGD-10 (10 yineleme) kullanılmaktadır (Tablo II).

c) AutoAttack: APGD-CE (çapraz entropi kayıplı Auto-PGD), APGD-T (hedefli DLR kayıplı Auto-PGD), FAB-T (hedefli Hızlı Uyarlanabilir Sınır saldırısı) ve Square (skor tabanlı kara kutu saldırısı) bileşenlerini birleştiren standartlaştırılmış topluluk saldırısı AutoAttack [19] kullanılmaktadır.

D. Savunma Yöntemleri

a) Çekişmeli Eğitim (AT): Temiz ve çekişmeli kayıpları birleştiren karma bir çekişmeli eğitim amacı kullanılmaktadır:

$$\mathcal{L} = (1-\lambda)\,\mathcal{L}_{CE}(f_\theta(x), y) + \lambda\,\mathcal{L}_{CE}(f_\theta(x_{adv}), y) \qquad (4)$$

burada $\lambda = 0{,}5$, standart sınıflandırma başarımı ile çekişmeli gürbüzlüğü dengelemektedir. İç enbüyükleme çekişmeli örnekleri PGD-10 ile üretmektedir ($\alpha = 2/255$, $\epsilon = 8/255$). Saldırı üretimi, Rice vd.'nin [58] referans gerçeklemesinde olduğu gibi model eğitim kipindeyken yapılmakta, böylece saldırı üretimi ile parametre güncellemesi tutarlı parti-normalizasyonu istatistikleri görmektedir. Yalnızca çekişmeli örneklerle eğitim doğal başarımı düşürebildiğinden iki kaybı karıştırmak, gürbüzlük kazanılırken temiz doğruluğun korunmasına yardım etmektedir. Kaybın yarısı temiz olduğu ve tarif temiz ön eğitilmiş kontrol noktalarına uygulandığı için bu tarif, bu çalışmada *karma kayıplı PGD çekişmeli ince ayar* olarak adlandırılmaktadır; Madry vd.'nin [17] PGD çekişmeli eğitimi değildir ve ürettiği gürbüz doğruluklar referans PGD çekişmeli eğitim sonuçlarıyla karşılaştırılarak okunmamalıdır. TRADES [15] gibi alternatif formülasyonlar kuramsal temelli ödünleşim mekanizmaları sunmaktadır; mimari etkileri savunmaya özgü etkileşimlerden yalıtmak için iki mimaride de tek bir tarif kullanılmıştır.

E. Eğitim Protokolü

a) Temiz Eğitim: CNN'ler için SGD eniyileyici, 0,1 başlangıç öğrenme oranı, kosinüs tavlama çizelgesi [59], 5×10^{-4} ağırlık sönümü ve 200 epok kullanılmıştır. ViT'ler için AdamW eniyileyici [60], 10^{-3} başlangıç öğrenme oranı, kosinüs tavlama, 0,05 ağırlık sönümü ve 200 epok kullanılmıştır.

b) Çekişmeli Eğitim: Temiz eğitilmiş kontrol noktalarından başlanarak düşürülmüş öğrenme oranlarıyla ince ayar yapılmaktadır. CNN'ler SGD ile 10^{-3} öğrenme oranı ve kosinüs tavlamayla en çok 100 epok, ViT'ler ise AdamW ile aynı öğrenme oranı ve çizelgeyle eğitilmektedir. Gradyanlar küresel L_2 normu 10'a kırpılmakta ve kaybı sonlu olmayan partiler atlanmaktadır. Veri artırma 4 piksel dolgulu rastgele kırpma ve yatay çevirmeden oluşmaktadır; tüm modeller $[0, 1]$ aralığında ham piksel girdisi almakta (ortalama/std normalizasyonu yoktur), saldırılar ve epsilon bütçeleri de doğrudan bu piksel uzayında işlemektedir. Eğitim parti boyu CNN için 128, ViT için 64'tür (değerlendirme parti boyları analize göre değişmektedir). Erken durdurma 20 sabır ve 0,1 yüzde puanlık iyileşme eşiğiyle uygulanmaktadır.

c) Doğrulama Bölmesi ve Tekrarlar: Model seçimi ve erken durdurma, sabit 2.000 örneklik bir doğrulama bölmesindeki PGD-10 çekişmeli doğruluğuyla yürütülmektedir. Bu bölme bir kez çekilmiş (tohum 777; indeksler kodla birlikte saklanmaktadır), çalışmadaki her model tarafından paylaşılmakta ve hem temiz hem çekişmeli aşamanın eğitim kümesinden çıkarılmaktadır; dolayısıyla hiçbir kontrol noktası üzerinde eğitildiği veriyle seçilmemektedir. Test kümesine yalnızca nihai art-değerlendirmelerde dokunulmaktadır. Temiz ön eğitim ve ardından çekişmeli ince ayardan oluşan boru hattının tamamı mimari başına üç kez, bağımsız tohumlarla tekrarlanmış (ResNet-18 için 1001 ile 1003, ViT-Tiny için 2001 ile 2003) ve koşular indekse göre eşlenmiştir; böylece her mimariler arası karşılaştırma aynı tekrar altında eğitilmiş modeller arasında yapılmaktadır. Aksi belirtilmedikçe tablolar bu üç koşunun ortalamasını ve standart sapmasını raporlamaktadır. İstisnalar SVHN ile dış modellerdir; SVHN'de iki koşu bulunduğundan değerleri ayrı ayrı basılmakta, WideResNet-28-10 referansı ve Bölüm IV-E'teki RobustBench kontrol noktaları ise tek birer dış modeldir.

Bu protokol benimsenmeden önce eğitilmiş ve temiz ön eğitimin zaten gördüğü bir doğrulama bölmesiyle seçilmiş daha eski bir kontrol noktası çifti, burada raporlanan koşularla aynı mutlak sıralamayı vermiş, ancak temiz doğruluk ile koşullu duyarlılık arasındaki payı farklı dağıtmıştır; kayıtları sızıntısız protokolden önceye ait olduğu için bu çiftin kayıtları yayımlanmamakta ve hiçbir sayısı bu makaleye girmemektedir.

F. Değerlendirme Metrikleri

a) Gürbüzlük Metrikleri: Modeller üç standart metrikle değerlendirilmektedir: temiz doğruluk (pertürbe edilmemiş test görüntülerinde sınıflandırma başarımı), gürbüz doğruluk (çekişmeli örneklerde sınıflandırma başarımı) ve saldırı başarı oranı (temizde doğru sınıflandırılan görüntülerden saldırı sonrası yanlışa dönenlerin oranı). Beyaz kutu değerlendirmelerde ek olarak *koşullu yanıltma oranı*, yani temizde doğru sınıflandırılan örneklerden saldırının devirdiklerinin kesri ve onun tümleyeni olan koşullu sağkalım raporlanmaktadır. Örnek bazındaki kayıtlarda hem PGD hem AutoAttack temizde yanlış sınıflandırılan örnekleri gürbüz olmayan saydığından mutlak gürbüz doğruluk birebir gürbüz = temiz × koşullu sağkalım biçiminde çarpanlarına ayrılmaktadır. TRADES'in [15] doğalartı-sınır ayrışımının beyaz kutu karşılığı olan bu ayrışım, gürbüzlük farklarının bir temiz doğruluk bileşenine ve bir koşullu duyarlılık bileşenine ayrılmasını sağlamaktadır. Doğruluklar ayrıca *her ikisi doğru* altkümesinde (karşılaştırılan iki modelin de temizde doğru sınıflandırdığı örnekler) raporlanmakta ve bu altküme, ortak bir örnek kümesi üzerinde birebir eşleştirilmiş bir karşılaştırma sağlamaktadır.

b) Transfer Saldırısı Metrikleri: Bu çalışmadaki transfer metrikleri, yalnızca koşullama kümesiyle ayrışan bir *koşullu yanıltma oranları* ailesidir. Ailenin taban üyesi *hedef doğru* oranıdır; bu oran, hedef modelin temizde doğru sınıflandırdığı örnekler içinde kaynak modelde üretilen çekişmeli örneklerle yanlışa dönenlerin kesridir. Kaynak model f_S'ye karşı üretilen $\{x^S_{adv}\}$ örnekleri için hedef model f_T'ye koşullu transfer oranı şöyledir:

$$T_c(f_S \to f_T) = \frac{\sum_{i=1}^{n} \mathbf{1}[f_T(x_i) = y_i]\,\mathbf{1}[f_T(x^S_{adv,i}) \neq y_i]}{\sum_{i=1}^{n} \mathbf{1}[f_T(x_i) = y_i]} \qquad (5)$$

Transfer değerlendirmesini doğru sınıflandırılan örneklerle koşullamak yerleşik bir pratiktir ve genellikle çalışmadaki her modelin doğru sınıflandırdığı örnekler üzerinde yapılmaktadır [8], [11], [12], [40], [41]. Hedef doğru oran bu havuzun tek yanlı gevşetmesidir ve koşullama en çok mimariler arası karşılaştırmalarda önem taşımaktadır. Ham yanlış sınıflandırma oranı $\frac{1}{n}\sum_i \mathbf{1}[f_T(x^S_{adv,i}) \neq y_i]$ hedefin temiz hatasını içerdiğinden temiz doğruluğu düşük bir hedef, saldırı hiç ek

Tablo I: Bir kaynak f_S ve bir hedef f_T için dört transfer protokolünün koşullama maskeleri. Bir (x, y) örneği listelenen her koşul sağlandığında paydaya girer; pay, maskedeki örneklerden $f_T(x^S_{adv}) \neq y$ olanları sayar. Son sütun bir çiftin iki yönünün aynı örnekler üzerinde puanlanıp puanlanmadığını belirtir. Başarılı kaynak protokolünün gevşek okuması yalnızca bir duyarlılık analizidir.

Protokol	**Örneğin paydaya girme koşulu**	**Aynı küme**
Koşulsuz (ham)	her zaman	evet
Hedef doğru	$f_T(x) = y$	hayır
Her ikisi doğru	$f_T(x) = y$ ve $f_S(x) = y$	evet
Başarılı kaynak	$f_T(x) = y$, $f_S(x) = y$, $f_S(x^S_{adv}) \neq y$	hayır
gevşek okuma	$f_T(x) = y$, $f_S(x^S_{adv}) \neq y$	hayır

örnek devirmese bile transfere daha "kırılgan" görünmektedir. Ham oran, şeffaflık ve bu karıştırıcının boyutunu nicelemek için ikincil metrik olarak raporlanmaktadır. Koşullama kümesinin kendisi bir protokol seçimi olduğundan iki alternatif de raporlanmaktadır. Bunlar kaynak ve hedefin ikisinin de doğru sınıflandırdığı örneklerle koşullayan *her ikisi doğru* protokolü [8], [11] ve saldırının kaynakta beyaz kutu anlamında başarılı olduğu hedef doğru örneklerle koşullayan *başarılı kaynak* protokolüdür. Her iki protokol de literatürde yerleşiktir. Başarılı kaynak oranı Ravikumar vd.'nin [11] transfer edilebilirlik metriğidir; o çalışmadaki Denklem (1), iki modelin de doğru sınıflandırdığı örneklerle sınırlanmış bir havuzda hedefe transfer olan örnek sayısını kaynakta üretilen örnek sayısına bölmektedir. Bir transfer oranı "başarılı" çekişmeli örnekler üzerinden raporlandığında örtük olarak kullanılan protokol de budur. Yönlü iddialar için birincil kestirim olarak her ikisi doğru oranı alınmaktadır, çünkü bu oran iki yönü de aynı örnekler üzerinde puanlamakta ve bu yüzden eşleştirilmiş çıkarımı desteklemektedir; diğer üç oran baştan sona onun yanında raporlanmaktadır. Bölüm IV-B'in gösterdiği gibi bu protokoller nitel olarak farklı asimetri sonuçları verebilmektedir ve bu makaledeki her transfer sayısının protokolüyle birlikte verilmesinin nedeni de budur. Transfer oranları tam test kümesinde (10.000 örnek) örnek bazında kayıtla hesaplanmakta ve örnekler üzerinde yüzdelik bootstrap ile %95 güven aralıkları verilmektedir (10.000 yeniden örnekleme).

c) Koşullama Maskeleri ve Ham Oran Özdeşliği: Tablo I dört protokolü, başarılı kaynak protokolünün iki okumasıyla birlikte tek bir yerde tanımlamaktadır. Her protokol payında, maskesindeki örneklerden hedefin kaynakta üretilmiş girdide yanlış sınıflandırdıklarını saymaktadır; protokoller yalnızca maskede ayrışmaktadır. Bu tabloya en çok başarılı kaynak protokolü ihtiyaç duymaktadır, çünkü protokolün adı beyaz kutu başarısının kaynağın temiz girdiyi doğru sınıflandırmasını gerektirip gerektirmediğini söylememektedir. Çalışma boyunca sıkı okuma kullanılmakta, gevşek okuma yalnızca bir duyarlılık analizi olarak raporlanmaktadır (Bölüm IV-B).

Koşulsuz ve hedef doğru oranlar toplam olasılık yasasıyla birbirine bağlıdır. Hedefin temiz hatası e, bir yönün koşulsuz ve hedef doğru oranları r_{ham} ve $r_{\text{koş}}$, hedefin temiz girdide yanlış sınıflandırdığı bir örneğin kaynakta üretilmiş girdide de yanlış sınıflandırılma olasılığı ise p ile gösterilsin. Bu durumda

$$r_{\text{ham}} = e\,p + r_{\text{koş}}\,(1 - e) \tag{6}$$

olur ve $p = 1$ olduğunda

$$r_{\text{ham}} - r_{\text{koş}} = e\,(1 - r_{\text{koş}}) \tag{7}$$

elde edilir. Tek bir model üzerine yazıldığında $r_{\text{ham}} = e + r_{\text{koş}}(1-e)$, TRADES'in [15] doğal-artı-sınır ayrışımıdır; orada $p = 1$'e karşılık gelen öncül tanım gereği sağlanmaktadır, çünkü sınır terimi bütün pertürbasyon komşuluğu üzerinde tanımlanmıştır. Transfer ortamında ise öncül tanımsal değildir. Kaynakta üretilmiş sabit bir pertürbasyon yanlış sınıflandırılmış bir örneği yanlış bırakabilir ya da doğru sınıfa geri taşıyabilir; dolayısıyla p ölçülmesi gereken görgül bir niceliktir. Denklem (6) her örnek kümesinde yapısı gereği sağlanan bir muhasebe özdeşliğidir ve tek görgül içeriği p'nin değeridir; bu makalenin eklediği ölçüm de bu değerdir. $p < 1$ olduğunda Denklem (7) sapmayı tam olarak $e\,(1 - p)$ kadar abartmakta ve bir eşitlik değil bir üst sınır olmaktadır. Bu nedenle Denklem (7) yalnızca p'nin bire yakın ölçüldüğü hedefler için kesin bir düzeltme olarak kullanılmaktadır; bu makalede söz konusu hedefler Bölüm IV-B1'teki çekişmeli eğitilmiş hedeflerdir. Standart eğitilmiş hedeflerde (Bölüm IV-E) kullanılması gereken düzeltme, ölçülmüş p ile genel biçim olan Denklem (6)'dir.

d) Gradyan Analizi Metrikleri: Gradyan özellikleri, büyüklükler değerlendirme parti boyundan bağımsız olsun diye örnek başına kayıplarla hesaplanarak üç tamamlayıcı metrik ailesiyle incelenmektedir. Gradyan normu ($\|\nabla_x \mathcal{L}\|_2$ ve $\|\nabla_x \mathcal{L}\|_\infty$) toplam duyarlılık büyüklüğünü ölçmektedir. Sabit mutlak eşikler gradyan ölçeğini yapıyla karıştırdığından gradyan seyrekliği ölçekten bağımsız ölçülerle nicelenmektedir: Hoyer seyrekliği, $|g|$'nin Gini katsayısı ve örnek başına en büyük değerin %1'inin altında kalan bileşenlerin oranı. Hoyer ve Gini, Hurley ve Rickard'ın [61] biçimselleştirdiği ölçek değişmezliği aksiyomlarını sağlamaktadır. Gradyan hizalanması, örnekler arasındaki ortalama ikili mutlak kosinüs benzerliğini ölçmektedir (500 analiz örneğinin tüm çiftleri üzerinden):

$$\text{Hizalanma} = \frac{1}{N(N-1)} \sum_{i \neq j} \left| \frac{\nabla_{x_i} \mathcal{L} \cdot \nabla_{x_j} \mathcal{L}}{\|\nabla_{x_i} \mathcal{L}\| \|\nabla_{x_j} \mathcal{L}\|} \right| \tag{8}$$

Paylaşılan duyarlılık *eksenleri* işaretten bağımsız olarak saldırı geometrisi için önem taşıdığından mutlak kosinüs kullanılmaktadır. Evrensel pertürbasyon argümanlarının ek olarak gerektirdiği şey işaret tutarlılığı olduğu için işaretli ortalama kosinüs de raporlanmaktadır ve bu değer her model için sıfıra yakın çıkmaktadır (Bölüm IV-G1). Yüksek mutlak hizalanma, girdiler arasında benzer pertürbasyon eksenlerine işaret etmektedir.

e) Mekansal Lokalite Metrikleri: Seyreklik kaç gradyan bileşeninin büyük olduğunu ölçmekte, ancak bu bileşenlerin görüntüde nerede durduğu hakkında bir şey söylememektedir. Bu yüzden mekansal yapı, toplamı bire normalize edilmiş kanal toplamı enerji haritası $e = \sum_c (\nabla_x \mathcal{L})^2_c$ üzerinde ayrıca ölçülmektedir. Enerjinin %50'sini ve %90'ını toplayan en küçük piksel oranı (küçük değer daha lokalize demektir), e'nin pikseller üzerinde bir dağılım olarak Shannon entropisi (düşük değer daha lokalize demektir) ve enerji bitişik piksellerde kümelendiğinde pozitif olan 4-komşuluklu Moran's I raporlanmaktadır. Dördü de gradyan ölçeğinden bağımsızdır

ve örnek başına hesaplanmaktadır; böylece iki mimari aynı girdiler üzerinde eşleştirilmiş testlerle karşılaştırılabilmektedir.

f) Katman Analizi için Jeton Agregasyonu: Bir dönüştürücü bloğu jeton başına bir vektör ürettiğinden bloğu özetlemek bir seçim gerektirmektedir. Üç seçenek raporlanmaktadır: yalnızca CLS jetonu, 196 yama jetonunun ortalaması ve tüm jetonların örnek başına düzleştirilmiş birleşimi. CNN'de her artık blok çıktısı mekansal boyutları üzerinden düzleştirilmektedir. ViT için üç özetin birden raporlanmasının nedeni, Bölüm IV-G2'ün gösterdiği gibi farklı kayma büyüklükleri vermeleri ve minimumu farklı derinliklere yerleştirmeleridir.

g) Dikkat Metrikleri: ViT için her bloğun softmax sonrası CLS→yama dikkat satırı, başlar üzerinden ortalanarak çıkarılmaktadır. Dikkatin ne kadar geniş yayıldığını ölçen Shannon entropisi ve saldırı altındaki yer değiştirmesi raporlanmaktadır; yer değiştirme, temiz ve çekişmeli dikkat dağılımları arasındaki 1 ile sınırlı toplam varyasyon uzaklığıyla ölçülmektedir. İki ölçü de örnek başına hesaplanıp koşu başına $n = 1000$ örnek üzerinde ortalanmaktadır.

h) ViT'e Özgü Transfer Saldırısı: Transfer sonuçlarının mimariden bağımsız saldırıların kullanılmasına bağlı olup olmadığını sınamak için kaynak örnekler ek olarak Jeton Gradyanı Düzenlileştirme (TGR) [45] ile üretilmektedir. TGR, geri yayılım sırasında dikkat, QKV ve MLP yollarındaki jeton-gradyan tensörlerinin uç değerli girdilerini sıfırlamakta ve kalan gradyanı $\gamma = 0{,}5$ ile ölçeklemektedir. Bu çalışmadaki gerçekleme yöntemi, özgün ImageNet varsayılanları yerine CIFAR-10 ViT sarmalayıcısına ve makale boyunca kullanılan bütçeye ($\epsilon = 8/255$, $\alpha = 2/255$, 10 adım, momentum 1,0) uyarlamaktadır. Ürettiği sonuç negatif olduğundan bu sürümün iki ayrıntısı daha önem taşımaktadır. Üç yolun hepsine yol başına ayarlanmış değerler yerine tek bir $\gamma = 0{,}5$ uygulanmakta ve jetonlar arasında her (örnek, kanal) için bütün jeton satır ve sütunları değil, tek bir en büyük ve tek bir en küçük girdi sıfırlanmaktadır. Yayımlanmış düzenlileştirme şeması birebir yeniden gerçeklenmediği için aşağıdaki negatif sonuç yalnızca bu uyarlamayı sınırlamaktadır; sonucu yöntemin yayımlanmış haline genişletmek özgün şemayla bir yineleme gerektirir. Düz MI-FGSM [41] örnekleri aynı koşuda aynı örnekler üzerinde üretilmekte ve birebir aynı bütçede eşleştirilmiş bir kontrol sağlamaktadır.

i) Öznitelik Bozunması Metrikleri: Çekişmeli pertürbasyonların ViT temsillerini katmanlar boyunca nasıl etkilediğini incelemek için her ℓ katmanında üç metrik hesaplanmaktadır. Öznitelik kosinüs benzerliği, temsilin yönünün ne ölçüde korunduğunu ölçmektedir:

$$\text{Benz}_\ell = \frac{h_\ell(x) \cdot h_\ell(x_{adv})}{\|h_\ell(x)\| \|h_\ell(x_{adv})\|} \tag{9}$$

burada h_ℓ, ℓ katmanındaki temsili göstermektedir. Öznitelik norm değişimi ise büyüklük etkilerini yakalamaktadır:

$$\Delta_\ell = \frac{\|h_\ell(x_{adv})\| - \|h_\ell(x)\|}{\|h_\ell(x)\|} \times 100\% \tag{10}$$

Öznitelik L_2 uzaklığı ($\|h_\ell(x) - h_\ell(x_{adv})\|_2$) mutlak sapmayı nicelemektedir.

G. İstatistiksel Doğrulama

Dört varyans kaynağı birbirinden ayrılmakta ve her biri geçerli olduğu yerde raporlanmaktadır. Mimari karşılaştırmaları eğitim koşusu varyansına dayandığından her tablo mimari başına üç bağımsız koşunun ortalamasını ve standart sapmasını vermektedir (Bölüm III-E). Saldırı başlatma varyansı, PGD-10'un sabit bir altkümede üç saldırı tohumuyla (42, 123, 456) yeniden koşulmasıyla ölçülmektedir; değerlendirilen örnekler ve sıraları sabit olduğundan tohumlar yalnızca saldırının rastgele başlangıcını değiştirmektedir. Koşullama protokolleri arasındaki yayılım olan protokol varyansı gürültü olarak değil bir sonuç olarak ele alınmaktadır (Bölüm IV-B). Dördüncü kaynak olan kontrol noktası seçimi varyansı, sabit bir yörüngeden son kontrol noktasını seçen çevrimdışı kuraldan (doğrulama bölmesi, erken durdurma sabrı ve eğri yumuşatması) doğmakta ve yörünge sabit tutularak on sekiz bileşim üzerinde ölçülmektedir. Bölüm IV-H bu kaynakların büyüklüklerini karşılaştırmakta, Bölüm IV-F ise seçim kuralının transfer asimetrisine etkisini izlemektedir.

Aynı örneklerin iki koşul altında puanlandığı her yerde eşleştirilmiş testler kullanılmaktadır: eşleştirilmiş ikili sonuçlar için McNemar'ın kesin testi, üç seyreklik ölçüsü için Holm düzeltmeli Wilcoxon işaretli sıra testi, farklar için eşleştirilmiş bootstrap güven aralıkları (10.000 yeniden örnekleme) ve her ikisi doğru transfer farkı için işaret çevirme permütasyon testi (20.000 permütasyon). Çalışma boyunca iki çıkarım birimi mevcuttur ve bu birimler farklı soruları yanıtlamaktadır. Örnek bazlı bir test iki sabit kontrol noktasının değerlendirilen görüntülerde farklı olup olmadığını, üç tekrar üzerinden yapılan koşum düzeyi bir test ise mimarilerin farklı olup olmadığını sormaktadır. Mimari bir iddiayı yalnızca ikincisi desteklemektedir ve üç koşumla bu test çok daha zayıftır. Her testin yanında birimi belirtilmekte, iddia mimari olduğu her yerde koşum düzeyi kullanılmakta, iki birimin uyuşmadığı yerde ise iddiayı destekleyen birim yerine ikisi birden raporlanmaktadır; bunun yaşandığı yer Bölüm IV-G1'dir. Eşdeğerlik iddiaları, karşılaştırmalardan önce PGD doğruluğundaki koşumlar arası değişimden sabitlenen ± 2 puanlık birincil marjla iki tek yönlü test (TOST) kullanılarak yapılmaktadır. Bu marj mutlak doğruluk için doğru, koşumlar arası standart sapması $0{,}23$ puan olan transfer asimetrisi için ise yanlış ölçektir; orada marj yaklaşık sekiz kat cömerttir ve TOST'u eşdeğerliği kabul etmeye doğru yanlılaştırmaktadır. Ölçümden önce sabitlenen marj veriyi gördükten sonra yeniden ayarlanmamış, korunmuştur ve her eşdeğerlik iddiası ± 1 ve ± 3 puanda da raporlanmaktadır; bir transfer asimetrisi için kabul edilen tek eşdeğerlik olan SVHN sonucu ± 1 puanda da geçerlidir. Bölüm IV-G2'teki dikkat entropisi eşdeğerliği ise farklı bir ölçekte yapılan ayrı bir sınamadır ve o ölçünün ölçeğinden sabitlenen kendi $\pm 0{,}05$ nat marjını kullanmaktadır. Tüm değerlendirme ve analiz betikleri rastgele tohumları sabitlemekte (CUDA determinizm bayrakları dahil tohum 42) ve her protokol kestirimi, saklanan örnek bazındaki kayıtlardan Tablo I'teki maskelerle yeniden hesaplanmaktadır.

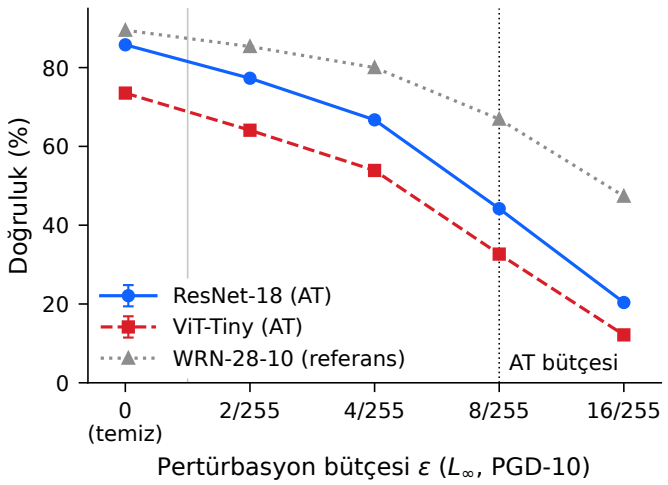
Tablo II: CIFAR-10'da ana gürbüzlük sonuçları ($\epsilon = 8/255$); mimari başına üç bağımsız eğitim koşusu üzerinden ortalama±std. AA, standart takımla AutoAttack anlamına gelmektedir.

Model	Savunma	Param.	Temiz	FGSM	PGD-10	AA
CNN Modelleri						
ResNet-18	Yok	11,2M	95,25±0,15	40,29±1,77	0,03±0,03	–
ResNet-18	AT	11,2M	85,78±0,36	53,46±0,08	44,11±0,50	**37,93±0,14**
WRN-28-10	AT†	36,5M	89,48	70,91	66,92	62,76
Görü Dönüştürücüsü Modelleri						
ViT-Tiny	Yok	5,7M	80,09±0,60	6,10±1,47	0,05±0,05	–
ViT-Tiny	AT	5,7M	73,53±0,55	36,31±0,42	32,69±0,22	**29,14±0,40**

†Gowal vd.'nin [54] RobustBench [14] üzerinden dağıtılan gürbüz kontrol noktası; tek harici kontrol noktası olduğundan standart sapma yoktur. Temiz/FGSM/PGD-10: yerel tam test değerlendirmeleri; AA: RobustBench'in raporladığı değer (bu model üzerinde AutoAttack yeniden koşulmamıştır).

Tablo III: Tam test kümesinde beyaz kutu gürbüzlüğünün koşullu ayrıştırması; üç koşu üzerinden ortalama±std.

Model	Koşullu yanıltma (%) PGD-10	Koşullu yanıltma (%) AA	Her ikisi doğru gürbüz (%) PGD-10	Her ikisi doğru gürbüz (%) AA
ResNet-18 AT	**48,58**±0,80	**55,78**±0,23	**59,86**±0,35	**51,89**±0,49
ViT-Tiny AT	55,53±0,50	60,37±0,33	46,11±0,59	41,15±0,39



Şekil 2: Pertürbasyon bütçesi ϵ'a göre PGD-10 gürbüz doğruluğu, tam test kümesi (üç koşu ortalaması; ±1 std hata çubukları işaretçilerden dardır). Yatay eksen kategoriktir ve $\epsilon = 0$ temiz doğruluktur. Tarama ayrı bir PGD-10 değerlendirmesidir; bu yüzden $8/255$ noktası Tablo II'den en çok $0{,}08$ puan ayrılır. CNN'in ViT üzerindeki marjı sabit değildir; küçük bütçelerde en geniş, $16/255$'te ise daralmış durumdadır.

IV. Deneyler

A. Gürbüzlük Karşılaştırması

Tablo II mutlak gürbüzlüğü vermektedir. Bu çalışmada eğitilen modellere ait her hücre, mimari başına üç bağımsız eğitim koşusunun ortalaması ve bu koşular üzerindeki standart sapmadır; her koşu 10.000 örneklik tam test kümesinde değerlendirilmiştir.

CNN her saldırı altında *mutlak* bir gürbüzlük üstünlüğü taşımaktadır: ResNet-18 AT, AutoAttack altında $\%37{,}93\pm0{,}14$ gürbüz doğruluğa ulaşırken ViT-Tiny AT $\%29{,}14 \pm 0{,}40$'ta kalmaktadır. Bir çiftin iki modeli de aynı 10.000 örnekte, örnek bazında kayıtla değerlendirildiğinden her koşu içinde McNemar'ın eşleştirilmiş testi uygulanabilmekte ve bu test üç çiftte de CNN lehine sonuç vermektedir (AutoAttack altında $p < 2 \times 10^{-84}$, PGD-10 altında $p < 2 \times 10^{-120}$). Çekişmeli eğitilmiş çiftte tohum düzeyindeki değişim raporlanan hiçbir doğrulukta 0,55 puanı aşmamaktadır; dolayısıyla sıralama koşudan koşuya gürültü değildir. CNN ayrıca daha yüksek bir temiz doğruluğu korumaktadır ($\%85{,}78$'e karşı $\%73{,}53$, 12,3 puanlık fark). Bu fark ViT'leri küçük veri kümelerinde sıfırdan eğitmenin güçlüğünü yansıtmaktadır; AutoAttack gürbüzlüğü de iki mimaride PGD-10'un altına düşmektedir (ResNet-18 için 6,2, ViT-Tiny için 3,6 puan). %62,76'daki WideResNet-28-10 referansı [54], kapasitenin, ek eğitim verisinin ve daha güçlü bir tarifin gürbüzlüğü mimari seçiminin ötesine birlikte ne kadar taşıdığını göstermektedir; bu model çalışma boyunca eşleşmiş çiftten ayrı tutulmaktadır.

Tablo III mutlak skorları temiz doğruluk ve koşullu duyarlılık bileşenlerine ayırmaktadır (Bölüm III-F). Temizde yanlış sınıflandırılan girdiler gürbüz olmayan sayıldığından çarpanlara ayırma birebirdir ve AutoAttack için CNN'de $85{,}78 \times 0{,}442 = 37{,}93$, ViT'te $73{,}53 \times 0{,}396 = 29{,}14$ olarak okunmaktadır. İki çarpan da CNN lehinedir. CNN 12,3 puan daha yüksek bir temiz doğruluktan başlamakta *ve* çözdüklerinin daha küçük bir kesrini kaybetmektedir; koşullu yanıltma PGD-10 altında $\%48{,}58$'e karşı $\%55{,}53$, AutoAttack altında $\%55{,}78$'e karşı $\%60{,}37$'dir. Çiftin iki modelinin de temizde doğru sınıflandırdığı $n = 7.061 \pm 68$ örnekte, yani birebir eşleştirilmiş bir karşılaştırmada CNN 13,8 ve 10,7 puan öndedir (her koşuda McNemar $p < 10^{-67}$; bu sınır söz konusu altkümede hesaplanmıştır ve yukarıda anılan tam küme sınırından zayıftır, aradaki fark büyük paydanın sağladığı kazançtır).

İki çarpanın aynı yönü göstermesi zorunlu olmadığından ayrıştırma, çarpanlar uyuştuğunda bile raporlanmaya değerdir. Sabit bölme protokolünden önce eğitilmiş ve temiz ön eğitimin zaten gördüğü bir doğrulama bölmesiyle seçilmiş daha eski bir kontrol noktası çifti aynı mutlak sıralamayı vermiş, ancak temiz doğruluk ile koşullu duyarlılık arasındaki payı farklı dağıtmıştır (Bölüm III-E). Bu türden bir atıf bu nedenle tek bir eğitim koşusundan çıkarılmamalıdır; tek başına raporlanan mutlak skor da işi hangi çarpanın yaptığını gizlemektedir.

Şekil 2, $\epsilon \in \{2/255, 4/255, 8/255, 16/255\}$ bütçelerinde tam test kümesindeki PGD-10 gürbüz doğruluğunu göstermektedir.

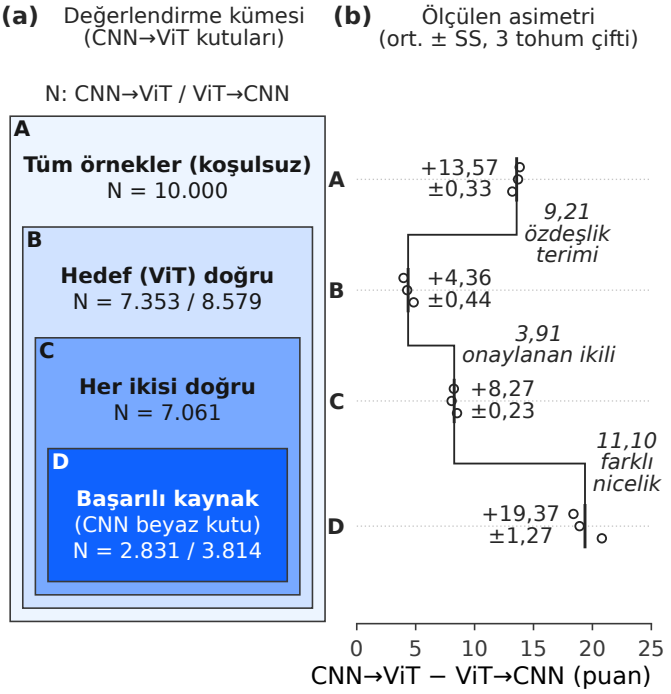
B. Sabit Modeller Üzerinde Dört Koşullama Protokolü

Her tohum çifti için PGD-10 çekişmeli örnekleri kaynak modelde üretilmiş ve tam test kümesinde bir hedef üzerinde değerlendirilmiştir. Sonuçlar örnek bazında kaydedildiğinden aynı saldırı koşusu, yeniden hesaplama gerekmeden Tablo I'teki her protokol altında puanlanabilmektedir; protokoller yalnızca paydaya hangi örneklerin girdiğinde ayrışmaktadır.

Paydalar protokoller arasında keskin biçimde değişmektedir. CNN→ViT ve ViT→CNN için paydalar sırasıyla koşulsuz durumda 10.000/10.000, hedef doğruda 7.353/8.579,

Tablo IV: Koşulsuz oran ve üç yerleşik koşullama protokolü altında transfer asimetrisi (PGD-10, ϵ=8/255, tam test kümesi; üç tohum çifti üzerinden ortalama±std).

Protokol	CNN→ViT	ViT→CNN	Fark (puan)
Koşulsuz (ham)	41,02±0,55	27,45±0,27	+13,57±0,33
Hedef doğru	19,87±0,18	15,51±0,59	+4,36±0,44
Her ikisi doğru	18,25±0,17	9,98±0,31	+8,27±0,23
Başarılı kaynak	36,39±0,76	17,02±0,52	+19,37±1,27



Yayılım 15,01 puan (başarılı kaynak eksi hedef doğru)

Şekil 3: Dört transfer protokolünün CNN→ViT yönündeki iç içe değerlendirme kümeleri (a; kutular şematiktir ve alanla orantılı değildir, N üç tohum çiftinin ortalamasıdır) ve her protokolün aynı modeller ve aynı veri üzerinde verdiği CNN→ViT eksi ViT→CNN asimetrisi (b; üç tohum çifti üzerinden çift içi eşleştirilmiş farkın ortalaması±SS, tek tek çiftler içi boş işaretçilerle). ViT→CNN kümeleri aynı sırayla iç içedir (N = 10.000, 8.579, 7.061 ve 3.814); koşulsuz ve her ikisi doğru kümeleri iki yönde aynıdır, diğer ikisi ise aynı değildir. (b) panelindeki bağlayıcılar üç ikili uzaklığı işaretlemektedir. CIFAR-10'da 15,01 puanlık yayılım, başarılı kaynağın her ikisi doğru üzerindeki fazlası (11,10 puan, farklı bir nicelik) ile onaylanan ikili içindeki uzaklığın (3,91 puan) toplamıdır; koşulsuz kestirim bu aralığın içinde, Denklem (7)'in yerleştirdiği gibi hedef doğrunun 9,21 puan üstünde yer almaktadır.

her ikisi doğruda 7.061 ortak örnek ve başarılı kaynakta 2.831/3.814'tür. Aynı modeller ve aynı veri üzerinde asimetri $+4{,}36 \pm 0{,}44$ ile $+19{,}37 \pm 1{,}27$ puan arasında değişmekte, uç değerler arasında 4,4 katlık bir oran bulunmakta ve en büyük ile en küçük protokol kestirimi arasındaki çift başına ortalama yayılım $15{,}01 \pm 0{,}84$ puan olmaktadır. Yeniden eğitim aynı niceliği çok daha az oynatmaktadır. Üç eğitim çifti boyunca asimetri, tablodaki sırayla dört protokol altında 0,63, 0,86, 0,46 ve 2,41 puanlık aralıklara yayılmaktadır; dolayısıyla benzeri benzeriyle, yani aralığı aralıkla karşılaştıran ölçüt 15,01 puana karşı en çok 2,41 puandır. Fark sütunundaki standart sapma (0,23 ile 1,27 puan) çift içi eşleştirilmiş farka aittir ve iki yön çiftler boyunca birlikte değiştiği için yön başına yayılımlardan geri hesaplanamamaktadır.

Yayılım tek bir nicelik değildir. CIFAR-10'da yayılım bitişik protokoller arasındaki iki uzaklığa ayrılmaktadır (Şekil 3b). Başarılı kaynak kestirimi kaynağın kendi beyaz kutu başarısızlığına koşullandığı için farklı bir niceliği, yani zaten işe yaramış bir saldırının ne ölçüde taşındığını kestirmektedir ve her ikisi doğru kestiriminin $11{,}10 \pm 1{,}09$ puan üstündedir. Yönlü iddialar için onaylanan ve yalnızca kaynağın da doğru olmasının gerekip gerekmediğiyle ayrışan iki protokol, hedef doğru ve her ikisi doğru, birbirinden $3{,}91 \pm 0{,}32$ puan uzaktadır; koşum düzeyindeki %95 t aralığı $[3{,}12;\ 4{,}70]$'tir (iki serbestlik derecesi). Bu uzaklık çözümleyicinin takdirinden değil iki farklı kestirilen nicelik arasındaki farktan doğmaktadır ve aşağıda betimlenen marjinal altkümeler onu açıklamaktadır. Her çiftte hedef doğru en küçük, başarılı kaynak en büyük kestirim olduğundan iki uzaklık birlikte 15,01 puanlık aralığı oluşturmaktadır. Koşulsuz kestirim bu aralığın içinde, hedef doğrunun $9{,}21 \pm 0{,}76$ puan üstünde ve başarılı kaynağın 5,79 puan altında yer almaktadır; hedeflerin temiz hataları, koşullu oranlar ve ölçülen öncül p bilindiğinde Denklem (7) onu tam bu konuma yerleştirmektedir (Bölüm IV-B1). Onaylanan uzaklık CIFAR-100'de 5,97 puan (aralık $[3{,}53;\ 8{,}40]$), L_2 bütçesi altında 1,95 puan ($[1{,}33;\ 2{,}56]$), iki SVHN çiftinde ise 0,82 ve 0,49 puandır. CIFAR-100'de koşulsuz kestirim aralığın üst ucudur ve 13,58 puanlık özdeşlik terimi 13,83 puanlık yayılımın neredeyse tamamını oluşturmaktadır.

Protokol istatistiksel okumayı da değiştirmektedir. İki yönü aynı örnekler üzerinde puanlayan ve bu yüzden eşleştirilmiş çıkarımı destekleyen her ikisi doğru protokolünde fark $8{,}27 \pm 0{,}24$ puandır; bu değerin tablodaki ±0,23'ten hafifçe ayrılmasının tek nedeni iki kestiricinin farklı olmasıdır. Her koşunun kendi eşleştirilmiş bootstrap güven aralığı vardır ($[7{,}61;\ 9{,}44]$, $[7{,}10;\ 9{,}01]$ ve $[7{,}28;\ 9{,}20]$). Uç noktaların ortalaması $[7{,}33;\ 9{,}22]$ aralığını vermektedir; bu aralık üç aralığın bir betimlemesidir ve kendi başına kapsama garantisi taşımamaktadır. Koşum düzeyinde çıkarım için koşumlar arası t aralığı $[7{,}68;\ 8{,}86]$'dır. İşaret çevirme permütasyonunun p değeri her tohumda 5×10^{-5}'in altındadır ve her aralık ±3'ün tamamen dışında kaldığı için TOST üç marjın hiçbirinde (±1, ±2 ve ±3 puan) eşdeğerliği kuramamaktadır.

Protokol adları alt seçimleri de açık bırakmaktadır. Kaynağın temiz girdide zaten yanlış sınıflandırdığı örnekleri de içeri alan gevşek başarılı kaynak okumasında (Tablo I) ölçülen asimetri +19,37 puandan +14,60 puana, protokol yayılımı ise 15,01 puandan 10,45 puana inmektedir. Bu $4{,}77 \pm 0{,}39$ puanlık kayma, Tablo IV'teki herhangi bir protokolün koşumlar arası standart sapmasından üç kattan fazla büyüktür; diğer üç protokol ise yapısı gereği değişmemektedir.

CIFAR-10'da kararlı olan yöndür. CNN'de üretilen örnekler ViT'e, dört protokolün dördünde, üç tohumun üçünde ve momentum tabanlı MI-FGSM [41] altında da tersinden daha iyi transfer olmaktadır ($19{,}07 \pm 0{,}33$'e karşı $\%15{,}42 \pm 0{,}52$, hedef

doğru; bu iki yönlü kontrol başka yerde kullanılan $\alpha = 2/255$ yerine saldırının kendi varsayılan adımı olan $\alpha = \epsilon/10$'u kullanmaktadır ve ViT→CNN değerinin Tablo XIV'deki eşleşmiş bütçeli değerden hafifçe ayrılmasının nedeni budur). Dolayısıyla etki PGD saldırısının kendisinin bir artefaktı değildir. Etkinin büyüklüğü ve anlamlılığı, onlarla birlikte de her türlü eşdeğerlik iddiası protokole bağlıdır.

Onaylanan iki protokol arasındaki uzaklığın bileşimsel bir kaynağı vardır. Hedefin temizde çözdüğü ama kaynağın çözemediği örnekler ortak çözülenlerden üç-dört kat daha kırılgandır ($\%41{,}2 \pm 0{,}8$ ve $\%59{,}1 \pm 1{,}7$ yanıltmaya karşı $\%10{,}0$ ve $\%18{,}2$) ve bu marjinal altkümeler, iki model temiz doğrulukta ayrıştığı için boyutça beş kat farklıdır (1.517 ± 102'ye karşı 291 ± 16). Hedef doğru koşullaması iki marjinal altkümeyi de içeri almakta ve bunların asimetrik boyutları iki oranı birbirine doğru çekmektedir; her ikisi doğru koşullaması ise onları dışarıda bırakmakta ve yönlü fark yeniden ortaya çıkmaktadır. Bu açıklama dört protokolün üçünü kapsamaktadır. Başarılı kaynak protokolü *kaynağın* kendi gürbüzlüğüne göre seçim yapmaktadır; bu gürbüzlük çiftin temiz doğruluk farkının bir fonksiyonu olmadığından protokol ikinci, kısmen ters yönlü bir terim katmaktadır (Bölüm IV-D4).

1) Ham oranın ne kadarı hedefin temiz hatası?: WideResNet-28-10 referansının hem kaynak hem hedef olarak eklenmesi her eğitim çifti için bir 3×3 matris vermektedir (Tablo V); Denklem (7) bu matrisin altı köşegen dışı yönünde, temiz hataları birbirinden çok farklı hedeflere karşı sınanabilmektedir. Özdeşliğin öncülü bu çekişmeli eğitilmiş hedeflerde sıkı biçimde sağlanmaktadır. 36 köşegen dışı yönde (iki veri kümesi, üç tohum çifti, üç hedef, iki kaynak) ölçülen p değeri $0{,}989$ ile $1{,}000$ arasındadır. Bu nedenle $p = 1$ biçimi ölçülen her koşulsuz oranı $0{,}41$ puan içinde yeniden üretmektedir; ortalama mutlak artık $0{,}095$ puandır ve artık, açıkladığı sapmanın en çok $\%1{,}39$'u kadardır. Bu artık puan cinsinden yeniden yazılmış öncül, yani $e\,(1-p)$ olduğundan ikinci bir doğrulama sayılmamaktadır; bilgi taşıyan nicelik p'nin kendisidir. Aynı sonuç sapma ile hedefin temiz hatası arasındaki bir korelasyon olarak ifade edilseydi ($r = 0{,}997$) eksik anlatılmış olurdu, çünkü bir niceliğin kendi baskın bileşeniyle bire yakın korelasyonu aritmetiktir.

Veri kümesine özgü kalan şey orantı çarpanıdır. $(1 - r_{\text{koş}})$ saldırının ne kadar transfer edilebilir olduğuna bağlı olduğundan uydurulan eğim CIFAR-10'da hedef hatasının puanı başına $0{,}762$, CIFAR-100'de $0{,}656$ puandır. Bu eğim ölçülen hedefler üzerinden bir ortalamadır ve özdeşlik başka model havuzlarına her uygulandığında yeniden kestirilmelidir. Koşulsuz transfer oranları bu yüzden mimariler arası transfer edilebilirliği ölçmemekte, transfer edilebilirliği hedefin temiz zayıflığıyla birlikte, Denklem (7)'in açıkça gösterdiği bir oranda ölçmektedir.

C. Hedef Zayıflığı Değil, Kaynak Etkisi

Üç mimarili 3×3 matrisler yönün nereden geldiğini de göstermektedir. Bir CNN→ViT üstünlüğü, CNN'de üretilen örneklerin herhangi bir hedefe daha iyi taşınmasından, yani bir kaynak etkisinden ya da ViT'in herhangi bir kaynak için daha kolay hedef olmasından, yani bir hedef etkisinden doğabilir. İki etki, her eğitim çiftinin altı köşegen dışı oranına

Tablo V: 3×3 transfer matrisi (PGD-10, ϵ=8/255, tam test kümesi; üç tohum çifti üzerinden ortalama±std; WideResNet satır ve sütunu tek harici kontrol noktasını kullanır). Ham = koşulsuz yanıltma oranı, Koş. = hedef doğru koşullu oran. Köşegen girdileri beyaz kutu saldırılardır. Bu matrisin saldırıları ayrı bir koşuda üretilmiştir (saldırı tohumu 42); Tablo III ve Tablo IV ile paylaştığı hücreler onlardan en çok $0{,}06$ puan ayrılır ve bu fark Bölüm IV-H'teki saldırı başlatma varyansının içindedir.

Kaynak	Hedef	Ham (%)	Koş. (%)
ResNet-18 AT	ResNet-18 AT	55,84±0,53	48,52±0,84
ResNet-18 AT	ViT-Tiny AT	41,07±0,58	19,93±0,20
ResNet-18 AT	WRN-28-10	21,69±0,09	12,48±0,10
ViT-Tiny AT	ResNet-18 AT	27,45±0,34	15,52±0,64
ViT-Tiny AT	ViT-Tiny AT	67,34±0,18	55,57±0,44
ViT-Tiny AT	WRN-28-10	18,25±0,12	8,65±0,14
WRN-28-10	ResNet-18 AT	32,63±0,14	21,48±0,31
WRN-28-10	ViT-Tiny AT	39,73±0,25	18,15±0,28
WRN-28-10	WRN-28-10	33,03	25,16

protokol protokol uydurulan ve toplamı sıfır kodlama kullanan $r(s \to t) = \mu + \alpha_s + \beta_t + \varepsilon_{st}$ toplamsal modeliyle ayrılmıştır. Böylece asimetri, kaynak farkı $\alpha_{\text{CNN}} - \alpha_{\text{ViT}}$, hedef farkı $\beta_{\text{ViT}} - \beta_{\text{CNN}}$ ve bir artık farkının toplamına eşit olmaktadır. Altı hücre ve beş parametre tek bir artık serbestlik derecesi bıraktığından yüksek bir R^2 beklenen bir sonuçtur ve az kanıt taşımaktadır; uydurma her matrisi betimlemekte, hiçbir şeyi sınamamaktadır, aşağıdaki sabit üçüncü model karşıtlıkları ise hiçbir model gerektirmemektedir.

Kaynak terimi asimetriyi iki veri kümesinde de taşımaktadır (Tablo VI). CIFAR-10'da kaynak farkı $+5{,}13 \pm 0{,}09$, hedef farkı $-2{,}03 \pm 0{,}51$ puandır. ViT üzerinde üretilen örnekler daha kötü taşınmakta ve ViT iki hedefin *daha az* kırılgan olanı olmaktadır; dolayısıyla hedef terimi ölçülen $+4{,}41 \pm 0{,}45$ puanlık asimetriye karşı çalışmaktadır. CIFAR-100 aynı örüntüyü daha büyük ölçekte yinelemektedir ($+9{,}54 \pm 0{,}64$'e karşı $-6{,}19 \pm 0{,}93$). Kaynak terimi puanlanabilen her protokolde işaretini korurken hedef terimi korumamaktadır. Her ikisi doğru protokolünde hedef farkı CIFAR-10'da sıfırdan ayırt edilemeyen $-0{,}53 \pm 0{,}59$, CIFAR-100'de $-2{,}85 \pm 0{,}93$ olurken kaynak farkı $+6{,}76 \pm 0{,}35$ ve $+11{,}79 \pm 0{,}83$'e çıkmaktadır; CIFAR-100 kayıtlarının izin verdiği başarılı kaynak protokolünde ise terimler $+20{,}82 \pm 1{,}43$ ve $-8{,}12 \pm 2{,}23$'tür. WideResNet aynı karşıtlıkları model gerektirmeden sağlamaktadır. Sabit bir hedef olarak WideResNet, ResNet'te üretilen örneklerin $\%12{,}48$'i, ViT'te üretilenlerin ise $\%8{,}65$'i ile kandırılmaktadır; yani ViT'te üretilen örnekler üçüncü bir mimariye bile daha kötü taşınmaktadır. Sabit bir kaynak olarak ise ResNet'i $\%21{,}48$, ViT'i $\%18{,}15$ oranında kandırmaktadır; dolayısıyla ViT üçüncü bir modelin pertürbasyonları için de daha zor hedeftir. Sabit model karşıtlıkları her ikisi doğru protokolünde de bu işaretleri korumakta (CIFAR-10'da $+4{,}69 \pm 0{,}38$ ve $-2{,}60 \pm 0{,}72$), hedef karşıtlığı ise iki veri kümesinde de her koşullu protokolde negatif kalmaktadır. Ham oranlarla puanlandığında aynı ayrıştırma CIFAR-10'da $+8{,}13$, CIFAR-100'de $+10{,}72$ puanlık bir hedef farkı vermektedir; koşulsuz oranlar ViT'in daha büyük temiz hatasını da saydığı için onu daha zayıf hedef gibi göstermektedir. Daha zayıf hedef oku-

ması gelen transfer korelasyonuna da dayandırılamaz. Gelen koşullu transfer her hedefin kendi beyaz kutu koşullu yanıltma oranını izlemektedir (üç hedef üzerinde $r = 0{,}986$), ancak bu korelasyonu iki aileden gelen saldırıları da soğuran gürbüz WideResNet taşımaktadır ($\%10{,}57$ gelen transfer). ResNet ile ViT arasında gelen transfer yalnızca $0{,}54$ puan farklıdır ($\%18{,}50$'ye karşı $\%19{,}04$), asimetri ise $4{,}41$ puandır.

Mahmood vd.'nin [8] 8×8 matrisleri, başka yerde eğitilmiş modeller üzerinde aynı ayrıştırmaya imkân vermektedir. Bu matrisler kendi her ikisi doğru protokolleri altında, çift başına $m = 1000$ örnekle ve her hücrede FGSM, PGD ve MIM saldırılarının en güçlüsüyle ($\epsilon = 0{,}031$) elde edilmiştir. Mahmood vd.'nin rejimi bu karşılaştırma için önemli olan her bakımdan buradakinden farklıdır. ViT ve BiT-M modelleri ImageNet-21k üzerinde ön eğitilmiş ve çekişmeli eğitim olmadan ince ayarlanmış, ResNet-56 ve ResNet-164 ise CIFAR üzerinde çekişmeli eğitim olmadan eğitilmiştir; köşegenleri de beyaz kutu saldırısı değil aynı modelin bağımsız eğitilmiş bir kopyası olduğundan dışarıda bırakılmıştır. Aile içi transfer aileler arası transferden çok daha güçlü olduğu için toplamsal model bu matrislere zayıf uymaktadır (CIFAR-10'da $R^2 = 0{,}368$, CIFAR-100'de $0{,}451$); aynı aile terimi R^2'yi $0{,}785$ ve $0{,}843$'e çıkarmaktadır. İki uydurmada da aile düzeyindeki kaynak farkı CIFAR-10'da ViT lehinedir (CNN eksi ViT olarak toplamsal uydurmada $-25{,}01$, aile terimiyle $-10{,}78$ puan) ve buradaki yönün tersini göstermektedir; melez ViT-R50'nin dışarıda bırakıldığı 12 aileler arası çiftin tamamında da ViT daha güçlü kaynaktır. CIFAR-100'de ResNet-56 ve ResNet-164 bu çalışmanın yönünü göstermekte ve $6/6$ çiftte CNN$\rightarrow$ViT daha güçlü olmaktadır; ancak bu yönü hedef terimi taşımakta (toplamsal $+30{,}15$, aile terimiyle $+16{,}81$), kaynak terimi ise yine ViT lehine kalmaktadır ($-21{,}90$ ve $-8{,}55$). Orada yön buradakiyle uyuşmakta, mekanizma ise uyuşmamaktadır. Bölüm V-A bu durumun açık bıraktığı soruyu tartışmaktadır.

D. Veri Kümeleri ve Tehdit Modelleri Arasında

Tablo VIII bu makaledeki her ayarda dört protokolü bir araya getirmektedir. Onaylanan iki protokol her ayarın içinde aynı işareti vermektedir; protokoller arasında işaret yalnızca SVHN'de değişmekte ve orada dört kestirimin tamamı sıfırın üç puan yakınında kalmaktadır. Ayarlar aşağıda sırayla ele alınmakta (Bölüm IV-D1 ile IV-D3 arası), ardından ölçülen her çiftte yayılım ile temiz doğruluk farkı arasındaki ilişki incelenmektedir (Bölüm IV-D4).

1) İkinci bir veri kümesi: CIFAR-100: Yalnızca CIFAR-10'da var olan bir protokol etkisi genel bir raporlama önerisini desteklemeyeceği için tasarımın tamamı CIFAR-100 üzerinde yinelenmiştir; mimariler, tehdit modeli, saldırı bütçesi, üç tohumlu yapı ve dört protokol aynı tutulmuştur. Üç yönsel ön kestirim ile üç uç nokta bandı, bu veri kümesinden herhangi bir ölçüm mevcut olmadan önce salt eklemeli bir belgeye kaydedilmiş, böylece sonucun ölçüldükten sonra yeniden yorumlanmasının önüne geçilmiştir. Kayıt eğitimin başlangıcından önce gelmemektedir; kayıt işlemesi, sayı bildiren ilk adımdan, yani epok 5'teki pilot kapısından altmış altı dakika öncedir.

Mutlak gürbüzlük CIFAR-10'a göre düşüktür ve CNN'in ViT üzerindeki sıralamasını korumaktadır (Tablo VII). Aynı dört protokol boyunca ölçülen CNN$\rightarrow$ViT asimetrisi $+4{,}96 \pm 1{,}01$ puandan (hedef doğru) $+18{,}53 \pm 0{,}71$ puana (koşulsuz) uzanmakta; her ikisi doğru protokolünde $+10{,}92 \pm 0{,}34$, başarılı kaynak protokolünde ise $+17{,}50 \pm 0{,}92$ puan olmaktadır. Tohum başına ortalama yayılım $13{,}83 \pm 1{,}30$ puandır; CIFAR-10'da bu değer $15{,}01 \pm 0{,}84$ olduğuna göre daha zor veri kümesi protokol etkisini aynı aralıkta, CIFAR-10 değerinin bir miktar altında bırakmaktadır. Yön, CIFAR-10'da olduğu gibi on iki ölçümün tamamında pozitiftir (dört protokol $\times$ üç tohum çifti). Her ikisi doğru protokolünde eşleştirilmiş fark $10{,}92$ puandır. CIFAR-10'da olduğu gibi verilen $[9{,}47;\ 12{,}35]$ aralığı üç tohumun kendi bootstrap uç noktalarının ortalamasıdır ve kapsama garantisi taşımamaktadır; mimarilere ilişkin bir iddiayla eşleşen koşumlar arası t aralığı ise $[10{,}07;\ 11{,}77]$'dir. İşaret çevirme permütasyonunun p değeri her tohumda 20.000 permütasyonun çözünürlüğünün altındadır ve TOST sınanan hiçbir marjda eşdeğerliği kuramamaktadır.

Kaydedilen üç ön kestirimin biri doğrulanmış, biri bağlayıcı kabul edilen okumada tutmamış, üçüncüsü ise bu tasarımda sınanamamıştır. İşaretin korunacağı ön kestirimi doğrulanmıştır ($12/12$). Protokol yayılımının daha zor veri kümesinde büyüyeceği ön kestirimi CIFAR-10 yayılımına karşı bir karşılaştırma olarak kaydedilmiş ve o tarihte bu yayılım $10{,}45$ puan olarak anılmıştı. Bu sayısal eşiğe karşı kestirim tutmaktadır ($13{,}83 > 10{,}45$); sıkı başarılı kaynak okuması altındaki güncel CIFAR-10 yayılımına karşı ise tutmamaktadır ($13{,}83 < 15{,}01$). Kayıt sayıyı değil CIFAR-10 yayılımını adlandırdığı için bu sonuç bir başarısızlık olarak sayılmıştır. Üçüncü ön kestirim, koşulsuz oranın koşullu orandan sapmasının hedefin temiz hatasıyla birlikte büyüyeceğini öngörüyordu. Ölçülen eğim hedef hatasının puanı başına $+0{,}656$ puandır ve öngörüldüğü gibi pozitiftir. Ancak CIFAR-100'de üç hedeften ikisinin temiz hatası yalnızca $0{,}21$ puan farklıdır ($36{,}15$ ve $36{,}36$); dolayısıyla korelasyon üç değil iki etkin küme üzerinden hesaplanmakta ve değeri (altı yön üzerinde $r = 0{,}931$, hedef düzeyinde $0{,}974$) iki noktalı bir karşıtlığa dayanmaktadır. Ölçüm ön kestirimi *sınamadan* onunla *tutarlıdır* ve üçüncü bir doğrulama sayılmamaktadır.

Kaydedilen uç noktalardan biri tutmamıştır. Çekişmeli eğitilmiş ViT için temiz doğruluk $\%33$ ile 40 bandında öngörülmüş, $\%43{,}17 \pm 1{,}10$ ölçülmüştür. Bant, çekişmeli eğitimin temiz doğruluk bedelinin iki mimaride aynı biçimde ölçekleneceği varsayımıyla türetilmişti. Bu varsayım tutmamıştır; ViT çekişmeli eğitim altında temiz ön eğitim doğruluğunun $0{,}885$'ini korurken ResNet $0{,}802$'sini korumuştur. Protokol iddiasının dayandığı iki çekişmeli uç nokta ise bantlarının içinde kalmıştır (PGD-10 öngörüsü $\%10$ ile 14, ölçüm $11{,}15$; AutoAttack öngörüsü $\%8$ ile 11, ölçüm $8{,}87$). Koşullama sınıf karışımını da değiştirdiğinden bir asimetri ilke olarak bir bileşim artefaktı olabilirdi, ancak ölçümler bunu göstermemektedir. Hedef doğru protokolünde asimetrinin bileşim bileşeni üç tohum çiftinde $-1{,}249$, $-1{,}330$ ve $-1{,}065$ puandır ve *negatiftir*; yani sınıf karışımı yeniden dengelenseydi asimetri büyürdü. Başarılı kaynak protokolünde bu bileşen küçüktür ve her tohumda pozitiftir ($+0{,}527$, $+0{,}435$ ve $+0{,}382$ puan); koşulsuz ve her ikisi doğru protokollerinde ise ayrıştırmanın gerektirdiği gibi tam olarak sıfırdır.

Bu sonuç iki niteleme taşımaktadır. Birincisi, iki çekiş-

Tablo VI: Transfer matrislerinin toplamsal kaynak-hedef ayrıştırması (puan; köşegen dışı hücreler). Kaynak farkı $= \alpha_{\text{CNN}} - \alpha_{\text{ViT}}$ (pozitif değer CNN'de üretilen örneklerin daha iyi taşındığını gösterir); hedef farkı $= \beta_{\text{ViT}} - \beta_{\text{CNN}}$ (pozitif değer ViT'in daha kırılgan hedef olduğunu gösterir); asimetri = CNN→ViT eksi ViT→CNN. Üst blok: bu çalışmanın 3×3 matrisleri (ResNet-18 AT, ViT-Tiny AT, WideResNet-28-10; standart eğitilmiş satırda her çiftin temiz eğitilmiş ResNet-18 ve ViT-Tiny modelleri ile RobustBench'in standart WideResNet-28-10 modeli), eğitim çifti ve protokol başına uydurulmuş, üç çift üzerinden ortalama±std. Matrisler Tablo V'deki ayrı saldırı koşusundan geldiği için CIFAR-10 hedef doğru asimetrisi burada $4{,}41$, Tablo IV'te $4{,}36$'dır; altı hücre ve beş parametreyle R^2 sınamaz, yalnızca betimler. Orta blok: uydurma yapılmadan sabit üçüncü model olarak WideResNet; hedef olarak bir kaynak karşıtlığı (CNN'den gelen oran eksi ViT'ten gelen oran), kaynak olarak bir hedef karşıtlığı (ViT'e giden oran eksi CNN'e giden oran) verir. Alt blok: Mahmood vd.'nin [8] 8×8 her ikisi doğru matrisleri (standart eğitilmiş modeller, m=1000, köşegen hariç); aksi belirtilmedikçe melez ViT-R50 dışındaki CNN ve ViT aileleri, aynı aile terimli ve terimsiz uydurmalar.

Veri	Protokol ya da uydurma	Kaynak farkı	Hedef farkı	Asimetri	En büyük |artık|	R^2
Bu çalışmanın matrisleri, eğitim çifti başına toplamsal uydurma						
CIFAR-10	Hedef doğru	+5,13±0,09	−2,03±0,51	+4,41±0,45	0,65±0,05	0,9782±0,0032
CIFAR-10	Her ikisi doğru	+6,76±0,35	−0,53±0,59	+8,30±0,16	1,04±0,11	0,9643±0,0072
CIFAR-10	Koşulsuz	+4,47±0,10	+8,13±0,33	+13,62±0,38	0,51±0,03	0,9964±0,0004
CIFAR-100	Hedef doğru	+9,54±0,64	−6,19±0,93	+4,96±1,02	0,80±0,05	0,9871±0,0015
CIFAR-100	Her ikisi doğru	+11,79±0,83	−2,85±0,93	+10,92±0,34	0,99±0,10	0,9851±0,0035
CIFAR-100	Başarılı kaynak	+20,82±1,43	−8,12±2,23	+17,50±0,92	2,40±0,06	0,9830±0,0008
CIFAR-100	Koşulsuz	+6,48±0,38	+10,72±0,97	+18,53±0,71	0,67±0,01	0,9946±0,0003
C10, standart eğitim	Hedef doğru	+69,18±2,31	−75,05±1,72	−4,49±0,85	0,69±0,20	0,9996±0,0002
Sabit üçüncü model olarak WideResNet-28-10, uydurma yok						
CIFAR-10	Hedef doğru	+3,83±0,17	−3,33±0,59	–	–	–
CIFAR-10	Her ikisi doğru	+4,69±0,38	−2,60±0,72	–	–	–
CIFAR-100	Hedef doğru	+7,94±0,54	−7,79±0,95	–	–	–
CIFAR-100	Her ikisi doğru	+9,81±1,03	−4,83±0,75	–	–	–
CIFAR-100	Başarılı kaynak	+16,03±1,42	−12,91±2,29	–	–	–
C10, standart eğitim	Hedef doğru	+67,80±2,11	−76,43±2,02	–	–	–
Mahmood vd. [8], 8×8 her ikisi doğru matrisler, aile düzeyi						
CIFAR-10	Toplamsal	−25,01	+2,08	−24,01	74,04	0,3681
CIFAR-10	Aynı aile terimi	−10,78	−12,15	−24,01	29,33	0,7852
CIFAR-100	Toplamsal	−22,77	+14,74	−9,02	66,29	0,4508
CIFAR-100	Aynı aile terimi	−9,43	+1,39	−9,02	24,33	0,8425
CIFAR-100	ResNet-56/164 ile ViT, toplamsal	−21,90	+30,15	+9,15	–	–
CIFAR-100	ResNet-56/164 ile ViT, aynı aile	−8,55	+16,81	+9,15	–	–

Tablo VII: CIFAR-100 yinelemesi (mimari başına üç bağımsız eğitim koşusunun ortalaması±std, tam test kümesi, ϵ=8/255). İki model de Bölüm III-E'deki tarifle eğitilmiştir. Mutlak gürbüzlük iki mimaride de CIFAR-10'a göre düşüktür ve CNN'in ViT üzerindeki sıralaması değişmemiştir.

Model	Temiz (%)	PGD-10 (%)	AutoAttack (%)
ResNet-18 AT	63,86±1,05	19,30±0,32	15,04±0,54
ViT-Tiny AT	43,17±1,10	11,15±0,60	8,87±0,83

meli bant en yakın tohum düzeyi kenarında $0{,}22$ puanlık (AutoAttack) ve $0{,}48$ puanlık (PGD-10) marjlarla tutmuştur ve bu marjlar aynı veri kümesindeki kontrol noktası seçimi gürültüsünden küçüktür. Eğitim koşusu sabit tutularak CIFAR-100 yörüngelerinde erken durdurma sabrı ve eğri yumuşatması tarandığında raporlanan PGD-10 doğruluğu $0{,}18$ ile $1{,}83$ puan arasında oynamaktadır (ortalama $0{,}86$). Aynı dokuz hücreli tarama CIFAR-10'da doğrulama bölmesi başına $0{,}54$ ile $2{,}83$ puan vermektedir; Bölüm IV-F'deki on sekiz hücreli değer ise bölmeyi de değiştirdiği için daha da büyüktür ve CIFAR-100 protokolünde bu boyut bulunmamaktadır. İkincisi, iki bağımsız bölme yerine aynı ayrılmış bölme iki aşamada da seçim için kullanılmıştır; bu tercih iki veri kümesini karşılaştırılabilir tutmak amacıyla CIFAR-10 protokolünden devralınmıştır.

2) Eşlenmeye yakın bir çiftle üçüncü bir veri kümesi: SVHN: CIFAR-10 ve CIFAR-100 iki mimariyi temiz doğrulukta birbirinden hayli uzağa yerleştirmektedir (yaklaşık 12 ve 21 puan). SVHN [62] ise böyle değildir. Aynı tarifle çekişmeli eğitildiğinde ResNet iki koşuda $\%94{,}76$ ve $\%93{,}77$ (ortalama $94{,}27$), ViT ise $\%92{,}82$ ve $\%92{,}03$ (ortalama $92{,}42$) temiz doğruluğa ulaşmakta, aradaki farklar $1{,}94$ ve $1{,}74$ puan (ortalama $1{,}84$) olmaktadır. İki koşudan hesaplanan $0{,}70$ ve $0{,}56$'lık standart sapmalar az bilgi taşıdığından koşu değerleri ayrı ayrı verilmiştir. Ortalama gürbüz doğruluklar PGD-10 altında $\%55{,}52$ ve $\%52{,}30$'dur. PGD-10 farkı hâlâ yaklaşık üç puan olduğundan bu çift eşlenmiş değil, eşlenmeye yakın olarak adlandırılmaktadır. Özdeşlik terimi temiz doğruluk farkını izliyorsa burada yönün kendisi bir protokol meselesine dönüşmelidir.

Ölçümler bu beklentiyle uyuşmaktadır. Dört protokolün ikisi CNN, ikisi ViT üstünlüğü bildirmektedir (Tablo VIII). Yönlü iddialar için onaylanan iki protokol, hedef doğru ile her ikisi doğru, birbiriyle uyuşmakta ve ikisi de ViT lehine çıkmaktadır; işaret değişimi bu iki protokolü koşulsuz ve başarılı kaynak oranlarından ayırmaktadır. Koşulsuz orandaki çevrilme Denklem (7)'den aritmetik olarak çıkmaktadır. Burada ViT hedefinin temiz hatası CNN'inkini yaklaşık iki puan aşmakta ve bu fark $-1{,}00$'lık hedef doğru farkını $+0{,}39$'luk ham farka taşımaya yetmektedir. İki yönü özdeş örnekler üzerinde puan-

Tablo VIII: Bu makaledeki her ayarda dört koşullama protokolü altında transfer asimetrisi (CNN→ViT eksi ViT→CNN, yüzde puan; PGD-10; L_∞ altında ϵ=8/255, L_2 altında ϵ=0,5; tam test kümeleri). Üç tohum çiftli ayarlarda çiftler üzerinden ortalama±std verilir; SVHN'de iki çift olduğundan standart sapma yerine iki değer ayrı ayrı basılır. Yayılım, çift başına dört protokol üzerindeki açıklığın çiftler üzerinden ortalamasıdır. Onaylanan iki protokol, hedef doğru ve her ikisi doğru, her ayarın içinde aynı işareti verir; protokoller arasında işaret yalnızca SVHN'de değişir ve orada dört kestirimin tamamı sıfırın üç puan yakınındadır.

Protokol	**CIFAR-10,** L_∞ 3 çift, n=10.000	**CIFAR-100,** L_∞ 3 çift, n=10.000	**SVHN,** L_∞ 2 çift, n=26.032	**CIFAR-10,** L_2 3 çift, n=10.000
Koşulsuz (ham)	$+13{,}57 \pm 0{,}33$	$+18{,}53 \pm 0{,}71$	$+0{,}33$ / $+0{,}45$	$+13{,}03 \pm 0{,}81$
Hedef doğru	$+4{,}36 \pm 0{,}44$	$+4{,}96 \pm 1{,}01$	$-1{,}16$ / $-0{,}85$	$+2{,}12 \pm 0{,}18$
Her ikisi doğru	$+8{,}27 \pm 0{,}23$	$+10{,}92 \pm 0{,}34$	$-0{,}34$ / $-0{,}36$	$+4{,}07 \pm 0{,}36$
Başarılı kaynak	$+19{,}37 \pm 1{,}27$	$+17{,}50 \pm 0{,}92$	$+2{,}98$ / $+2{,}41$	$+12{,}06 \pm 0{,}23$
Yayılım (en büyük − en küçük)	$15{,}01 \pm 0{,}84$	$13{,}83 \pm 1{,}30$	4,14 / 3,26	$10{,}92 \pm 0{,}82$

ladığı için birincil kabul edilen her ikisi doğru protokolünde fark $-0{,}35$ puandır; işaret çevirme permütasyonunun p değeri $0{,}105$'tir ve TOST eşdeğerliği, sınanan en dar marj (± 1 puan) dahil üç marjın üçünde de kabul edilmektedir. Böyle bir eşdeğerlik iddiasının kurulup kurulamayacağına da protokol karar vermektedir. Ölçümden önce sabitlenen ± 2 marjında iki nokta kestirimi ($+2{,}98$ ve $+2{,}41$) marjın dışında kaldığı için hiçbir başarılı kaynak kestirimi bu sınamayı geçemezken, iki her ikisi doğru kestirimi ($-0{,}34$ ve $-0{,}36$) marjın rahatça içindedir. Kabul bir niteleme gerektirmektedir. SVHN iki tohum çiftiyle koşulduğundan verilen $[-0{,}76;\ +0{,}07]$ aralığı iki tohumun bootstrap uç noktalarının ortalamasıdır ve koşumlar arası bir aralık elde edilememektedir; eşdeğerlik koşum içi karşılaştırmaya ve iki koşumun yakın uyuşmasına dayanmakta, iki koşum ise koşumlar arası değişimi sınırlayamamaktadır. Yalnızca başarılı kaynak oranını raporlayan bir çalışma SVHN'de $2{,}70$ puanlık bir CNN üstünlüğü, yalnızca hedef doğru oranını raporlayan bir çalışma ise $1{,}00$ puanlık bir ViT üstünlüğü duyururdu.

SVHN'de dört protokollü yayılım iki çiftte $4{,}14$ ve $3{,}26$ puandır (ortalama $3{,}70$); bu değer CIFAR-10'da $15{,}01 \pm 0{,}84$, CIFAR-100'de $13{,}83 \pm 1{,}30$ puan iken temiz doğruluk farkları sırasıyla $1{,}84$, ≈ 12 ve ≈ 21 puandır. Özdeşlik terimine karşılık gelen üç protokollü yayılım ise $1{,}49$ ve $1{,}30$ puandır. İlişki üç veri kümesi arasında tekdüze değildir ve en büyük fark en büyük yayılımı vermemektedir. SVHN'i ayıran özellik eşlenmeye yakın çifttir. Yayılım yeterince küçüldüğünde asimetrinin kendisini aşamamakta ve işaret mimarilerin değil protokolün bir özelliği haline gelmektedir; Bölüm IV-B'te kararlı olarak raporlanan yön, iki CIFAR veri kümesinin de bulunduğu *iki modelin temiz doğrulukta ayrıştığı rejimde* kararlıdır. SVHN önceden sabitlenmiş indirgenmiş bir yapılandırmayla koşulmuştur; üç yerine iki tohum çifti kullanılmış, çekişmeli eğitim 50 epokla sınırlanmış, AutoAttack ve üçüncü mimari yer almamıştır. Bu nedenle Bölüm IV-B1'teki 3×3 kontrol burada kurulmamıştır.

3) İkinci bir tehdit modeli: L_2: Protokol etkisinin L_∞'ye özgü bir artefakt olup olmadığını sınamak için aynı CIFAR-10 kontrol noktaları $\epsilon = 0{,}5$'lik bir L_2 bütçesi altında yeniden değerlendirilmiş ve üç yönsel ön kestirim herhangi bir L_2 çıktısına bakılmadan önce kaydedilmiştir. Modeller L_∞ ile eğitildiğinden bu ölçüm L_2 gürbüzlüğünü değil protokolün sonucu nasıl etkilediğini yoklamaktadır ve aşağıdaki mutlak değerler L_2 ile eğitilmiş referanslarla karşılaştırılamamaktadır.

Tablo IX: Aynı kontrol noktaları, L_2 bütçesi (ϵ=0,5; üç tohum çiftinin ortalaması±std). PGD-L2 tam test kümesini, AutoAttack-L2 ise ölçümden önce sabitlenen 5.000 örneklik bir altkümeyi kullanır; bu yüzden temiz sütunu tam küme değerinden bir miktar farklıdır ve ikisi aynı örneklerden gelmez.

Model	**Temiz**	**PGD-L2**	**Temiz (5k)**	**AA-L2**
ResNet-18 AT	85,78	$63{,}78 \pm 0{,}38$	85,33	$60{,}61 \pm 0{,}42$
ViT-Tiny AT	73,53	$51{,}72 \pm 0{,}23$	73,61	$49{,}85 \pm 0{,}20$

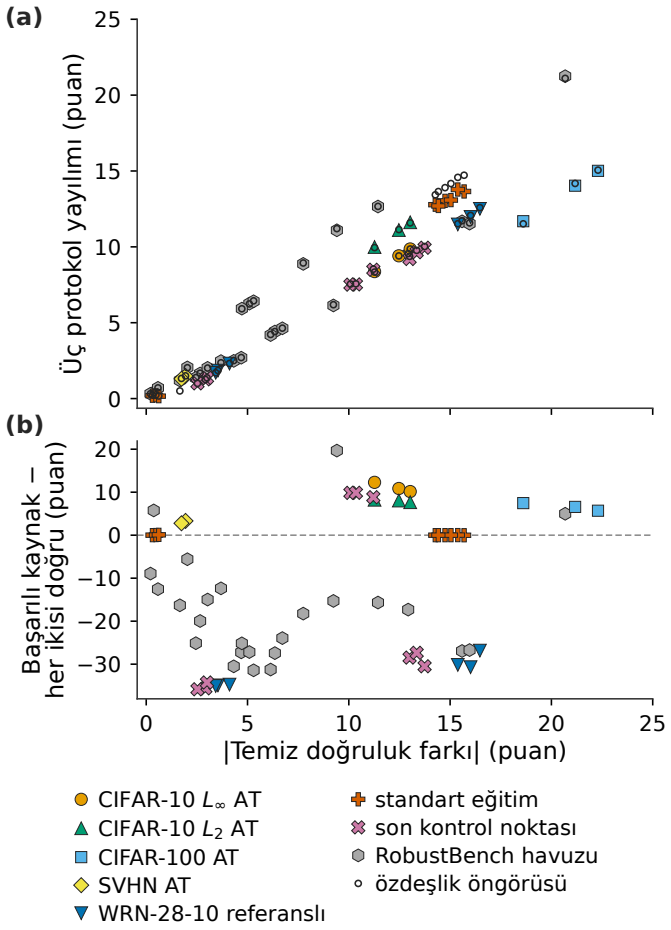
Norm değişince protokol yayılımı $10{,}92$ puana küçülmektedir (L_∞ altında $15{,}01$); ancak hem kayıtta belirlenen iki puanlık tabanın hem de koşumlar arası standart sapmanın çok üstünde kalmakta ve işaret on iki ölçümün tamamında pozitif çıkmaktadır; böylece kaydedilen ilk iki ön kestirim tutmaktadır. Dört protokolün (Tablo VIII) bildirdiği asimetriler $+13{,}03 \pm 0{,}81$ (koşulsuz), $+2{,}12 \pm 0{,}18$ (hedef doğru), $+4{,}07 \pm 0{,}36$ (her ikisi doğru) ve $+12{,}06 \pm 0{,}23$ puandır (başarılı kaynak). Üçüncü ön kestirim, yani koşulsuz oranın koşullu orandan sapmasının hedefin temiz hatasıyla artacağı, Denklem (7) sağlandığı sürece yanlışlanamaz ve uydurulan $+0{,}914$ eğimi bir şeyi sınamak yerine $1 - r_{\text{koş}}$'u kestirmektedir. On sekiz yön yalnızca yedi ayrık hedef hatası değeri aldığından ve bunların altısı aynı sabit WideResNet'ten geldiğinden korelasyon yerine eğim raporlanmaktadır. Ön kestirim özdeşlik yazılmadan önce kaydedilmişti ve şimdi özdeşliğin örneklem dışı bir sınaması işlevini görmektedir. Eğim de özdeşliğin öngördüğü yerde durmaktadır. Koşullu oranlar bu L_2 bütçesi altında L_∞'dekinden çok daha düşük olduğundan (kabaca $\%2$ ile 9'a karşı $\%9$ ile 22) özdeşlik daha dik bir eğim öngörmektedir ve ölçülen $0{,}914$, aynı modellerin L_∞ altındaki $0{,}762$ değerini aşmaktadır. Mutlak gürbüzlük (Tablo IX) iki saldırı altında da CNN'in ViT üzerindeki sıralamasını korumakta ve McNemar $p < 10^{-57}$ her tohum çiftinde sağlanmaktadır.

4) Yayılım ve temiz doğruluk farkı: Yukarıdaki ayarlar yayılımın temiz doğruluk farkıyla büyüdüğünü düşündürmektedir; CIFAR-100 ve SVHN ölçümlerinden önce kaydedilen analiz bu ilişkiyi tüm final modellerin yön çiftleri üzerinde sınamıştır (sekiz tohum ve veri kümesi kümesinden 20 yön çifti, küme bootstrap). Dört protokollü eğim $-0{,}133$'tür ve $[-0{,}570;\ +0{,}469]$ aralığı sıfırı içerdiği için geri çekilmiştir. Başarılı kaynak protokolünü dışarıda bırakan üç protokollü eğim ise $+0{,}470$ $[+0{,}361;\ +0{,}665]$'tir. Bu eğim bir meka-

nizma için bağımsız kanıt değildir. Yön çiftlerinin 20'sinden 19'unda, her ikisi doğru kestirimi ikisinin arasında kaldığı için üç protokollü yayılım koşulsuz ve hedef doğru asimetrileri arasındaki mutlak farka eşittir ve bu fark Denklem (7)'in öngörüsüyle 0,16 puan içinde uyuşmaktadır; yalnızca özdeşlik terimi $+0{,}471$ $[+0{,}3615;\ +0{,}6666]$ eğimini vermektedir. Üç protokollü eğim özdeşliğin ikinci kez ölçülmesidir ve Denklem (7)'in örneklem dışı bir sınaması olarak okunmaktadır.

Bu uydurmada ilk kullanılan havuz SVHN çiftini dışarıda bırakmıştı. Bu tercih, SVHN'i uydurulan kola koyan ve onu küçük farklardaki boş bandı dolduracak çift olarak adlandıran ön kayıttan bir sapmadır; bağımsız bir tutarlılık kontrolüne yeniden atanması SVHN sonucu elde edildikten sonra yazıldığından yukarıdaki SVHN'i içeren uydurma bağlayıcıdır. SVHN'in dışarıda bırakıldığı havuzda dört protokollü eğim $-0{,}528$ $[-0{,}664;\ -0{,}418]$, üç protokollü eğim $+0{,}431$ $[+0{,}333;\ +0{,}633]$'tür. Zıt işaretler, orada 18 çiftin 16'sında dördün ucu olan başarılı kaynak protokolünden gelmektedir ve en geniş protokol çifti hedef doğru ile başarılı kaynak arasındadır (23,77 puan ortalama açıklık, 18 yönün 13'ünde en geniş). Kontrollü bir kol aynı ilişkiyi eğitim yörüngeleri içinde kalibre etmektedir. Çiftin bir üyesi sabit tutulup diğeri kendi yörüngesi boyunca taranmakta, böylece mimari, tohum, veri kümesi ve bütçe sabit kalırken fark değişmektedir (sekiz kümeden 116 nokta, yörünge düzeyinde küme bootstrap). Bu kolun üç protokollü eğimi $+0{,}673$ $[+0{,}602;\ +0{,}727]$ ile gözlemsel eğimin işaretini taşımakta, o da özdeşlik teriminin baskın olduğu bir nicelik olduğu için aynı uyarıya tabi olmaktadır. Dört protokollü eğimi $+0{,}273$ $[+0{,}219;\ +0{,}371]$ ise bağlayıcı havuzdaki gözlemsel aralığın tamamen içinde kaldığından kollar bu nicelikte ne uyuşmakta ne de ayrışmaktadır; gözlemsel havuz eşlenmiş mimari çiftine kısıtlandığında dört protokollü eğim $-0{,}100$ $[-0{,}464;\ +0{,}092]$ olmaktadır. Hangi çiftlerin uydurmaya girdiğine bu kadar duyarlı bir nicelik bir mekanizma iddiasına dayanak olamaz. Altı ile sekiz küme varken yüzdelik küme bootstrap kapsamayı düşük tuttuğundan bu aralıkların tümü genişliklerini olduğundan dar göstermektedir; ayrıca tek ve sabit bir kontrol noktası olan WideResNet her gözlemsel kümede yer almaktadır.

Şekil 4 ilişkiyi ölçülen her çifte genişletmektedir. Bu çiftler üç veri kümesinin ve iki tehdit modelinin çekişmeli eğitilmiş çiftleri, bunların WideResNet ile eşleşmeleri, son kontrol noktasındaki aynı CIFAR-10 çiftleri (Bölüm IV-F), standart eğitilmiş çiftler ve Bölüm IV-E'teki dış havuzdur; toplam 60 sırasız çift söz konusudur. CIFAR-100 ve L_2 ayarlarının WideResNet eşleşmeleri dahil edilmemiş, havuzun ilk CIFAR-10 eğitim çiftiyle çakışan üç çifti ise çekişmeli eğitilmiş gruplarda bir kez sayılmıştır. Üç protokollü yayılım farkla birlikte artmakta (eğim $+0{,}796$, Pearson $r = 0{,}957$; herhangi bir grup dışarıda bırakıldığında $+0{,}767$ ile $+0{,}855$ arasında) ve 60 noktanın 57'sinde koşulsuz eksi hedef doğru farkına eşit olmaktadır. İçi boş halkalarla çizilen Denklem (7) öngörüsü her noktayı 1,09 puan içinde izlemekte (ortalama mutlak sapma 0,13), en büyük sapmalar ise p'nin birden en uzak olduğu standart eğitilmiş hedeflerde görülmektedir (Bölüm IV-E). Dört protokollü yayılım farkı izlememekte (eğim $+0{,}092$, $r = 0{,}053$) ve temiz doğrulukları neredeyse eşit gürbüz çiftlerde büyük kalmaktadır. Bu yayılım Carmon



Şekil 4: Ölçülen 60 model çiftinin tamamında protokol yayılımının mutlak temiz doğruluk farkına göre değişimi. (a) Asimetrinin koşulsuz, hedef doğru ve her ikisi doğru protokolleri üzerindeki yayılımı; küçük içi boş halkalar aynı çift için $p = 1$ alınarak hesaplanan Denklem (7) öngörüsünü gösterir. (b) Aynı çiftlerde başarılı kaynak eksi her ikisi doğru asimetrisi, yani üç protokollü yayılımın dışarıda bıraktığı terim. İşaretçiler her ayarın çekişmeli eğitilmiş çiftlerini, bunların WideResNet-28-10 referansıyla eşleşmelerini, son kontrol noktasındaki aynı çiftleri, standart eğitilmiş çiftleri ve RobustBench havuzunu ayırır; çiftler modelleri paylaştığı için uydurma doğrusu çizilmemiştir.

vd. [63] ile Gowal vd.'nin [54] iki WideResNet-28-10 kontrol noktasında (0,21 puan fark) 9,03, XCiT-S12 ile Gowal vd. modelinde (0,58) 12,73, bu çalışmanın ResNet-18 modeli ile Engstrom vd.'nin [64] ResNet-50 modelinde (1,66) ise 17,50 puandır. Bunun nedenini (b) paneli göstermektedir. Başarılı kaynak terimi farkla ilişkisizdir; PGD-10 gürbüz doğrulukları sıfıra yakın olduğu için hemen her kaynak saldırısının başarılı olduğu standart eğitilmiş çiftlerde sıfıra yakın, gürbüz modeller arasında ise büyüktür ve iki işaretten birini taşımaktadır. Çiftler modelleri ve koşumları paylaştığı için bu eğimler havuzu betimlemekte, hiçbir şeyi sınamamaktadır.

Eşlenmiş çift öngörüsü ayrı bir bulgu değil, özdeşliğin bir sonucudur. Koşulsuz, hedef doğru ve her ikisi doğru kestirimleri temiz hatalarla ölçeklenen terimler üzerinden ayrıştığın-

dan, temiz doğrulukta eşlenmiş bir çiftin mimarisi ne olursa olsun bu kestirimleri birbirine yakın bırakması beklenir. Verilerin katkısı, öngörünün gerektirdiği üç ölçülmüş olgudur. İncelenen her çekişmeli eğitilmiş hedefte p en az $0{,}984$'tür, her ikisi doğru kestirimi 60 noktanın 57'sinde diğer ikisinin arasında yer almaktadır ve başarılı kaynak terimi farka bağlı değildir. Buna uygun olarak $1{,}84$ puanlık farkla SVHN'in iki çiftinde üç protokollü yayılım $1{,}49$ ve $1{,}30$ puandır; aralarında $0{,}47 \pm 0{,}16$ puan bulunan standart eğitilmiş ResNet-18 ile WideResNet-28-10 çiftinde ise dört protokolün tamamı $0{,}19 \pm 0{,}02$ puan içindedir (Bölüm IV-E). CIFAR-10'daki 15 puanlık aralığın temiz doğruluk farkından gelen kısımları, yani özdeşlik terimi ve onaylanan ikili içindeki uzaklık, temiz doğrulukta eşlenmiş çiftlerde küçülmelidir; yukarıdaki gürbüz çiftlerin gösterdiği gibi başarılı kaynak fazlasının küçülmesi ise gerekmemektedir.

E. Standart Eğitilmiş Hedefler ve Dış Model Havuzu

Bu çalışmanın çekişmeli eğitilmiş çiftinin yanıtlayamadığı iki soru kalmaktadır. Bunlar öncül p'nin transfer çalışmalarının çoğunun saldırdığı rejim olan standart eğitilmiş hedeflerde sağlanıp sağlanmadığı ve eşlenmiş çift öngörüsünün başkalarının eğittiği modellerde tutup tutmadığıdır. İki soru da yeni bir eğitim yapılmadan yanıtlanmıştır. İlk olarak üç eğitim çiftinin, çekişmeli ince ayarın başlangıç noktaları olan temiz eğitilmiş ResNet-18 ve ViT-Tiny kontrol noktaları, RobustBench [14] üzerinden dağıtılan standart eğitilmiş WideResNet-28-10 (tanımlayıcı `Standard`) ile birleştirilerek çift başına bir 3×3 matris kurulmuştur. İkinci olarak sekiz modelli bir CIFAR-10 havuzu, ilk çiftin çekişmeli eğitilmiş ResNet-18 ve ViT-Tiny modellerini, standart eğitilmiş WideResNet'i ve RobustBench tanımlayıcılarıyla anılan beş gürbüz RobustBench kontrol noktasını bir araya getirmektedir: bir PreAct ResNet-18 (`Wong2020Fast`) [65], bir ResNet-50 (`Engstrom2019Robustness`) [64], etiketsiz veriyle eğitilmiş bir WideResNet-28-10 (`Carmon2019Unlabeled`) [63], dikkati evrişim bileşenleriyle birleştiren bir XCiT-S12 (`Debenedetti2022Light_XCiT-S12`) [56] ve önceki bölümlerin WideResNet-28-10 referansı [54]. Her yöne tam test kümesinde, örnek bazında kayıtla $\epsilon = 8/255$ bütçeli PGD-10 saldırısı uygulanmış; dört protokol, p ve $p = 1$ artığı bu kayıtlardan hesaplanmıştır (Tablo X).

Standart eğitilmiş hedeflerde öncül zayıflamaktadır. Üç temiz matrisin 18 köşegen dışı yönünde p değeri $0{,}877$ ile $1{,}000$ arasında değişmektedir; en düşük değerler standart eğitilmiş WideResNet hedef olduğunda görülmekte ($0{,}877$ ile $0{,}996$), temiz ViT-Tiny hedefinde ise p $0{,}923$ ile $0{,}934$ arasında kalmaktadır. Bu durumda $p = 1$ biçimi koşulsuz oranı, üç hedef içinde temiz hatası en büyük olan ViT-Tiny hedefinde $1{,}58$ puana kadar ıskalamaktadır. Orada Denklem (7) bir üst sınırdır ve kullanılması gereken düzeltme, ölçülmüş p ile genel biçim olan Denklem (6)'dir. Sekiz hedeften yedisinin çekişmeli eğitilmiş olduğu havuzda her çekişmeli eğitilmiş hedefte $p \geq 0{,}984$, standart eğitilmiş hedefte $p \geq 0{,}933$'tür ve $p = 1$ artığı 56 yönün tamamında $0{,}35$ puan içinde kalmaktadır; bu çalışmanın çiftlerinin son kontrol noktasında ise artık $0{,}20$ puanı aşmamaktadır (Bölüm IV-F).

Standart eğitilmiş matrisler eşlenmiş çift öngörüsünü farklı bir eğitim rejiminde de sınamaktadır. Temiz ResNet-18 ile standart WideResNet temiz doğrulukta $0{,}47 \pm 0{,}16$ puan ayrışmakta ve dört protokol kestirimleri $0{,}19 \pm 0{,}02$ puan içinde uyuşmaktadır (ilk çiftte $-3{,}35$, $-3{,}54$, $-3{,}51$ ve $-3{,}50$). Yaklaşık 15 puan ayrışan iki eşlenmemiş çiftte ($15{,}16 \pm 0{,}48$ ve $14{,}69 \pm 0{,}60$) yayılım $13{,}25 \pm 0{,}34$ ve $13{,}08 \pm 0{,}60$ puandır ve her koşuda koşulsuz protokol diğer üçünün bildirdiği işareti tersine çevirmektedir; temiz ResNet-18 ve ViT-Tiny için koşulsuz protokol $+7{,}81$ ile $+10{,}09$ puan verirken hedef doğru protokolü $-5{,}22$ ile $-3{,}56$ puan vermektedir. Dolayısıyla standart eğitim altında bu çalışmanın ResNet-18 ve ViT-Tiny modelleri her koşullu protokolde ters yönü, yani Mahmood vd.'nin bildirdiği yönü göstermektedir (her ikisi doğru $-3{,}02$ ile $-1{,}30$), ancak onların mekanizmasını göstermemektedir. Toplamsal uydurma (Tablo VI) temiz ViT-Tiny modelini açık ara en zayıf kaynak olarak tutmakta (kaynak farkı $+69{,}18 \pm 2{,}31$) ve işareti hedef terimi üzerinden çevirmektedir ($-75{,}05 \pm 1{,}72$); temiz ViT-Tiny, zayıf bir kaynak olduğundan da daha zor bir hedeftir. Standart WideResNet iki karşıtlığı da doğrudan göstermektedir; ResNet'te üretilen örneklerin $\%81{,}40$'ı, ViT'te üretilenlerin ise $\%13{,}60$'ı tarafından kandırılmakta, kendisi de ResNet'i $\%84{,}05$, ViT'i $\%7{,}62$ oranında kandırmaktadır.

Temiz farkları $0{,}21$ ile $20{,}68$ puan arasında değişen 28 çiftli havuzda üç protokollü yayılım temiz farkın puanı başına $0{,}872$ puan artmakta (model dışarıda bırakmalı bootstrap aralığı $[+0{,}534;\ +1{,}274]$, $r = 0{,}944$), dört protokollü yayılım ise güvenilir bir ilişki göstermemektedir ($+0{,}559$, $[-0{,}205;\ +4{,}582]$). İşaret protokoller arasında 28 çiftin yalnızca birinde, bu çalışmanın çekişmeli eğitilmiş ViT-Tiny modeli ile standart eğitilmiş WideResNet çiftinde değişmektedir; bu çift aynı zamanda en geniş farka sahip çifttir ($20{,}68$ puan; koşulsuz $-6{,}72$, hedef doğru $+14{,}53$). Temiz doğrulukları neredeyse eşit gürbüz modeller eşlenmiş çift öngörüsünü ve onun sınırını aynı anda doğrulamaktadır. Carmon vd. ile Gowal vd.'nin aralarında $0{,}21$ puan bulunan iki gürbüz WideResNet-28-10 kontrol noktasında üç protokollü yayılım $0{,}32$, dört protokollü yayılım ise $9{,}03$ puandır. Havuzun hedef doğru matrisine yapılan toplamsal uydurma (56 hücrede $R^2 = 0{,}8955$) bu çalışmanın ViT-Tiny modelini çekişmeli eğitilmiş en zayıf kaynak olarak konumlandırmakta (kaynak etkisi $-4{,}87$, diğer gürbüz modellerde $+2{,}94$ ile $+3{,}65$), hedef etkisini ise gürbüz modellerin aralığı ($-4{,}26$ ile $+2{,}76$) içinde $-0{,}63$ olarak vermektedir. Evrişim bileşenli bir dikkat modeli olan gürbüz XCiT-S12, CNN'ler kadar güçlü bir kaynaktır ($+3{,}06$). Bölüm IV-C'deki kaynak etkisi bu nedenle bir aile olarak dönüştürücülerin değil, sıfırdan düşük bir temiz doğruluğa eğitilmiş bu ViT-Tiny modelinin özelliği olarak okunmalıdır; havuzdaki tek gürbüz dikkat tabanlı model daha fazlasını söylemeye yetmemektedir.

F. Kontrol Noktası Seçimi ve Asimetri

Sabit bir yörüngeden son kontrol noktasını seçen çevrimdışı kural, gürbüz aşırı öğrenme bu seçimi çekişmeli eğitimde sonuç doğurucu kılsa da [58] genellikle örtük bırakılmaktadır. Bir eğitim yörüngesi sabit tutulup yalnızca son kontrol noktasının nasıl seçildiği, yani doğrulama bölmesi, erken durdurma sabrı ve argmaks öncesinde doğrulama eğrisinin yumuşatılıp yumuşatılmadığı değiştirildiğinde (on sekiz bileşim) raporlanan PGD-10 doğruluğu ResNet'te tohum başına $2{,}62$ ile $2{,}85$,

Tablo X: Denklem (6)'deki öncül p ve bu çalışmanın çekişmeli eğitilmiş çifti dışında eşlenmiş çift öngörüsü (CIFAR-10, PGD-10, ϵ=8/255, tam test kümesi). Üst blok: köşegen dışı yönler üzerinden hedef türüne göre p ve $p = 1$ biçiminin puan cinsinden en büyük mutlak hatası ("–": hedef türü başına saklanmamıştır). Orta blok: her biri bir eğitim çiftinin temiz ResNet-18 ya da ViT-Tiny modeli veya RobustBench'in standart eğitilmiş WideResNet-28-10 modeli olan standart eğitilmiş çiftler, üç çift üzerinden ortalama±std; işaret dönmesi dört protokolün işarette uyuşmadığını gösterir. Alt blok: sekiz modelli havuzun 28 çifti üzerinde protokol yayılımının mutlak temiz doğruluk farkına göre eğimi; çiftler modelleri paylaştığı için aralık model dışarıda bırakmalı bootstrap ile verilmiştir.

Hedef	**Yön**	p **aralığı**	**Maks. |artık|**
AT hedefleri, 3×3	36	0,9890–1,0000	0,41
AT hedefleri, son k. n.	18	0,9915–1,0000	0,20
Temiz ViT-Tiny	6	0,9231–0,9338	1,58
Temiz ResNet-18	6	0,8961–1,0000	0,51
Standart WRN-28-10	6	0,8774–0,9962	0,64
Havuz, AT hedefleri	49	0,9846–1,0000	–
Havuz, standart WRN	7	0,9330–0,9962	–
Havuz, tüm hedefler	56	0,9330–1,0000	0,35
Std. eğitilmiş çift	**|Temiz fark|**	**Yayılım**	**İşaret dön.**
ResNet-18 / WRN	0,47±0,16	0,19±0,02	0/3
ResNet-18 / ViT-Tiny	15,16±0,48	13,25±0,34	3/3
ViT-Tiny / WRN	14,69±0,60	13,08±0,60	3/3
Havuz yayılımı	**Eğim**	**%95 aralık**	r
Üç protokol	+0,872	[+0,534; +1,274]	0,944
Dört protokol	+0,559	[−0,205; +4,582]	0,350
İşaret dön. (4 prot.)		1/28 çift	

ViT'te 1,58 ile 2,09 puan oynamaktadır. Bu hücrelerde diskteki ağırlıklar özdeştir ve yalnızca içlerinden birini seçen kural farklıdır. Bu yayılımın yaklaşık yarısı üç boyuttan yalnızca birinden gelmektedir. Argmaks öncesinde doğrulama eğrisini yumuşatmak, üç ResNet koşumunun üçünde ve üç ViT koşumunun ikisinde test PGD-10 doğruluğunu monoton biçimde düşürmektedir; yani sistematik olarak daha kötü bir kuraldır. Çalışmaların fiilen değiştirdiği bölme ve sabır seçimleriyle sınırlandığında yayılım ResNet'te tohum düzeyi standart sapmanın 1,09 katına, ViT'te 1,42 katına inmektedir. Bu yayılım mutlak birimlerle raporlanmakta ve bilinçli olarak tohum düzeyi yayılıma oran biçiminde verilmemektedir; çünkü o oran on sekiz hücreden hangisinin referans alındığına bağlıdır ve on sekizinin tamamı tarandığında ResNet'te 0,67 ile 3,38, ViT'te 0,63 ile 7,38 arasında değişerek bazı referanslarda karşılaştırmayı tersine çevirmektedir.

CIFAR-100 koşuları bir karşı ağırlık sağlamaktadır. Bu çalışmanın protokolünün seçtiği epok üç ResNet tohumu arasında 25 epok kaymakta, buna karşılık ortaya çıkan test PGD-10 standart sapması 0,32 puanda kalmaktadır. Seçim *yolu* oynak, seçilen *sonuç* ise kararlı olmuştur; bunlardan hangisinin gerçekleşeceği mimariye değil yörüngenin platosuna bağlıdır.

Seçim kuralı, yayılımın bağlı olduğu temiz doğruluk farkını belirlediği için transfer asimetrisine de ulaşmaktadır. Üç eğitim çiftinin seçilen kontrol noktası yerine son kontrol noktasında, yani erken durdurmanın eğitimi sonlandırdığı epokta yeniden puanlanması (ResNet'ler için 71, 76 ve 77, ViT'ler için 45, 38 ve 39; seçilen 51, 56, 57 ve 25, 18, 19. epoklardan yirmi epok sonra) temiz farkı $12{,}26 \pm 0{,}90$ puandan $10{,}55 \pm 0{,}59$ puana (değişim $-1{,}71 \pm 0{,}84$), dört protokollü yayılımı ise $15{,}01 \pm 0{,}84$ puandan $12{,}84 \pm 0{,}34$ puana (değişim $-2{,}16 \pm 0{,}93$) daraltmaktadır; üç protokollü yayılım da $9{,}21 \pm 0{,}76$'dan $7{,}84 \pm 0{,}56$'ya inmektedir. Hedef doğru asimetrisi neredeyse yerinden oynamamakta ($+4{,}36 \pm 0{,}44$'e karşı $+4{,}64 \pm 0{,}56$), başarılı kaynak kestirimi $+19{,}37$'den $+17{,}48$'e düşmekte, dört protokolün tamamı her çiftte CNN→ViT işaretini korumakta ve öncül önceki gibi sağlanmaktadır ($p \geq 0{,}9915$, $p = 1$ artığı en çok 0,20 puan).

Tablo XI: Örnek başına kayıp gradyanlarından hesaplanan gradyan karakteristikleri (koşu başına n=500 test örneği; üç koşu üzerinden ortalama±std). Kalın yazı, çekişmeli eğitilmiş iki modelden büyük olanı gösterir; yerel kontrol tek bir kontrol noktası olduğundan standart sapma verilmemiştir.

Metrik	**ResNet-18 AT**	**ViT-Tiny AT**	**ViT (yerel)**[‡]
Hoyer seyrekliği	**0,4928**±0,0120	0,4561±0,0055	0,4046
Gini katsayısı	**0,6498**±0,0089	0,6099±0,0051	0,5712
Maks. %1 altı kesir	**0,3477**±0,0210	0,2682±0,0090	0,1785
Hizalanma (mutlak)	0,0378±0,0009	**0,0562**±0,0004	0,0794
Hizalanma (işaretli)	0,0010±0,0003	0,0004±0,0001	–

[‡]CIFAR'a özgü ViT kontrolü (4×4 yama, 5,4M parametre); sabit bölme protokolünden önceye ait, test kümesinde seçilmiş tek kontrol noktası; yalnızca büyütme etkisinin işareti için eklenmiştir.

Saklanan eğitim yörüngeleri eğitim boyunca aynı tabloyu vermektedir. Bu yörüngeler ana çiftlerin seçilen kontrol noktalarından değil, aynı tohumlarla yapılan CIFAR-10 yeniden eğitim koşularından ve doğrudan CIFAR-100 koşularından gelmekte ve yaklaşık her on epokta bir kaydedilmektedir. CIFAR-10'da bu yeniden eğitim koşuları temiz farkı hem seçilen hem son epokta 10,59 puanda ya da üstünde tutmaktadır; dolayısıyla seçim farkı yaklaşık 1,7 puan oynatmakta, ancak ortadan kaldırmamaktadır. Farkın tam büyüklüğü ise seçime duyarlıdır. Bir çiftin bir üyesini seçilen epoğundan son epoğuna taşımak dört protokollü yayılımı ResNet taşındığında $-1{,}53 \pm 1{,}15$ puan, ViT taşındığında $-0{,}03 \pm 1{,}15$ puan değiştirmekte, ViT'in taşınması ise hedef doğru asimetrisini $+2{,}53 \pm 0{,}15$ puan kaydırmaktadır; CIFAR-100'de yayılım $-1{,}84 \pm 0{,}94$ ve $+0{,}84 \pm 0{,}24$ puan değişmektedir. Seçim kuralı böylece asimetrinin düzeyini yaklaşık iki buçuk puana, yayılımını ise yaklaşık iki puana kadar oynatmakta, ancak yönü ya da büyüklük mertebesini değiştirmemektedir. Bu kuralın yöntem bölümünde belirtilmesi gerekir.

G. Doğrudan Ölçümde Ayakta Kalmayan Üç Okuma

Mimari karşılaştırmaları transfer asimetrisinin ötesinde üç okumayı da akla getirmektedir: CNN gradyanlarının mekansal olarak daha lokalize olduğu, çekişmeli pertürbasyonun ViT dikkatini bozduğu ve ViT'e özgü transfer saldırılarının ViT kaynaklı transferi iyileştirdiği. Her biri doğrudan ölçülmüş, hiçbiri bu rejimde geçerli çıkmamış ve aynı ölçümler iki davranışsal farkı ayakta bırakmıştır.

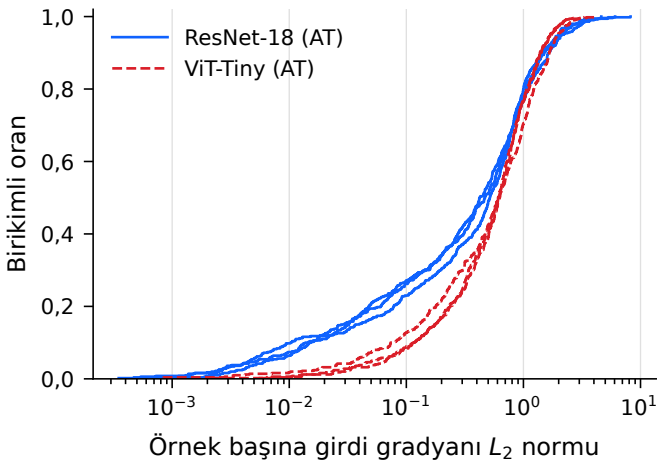
1) Mekansal lokalite olmadan gradyan seyrekliği: CNN girdi gradyanları üç ölçekten bağımsız ölçünün üçünde de ViT gradyanlarından daha seyrektir (Tablo XI; normlar değerlendirme parti boyuna bağlı olmasın diye örnek başına

Tablo XII: Girdi gradyanlarının mekansal lokalitesi (koşu başına n=500 örnek; üç koşu üzerinden ortalama±std). Eşleştirilmiş farklar aynı örnekler üzerinde hesaplanır. Çıkarım koşum düzeyindedir: p, üç koşumun ortalama farkları üzerinde tek örneklem t testidir ve dört ölçüye Holm düzeltmesi uygulanmıştır; böylece çıkarımın birimi iddianın birimiyle eşleşir. Düşük alan ve entropi daha lokalize, yüksek Moran's I daha kümeli demektir.

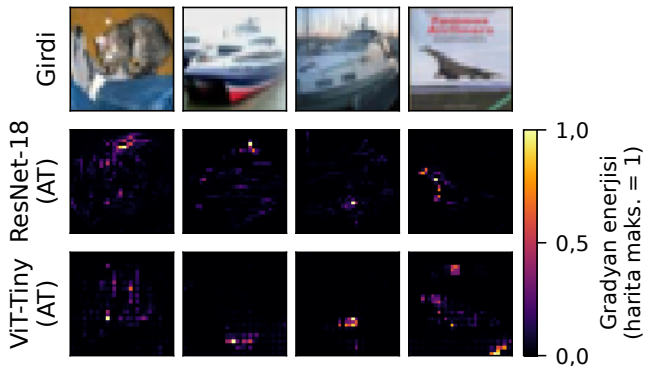
Ölçüt	ResNet-18	ViT-Tiny	Fark (R−V)	p (Holm)
%50 enerji alanı	0,0378±0,0017	0,0397±0,0010	−0,0019±0,0027	0,54
%90 enerji alanı	0,2345±0,0078	0,2570±0,0067	−0,0224±0,0133	0,40
Mekansal entropi (nat)	5,2014±0,0387	5,2524±0,0197	−0,0509±0,0580	0,54
Moran's I	0,4141±0,0132	0,3941±0,0024	+0,0200±0,0156	0,47

kayıp gradyanları, hizalanma için tüm $500 \times 499/2$ örnek çifti üzerinden ortalama mutlak kosinüs) ve sıralama, tohum düzeyi standart sapmalar farktan en az üç kat küçük kalarak her koşuda yeniden üretilmektedir. İki çıkarım biriminin uyuşmadığı tek yer burasıdır ve bu nedenle ikisi de raporlanmaktadır. Aynı 500 örneğin iki modelde de ölçüldüğü koşum içinde örnek başına eşleştirilmiş Wilcoxon testleri üç ölçüde de sıfır hipotezini reddetmektedir (Holm düzeltmeli $p < 10^{-11}$, eşleştirilmiş Cohen d 0,32 ile 1,23 arasında). Mimari bir iddianın gerektirdiği birim olan koşum düzeyinde ise üç eşleştirilmiş koşum Gini, %1 altı kesir ve Hoyer için 0,036, 0,042 ve 0,067 ham p değerleri vermekte, Holm düzeltmesi bunları 0,108'e çıkarmaktadır. Sıralama her koşuda tutarlı ama koşum düzeyinde anlamsız olduğu için anlamlı olarak değil, yeniden üretilebilir olarak raporlanmaktadır. Sıralama çekişmeli eğitimin ürünüdür. Aynı koşuların temiz eğitilmiş karşılıklarında daha seyrek model *ViT'tir* (Hoyer $0{,}380 \pm 0{,}009$'a karşı $0{,}347 \pm 0{,}002$); bu durum Chalasani vd.'nin [29] çekişmeli eğitilmiş modeller için bildirdiği daha seyrek öznitelik atıflarıyla uyumludur. CIFAR'a özgü ViT kontrolü ise her ölçüde büyütülmüş ViT'ten daha az seyrektir; dolayısıyla sıralama $32 \rightarrow 224$ büyütmenin artefaktı değildir. Örnekler arası hizalanma mutlak kosinüste ViT'te daha yüksektir; bu fark koşum düzeyinde anlamlılığa ulaşmakta ($p = 0{,}0009$) ve temiz eğitilmiş çiftte zaten görülmektedir (0,058'e karşı 0,029). *İşaretli* ortalama kosinüs ise iki modelde de sıfıra yakındır (her koşumda $\leq 0{,}0014$); yani örnekler duyarlılık eksenlerini paylaşmakta, ancak tutarlı bir yönü paylaşmamaktadır.

Seyreklik kaç gradyan bileşeninin büyük olduğunu saymakta, ancak bu bileşenlerin görüntüde bir arada durup durmadığını, yani gradyanları lokalize olarak betimleyen ifadenin ileri sürdüğü şeyi söylememektedir. Aynı gradyanların kanal toplamı enerji haritası üzerinde dört ölçekten bağımsız betimleyicinin hiçbiri koşum düzeyinde farklılaşmamaktadır (Tablo XII; Holm düzeltmeli p değerleri 0,40 ile 0,54 arasında). Enerjinin %90'ını taşıyan alan CNN için görüntü alanının iki yüzde puanı kadar *daha küçük* bir alana işaret etmekte ve dört mekansal sıralamanın ikisi koşumlar arasında işaret değiştirmektedir; seyreklik sıralaması ise her koşuda her ölçüde korunmaktadır. Çekişmeli eğitilmiş CNN gradyanları kütlelerinin daha büyük kısmını daha az piksele yerleştirmekte, ancak bu pikseller ViT'inkilerden mekansal olarak daha kümeli olmamaktadır; bu nedenle bu çalışmanın iddiaları seyreklikle sınırlı tutulmuştur. Şekil 5 ölçekten bağımsız ölçülerin yakalamadığı örnek başına gradyan normlarının dağılımını eklemektedir; Şekil 6'teki büyüklük haritaları da lokalite olarak değil seyreklik olarak okunmalıdır.



Şekil 5: Örnek başına girdi gradyanı L_2 normlarının deneysel dağılımı (örnek başına çapraz entropi kaybı, ilk 500 test görüntüsü, eğitim koşusu başına bir eğri, mimari başına üç koşu; logaritmik eksen). Bu girdilerden dördünün büyüklük haritaları Şekil 6'te verilmektedir.



Şekil 6: Aynı test görüntüleri için iki modelde girdi gradyanı büyüklük haritaları (tohum çifti 1; ilk dört test görüntüsü; her harita kendi en büyük değerine ölçeklendiğinden büyüklükler paneller arasında karşılaştırılamaz). CNN gradyanları kütlelerinin daha büyük kısmını daha az bileşene yerleştirmektedir (Tablo XI). Tablo XII bu durumun mekansal dizilişte bir farkla birlikte gelmediğini göstermektedir; bu yüzden paneller lokalite olarak değil seyreklik olarak okunmalıdır.

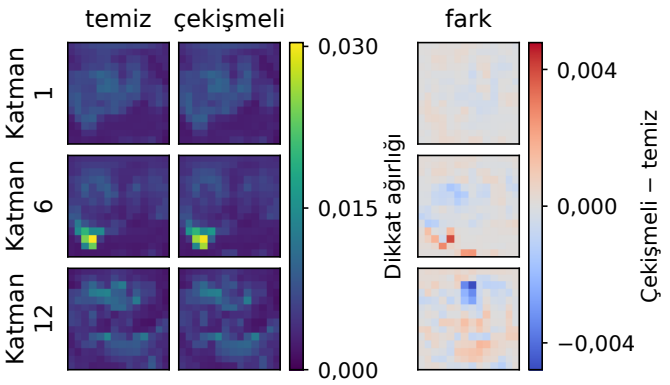
2) Dikkat entropisi ve öznitelik kayması: Çekişmeli hasarın derinlik boyunca nerede biriktiği iki mimaride farklıdır (Tablo XIII; artık blok çıkışları, koşu başına $n = 1000$) ve bu ölçüm temiz eğitilmiş ViT'lerin katman bazlı analizlerini [30] çekişmeli eğitilmiş ortama taşımaktadır. ViT'te kayma kademelidir ve yalnızca yönü değiştirmektedir. Benzerlik 11. bloktaki minimuma kadar azalmakta ve çıkışta hafifçe toparlanmakta, öznitelik normları ise temiz değerlerinin %0,45'i içinde kalmaktadır. CNN'de ise hasar yoğunlaşmıştır; son aşamanın ilk bloğu $-\%13{,}14 \pm 1{,}89$'luk bir norm daralmasıyla

Tablo XIII: Her modelin kendi beyaz kutu PGD-10 saldırısı altında blok bazlı temizden çekişmeliye kosinüs benzerliği (koşu başına n=1000; üç koşu ortalaması). Tüm özetler artık blok çıkışında alınmıştır, böylece ViT ve CNN sütunları eşdeğer noktalarda ölçülmektedir; ViT sütunları yalnızca bir bloğun jetonlarının nasıl toplandığında ayrışır. MLP alt-blok çıkışına ait değerler metinde verilmiştir. Koşumlar arası standart sapma ViT sütunlarında en çok 0,0061, ResNet sütununda en çok 0,0181'dir (aşama 4, blok 1); kalın yazı her sütunun en küçük değerini gösterir.

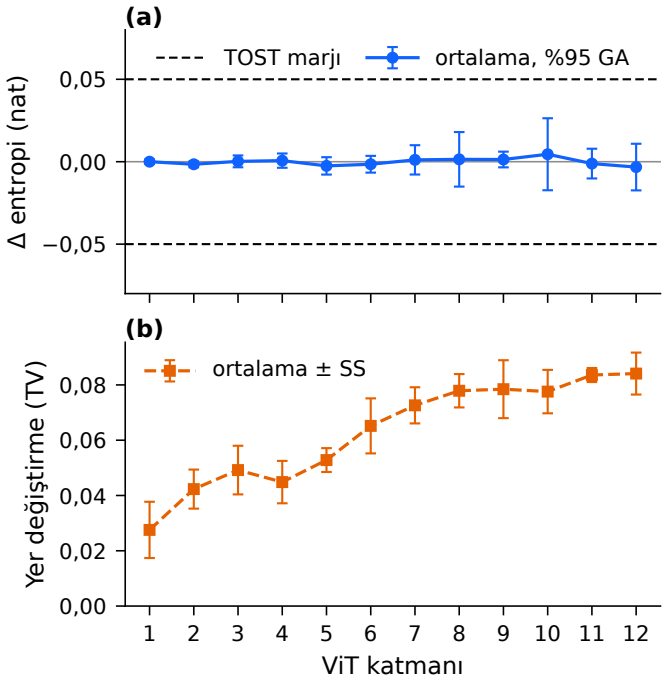
	ViT-Tiny AT			ResNet-18 AT	
Blok	**CLS**	**Yama ort.**	**Tüm jetonlar**	**Aşama.blok**	**Kosinüs**
1	0,9993	0,9980	0,9927	1.1	0,9951
2	0,9950	0,9959	0,9901	1.2	0,9918
3	0,9902	0,9940	0,9881	2.1	0,9879
4	0,9873	0,9919	0,9861	2.2	0,9853
5	0,9845	0,9904	0,9847	3.1	0,9753
6	0,9814	0,9894	0,9835	3.2	0,9607
7	0,9782	0,9885	0,9826	4.1	**0,8777**
8	0,9743	0,9875	0,9816	4.2	0,9108
9	0,9703	**0,9870**	0,9809		
10	0,9661	0,9872	0,9805		
11	**0,9604**	0,9874	**0,9803**		
12	0,9663	0,9915	0,9837		

$0{,}8777 \pm 0{,}0181$'e düşmekte, son blok ise temsili kısmen onarmaktadır ($0{,}9108 \pm 0{,}0060$). Ölçülen ViT profili jeton agregasyonuna bağlıdır. Minimumlarında CLS yolu yama jetonu ortalamasının yaklaşık üç katı kaymakta ($0{,}9604$'e karşı $0{,}9870$; $1 - \cos$ cinsinden oran $3{,}05$) ve minimumlar farklı derinliklerde (blok 11 ve 9) bulunmaktadır; artık blok çıkışı yerine MLP alt-blok çıkışında okunduğunda minimumlar blok 10'da $0{,}9343$'e ve blok 8'de $0{,}9840$'a kaymaktadır. Farklı makalelerden katman bazlı kayma eğrileri ancak hem agregasyon hem de tensör belirtildiğinde karşılaştırılabilir.

Dikkat okuması bu ölçümlerde doğrulanmamaktadır. Çekişmeli pertürbasyon CLS dikkat dağılımının entropisini değiştirmemektedir. Katman başına en büyük ortalama değişim $0{,}0045$ nat iken temiz katman ortalamaları $4{,}61$ ile $5{,}11$ nat arasındadır; ölçünün ölçeğinden sabitlenen $\pm 0{,}05$ nat marjıyla üç koşum üzerinden yapılan koşum düzeyi TOST, 12 katmanın tamamında eşdeğerliği kabul etmekte ve en zayıf sonuç $p = 0{,}006$ olmaktadır (Şekil 8a). Derinlikle büyüyen şey dikkat haritasının yer değiştirmesidir; bu değer ilk katmanda $0{,}028$ toplam varyasyondan son katmanda $0{,}084$'e çıkmaktadır (panel b). Dolayısıyla saldırı dikkati hafifçe yeniden yönlendirmekte, ancak genişletmemekte ya da keskinleştirmemektedir. Şekil 7'teki tek örnekli haritalar yayılmayı değil yeniden yönlendirmeyi göstermektedir ve 8 örneklik daha önceki bir şekil kümesi bu ölçümün desteklemediği bir dikkat etkisi izlenimi vermişti. Öznitelik kayması devrilen ve devrilmeyen örnekleri de ayırmamaktadır; buradaki devrilmeyen grup, modelin temiz girdide zaten yanlış sınıflandırdığı örnekleri de içermektedir. Son blok kosinüsü ViT'te devrilen örneklerde $0{,}9895$, devrilmeyenlerde $0{,}9877$, CNN'de ise $0{,}9058$ ve $0{,}9143$'tür; iki fark da koşum düzeyinde anlamlı değildir (üç koşum üzerinden eşleştirilmiş t, $p = 0{,}20$ ve $p = 0{,}080$), ancak CNN farkı üç koşumun üçünde de aynı işareti taşımaktadır. Yama pertürbasyonları altındaki dikkat kayması etkileri [33]



Şekil 7: Çekişmeli saldırı altında ViT katmanları boyunca CLS jetonu dikkat haritaları (softmax sonrası, başlar üzerinden ortalanmış). Her satır farklı bir katmanı (1, 6, 12) gösterir; sütunlar temiz dikkat, çekişmeli dikkat ve farklarıdır ve dikkat sütunları için bir, fark sütunu için bir ortak renk ölçeği kullanılmıştır. Gösterilen tek bir örnektir (ilk test görüntüsü, tohum çifti 1); dikkat yer değiştirmesindeki derinlik eğilimi koşu başına n=1.000 örnek üzerinden Şekil 8(b)'de ölçülmektedir.



Şekil 8: (a) Saldırı altında CLS dikkat entropisindeki değişim (çekişmeli eksi temiz), katman başına, üç koşum ortalaması ve %95 t güven aralıkları; kesikli çizgiler $\pm 0{,}05$ nat TOST marjını gösterir ve her aralık bu marjın içindedir. (b) CLS dikkat yer değiştirmesi (temiz ile çekişmeli haritalar arasındaki toplam varyasyon), katman başına, koşumlar üzerinden ortalama$\pm$std. Koşu başına n=1.000 örnek; tek örnekli haritalar Şekil 7'te verilmektedir.

ve dikkat mekanizmasının kendisine yönelik saldırılar [32] farklı bir tehdit modeline aittir.

3) ViT'e özgü bir transfer saldırısı: Transfer sonuçlarına yöneltilebilecek doğal bir itiraz, dönüştürücü yapısı için ta-

Tablo XIV: Eşleşmiş bütçede Jeton Gradyanı Düzenlileştirme (TGR) [45] ve düz momentumlu yinelemeli FGSM (MI-FGSM) altında ViT→CNN transferi (L_∞, ϵ=8/255, 10 adım, α=2/255; koşu başına n=10.000; üç koşu üzerinden ortalama±std).

Ölçüt (%)	TGR	MI-FGSM
Kaynakta beyaz kutu (ham)	51,56±0,80	**66,43**±0,29
Transfer, hedef doğru	12,70±0,41	**15,71**±0,60
Transfer, her ikisi doğru	7,93±0,42	**10,08**±0,30

sarlanmış saldırıların daha iyi taşındığı bildirildiğinden ViT'i genel türevlenebilir bir model olarak ele alan gradyan saldırılarının ViT kaynaklı yönü dezavantajlı bıraktığıdır. Geri yayılım sırasında kaynağın dikkat, QKV ve MLP yollarındaki uç değerli jeton gradyanlarını bastıran Jeton Gradyanı Düzenlileştirme (TGR) [45] bu itirazı sınamaktadır; bu çalışmadaki uyarlama yöntemi makale boyunca kullanılan bütçeyle CIFAR-10 ViT-Tiny modeline uygulamakta (Bölüm III-C) ve aynı koşuda eşleştirilmiş kontrol olarak düz MI-FGSM üretmektedir. TGR bu rejimde transferi iyileştirmemekte, tersine kötüleştirmektedir (Tablo XIV). Kaynakta 14,9 puanlık beyaz kutu gücünden vazgeçmekte, koşullu transfer ise hedef doğru protokolünde 3,0, her ikisi doğruda 2,2 puan düşmektedir; her ikisi doğru altkümesindeki eşleştirilmiş McNemar testleri her koşuda MI-FGSM lehinedir ($p = 6{,}1 \times 10^{-10}$, $1{,}1 \times 10^{-27}$, $7{,}0 \times 10^{-34}$). Hedefler çekişmeli eğitilmiş, girdiler model içinde büyütülen 32×32 CIFAR-10 görüntüleri, kaynak ise 5,7M parametreli bir ViT-Tiny'dir; TGR ise standart eğitilmiş ImageNet ViT'leri için kurulmuştur. Bu nedenle sonuç yöntemi genel olarak değil, bu rejimdeki uyarlamayı sınırlamaktadır. Bu makale açısından sonucun anlamı, CNN→ViT asimetrisinin mimariden bağımsız saldırıların bir artefaktı olmamasıdır; ViT yönüne dönüştürücüye özgü bir saldırı vermek onu zayıflatmaktadır.

H. Varyans Kaynakları

Yukarıdaki karşılaştırmaları dört varyans kaynağı ilgilendirmektedir. Saldırı başlatma stokastisitesi ihmal edilebilir düzeydedir; PGD-10'u sabit 1.000 örneklik bir altkümede üç saldırı tohumuyla (42, 123, 456) yeniden koşmak, yükleyici örnekleri karıştırmadığı için temiz doğruluğu hiç değiştirmemekte ve gürbüz doğruluğu CNN'de $0{,}05$, ViT'te $0{,}00$ puanlık standart sapmayla oynatmaktadır. Eğitim koşusu varyansı daha büyük ama yine küçüktür. Mimari başına üç bağımsız koşuda, çekişmeli eğitilmiş çift için standart sapma temiz doğrulukta en çok $0{,}55$, PGD-10'da en çok $0{,}50$ puandır (Tablo II).

Protokol etkisini doğrudan bu iki sayıyla karşılaştırmak bir ölçek hatası olurdu, çünkü protokol etkisi transfer asimetrisi üzerinde, yukarıdaki iki sayı ise mutlak doğruluk üzerinde ölçülmektedir. Bu nedenle protokol ve eğitim koşusu etkileri *aynı* nicelik olan köşegen dışı asimetri üzerinde ve mutlak birimlerle nicelenmiştir. Sabit bir tohum çiftinde yalnızca koşullama protokolünü değiştirmek asimetriyi $15{,}01 \pm 0{,}84$ puan oynatmaktadır. Bu değer tohum başına açıklıkların ortalamasıdır; uç protokoller üç tohumda da aynı olduğu için burada protokol ortalamalarının açıklığıyla çakışmakta, uç protokollerin aynı olmadığı CIFAR-100'de ise ondan ayrışmaktadır ($13{,}83$'e karşı $13{,}58$). İki mimariyi yeniden eğitmek aynı asimetriyi en çok $2{,}41$ puanlık bir aralıkta, ölçüldüğü protokole göre $0{,}23$ ile $1{,}27$ puanlık bir standart sapmayla oynatmaktadır (Bölüm IV-B). En çok iki buçuk puana karşı on beş puan, makalenin dayandığı sıralamadır. Kontrol noktası seçim kuralını değiştirmek dört protokollü yayılımı ortalama $2{,}16$ puan oynatmaktadır (Bölüm IV-F); bu değer yeniden eğitimin bir protokol içinde asimetriyi oynattığı miktara ($2{,}41$'e kadar) yakındır ve söz konusu sıralamayı bozmamaktadır.

Bu iki yayılımın oranı manşete taşınmamıştır. Üç koşumla payda iki serbestlik derecesi taşıdığından herhangi bir tek oran için χ^2 aralığı çok geniştir; başarılı kaynak protokolünde bu aralık $0{,}8$ ile $9{,}9$ arasında uzanmakta ve biri içermektedir. Duyarlılık olarak raporlandığında oran, yayılım ölçüleri ve referans protokoller boyunca $5{,}2$ ile $32{,}6$ arasında değişmekte, birincil kabul edilen her ikisi doğru protokolündeki benzeri benzeriyle karşılaştırmada ise $28{,}3$ olmaktadır. İki uyarı oranı daha da sınırlamaktadır. En büyük asimetriyi veren protokol aynı zamanda en büyük koşumlar arası standart sapmayı taşımakta, yani pay ile payda bağımsız olmamaktadır; üç koşum tek bir doğrulama bölmesini paylaştığından da payda bölmeler arası varyansı dışarıda bırakmakta ve bu durum oranı bir üst sınır yapmaktadır. Mutlak karşılaştırma iki uyarıdan da etkilenmediği için iddiayı kat değeri değil o taşımaktadır. Dördüncü kaynak olan kontrol noktası seçim kuralı Bölüm IV-F'de ele alınmıştır.

Üç CIFAR-10 eğitim çifti ve bunların CIFAR-10 değerlendirmeleri, Bölüm III-E'de anılan önceki kontrol noktası çifti gibi NVIDIA RTX 5060 Ti (16GB VRAM) üzerinde koşulmuştur; CIFAR-100, SVHN ve L_2 kampanyaları, kontrol noktası seçimi yörüngeleri ile standart eğitilmiş, son kontrol noktası ve RobustBench havuzu transfer koşuları ise RTX 5090 (32GB) üzerinde yürütülmüştür. Tüm koşularda PyTorch 2.6.0, CUDA 12.8 ve deterministik cuDNN ayarları kullanılmıştır. AutoAttack değerlendirmesi standart yapılandırmayla (APGD-CE, APGD-T, FAB-T, Square) 10.000 örneklik tam test kümesinde, örnek bazında kayıtla ve tohumlanmış 1.000 örneklik parçalar halinde koşulmuştur. Üç tohumlu eğitim boru hattı toplam 21,7 GPU-saat gerektirmiştir.

V. Tartışma

A. Ölçümlerin Gösterdikleri

Merkezi sonuç, tek bir nicelik üzerindeki yayılımların sıralamasıdır. Yalnızca koşullama kümesini değiştirmek sabit modellerde ölçülen transfer asimetrisini $15{,}01 \pm 0{,}84$ puan oynatırken, iki mimariyi yeniden eğitmek onu en çok $2{,}41$ puanlık bir aralıkta ve $0{,}23$ ile $1{,}27$ arasındaki standart sapmalarla oynatmaktadır (Bölüm IV-H). Farklı bir nicelik üzerinde ölçek vermek gerekirse, bir saldırıyı yeni bir rastgele başlangıçla yeniden koşmak mutlak gürbüz doğruluğu yaklaşık $0{,}05$ puan, yeniden eğitmek ise çekişmeli eğitilmiş çifti en çok $0{,}55$ puan oynatmaktadır. Ölçüm seçiminin bu kadar oynattığı bir sayı, protokolü belirtilmeden raporlandığında okura mimariler hakkında çok az şey söylemektedir.

Bir itiraz kendi terimleriyle yanıtlanmayı hak etmektedir. Dört protokol dört farklı niceliği kestirdiğinden aralarındaki uzaklık bir varyans değildir ve ona varyans demek bir kategori hatası olur. Bu itiraz yerindedir; burada mimarilerin,

protokollerin hatayla kestirdiği tek bir gerçek asimetrisi olduğu varsayılmamaktadır. İddia, okurun neyi geri kazanabildiğiyle ilgilidir. Bir çalışma protokolü adlandırmadan tek bir sayı raporladığında okur dört nicelikten hangisinin kestirildiğini anlayamaz; ölçülen yayılım bu belirsizliğin büyüklüğü, yani protokolü belirtmemenin maliyetine ilişkin bir sınırdır. Koşullamanın kendisi yerleşik bir pratik olmayı sürdürmektedir [11], [40], [41] ve gereklidir; önemli olan, koşullama kümesi seçiminin sonuçla birlikte ve ana metinde raporlanmasıdır.

Yönün genellenip genellenmediği ayrı bir sorudur ve Mahmood vd. [8] ile yapılan karşılaştırma bu soruyu ancak kısmen yanıtlamaktadır. Mahmood vd. ters yönü, yani dönüştürücüden dışarı transferin dönüştürücüye doğru transferden güçlü olduğunu bildirmekte, Benz vd. [7] ile Shao vd. [9] de kendi model kümelerinde aynı sıralamayı raporlamaktadır. CIFAR-10'daki anlaşmazlığı protokol açıklamamaktadır. Denklem (7) ile yeniden puanlandığında BiT-M-R50x1 ve ViT-L-16 çifti her ikisi doğru ile koşulsuz puanlama arasında $-0{,}59$ puan kaymaktadır ($p = 1$ altında ve kaynağın yanlış sınıflandırdığı örneklerin bilinmeyen payı hesaba katıldığında aralık $[-1{,}25;\ +2{,}15]$); bu çiftin her ikisi doğru asimetrisi ise $-36{,}80$'dir ve aileler arası 12 CIFAR-10 çiftinin hiçbirinde işaret değişmemektedir. Bu çiftin iki hedefi temiz girdilerin en çok $\%2{,}5$'ini yanlış sınıflandırdığından (temiz doğruluklar $\%97{,}5$ ve $\%99{,}1$) sonuç p'ye neredeyse hiç bağlı değildir; çekişmeli eğitilmiş hedeflerde ölçülen en düşük p ile etki $-0{,}57$ olmaktadır. CIFAR-100'de yeniden puanlama daha az belirleyicidir. Merkezi kestirim, aileler arası 12 çiftin 6'sında, hepsi bir ViT'e karşı ResNet-56 ya da ResNet-164 olmak üzere, ham puanlamada bir işaret dönüşü öngörmektedir; ancak bu aralıkların her biri sıfırı içermekte ve kaynaklar temiz girdilerin $\%28{,}40$'ına kadarını yanlış sınıflandırdığından her ikisi doğru oranın hedef doğru oranın yerine konması en zayıf burada kalmaktadır. Söz konusu yeniden puanlama hedef doğru oranın yerine her ikisi doğru oranı koymaktadır ve kaynak temiz hataları Mahmood vd.'nin modellerinin hepsinden büyük olan bu çalışmanın çiftinde bu yaklaşıklık $3{,}54$ puan hata vermektedir. Bölüm IV-C'deki kaynak-hedef ayrıştırması ise kısmi bir uzlaşma sunmaktadır. CIFAR-100'de sıfırdan eğitilmiş ResNet-56 ve ResNet-164 melez olmayan üç ViT'in tamamına karşı bu çalışmanın yönünü göstermekte ve bu yönü bir hedef terimi taşımaktadır; ön eğitilmiş BiT-M modelleri ise toplamsal uydurmanın kaynak terimine yüklediği ters yönü göstermektedir. Bu çalışmanın temiz eğitilmiş ResNet-18 ve ViT-Tiny modelleri de Mahmood vd.'nin yönüne aynı yoldan, hedef terimi üzerinden ulaşmakta, ViT-Tiny ise açık ara daha zayıf kaynak olarak kalmaktadır (Bölüm IV-E). Demontis vd. [39] transfer edilebilirliği hedefin kırılganlığına ve vekil modelin karmaşıklığına bağlamaktadır; bu çalışmanın çekişmeli eğitilmiş matrislerinde ise yöne kaynak tarafı karar vermektedir. Rejimler arasındaki hangi farkın, ImageNet-21k ön eğitiminin mi yoksa model ölçeğinin mi, kaynak etkisini tersine çevirdiği açık kalmaktadır. Örnek bazındaki kayıtların yayımlandığı ortak bir protokol, bu sorunun doğrudan yanıtlanmasına imkân verecektir.

Dört protokol birbirinin yerine geçmemektedir ve her birinin savunulabilir bir kullanımı vardır. Koşulsuz oran mimari karşılaştırması için hiç kullanılmamalıdır. Bu oranın hedef doğru orandan sapması, hedefin temiz hatasının toplam olasılık yasası üzerinden içeri girmesidir ve p'nin bire yakın olduğu yerde bu ilişki tam olarak geçerlidir; dolayısıyla koşulsuz oran transfer edilebilirliği değil, bilinen bir oranda hedef zayıflığını ölçmektedir. Hedef doğru protokolü bu karıştırıcıyı gidermekte, ancak kaynağın kendisinin çözemediği örnekleri kabul etmektedir; bu marjinal altkümeler son derece kırılgan ve asimetrik boyutlu olduğundan protokol iki yönü, temiz doğruluk farkına bağlı bir miktarda birbirine doğru çekmektedir. Her ikisi doğru protokolü iki yönü özdeş örnekler üzerinde puanlamakta ve dördü içinde eşleştirilmiş çıkarımı destekleyen tek protokol olmaktadır; birincil kestirim olarak bu yüzden o kabul edilmektedir. Başarılı kaynak protokolü ise zaten işe yaramış bir saldırının ne ölçüde taşındığı sorusunu yanıtlamaktadır ve daha büyük değeri, kaynak başarısıyla koşullamanın güçlü pertürbasyonları seçmesini yansıtmaktadır.

Dört protokol ve üç eğitim koşusu boyunca CNN'de üretilen örnekler *iki CIFAR veri kümesinde de* ViT'e tersinden daha iyi transfer olmakta, CIFAR-10'da bu yön MI-FGSM altında da korunmaktadır. Ayrıştırma bu yönü kaynak tarafına yerleştirmektedir. Bu çalışmanın ViT-Tiny modelinde üretilen örnekler dış WideResNet dahil her hedefe daha kötü taşınmakta ve dış havuzda bu ViT-Tiny en zayıf gürbüz kaynak olurken evrişim bileşenli bir dikkat modeli olan gürbüz XCiT-S12 böyle bir zayıflık göstermemektedir. Eşlenmeye yakın SVHN modellerinde iki protokol CNN, ikisi ViT üstünlüğü bildirmekte, birincil her ikisi doğru protokolü ise eşdeğerliğin kabul edildiği $-0{,}35$ puanlık bir fark vermektedir (Bölüm IV-D2). Yön bu nedenle bu eşlenmemiş çiftin bir özelliğidir. Orada protokol etkinin ne kadar büyük göründüğünü ve eşdeğerliğin ileri sürülüp sürülemeyeceğini değiştirmekte, temiz doğruluklar yakınlaştığında ise işareti de değiştirebilmektedir. Dönüştürücüye özgü bir saldırının [45] ViT yönünü kurtaramaması, saldırının erişemediği nedenlerle zayıf kalan bir kaynakla tutarlıdır.

Koşullu ayrıştırma mutlak gürbüzlüğü bir temiz doğruluk çarpanı ile bir koşullu duyarlılık çarpanına ayırmaktadır. Düzeltilmiş koşularda iki çarpan da CNN lehinedir; dolayısıyla ayrıştırma ile manşet uyuşmaktadır. Sızıntısız protokolden önce eğitilmiş daha eski bir kontrol noktası çifti aynı mutlak sıralamayı, ancak iki çarpan arasında farklı bir pay dağılımını vermiştir (Bölüm III-E). Bu nedenle yalnızca mutlak doğruluğu raporlayan bir makale hiçbir değişiklik görmezdi; tek koşudan ayrıştırma raporlayan bir makale ise yinelenmeyen, mekanizma düzeyinde bir sonuç çıkarabilirdi.

Doğrulanmayan üç okuma, kanıt konusunda ortak bir ders taşımaktadır. Seyreklik ölçüleri [61] mekansal lokaliteyi kanıtlamamaktadır; çekişmeli eğitilmiş CNN gradyanları kütlenin daha büyük kısmını daha az bileşende toplamakta (Hoyer $0{,}4928$'e karşı $0{,}4561$, her koşuda tutarlı ama koşum düzeyinde anlamsız), ancak dört mekansal betimleyici bu bileşenlerin dizilişinde bir fark göstermemektedir. CLS dikkat entropisi $n = 1000$'de saldırı altında değişmemekte, dikkat haritaları ise küçük ve derinlikle artan bir miktarda yer değiştirmektedir; yama saldırılarıyla elde edilen dikkat kayması sonuçları [32], [33] ölçüm yapılmadan L_∞ sınırlı pertürbasyonlara taşınmamalıdır. TGR [45] bu rejimde 14,9 puanlık beyaz kutu gücüne mal olmakta ve bunun hiçbirini hedefte geri vermemektedir. İki davranışsal fark ise ayakta

kalmaktadır. Birincisi, çekişmeli eğitimin yarattığı seyreklik sıralaması ve onunla birlikte gelen, mutlak kosinüste görülen ama işaretli ortalaması sıfıra yakın olan bir hizalanma farkıdır; örnekler duyarlılık eksenlerini paylaşmakta, ancak bir evrensel pertürbasyon iddiasının [66] gerektireceği biçimde yönleri paylaşmamaktadır. İkincisi derinlik profilleridir; hasar CNN'de son artık aşamada yoğunlaşmakta, ViT'te derinlik boyunca yayılmakta ve ölçülen ViT profili jeton agregasyonuna bağlı kalmaktadır.

B. Raporlama Gereklilikleri

Ölçümler mimariler arası transfer ve gürbüzlük çalışmaları için aşağıdaki gerekliliklere dönüşmektedir. Gereklilikler, ilgili seçimin bu makalede bir sonucu ne kadar oynattığına göre sıralanmıştır ve bunlardan ilk ikisi en önemli olanlardır.

1) *Her transfer sayısının koşullama kümesi belirtilmelidir.* Başarılı kaynak protokolünün sıkı ya da gevşek okuması gibi alt seçimler de buna dahildir; bu alt seçim tek başına yayılımı $4{,}77$ puan oynatmıştır (Bölüm IV-B, Tablo I).
2) *Koşulsuz transfer oranları mimari karşılaştırması olarak sunulmamalıdır.* Örnek bazında kayıtlar varsa hedef doğru oran tam olarak hesaplanabilir. Yalnızca yayımlanmış ham oranlar ve temiz hatalar mevcutsa Denklem (6) bu oranı $r_{\text{koş}} \in [(r_{\text{ham}} - e)/(1-e),\ (r_{\text{ham}} - e\,p_{\text{alt}})/(1-e)]$ aralığıyla sınırlamaktadır; burada p_{alt} o rejimde beklenebilecek en düşük öncüldür ve ölçülen çekişmeli eğitilmiş hedeflerde $0{,}984$, standart eğitilmiş hedeflerde $0{,}877$'dir (Bölüm IV-B1 ve IV-E).
3) Yönlü iddialar için, eşleştirilmiş çıkarıma imkân vermek üzere iki yönü özdeş örnekler üzerinde puanlayan bir protokol yeğlenmelidir (Bölüm IV-B).
4) Özdeşlik terimi temiz doğruluk farkıyla ölçeklendiğinden her modelin temiz doğruluğu ve karşılaştırılan her çiftin temiz doğruluk farkı raporlanmalıdır (Bölüm IV-D4 ve IV-E).
5) Bir yön hedefe atfedilmeden önce kaynak ve hedef etkileri, örneğin sabit bir üçüncü modelle, birbirinden ayrılmalıdır (Bölüm IV-C).
6) Sabit yörüngelerde hem mutlak gürbüz doğruluğu hem de protokol yayılımını yaklaşık iki puan oynatan kontrol noktası seçim kuralı belirtilmelidir (Bölüm IV-F).
7) Mutlak gürbüzlük, temiz doğruluk ve koşullu duyarlılık çarpanlarına ayrışımıyla birlikte raporlanmalı ve mekanizma iddiaları birden fazla eğitim koşusuna dayandırılmalıdır; daha eski bir kontrol noktası çifti mutlak sıralamayı korumuş, ancak onu iki çarpan arasında farklı paylaştırmıştır (Bölüm III-E ve IV-A).
8) Katman bazlı analizlerde jeton agregasyonu ve tensör belirtilmeli, dikkat iddiaları bir şekil kümesinde değil yüzlerce örnek üzerinde sınanmalıdır (Bölüm IV-G2).

Bu kıyaslamada eşleşmiş karma kayıplı tarif altında iki aile arasında seçim yapan uygulayıcılar açısından CNN daha yüksek mutlak gürbüz doğruluk vermekte ve bu üstünlük ölçülen her görünümde korunmaktadır. %62,76'daki WideResNet referansı ise ek veriyle ve daha güçlü bir tarifle eğitilmiş daha büyük bir modelin [54] gürbüzlüğü bu iki aile arasındaki seçimden daha ileri taşıdığını göstermektedir.

C. Sınırlılıklar

Buradaki her mimari sonuç, küçük modellerden oluşan tek bir çekişmeli eğitilmiş çifte, yani ResNet-18 ile 32×32 girdileri 224×224'e büyütülerek sıfırdan eğitilmiş bir ViT-Tiny'ye ve tek bir karma kayıplı PGD çekişmeli ince ayar tarifine dayanmaktadır. Küçük veri kümelerinde ViT çekişmeli eğitiminin tarife duyarlı olduğu bilinmekte [56], [57], Wang vd.'nin [67] difüzyonla üretilmiş veri tarifiyle eğitilen bir ViT'in CIFAR-10'da WideResNet'leri geçtiği bildirilmektedir [36]; iki model parametre sayısında da ayrışmaktadır (11,2M'ye karşı 5,7M). SVHN ile standart eğitilmiş çiftlerin işaret ettiği gibi temiz doğrulukta eşlenmiş çiftlerde CIFAR-10'daki 15 puanlık aralığın yalnızca temiz doğruluk farkından gelen kısımları küçülmelidir; başarılı kaynak fazlası ise eşlenmiş gürbüz çiftlerde büyük kalmaktadır. SVHN sonucunun kendisi ise iki çifte, 50 epoka ve AutoAttack içermeyen bir değerlendirmeye dayanmaktadır ve iki koşum koşumlar arası değişimi sınırlayamaz. Denklem (7)'in kesin biçimi yalnızca p'nin bire yakın olduğu, bu verilerde çekişmeli eğitilmiş hedeflere karşılık gelen durumlarda doğrulanmıştır. Mekanizma açıklaması eksiktir; marjinal altkümelerin bileşimi dört protokolün üçünü kapsamaktadır; başarılı kaynak protokolü ise kaynağın kendi gürbüzlüğüne bağlı ikinci bir sürücü ekler ve bu sürücünün yayılım üzerindeki etkisi güvenilir biçimde kestirilememiştir. Kayıtlar ilgili ölçümlerden önce işlenmiş, ancak eğitimden önce işlenmemiştir. CIFAR-100 kaydı eğitimin başlamasından sonra gelmiş, ilk kullanılan uydurma havuzu ise SVHN'i, sonucu elde edildikten sonra yazılan bir yeniden atamayla dışarıda bırakmıştır; bu nedenle bağlayıcı uydurma SVHN'i içeren uydurmadır. Her model $\epsilon = 8/255$ ile L_∞ altında eğitildiğinden L_2 sonucu L_2 gürbüzlüğünü değil protokolü yoklamaktadır. Düzeltilmiş protokol doğrulama düzenini ve eğitim koşusunu aynı anda değiştirdiği için iki kontrol noktası kümesinin neden farklılaştığı yalıtılamamaktadır. Altı tam bütçeli yörünge üzerinde yürütülen sızıntı ablasyonu sızıntının kontrol noktası seçimine bir etkisini saptamamıştır; ancak tedavi tek bir doğrulama bölmesi kullandığından ve bu tasarımda bölme kimliği ile sızıntı birbirinden ayrıştırılamadığından ablasyon, sorulan sorunun daha zayıf bir sürümünü yanıtlamaktadır. Son olarak TGR sonucu özgün yöntemin yayımlanmış kurulumunun yeniden üretiminden değil bir uyarlamasından gelmekte, CIFAR'a özgü ViT kontrolü ise ikinci bir eşleşmiş çift sağlamadan büyütme karıştırıcısını kalibre etmektedir.

D. Gelecek Yönelimler

En doğrudan uzantı bir kalibrasyon eğrisidir. Temiz doğruluk farkları denetlenen ve tek bir ortak tarifle eğitilen mimari çiftleri, eşlenmiş çift öngörüsünü bir avuç noktadan ölçülmüş bir fonksiyona dönüştürecek ve başarılı kaynak teriminin dış havuzun düşündürdüğü gibi kaynak gürbüzlüğüne bağlı olup olmadığını gösterecektir. Kapasitesi eşlenmiş bir çift (örneğin ViT-Small'a karşı ResNet-50), kaynak etkisinin, seyreklik sıralamasının ve derinlik profillerinin ailelere mi yoksa bu küçük modellere mi ait olduğunu sınayacaktır. Yayımlanmış transfer çalışmalarının yeniden puanlanması yön başına temiz doğrulukları, kesin bir düzeltme için de örnek bazında kayıt-

ları gerektirmektedir; bunları yayımlayan çalışmalarda Denklem (6)'deki düzeltme sıradan bir adım haline gelmektedir.

VI. Sonuç

Bu çalışmada bir transfer oranının koşullama kümesinin, bir CNN ile ViT gürbüzlük karşılaştırmasının vardığı sonucu ne ölçüde belirlediği sorulmuş ve bu soru, sabit modeller ve veri üzerinde yalnızca bu küme değiştirilerek yanıtlanmıştır. Koşullama kümesi sonucu yeniden eğitimden daha çok belirlemektedir; tek bir çekişmeli eğitilmiş çiftte ölçülen asimetriyi, herhangi bir tek protokolün koşumlar arası aralığından birkaç kat geniş bir aralıkta oynatmaktadır.

Bu aralığın büyük kısmı öngörülebilirdir. Koşulsuz ve hedef doğru oranlar arasındaki kısım hedefin temiz hatasının toplam olasılık yasası üzerinden içeri girmesidir; öncülü bire yakın ölçüldüğü yerde kesin bir düzeltme, ölçülmediği yerde ise bir üst sınırdır. Başarılı kaynak protokolü farklı bir soruyu yanıtlamakta, savunulabilir kalan iki protokol ise iki modelin marjinal altkümelerinin açıkladığı bir bileşim terimi kadar birbirinden ayrışmaktadır. Bir transfer sayısı bu nedenle ancak hesaplandığı kümeyle birlikte yorumlanabilir.

Asimetrinin mimariler hakkında söyledikleri, büyüklüğünün düşündürdüğünden daha dardır. Asimetrinin yönü daha zayıf bir ViT hedefinden değil, her hedefe daha kötü taşınan ve bu belirli ViT-Tiny üzerinde üretilen örneklerden gelmektedir. Aralığın özdeşliğin taşıdığı kısmı ise çiftin temiz doğruluk farkını izlemekte ve hem bu çalışmanın modellerinde hem dış bir havuzda temiz doğrulukta eşlenmiş çiftlerde küçülmektedir; başarılı kaynak fazlası küçülmemekte, kontrol noktası seçim kuralı da aralığı birkaç puan kaydırmaktadır. Mutlak gürbüzlük her saldırı altında CNN lehine çıkmış, mimari karşılaştırmalarının kolayca akla getirdiği üç okuma ise doğrudan ölçümde ayakta kalmamıştır.

Çalışma üç veri kümesini ve tek bir çekişmeli eğitilmiş model çiftini kapsamakta, standart eğitilmiş ve dış modeller yalnızca protokol analizinde kullanılmaktadır; bu nedenle etkinin başka çiftlerdeki büyüklüğü kalibre edilmeyi beklemektedir. Her protokol kestirimi örnek bazındaki kayıtlardan yeniden hesaplandığı için karşılaştırma başka modellerde yeni saldırılar gerektirmeden tekrarlanabilir; Bölüm V-B'teki raporlama gereklilikleri bunu mümkün kılmak için okurun neye ihtiyaç duyduğunu belirtmektedir.

Veri ve Kod Erişilebilirliği

Bu çalışmadaki deneyler, herkese açık olan CIFAR-10 ve CIFAR-100 veri kümeleri [13] ile SVHN veri kümesini [62] kullanmaktadır. Önceden eğitilmiş WideResNet-28-10 ağırlıkları RobustBench kıyaslamasından [14], [54] alınmıştır. Analiz hattı, bu makaledeki her tabloyu ve şekli üreten betikler, örnek bazında değerlendirme kayıtları, sabit doğrulama bölmesi indeksleri ve tohum listeleri https://github.com/cagrisahin58/cnn-vit-robustness-protocols adresinde herkese açıktır. Örnek bazındaki kayıtlar temiz eğitilmiş model çiftlerinin, sekiz modelli RobustBench havuzunun ve son kontrol noktası yeniden puanlamasının transfer koşularını da içermektedir; depoda ayrıca Mahmood vd.'nin [8] Tablo 1 ve Tablo 2'sinin makineyle okunmuş bir kopyası ile bu tabloları ayrıştıran ve yeniden puanlayan betikler bulunmaktadır. Bu malzeme burada raporlanan her sayıyı yeniden üretmeye yetmektedir ve dört koşullama protokolünün tamamı örnek bazındaki kayıtlardan hesaplandığı için protokol karşılaştırması yeniden eğitim gerektirmeden tekrarlanabilmektedir. Eğitilmiş kontrol noktaları yaklaşık 40 GB tutmakta ve yazarlardan istek üzerine sağlanmaktadır.

Teşekkür

Yazarlar, hesaplama kaynakları için Fırat Üniversitesi Yazılım Mühendisliği Bölümü'ne teşekkür eder.

Yazarlar bu çalışmanın hazırlanması sırasında Claude (Anthropic) kullanmıştır. Araç, makale metninin tüm bölümlerinin yazımına ve gözden geçirilmesine ve makaleyle birlikte yayımlanan analiz ve denetim betiklerinin gerçeklenmesine yardımcı olmuştur. Çalışmanın tasarımı, deney protokolü ve tüm sonuçlar yazarlara aittir; yazarlar raporlanan her sayıyı yayımlanan artefaktlarla doğrulamıştır.

Kaynaklar

[1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, "Intriguing properties of neural networks," in *Proc. International Conference on Learning Representations (ICLR)*, 2014.

[2] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and harnessing adversarial examples," in *Proc. International Conference on Learning Representations (ICLR)*, 2015.

[3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[6] Y. Bai, J. Mei, A. L. Yuille, and C. Xie, "Are transformers more robust than CNNs?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 26 831–26 843.

[7] P. Benz, S. Ham, C. Zhang, A. Karjauv, and I. S. Kweon, "Adversarial robustness comparison of vision transformer and MLP-Mixer to CNNs," in *Proc. British Machine Vision Conference (BMVC)*, 2021.

[8] K. Mahmood, R. Mahmood, and M. van Dijk, "On the robustness of vision transformers to adversarial examples," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 7818–7827.

[9] R. Shao, Z. Shi, J. Yi, P.-Y. Chen, and C.-J. Hsieh, "On the adversarial robustness of vision transformers," *Transactions on Machine Learning Research*, 2022.

[10] M. Naseer, K. Ranasinghe, S. Khan, F. S. Khan, and F. Porikli, "On improving adversarial transferability of vision transformers," in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[11] D. Ravikumar, S. Kodge, I. Garg, and K. Roy, "TREND: Transferability-based robust ENsemble design," *IEEE Transactions on Artificial Intelligence*, vol. 4, no. 3, pp. 534–548, 2023.

[12] Z. Zhao, H. Zhang, R. Li, R. Sicre, L. Amsaleg, M. Backes, Q. Li, Q. Wang, and C. Shen, "Revisiting transferable adversarial images: Systemization, evaluation, and new insights," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 48, no. 1, pp. 765–780, 2026.

[13] A. Krizhevsky and G. Hinton, "Learning multiple layers of features from tiny images," University of Toronto, Tech. Rep., 2009.

[14] F. Croce, M. Andriushchenko, V. Sehwag, E. Debenedetti, N. Flammarion, M. Chiang, P. Mittal, and M. Hein, "RobustBench: a standardized adversarial robustness benchmark," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2021.

[15] H. Zhang, Y. Yu, J. Jiao, E. Xing, L. El Ghaoui, and M. Jordan, "Theoretically principled trade-off between robustness and accuracy," in *Proc. International Conference on Machine Learning (ICML)*, 2019, pp. 7472–7482.

[16] Ç. Şahin and Ö. Yıldırım, "A behavioral comparison of adversarially trained ResNet-18 and ViT-Tiny on CIFAR-10: Transfer metrics, gradient structure, and block-wise feature drift," in *Proc. ATEEC 2026*, 2026, preliminary version of the present study; submitted.

[17] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, "Towards deep learning models resistant to adversarial attacks," in *Proc. International Conference on Learning Representations (ICLR)*, 2018.

[18] N. Carlini and D. Wagner, "Towards evaluating the robustness of neural networks," in *Proc. IEEE Symposium on Security and Privacy (SP)*, 2017, pp. 39–57.

[19] F. Croce and M. Hein, "Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks," in *Proc. International Conference on Machine Learning (ICML)*, 2020, pp. 2206–2216.

[20] Y. Wang, D. Zou, J. Yi, J. Bailey, X. Ma, and Q. Gu, "Improving adversarial robustness requires revisiting misclassified examples," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[21] C. Guo, M. Rana, M. Cisse, and L. van der Maaten, "Countering adversarial images using input transformations," in *Proc. International Conference on Learning Representations (ICLR)*, 2018.

[22] J. Cohen, E. Rosenfeld, and Z. Kolter, "Certified adversarial robustness via randomized smoothing," in *Proc. International Conference on Machine Learning (ICML)*, 2019, pp. 1310–1320.

[23] F. Tramèr, A. Kurakin, N. Papernot, I. Goodfellow, D. Boneh, and P. McDaniel, "Ensemble adversarial training: Attacks and defenses," in *Proc. International Conference on Learning Representations (ICLR)*, 2018.

[24] S. Lyu, S. Shaikh, F. Shpilevskiy, E. Shelhamer, and M. Lécuyer, "Adaptive randomized smoothing: Certified adversarial robustness for multi-step defences," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 37, 2024, pp. 134 043–134 074.

[25] D. Wu, Y. Wang, S.-T. Xia, J. Bailey, and X. Ma, "Skip connections matter: On the transferability of adversarial examples generated with ResNets," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[26] C. Xie and A. Yuille, "Intriguing properties of adversarial training at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[27] C. Xie, M. Tan, B. Gong, J. Wang, A. L. Yuille, and Q. V. Le, "Adversarial examples improve image recognition," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 816–825.

[28] D. Tsipras, S. Santurkar, L. Engstrom, A. Turner, and A. Madry, "Robustness may be at odds with accuracy," in *Proc. International Conference on Learning Representations (ICLR)*, 2019.

[29] P. Chalasani, J. Chen, A. R. Chowdhury, X. Wu, and S. Jha, "Concise explanations of neural networks using adversarial training," in *Proc. International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 1383–1391.

[30] M. Raghu, T. Unterthiner, S. Kornblith, C. Zhang, and A. Dosovitskiy, "Do vision transformers see like convolutional neural networks?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34. Curran Associates, Inc., 2021, pp. 12 116–12 128.

[31] S. Bhojanapalli, A. Chakrabarti, D. Glasner, D. Li, T. Unterthiner, and A. Veit, "Understanding robustness of transformers for image classification," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 211–10 221.

[32] Y. Fu, S. Zhang, S. Wu, C. Wan, and Y. Lin, "Patch-Fool: Are vision transformers always robust against adversarial perturbations?" in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[33] J. Gu, V. Tresp, and Y. Qin, "Are vision transformers robust to patch perturbations?" in *Proc. European Conference on Computer Vision (ECCV)*, ser. Lecture Notes in Computer Science, vol. 13672. Springer, 2022, pp. 404–421.

[34] S. Paul and P.-Y. Chen, "Vision transformers are robust learners," in *Proc. AAAI Conference on Artificial Intelligence (AAAI)*, vol. 36, no. 2, 2022, pp. 2071–2081.

[35] S. Jain and T. Dutta, "Towards understanding and improving adversarial robustness of vision transformers," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 24 736–24 745.

[36] J. Wu, Z. Song, X. Zhang, S. Xie, L. Lin, and K. Wang, "Vision transformers beat WideResNets on small scale datasets adversarial robustness," in *Proc. AAAI Conference on Artificial Intelligence (AAAI)*, vol. 39, no. 1, 2025, pp. 886–894.

[37] Z. Zhu, X. Wang, Z. Jin, J. Zhang, and H. Chen, "Enhancing transferable adversarial attacks on vision transformers through gradient normalization scaling and high-frequency adaptation," in *Proc. International Conference on Learning Representations (ICLR)*, 2024.

[38] N. Papernot, P. McDaniel, and I. Goodfellow, "Transferability in machine learning: from phenomena to black-box attacks using adversarial samples," *arXiv preprint arXiv:1605.07277*, 2016.

[39] A. Demontis, M. Melis, M. Pintor, M. Jagielski, B. Biggio, A. Oprea, C. Nita-Rotaru, and F. Roli, "Why do adversarial attacks transfer? Explaining transferability of evasion and poisoning attacks," in *Proc. 28th USENIX Security Symposium (USENIX Security 19)*, 2019, pp. 321–338.

[40] Y. Liu, X. Chen, C. Liu, and D. Song, "Delving into transferable adversarial examples and black-box attacks," in *Proceedings of the 5th International Conference on Learning Representations (ICLR)*, 2017.

[41] Y. Dong, F. Liao, T. Pang, H. Su, J. Zhu, X. Hu, and J. Li, "Boosting adversarial attacks with momentum," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 9185–9193.

[42] Q. Li, Y. Guo, W. Zuo, and H. Chen, "Towards evaluating transfer-based attacks systematically, practically, and fairly," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023, pp. 41 707–41 726.

[43] W. Yu, J. Gu, Z. Li, and P. Torr, "Reliable evaluation of adversarial transferability," in *Proc. IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2025, pp. 797–810.

[44] Z. Wei, J. Chen, M. Goldblum, Z. Wu, T. Goldstein, and Y.-G. Jiang, "Towards transferable adversarial attacks on vision transformers," in *Proc. AAAI Conference on Artificial Intelligence (AAAI)*, vol. 36, no. 3, 2022, pp. 2668–2676.

[45] J. Zhang, Y. Huang, W. Wu, and M. R. Lyu, "Transferable adversarial attacks on vision transformers with token gradient regularization," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 16 415–16 424.

[46] W. Ma, Y. Li, X. Jia, and W. Xu, "Transferable adversarial attack for both vision transformers and convolutional networks via momentum integrated gradients," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4607–4616.

[47] Z. Chen, C. Xu, H. Lv, S. Liu, and Y. Ji, "Understanding and improving adversarial transferability of vision transformers and convolutional neural networks," *Information Sciences*, vol. 648, p. 119474, 2023.

[48] F. Waseda, S. Nishikawa, T.-N. Le, H. H. Nguyen, and I. Echizen, "Closer look at the transferability of adversarial examples: How they fool different models differently," in *Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2023, pp. 1360–1368.

[49] F. Pinto, P. H. S. Torr, and P. K. Dokania, "An impartial take to the CNN vs Transformer robustness contest," in *Proc. European Conference on Computer Vision (ECCV)*, ser. Lecture Notes in Computer Science, vol. 13673. Cham: Springer, 2022, pp. 466–480.

[50] K. Ali, M. S. Bhatti, A. Saeed, A. Athar, M. A. Al Ghamdi, S. H. Almotiri, and S. Akram, "Adversarial robustness of vision transformers versus convolutional neural networks," *IEEE Access*, vol. 12, pp. 105 281–105 293, 2024.

[51] N. Carlini, A. Athalye, N. Papernot, W. Brendel, J. Rauber, D. Tsipras, I. Goodfellow, A. Madry, and A. Kurakin, "On evaluating adversarial robustness," *arXiv preprint arXiv:1902.06705*, 2019.

[52] F. Tramèr, N. Carlini, W. Brendel, and A. Madry, "On adaptive attacks to adversarial example defenses," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.

[53] S. Zagoruyko and N. Komodakis, "Wide residual networks," in *Proc. British Machine Vision Conference (BMVC)*. BMVA Press, 2016, pp. 87.1–87.12.

[54] S. Gowal, C. Qin, J. Uesato, T. Mann, and P. Kohli, "Uncovering the limits of adversarial training against norm-bounded adversarial examples," *arXiv preprint arXiv:2010.03593*, 2020.

[55] R. Wightman, "PyTorch image models," https://github.com/huggingface/pytorch-image-models, 2019.

[56] E. Debenedetti, V. Sehwag, and P. Mittal, "A light recipe to train robust vision transformers," in *Proc. IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2023, pp. 225–253.

[57] Y. Mo, D. Wu, Y. Wang, Y. Guo, and Y. Wang, "When adversarial training meets vision transformers: Recipes from training to architecture," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 18 599–18 611.

[58] L. Rice, E. Wong, and J. Z. Kolter, "Overfitting in adversarially robust deep learning," in *Proc. International Conference on Machine Learning (ICML)*, 2020, pp. 8093–8104.
[59] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. International Conference on Learning Representations (ICLR)*, 2017.
[60] ——, "Decoupled weight decay regularization," in *Proc. International Conference on Learning Representations (ICLR)*, 2019.
[61] N. Hurley and S. Rickard, "Comparing measures of sparsity," *IEEE Transactions on Information Theory*, vol. 55, no. 10, pp. 4723–4741, Oct. 2009.
[62] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, "Reading digits in natural images with unsupervised feature learning," in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
[63] Y. Carmon, A. Raghunathan, L. Schmidt, P. Liang, and J. C. Duchi, "Unlabeled data improves adversarial robustness," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
[64] L. Engstrom, A. Ilyas, H. Salman, S. Santurkar, and D. Tsipras, "Robustness (Python library)," https://github.com/MadryLab/robustness, 2019.
[65] E. Wong, L. Rice, and J. Z. Kolter, "Fast is better than free: Revisiting adversarial training," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.
[66] S.-M. Moosavi-Dezfooli, A. Fawzi, O. Fawzi, and P. Frossard, "Universal adversarial perturbations," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 86–94.
[67] Z. Wang, T. Pang, C. Du, M. Lin, W. Liu, and S. Yan, "Better diffusion models further improve adversarial training," in *Proc. International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 36 246–36 263.